

Chapitre 6 : Apprentissage Synergique Multi-Échelle et Structures Fractales

Chapitre 6 : Apprentissage Synergique Multi-Échelle et Structures Fractales	565
6.1. Introduction	Erreur ! Signet non défini.
6.1. Introduction	567
6.1.1. Contexte et Motivation	567
6.1.2. Objectifs du Chapitre	570
6.1.3. Structure du Chapitre	575
6.2. Principes de l'Apprentissage Multi-Échelle	578
6.2. Principes de l'Apprentissage Multi-Échelle	579
6.2.1. Hiérarchies Synergiques et Niveaux d'Abstraction	579
6.2.2. Théorie des Systèmes Emboîtés	583
1. Processus d'Agrégation.....	587
2. Pseudo-code.....	587
6.2.3. Rétroactions et Anticipations Multi-Niveau.....	589
6.3. Fractalité et Auto-Similarité dans le DSL.....	596
6.3.1. Concept de Fractales en IA	596
6.3.2. Auto-Similarité dans les Réseaux Synergiques.....	601
6.3.3. Modélisation et Indicateurs.....	608
6.3.4. Avantages et Limitations	614
6.4. Interactions Multi-Niveau et Coordination.....	619
6.4.1. Bottom-Up vs. Top-Down	619
6.4.2. Communication Synergiques entre Niveaux	628
6.4.3. Synchronisation et Clustering	633
6.5. Dynamique et Algorithmes Multi-Échelle.....	640
6.5.1. Agrégation Progressive (Bottom-Up)	640
6.5.2. Division ou Zoom (Top-Down)	645
6.5.3. Hybridation (Approche Mixte).....	651

6.5.4. Algorithmes de Mise en Œuvre	656
6.6. Études de Cas et Illustrations	664
6.6.1. Systèmes de Vision Multi-Modal	664
6.6.2. Analyse Contextuelle de la Parole et du Langage	668
B. Intérêt Mathématique et Pratique	669
6.6.3. Robotique Synergique : Intégration Sensorimotrice	673
6.6.4. Agents Conversationnels Riches et Contextuels	678
6.6.5. Applications dans la Simulation et la Prédiction d'Événements	683
6.7. Conclusion	689
6.7. Conclusion	690
6.7.1. Synthèse des Contributions du Chapitre	690
6.7.2. Rôle de la Fractalité	691
6.7.3. Limites et Perspectives	691
6.7.4. Liens avec les Chapitres Suivants	692
6.7.5. Vision Globale	693

Dans ce **chapitre 6**, nous entrons dans une nouvelle dimension du **DSL** (Deep Synergy Learning) : l'**apprentissage multi-échelle**, où les synergies ne se limitent pas à un unique niveau de granularité mais se déclinent à **plusieurs** niveaux (micro, méso, macro, voire intermédiaires). Cette notion introduit également la perspective de **structures fractales**, c'est-à-dire une forme d'**auto-similarité** potentielle à différentes échelles du réseau, qui peut se manifester lorsque les lois d'organisation se répliquent à chaque palier.

6.1. Introduction

Le **chapitre 6** prolonge les fondements et l'architecture posés dans les chapitres précédents (notamment le chapitre 5 sur la mise en place technique d'un SCN) pour montrer comment on peut **gérer** et **exploiter** la diversité d'échelles dans le DSL. À l'issue de ce chapitre, on comprendra en quoi la multi-échelle ouvre la voie à une **coordination** plus souple entre divers niveaux (local, global...) et comment la fractalité peut modéliser ou expliquer l'émergence de motifs répétitifs au sein du réseau de synergies.

6.1.1. Contexte et Motivation

Le **DSL** (Deep Synergy Learning) repose sur des entités \mathcal{E}_i et leurs liens $\omega_{i,j}$, guidés par la fonction de synergie $S(i, j)$. Jusqu'ici, nous avons souvent envisagé la formation de clusters ou la dynamique d'auto-organisation à une **même** échelle (entités ou sous-ensembles d'entités). Or, dans de nombreux systèmes naturels (cérébraux, écologiques, sociaux) ou artificiels (réseaux complexes, infrastructures distribuées), on observe des **structures** à **plusieurs niveaux** de résolution :

- Des **micro-clusters** (petits groupes fortement cohérents),
- Des **macro-ensembles** plus vastes,
- Des **niveaux intermédiaires** jouant un rôle de pivot.

De plus, il se peut qu'un **même motif** (par exemple, un cluster en "étoile" ou un schéma cyclique) se **reproduise** à diverses échelles, suggérant une **auto-similarité** ou un comportement dit *fractal*.

6.1.1.1. Rappel : Le DSL (Deep Synergy Learning) fonctionne sur la base de synergies entre entités, mais l'échelle à laquelle on étudie ces synergies peut varier (local, global, intermédiaire)

Le **Deep Synergy Learning (DSL)** s'appuie, dans sa formulation de base, sur une règle d'**auto-organisation** qui met à jour les liaisons $\omega_{i,j}(t)$ en fonction de la synergie $S(i, j)$ évaluée entre les entités \mathcal{E}_i et \mathcal{E}_j . La mise à jour peut prendre la forme :

$$\omega_{i,j}(t + 1) = \omega_{i,j}(t) + \eta [S(i, j) - \tau \omega_{i,j}(t)],$$

ou toute autre **règle DSL** (additive, multiplicative, etc.) suivant les paradigmes du chapitre 4. Sur un plan **mathématique**, cette dynamique ne dépend pas a priori de la "taille" ou de la "portée" de l'ensemble d'entités étudiées. Il reste donc à comprendre comment, dans les **chapitres** ultérieurs, on fait évoluer le SCN sur des **niveaux** ou **paliers** différents (local, global, intermédiaire) afin d'observer des **patterns** qui s'articulent entre eux. C'est ce que vise à rappeler cette **Section 6.1.1.1**.

Même si l'équation $\omega_{i,j}(t + 1) = F(\omega_{i,j}(t), S(i, j))$ reste la même, on peut l'**appliquer** à divers **sous-ensembles** d'entités ou l'observer à plusieurs **niveaux**.

Au niveau **micro**, on s'intéresse par exemple à la formation de petits *clusters* locaux autour de quelques entités fortement connectées. Ces entités peuvent correspondre à un groupe de robots partageant une tâche concrète, ou à un sous-ensemble de concepts quasi synonymes dans un SCN linguistique.

Au niveau **macro**, on observe l'émergence de grands ensembles unifiant plusieurs sous-groupes, voire la structuration complète d'un **réseau** dans son ensemble, où la synergie prend une dimension plus globale (missions d'envergure, communautés thématiques, etc.).

D'un point de vue **mathématique**, la forme de la **mise à jour** $\Delta\omega_{i,j}$ n'évolue pas, seul change le **regard** que l'on porte, soit en "zoomant" sur quelques entités et leurs liaisons, soit en "dézoomant" pour englober la totalité. Cela ouvre la voie à l'étude des **interactions** entre ces focales multiples et la manière dont la dynamique DSL se manifeste à chaque échelle.

Lorsque la même **logique** d'auto-organisation (synergie, renforcement, inhibition) se répète à plusieurs **niveaux** d'observation, il n'est pas rare de constater une sorte de **fractalité** ou d'**auto-similarité**. Concrètement, le *pattern* qu'on voit apparaître à échelle locale, par exemple un "cœur dense" entouré de liaisons plus faibles, peut se reproduire (en plus grand) au niveau global. Sur un plan **mathématique**, cela signifie que la forme fonctionnelle de $F(\omega, S)$ ne dépend pas explicitement de la taille du système : si l'on isole un "cluster local" et qu'on y réapplique la même règle DSL, on peut observer un *motif* semblable à celui obtenu dans le réseau global. Cette invariance d'échelle s'apparente à la **fractalité** (ou "auto-similarité"), un concept clé qui peut se manifester dès lors que la "loi" de renforcement/inhibition demeure identique quel que soit le nombre d'entités ou la dimension du cluster. On pourrait ainsi repérer, dans un sous-SCN local, la même topologie (par exemple un noyau en cycle, ou des ramifications arborescentes) que l'on voit émerger sur tout le réseau.

Les **bénéfices** d'étudier et de prendre en compte cette **multi-échelle** sont nombreux. Sur un plan **cognitif**, il est précieux d'analyser un cluster local de haute cohérence, sans forcément perdre de vue l'organisation globale, ce qui donne un **système** plus modulaire et plus robuste. Un cluster local, par exemple, pourra persister, grandir ou changer de nature, même si le niveau macro subit d'autres transformations. Dans le **DSL**, la possibilité de gérer ces multiples échelles ouvre la porte à des **SCN** plus vastes, répartis en "groupements" hiérarchiques, que l'on peut manipuler ou faire coopérer entre eux. Cela rejoint aussi l'idée (explicitée au chapitre 6) qu'on peut disposer d'un "méta-niveau" de type **meta-SCN** (chap. 5.7.2) supervisant l'agrégation des sous-blocs locaux, réutilisant la même dynamique DSL.

Conclusion.

La **variation d'échelle** au sein d'un **SCN** n'est pas un simple artifice, mais bien une propriété fondamentale du **DSL** : la même **dynamique** de mise à jour $\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau\omega_{i,j}(t)]$ s'applique tout autant au niveau local (quelques entités connectées) qu'au niveau global (tout le réseau), et c'est l'**observation** alternée de ces deux paliers qui révèle parfois un **caractère fractal**. Cette fractalité se manifeste lorsque la *même forme* d'auto-organisation ressurgit à plusieurs **niveaux** de granularité, s'exprimant dans la topologie des *clusters*. Ainsi, l'analyse **multi-échelle** s'impose comme une **extension naturelle** de la dynamique DSL, prolongeant la discussion des chapitres passés et introduisant le thème d'un **SCN** "à plusieurs échelons" qui sera développé dans l'ensemble du **Chapitre 6**.

6.1.1.2. Nécessité de s'intéresser aux différents niveaux (micro-clusters vs. macro-structures) et à la possible auto-similarité (concept fractal) qui peut émerger dans la répartition des entités

Le **Deep Synergy Learning (DSL)**, en tant que paradigme d'**auto-organisation** reposant sur le renforcement (ou l'inhibition) des liaisons $\omega_{i,j}$, ne se cantonne pas nécessairement à une seule **échelle** d'observation. Dans beaucoup de configurations pratiques, les entités $\{\mathcal{E}_i\}$ et leurs liaisons finissent par s'**ordonner** simultanément à plusieurs **niveaux** : on repère parfois un **micro-cluster** local de quelques entités fortement interconnectées, coexistant avec un **macro-cluster** plus vaste où la cohésion moyenne, tout en restant notable, est moins intense. Cette **pluralité d'échelles** soulève plusieurs questions d'intérêt méthodologique et mathématique, notamment la manière dont les processus de renforcement $\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau\omega_{i,j}(t)]$ se manifestent tant au niveau **local** (quelques nœuds) qu'au niveau **global** (regroupements massifs).

Micro-Clusters et Macro-Structures : une réalité fréquente

Les **micro-clusters** désignent de petits *noyaux* regroupant un **faible** nombre d'entités, mais reliées avec une grande **densité** ou de forts poids $\omega_{i,j}$. Par exemple, dans un **SCN** gérant un essaim de robots, ce peut être 2–3 robots partageant une **synergie** intense (même mission, même zone). Dans un **SCN** cognitif, il s'agirait de 4–5 concepts étroitement liés

par co-occurrence ou complémentarité sémantique. À l'inverse, un **macro-cluster** inclut un **grand** nombre d'entités, potentiellement un ensemble plus lâche mais occupant un rôle systémique (par ex. un sous-réseau d'agents répartis dans tout le système).

D'un point de vue **mathématique**, un micro-cluster apparaît comme un *sous-graphe* où les liaisons $\omega_{i,j}$ sont particulièrement élevées, tandis qu'un macro-cluster s'étend à un échelon supérieur, parfois *englobant* plusieurs micro-clusters internes. Cette cohabitation de niveaux multiples répond à une **variabilité** dans les rôles, les proximités ou les tâches assignées aux entités.

A. Mécanismes locaux vs. globaux et hiérarchie émergente

La même **règle** d'évolution $\omega_{i,j}(t+1) = F(\omega_{i,j}(t), S(i,j))$ s'applique a priori uniformément à l'ensemble du SCN. Cependant, le **renforcement** (ou l'inhibition) peut se manifester plus **rapidement** au niveau **local** : quelques entités proches en synergie renforcent vite leurs liaisons, formant un micro-cluster en quelques itérations. Au niveau **global**, la formation ou la stabilisation d'un grand cluster requiert plus de *temps* ou un certain enchaînement de fusions de micro-clusters. On observe alors une **hiérarchie** : le DSL ne converge pas uniquement vers "un cluster global" ou "un ensemble de micro-groupes", mais produit souvent des **strates** intermédiaires reliant micro et macro.

Cette **stratification** n'est pas juste un artefact : elle reflète la capacité d'un SCN à gérer différentes **échelles** de granularité, où les micro-groupes jouissent d'une forte cohérence interne tandis que des macro-ensembles partagent un niveau d'affinité plus moyen mais suffisant pour la reconnaissance d'une "communauté" large. Sur le plan **ingénierie**, on exploite volontiers cette hiérarchie pour segmenter des **tâches** multiples (sous-groupes autonomes) tout en conservant une *vue* d'ensemble. Sur le plan **analyse**, cela souligne la **modularité** d'un SCN, précieuse dans de grands systèmes distribués (cf. Chap. 5.7).

B. Auto-similarité et phénomène fractal

Si les mêmes **mécanismes** de renforcement/inhibition demeurent constants à chaque **niveau**, on peut voir émerger des **motifs** qui se "reproduisent" à différentes échelles. C'est la notion d'**auto-similarité**, ou "**fractalité**". Sur un plan **mathématique**, on parle d'invariance d'échelle : la *topologie* ou la *distribution* des liens $\omega_{i,j}$ dans un petit cluster peut *ressembler* au motif global, simplement à une **taille** différente. Cette invariance est assez fréquente dans des systèmes biologiques ou cognitifs, où des *lois uniformes* (renforcement local, feedback global) peuvent induire des structures *self-similar*.

Pour illustrer, si un micro-cluster de 5 entités adopte une forme quasi "biclique" (deux sous-ensembles reliés par des poids forts), on peut découvrir que le grand cluster de 100 entités reproduit un motif analogue : un sous-ensemble principal et un second sous-ensemble, connectés par un pont central. L'origine de ce *pattern fractal* réside dans le fait que la **règle** DSL n'exclut pas, à petite ou grande échelle, des comportements similaires. Cette **fractalité** se révèle alors un indicateur d'une dynamique cohérente, où la forme d'organisation se répète localement et globalement.

C. Pourquoi étudier ces multiples échelles ?

D'un point de vue **fondamental**, cette pluralité d'échelles montre la **richesse** du DSL : la plasticité du SCN lui permet de façonner simultanément un **microniveau** (entités très liées) et un **macroniveau** (gros clusters englobant plusieurs micro-clusters). Cela introduit :

1. **Robustesse** : un micro-cluster n'est pas forcément dissous si la structure macro se reconfigure (et inversement).
2. **Vision holistique** : la même **énergie** ou la même **fonction** (Chap. 4) gère tout le réseau ; pourtant, l'**observation** différenciée (micro vs. macro) permet de saisir des phénomènes de *coopération locale* et *communalisation globale*.
3. **Clés d'analyse** : si la structure exhibe une **auto-similarité** notable, on peut quantifier son degré fractal par des indices topologiques ou géométriques, ce qui éclaire la dynamique d'auto-organisation.

Conclusion (6.1.1.2).

La mise en évidence de **multiples échelles** (micro-clusters et macro-structures) dans un **SCN** n'est pas un simple détail d'observation, mais relève d'une **nécessité** théorique et pratique. Les phénomènes de **renforcement** $\omega_{i,j}$ se déploient à divers niveaux, générant parfois un effet **fractal** : la constitution d'un *micro-cluster* ressemble, en miniature, à la consolidation d'un grand cluster. Comprendre ces différences et similitudes d'échelle, ainsi que les mécanismes d'**auto-similarité**, ouvre un nouveau champ de discussion. D'un côté, cela témoigne de la **versatilité** du DSL, capable de gérer des structures complexes et hiérarchiques. De l'autre, cela amorce la réflexion (développée dans ce **chapitre 6**) sur la conception de **SCN** multi-niveaux, articulés entre micro- et macro-organisation, suscitant des dynamiques d'**invariance d'échelle** susceptibles de produire des *patterns* auto-similaires (fractalité).

6.1.2. Objectifs du Chapitre

Après avoir mis en évidence (6.1.1) l'importance de considérer différentes **échelles** (micro, macro, intermédiaires) au sein d'un SCN (Synergistic Connection Network) et la possibilité qu'un **phénomène fractal** survienne, il est nécessaire de préciser **quels** sont les objectifs que ce chapitre se propose de remplir. En effet, la **multi-échelle** n'est pas simplement une curiosité : elle constitue un **cadre conceptuel** et **opérationnel** qui élargit la portée du DSL (Deep Synergy Learning), tout en soulevant des questions nouvelles en matière de **modélisation**, de **dynamique** et d'**implémentation**.

6.1.2.1. Expliquer comment la *multi-échelle* se traduit dans le DSL, et en quoi elle permet d'organiser et de coordonner différents niveaux d'abstraction

Le **Deep Synergy Learning (DSL)**, dans son expression la plus simple, décrit un réseau d'entités $\{\mathcal{E}_i\}$ dont les liaisons $\omega_{i,j}$ évoluent par le biais d'une règle d'**auto-organisation** (additive, multiplicative, etc.). Au cours des chapitres précédents, on a principalement envisagé cette dynamique dans le cadre d'un "**niveau unique**" : chaque entité interagit avec les autres via des synergies $S(i, j)$, et l'on observe un **SCN** global où l'on repère la formation de clusters (ou la répartition en sous-structures). Toutefois, dans des systèmes complexes, cette perspective **mononiveau** peut se révéler insuffisante, car l'**organisation** émerge souvent à **plusieurs échelles**. C'est précisément l'enjeu de cette section (6.1.2.1) : clarifier en quoi la *multi-échelle* s'intègre dans la logique du DSL et comment elle améliore la **coordination** entre divers niveaux d'abstraction.

Traduction de la multi-échelle dans le DSL

Sur le plan **mathématique**, la mise à jour des pondérations suit une équation générale du type

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta [S(i,j)\tau \omega_{i,j}(t)] \quad (\text{ou autre forme}).$$

Quand on introduit la *multi-échelle*, on considère que la **même** forme de règle DSL peut s'appliquer à plusieurs **niveaux** simultanément ou successivement. Autrement dit, chaque entité \mathcal{E}_i peut apparaître à un niveau "micro" (représentation plus fine) ou à un niveau "macro" (regroupement plus large de sous-entités), et la **dynamique** $\omega(t) \rightarrow \omega(t+1)$ peut être itérée aussi bien sur des micro-groupes que sur des macro-groupes.

Cette approche repose sur deux principes. D'abord, on **redéfinit** ce que signifie "entité" à chaque échelle : une **micro-entité** (ex. petite brique de connaissances, groupe restreint de neurones) ou une **macro-entité** (cluster plus étendu, aire plus large). Ensuite, on maintient la **règle d'auto-organisation** inchangée dans ses **fondements** : $\omega_{i,j}$ s'ajuste selon une synergie $S(i, j)$ et un terme de décroissance (ou d'inhibition). L'acte de "changer d'échelle" signifie, sur le plan analytique, "définir un second SCN" dont les nœuds sont désormais des **sous-ensembles** du premier SCN, et dont la **synergie** entre ces macro-nœuds s'évalue selon des agrégations de $\{\omega_{i,j}\}$ locales.

Organisation et coordination des différents niveaux

En introduisant la notion de **multi-échelle**, il ne s'agit pas seulement de contempler plusieurs niveaux de granularité ; on veut également que ces **niveaux** s'**influencent** mutuellement. Cela se traduit par :

- Des **flux ascendants** (bottom-up) : un **micro-cluster** émergeant (un petit ensemble fortement connecté à l'échelle locale) peut “remonter” vers une **macro-organisation**, se faisant reconnaître comme une entité cohérente dans le niveau supérieur.
- Des **flux descendants** (top-down) : le **macro-niveau**, doté d'une vue globale, peut imposer ou suggérer des contraintes aux micro-nœuds, par exemple en renforçant la liaison entre deux micro-entités si leur appartenance à un même macro-cluster s'avère cruciale pour la cohérence globale.

Ce processus de **coordination** multi-niveau confère au DSL une capacité à gérer des systèmes de **taille** et de **complexité** potentiellement beaucoup plus élevées. On peut, par exemple, répartir la **mise à jour** $\omega(t)$ selon des blocs locaux (micro) supervisés par un “meta-SCN” (macro), suivant les principes énoncés en Chapitre 5.7. Chaque **échelon** demeure fidèle à la règle DSL, mais opère sur des entités (ou clusters) d'échelle différente. On obtient alors une **architecture** hiérarchique et **modulaire** du SCN, évitant l'explosion combinatoire ou le chaos d'une organisation totalement “plate”.

Exemples concrets

Dans un **système cognitif** inspiré du cerveau, on peut assimiler le niveau “micro” à des micro-colonnes corticales (ou petits sous-réseaux de neurones) et le niveau “macro” à de grandes aires (voies sensorielles, cortex associatif). Les **mêmes** principes de synergie (co-activation neuronale) et d'update $\omega_{i,j}$ (synaptique) se répètent, de sorte que ce qui est acquis localement se reflète globalement. Dans un tel cadre, la **multi-échelle** illustre l'émergence et la stabilisation d'un schéma “macro” (ex. “aire visuelle connectée à aire frontale”) tout en conservant un ajustement local de micro-groupes.

En **robotique** multi-agent, le niveau “micro” peut consister en quelques robots géographiquement proches s'échangeant un flot de données et accroissant $\omega_{i,j}$ si leur collaboration s'avère fructueuse, tandis que le niveau “macro” traite la **mission** d'ensemble et “vois” un cluster englobant ces robots plus un autre groupe. Le SCN multi-échelle intègre alors la capacité de chaque micro-cluster à se spécialiser, tout en unifiant la planification globale.

Enjeux de la multi-échelle

Regrouper plusieurs **niveaux** dans un **SCN** soulève quelques questions spécifiques :

1. **Comment** modéliser la synergie entre macro-entités ? Faut-il calculer la **moyenne** ou le **maximum** des synergies entre leurs micro-composantes ?
2. **Comment** gérer la mise à jour ω si l'on bascule d'un niveau à l'autre ? On peut imaginer un *meta-SCN* (Chap. 5.7.2) où la synergie macro \hat{S} est engendrée par l'agrégation des synergies micro $\{S(i, j)\}$.
3. **Comment** éviter la désynchronisation entre micro- et macro-niveaux ? Cela rejoint les principes de coordination décrits plus haut : la dynamique est plus riche qu'un simple renforcement local, car un macro-cluster (englobant plusieurs micro-clusters) peut imposer ou suggérer une consolidation de certaines liaisons $\omega_{i,j}$.

Conclusion

La **multi-échelle** dans le **DSL** n'est pas seulement un ornement conceptuel : elle constitue un **prolongement** naturel de la logique d'auto-organisation à plusieurs **niveaux** d'abstraction. Du point de vue **mathématique**, cela signifie que la règle de mise à jour $\omega(t+1) = F(\omega(t), S)$ peut se répliquer (ou se composer) sur des échelons micro, macro et intermédiaires, conduisant à des phénomènes complexes d'**agrégation** et de **division** de clusters à différentes granularités. Sur le plan **ingénierie**, la multi-échelle offre un **levier** organisationnel : on peut circonscrire des **sous-groupes** très spécialisés (niveau micro) sans perdre la perspective d'ensemble (niveau macro). Enfin, cette organisation hiérarchique **facilite** la coordination dans les systèmes vastes, réduit la **complexité** en segmentant des **sous-problèmes**, et peut faire apparaître des phénomènes d'**auto-similarité** (cf. Section 6.1.1.2) rappelant la notion fractale. L'objectif du **Chapitre 6** sera d'approfondir ces idées et de décrire les mécanismes par lesquels le SCN gère la multi-échelle et orchestre la cohérence entre micro- et macro-structures.

6.1.2.2. Introduire la *fractalité* comme un cadre pour appréhender l'*auto-similarité* des patterns synergiques à diverses échelles

Lorsque l'on considère la **multi-échelle** dans un **SCN** (Synergistic Connection Network), il n'est pas rare de voir apparaître des **motifs** qui se **répètent** ou qui se **reproduisent** à plusieurs **niveaux** d'observation. Dans des systèmes complexes, cette forme de **répétition** ou d'**invariance d'échelle** est précisément décrite par la notion de **fractalité**. Par ailleurs, lorsque l'on observe qu'un micro-cluster local "ressemble", dans sa structure ou sa répartition de pondérations, à un macro-cluster plus vaste, on suspecte un **processus** fractal au sein du DSL. Le but de cette section (6.1.2.2) est donc de situer la *fractalité* dans la logique multi-échelle du **Deep Synergy Learning** et de montrer en quoi elle offre un *cadre* théorique pour analyser et comprendre l'**auto-similarité** qui peut émerger dans la répartition des entités.

A. Rappel du Concept de Fractalité

Une **fractalité** (ou structure **factorisée**) se caractérise par l'**auto-similarité** à des échelles multiples. Géométriquement, dans un ensemble fractal au sens classique (Cantor, Von Koch, Sierpinski, etc.), la même "forme" se reproduit à plus petite échelle, parfois par homothétie ou transformations plus compliquées, d'où la notion d'**invariance d'échelle**. Sur le plan **mathématique**, une définition usuelle s'appuie sur :

$$\text{Auto-similarité} \Leftrightarrow \exists \text{ transformations } f_1, \dots, f_m: E = \bigcup_{k=1}^m f_k(E),$$

pour un ensemble E dit fractal. Les notions de **dimension fractale** ou **loi de puissance** (règle de type $\text{prob}(\text{taille} > s) \sim s^{-\alpha}$) apparaissent comme des marqueurs typiques.

B. Lien avec l'Auto-Similarité dans un Réseau

La **fractalité** est transposable à des **réseaux** (ou graphes) : on peut dire qu'un réseau exhibe une **structure fractale** si, en "zoomant" sur un sous-réseau (ou un cluster interne), on obtient une topologie "équivalente" (à un changement d'échelle près) au réseau global. D'un point de vue statistique, cela se manifeste souvent par des **lois de puissance** (distribution des degrés, distribution des tailles de clusters, etc.) et la conservation de certaines **mesures** topologiques quand on reconfigure le réseau à plus petite échelle (par ex. en regroupant des nœuds en "super-nœuds").

Dans un **SCN**, la **forme** du réseau émerge des pondérations $\{\omega_{i,j}\}$. Les *patterns* synergiques typiques (formation de sous-ensembles denses, arêtes intergroupes plus faibles) peuvent se **répéter** d'un micro-groupe à un macro-groupe. Il s'agit donc d'une **auto-similarité** dans la distribution de $\omega_{i,j}$, les *clusters* se formant à divers niveaux selon le même schéma (renforcement local, inhibition externe). Si l'on constate en pratique que cette logique donne, à plusieurs degrés de zoom, des **structures** analogues, on peut parler d'une **fractalité** ou d'un **mécanisme fractal** dans la répartition des entités $\{\mathcal{E}_i\}$.

C. Fractalité comme Cadre d'Analyse pour le DSL

1. Auto-similarité dans les Patterns Synergiques

Dans un DSL, un *pattern synergique* correspond à un certain agencement de liaisons $\{\omega_{i,j}\}$: par exemple, un *cycle dense*, un *noyau* fortement relié, ou un *clustering* modulaire. L'**auto-similarité** signifie que la **même forme** se retrouve à plusieurs niveaux : un micro-cluster pourrait présenter le même *type* de répartition de poids (forts au centre, décroissants en périphérie) qu'un macro-cluster englobant 50 entités, simplement "agrandi" ou "répliqué" à une échelle supérieure.

Au niveau **mathématique**, on peut formaliser ceci en étudiant la "**dimension fractale**" (au sens box-counting ou similaire) du SCN : si cette dimension présente un comportement indiquant un *scaling law*, cela témoigne d'une invariance d'échelle dans l'organisation. De manière plus heuristique, on peut observer si la distribution des tailles de clusters $\{C_k\}$ suit une **loi de puissance** $P(\text{taille} = s) \sim s^{-\alpha}$. C'est un **signe** qu'il n'y a pas de *taille préférentielle*, ce qui est souvent gage d'une fractalité latente.

2. Notion de "Multi-niveau" fractal

Le **multi-niveau** (chap. 6.1.2.1) devient plus qu’une simple stratification : il se mue en **structure** réellement fractale si, en passant d’un niveau d’agencement micro à un niveau d’agencement macro, on reconstruit la “même dynamique” DSL, reproduisant la même topologie à une échelle démultipliée. Cela évoque des *systèmes biologiques* (une même logique neuronale répétée dans des modules de plus en plus grands, etc.) ou des *systèmes sociaux* (les mêmes mécanismes de collaboration localement et globalement, induisant des hiérarchies auto-similaires).

3. Bénéfices de l’Analyse Fractale

Robustesse et Invariance : La fractalité assure qu’une perturbation locale peut être absorbée par la répétition des structures ; si l’échelle micro subit une variation, l’échelle macro conserve son mode d’organisation, et réciproquement. **Mesures** : En quantifiant la dimension fractale (ou en repérant un exposant de loi de puissance), on caractérise la “façon” dont le réseau s’étale sur les diverses échelles.

Guidage : Si l’on souhaite que le SCN favorise une structure fractale (pour des raisons de modularité ou de robustesse), on peut paramétrer le DSL (les taux η , l’inhibition γ , etc.) de manière à encourager un schéma répétitif d’organisation.

D. Conclusion (6.1.2.2)

La **fractalité**, ou la *reconnaissance* d’un phénomène **auto-similaire** dans les *patterns* synergiques d’un **SCN**, ouvre un **cadre** analytique et conceptuel pour comprendre la “répétition” d’une logique d’auto-organisation à plusieurs **échelles**. Au-delà d’une simple observation, la fractalité procure :

- Une **explication** de la cohérence entre micro-clusters et macro-structures (la même forme se retrouve “répliquée” en plus grand),
- Un **outillage** de mesure (dimension fractale, lois de puissance) permettant de qualifier la “richesse” ou le “style” de la distribution $\{\omega_{i,j}\}$ et de l’auto-organisation.

Dans ce **chapitre 6**, se pencher sur la multi-échelle implique de solliciter le **concept fractal** pour appréhender la manière dont un **DSL** peut générer ou révéler ces *invariances d’échelle* dans la hiérarchie des clusters. Les sections suivantes détailleront les mécanismes et les implications techniques de la fractalité dans un SCN, montrant comment cette propriété de “répétition” à diverses granularités se retrouve dans la distribution des poids, l’organisation des clusters, et la dynamique de renforcement/inhibition elle-même.

6.1.2.3. Aborder les *modèles mathématiques*, les *dynamiques associées* et l’*implémentation* de l’apprentissage multi-échelle

Lorsque l’on traite la **multi-échelle** et la possible **fractalité** au sein d’un **SCN** (Synergistic Connection Network), il ne suffit pas de s’en tenir aux intuitions ou aux observations qualitatives. Il convient de proposer des **modèles mathématiques** explicites décrivant cette émergence d’échelles, d’**analyser** les dynamiques (lois de mise à jour, couplages inter-niveaux) et enfin de voir comment s’enchaîne l’**implémentation** concrète dans un système capable de manipuler de manière hiérarchique des entités et des clusters. Le **DSL** (Deep Synergy Learning) doit donc s’adapter pour gérer des **niveaux multiples**, tout en conservant la logique de renforcement/inhibition exposée jusqu’ici.

A. Modèles Mathématiques pour la Multi-Échelle

La première étape consiste à formuler un **SCN** à plusieurs **niveaux** : au niveau “de base” (micro), on a l’ensemble d’entités $\mathcal{E}_1, \dots, \mathcal{E}_n$ et leurs liaisons $\omega_{i,j}^{(0)}$. Quand un **cluster** local $\mathcal{C}_\alpha \subseteq \{\mathcal{E}_1, \dots, \mathcal{E}_n\}$ se dégage, on définit une *macro-entité* \mathcal{M}_α à l’échelle suivante (niveau 1). On construit alors une **nouvelle** matrice $\omega_{\alpha,\beta}^{(1)}$ décrivant les synergies **entre** ces macro-entités. Cette définition se poursuit pour des **niveaux** plus élevés ($k = 2, 3, \dots$), aboutissant à une hiérarchie. D’un point de vue purement **mathématique**, on peut :

1. Poser un *ensemble d’entités* $\mathcal{E}^{(0)}$ au niveau 0 (micro).
2. Définir par **agrégation** un ensemble $\mathcal{E}^{(1)}$ (macro-nœuds) où chaque $\mathcal{M}_\alpha^{(1)} \subseteq \mathcal{E}^{(0)}$ est un *cluster* repéré.

3. Répéter la logique, créant des ensembles $\mathcal{E}^{(k)}$ pour $k = 2, \dots, K$.

Ceci se rapproche des techniques de **coarse-graining** en physique statistique, où l'on regroupe des "sites" en "super-sites", et des approches de **quotient** de graphes en théorie des réseaux (chaque cluster devient un super-nœud). La mise à jour $\omega(t+1) = F(\omega(t))$ doit alors se décliner à chaque **palier**. Pour les liaisons entre macro-nœuds, on introduit une fonction d'**agrégation** Ψ des liaisons micro. Par exemple :

$$\omega_{\alpha,\beta}^{(k)} = \Psi(\{\omega_{i,j}^{(k-1)} \mid i \in \mathcal{M}_\alpha^{(k)}, j \in \mathcal{M}_\beta^{(k)}\}).$$

Une fois ces macro-pondérations définies, on peut **réappliquer** la règle DSL pour ajuster $\omega_{\alpha,\beta}^{(k)}$ en fonction d'une synergie $S^{(k)}(\alpha, \beta)$. Ainsi se construit un **modèle** multi-échelle strictement formalisé.

B. Dynamiques associées : couplage entre niveaux

En ayant défini des **niveaux** successifs ($k = 0, \dots, K$), il faut spécifier **comment** s'effectuent les **misés à jour** :

1. **Dynamique indépendante** : On peut imaginer que chaque niveau applique la **même** règle DSL (additive, multiplicative, etc.), comme si l'on disposait de $K+1$ SCN indépendants. Le lien entre eux est simplement la **projection** (les macro-nœuds de k sont issus de sous-ensembles du niveau $k-1$).
2. **Rétroaction inter-niveau** : on peut aller plus loin, en autorisant un **feedback** descendante (top-down) : si, au niveau macro, on constate un lien $\omega_{\alpha,\beta}^{(k)}$ extrêmement fort, on incite (au niveau $k-1$) les liaisons $\{\omega_{i,j}^{(k-1)}\}$ reliant des entités micro internes à α, β à se consolider. Symétriquement, un cluster local au niveau $k-1$ peut "remonter" un signal vers la macro-liaison $\omega_{\alpha,\beta}^{(k)}$.
3. **Schéma cyclique ou séquentiel** : Dans certains algorithmes, on effectue d'abord la **mise à jour** DSL sur le niveau micro (cette itération se stabilise), puis on agrège pour constituer des macro-nœuds, calcule $\omega^{(k+1)}$ et exécute quelques étapes de mise à jour macro, etc., dans un **cycle**. Cela aboutit à un SCN hiérarchique où chaque palier se stabilise partiellement avant de passer au suivant.

Ces dynamiques **couplées** (multi-niveau) peuvent favoriser une **auto-similarité** (Section 6.1.2.2) dans la répartition des clusters, puisque la *même logique* de renforcement/inhibition se répercute depuis le niveau local jusqu'au niveau global. Elles étendent la simple équation $\omega(t+1) = F(\omega(t))$ en un système **multi-échelle** :

$$\omega^{(k)}(t+1) = F_k(\omega^{(k)}(t), \omega^{(k-1)}(t), \omega^{(k+1)}(t)),$$

introduisant potentiellement un **couplage** $\omega^{(k)} \leftrightarrow \omega^{(k-1)} \leftrightarrow \omega^{(k+1)}$.

C. Implémentation de l'apprentissage multi-échelle : méthodes pratiques

Sur le plan **ingénierie**, on peut mettre en place une **architecture** logicielle modulaire. Chaque palier k dispose d'un *Module Mise à Jour* et d'un *Module Synergie*, gérant respectivement :

- La mise à jour $\omega^{(k)}$ via la règle DSL,
- Le calcul $S^{(k)}(\alpha, \beta)$ pour les macro-nœuds $\mathcal{M}_\alpha, \mathcal{M}_\beta$.

Une **passerelle** d'agrégation Ψ relie le niveau k au niveau $k-1$, tandis qu'un **mécanisme** de feedback (optionnel) renvoie des consignes top-down au niveau inférieur. Selon la **complexité** du SCN, on applique un schéma :

1. **Séquentiel** : on met à jour d'abord $\omega^{(0)}$ (micro), on regroupe en macro-nœuds, on met à jour $\omega^{(1)}$ (macro), etc.
2. **Parallèle** : chaque niveau évolue en parallèle, on synchronise à intervalles réguliers.

3. **Distribué** : si ω est déjà réparti (Chap. 5.7), on peut répliquer la hiérarchie par bloc local, puis un *meta-niveau* global.

Des algorithmes concrets — par exemple, un “**hierarchical SCN**” — consistent à détecter automatiquement des clusters stables au niveau k , les étiqueter pour créer $\mathcal{E}^{(k+1)}$, initialiser $\omega^{(k+1)}$ par agrégation, et enfin lancer la règle DSL à ce niveau. Il s’agit donc d’une **fusion** entre le concept de “clustering itératif” (type agglomératif) et la dynamique DSL.

Conclusion

Le **troisième** volet de cette introduction à la **multi-échelle** est la **modélisation mathématique**, la **dynamique associée** et la **mise en œuvre** de l’**apprentissage** multi-niveau dans un SCN. Les points clés sont :

1. **Modèles** : définir la hiérarchie (niveau 0, 1, 2, ...), les règles d’**agrégation** (comment on regroupe des entités en macro-nœuds) et la manière d’initialiser les pondérations $\omega^{(k)}$.
2. **Dynamiques** : préciser si chaque niveau applique la **même** règle DSL (additive, multiplicative, etc.), comment s’effectuent les **rétroactions** entre micro et macro, et de quelle façon la structure fractale (auto-similarité) se bâtit ou se maintient.
3. **Implémentation** : articuler un système modulaire (Module Synergie, Module Mise à Jour) capable de *monter* et *descendre* dans la hiérarchie, éventuellement de façon parallèle ou distribuée.

Grâce à ces approches, un **SCN** peut gérer de vastes ensembles d’entités dans un **cadre** unifiant la **multi-échelle** et l’**invariance d’échelle** (fractalité potentielle). On passe donc de la simple **observation** de multiples niveaux (Sections 6.1.1 et 6.1.2.1–2) à une **construction formelle** (règles, formules, algorithmes) permettant de réaliser effectivement un **apprentissage** hiérarchique, reflétant la richesse du **DSL** dans des contextes réels ou de recherche avancée.

6.1.3. Structure du Chapitre

Après avoir présenté (6.1.1 et 6.1.2) les **motivations** du DSL (Deep Synergy Learning) à aborder la **multi-échelle** et la **fractalité**, il est utile de donner un **aperçu** de l’organisation de ce chapitre 6, afin que le lecteur puisse se repérer dans les différentes sections et comprendre le fil conducteur.

6.1.3.1. Aperçu : (6.2) principes et hiérarchies, (6.3) fractalité et auto-similarité, (6.4) interactions multi-niveau, (6.5) dynamiques multi-échelles, (6.6) études de cas, (6.7) conclusion

La **Section 6.1.3.1** s’attache à présenter la **trame** du **Chapitre 6**, qui conduit le lecteur depuis les **concepts** de multi-échelle dans un **SCN** (Synergistic Connection Network) et leur déclinaison sous la forme d’une **hiérarchie** (Section 6.2), jusqu’aux **détails** des dynamiques multi-niveau (Sections 6.4, 6.5) et les **études de cas** illustratives (Section 6.6). Chaque section vient ainsi approfondir l’un des grands **thèmes** introduits dans la première partie du chapitre (6.1), en offrant un fil directeur cohérent et progressif :

(6.2) Principes et hiérarchies

La **Section 6.2** vise à poser les **règles générales** de la multi-échelle. Elle montre comment, dans un **SCN**, on peut distinguer plusieurs **niveaux** de granularité (micro, macro, voire intermédiaire), définissant une **hiérarchie**. D’un point de vue **mathématique**, cela exige de préciser :

1. Comment on **aggrège** des entités de bas niveau (\mathcal{E}_i) en “super-nœuds” ou macro-entités au niveau supérieur.
2. Quelles sont les **lois** ou **règles** que l’on emploie pour moduler les liens ω entre macro-entités, en s’inspirant ou en prolongeant la dynamique DSL originelle.

Sur le plan conceptuel, cette partie s'intéresse à la **théorie des systèmes emboîtés** et introduit des arguments de **cohérence** hiérarchique (flux ascendants “bottom-up”, flux descendants “top-down”), illustrant l'idée que plusieurs paliers de représentation se coordonnent.

(6.3) Fractalité et auto-similarité

La **Section 6.3** développe la **notion de fractalité** (déjà esquissée en 6.1.2.2) comme un **cadre** pour analyser la possible *auto-similarité* dans les *patterns* synergiques d'un SCN multi-échelle. Concrètement, on décrit les **fondements** mathématiques de la fractalité (dimension fractale, lois de puissance, auto-similarité stricte ou statistique) et on explique en quoi un **SCN** peut, dans certains cas, présenter ces attributs. On approfondit aussi :

1. Les **indicateurs** à mesurer pour repérer la fractalité (distribution des tailles de clusters, coefficients d'échelle, etc.).
2. Les **limites** : tout réseau auto-organisé n'est pas fractal, et les conditions (paramétriques, algorithmiques) favorisant l'invariance d'échelle demeurent un sujet de recherche.

On met ainsi en avant la dimension **théorique** du **DSL** lorsqu'il rencontre des phénomènes d'**invariance d'échelle** : comment un micro-cluster “ressemble” à un macro-cluster, et comment un *même* schéma d'organisation se reproduit.

(6.4) Interactions multi-niveau

La **Section 6.4** se focalise sur les **mécanismes de coordination** entre les divers niveaux (ou paliers) d'un SCN multi-échelle. Plus précisément, elle décrit :

1. **Flux ascendants** (bottom-up) : si un cluster local se stabilise, comment cette stabilisation est “signalée” au niveau macro, conduisant à la consolidation d'un super-nœud ou à un réagencement global.
2. **Flux descendants** (top-down) : si le macro-niveau détecte un arrangement global stable ou un objectif supérieur, il peut “descendre” l'information vers les micro-nœuds pour orienter leurs liens $\omega_{i,j}$ ou imposer certaines synergies minimales.

Cette partie s'attache aussi à la notion de **synchronisation** inter-niveau : doit-on bloquer un niveau pendant qu'un autre se met à jour, ou peut-on évoluer en parallèle ? Les **conflits** (un micro-cluster local s'opposant aux objectifs macro) sont abordés, de même que la manière d'y remédier par un protocole multi-niveau.

(6.5) Dynamiques multi-échelles

La **Section 6.5** passe à la **dynamique** d'apprentissage elle-même : comment applique-t-on concrètement la **règle DSL** (additive, multiplicative...) à chaque palier, de façon séquentielle ou simultanée ? Plusieurs algorithmes sont proposés, illustrés par des **pseudo-codes**. Cette partie répondra, par exemple, aux interrogations :

1. **Ordonnement** des mises à jour : met-on à jour toutes les liaisons $\omega^{(k)}$ au niveau k avant de passer au niveau $k + 1$, ou opère-t-on en *allers-retours* ?
2. **Agrégation et Division** : comment un cluster macro peut se *subdiviser* si sa cohésion interne fléchit, comment un micro-cluster peut *fusionner* avec un autre, etc.
3. **Impact sur la complexité** : la structuration en **hiérarchie** rend-elle la gestion du $O(n^2)$ plus aisée en répartissant les calculs ?

Au final, la **Section 6.5** fournit un **cadre** algorithmique pour mettre en pratique la **multi-échelle** dans un SCN, reliant les définitions théoriques (Sections 6.2–6.3) et les **exemples** ou **études de cas** (Section 6.6).

(6.6) Études de cas

La **Section 6.6** montre **plusieurs** applications ou exemples concrets où le **DSL** multi-échelle apporte une **plus-value** :

1. **Vision multi-modale** : comment on segmente des “patches” d’image en micro-clusters, puis on agrège des zones plus larges en macro-structures, etc.
2. **Analyse contextuelle du langage** : un texte divisé en segments (micro-clusters de mots), puis agrégé en chapitres ou thèmes (macro).
3. **Robotique sensorimotrice** : la gestion de micro-groupes de robots physiquement proches, un meta-niveau coordonnant plusieurs groupes.
4. **Agents conversationnels** : hiérarchie de modules cognitifs (lexicaux, sémantiques, pragmatiques) dans un SCN multi-niveau.

Chaque cas d’usage illustre la **capacité** du DSL à *emprunter* des chemins multi-niveau, parfois même fractals, pour organiser des ensembles hétérogènes de données ou d’entités.

(6.7) Conclusion

La **Section 6.7** clôt le chapitre en rappelant :

- L’**intérêt** des hiérarchies multi-échelle : robustesse, réduction de complexité, possibilité d’exploiter la fractalité, etc.
- Les **points clés** (lois d’agrégation, dynamiques multiples, feedback inter-niveau) et la **portée** de ces schémas.
- Les **perspectives** pour les chapitres suivants ou pour des recherches futures, mettant en avant la **souplesse** de la multi-échelle dans l’**auto-organisation** d’un SCN.

Conclusion

Avec ce **plan** (Sections 6.2–6.7), le **Chapitre 6** engagera le lecteur dans :

1. Une mise en place **conceptuelle** (6.2) de la multi-échelle et des hiérarchies,
2. Une plongée **théorique** (6.3) dans la fractalité et l’auto-similarité,
3. Une exploration **technique** (6.4, 6.5) des interactions et des dynamiques multi-niveau,
4. Une **application** concrète (6.6) via des études de cas,
5. Une **synthèse** (6.7) regroupant ces apports.

Cette progression s’inscrit dans la continuité de l’idée exposée en (6.1) : à mesure que l’on **monte** dans les **échelles**, le **DSL** peut révéler ou forger des clusters multi-niveaux, parfois fractals, offrant un cadre d’**auto-organisation** plus abouti et plus modulable qu’un réseau “à plat”.

6.2. Principes de l'Apprentissage Multi-Échelle

6.2.1. Hiérarchies Synergiques et Niveaux d'Abstraction

- 6.2.1.1. Notion de micro-cluster vs. macro-cluster.
- 6.2.1.2. Rôles et fonctions des différents niveaux (local, intermédiaire, global).
- 6.2.1.3. Exemples : micro-réseaux d'entités sensorielles vs. macro-ensembles pour une vue conceptuelle.

6.2.2. Théorie des Systèmes Emboîtés

- 6.2.2.1. Systèmes emboîtés : cellule \rightarrow tissu \rightarrow organe \rightarrow organisme (analogie).
- 6.2.2.2. Transposition au DSL : agrégation progressive d'entités vers des super-nœuds (macro-nœuds).
- 6.2.2.3. Multi-niveau comme "pilier" pour la gestion de la complexité.

6.2.3. Rétroactions et Anticipations Multi-Niveau

- 6.2.3.1. Flux ascendants (bottom-up) : micro \rightarrow macro.
- 6.2.3.2. Flux descendants (top-down) : macro \rightarrow micro.
- 6.2.3.3. Communication entre niveaux synergiques et stabilisation.

6.2. Principes de l'Apprentissage Multi-Échelle

Lorsqu'on souhaite doter le **DSL** (Deep Synergy Learning) d'une capacité à se déployer sur **plusieurs échelles** (micro, intermédiaire, macro), il faut d'abord saisir l'idée de **hiérarchies synergiques** et des **niveaux d'abstraction** qu'elles génèrent. La section 6.2.1 introduit cette notion, puis 6.2.2 l'illustre via la "théorie des systèmes emboîtés" et 6.2.3 décrit comment ces niveaux interagissent par des flux ascendants (bottom-up) et descendants (top-down). L'objectif est de poser les **fondations mathématiques** permettant à un **SCN** (Synergistic Connection Network) de fonctionner harmonieusement à diverses granularités — du micro-cluster au macro-cluster — de façon coordonnée.

6.2.1. Hiérarchies Synergiques et Niveaux d'Abstraction

Dès qu'on dépasse un certain degré de complexité (grand nombre d'entités, de liens $\omega_{i,j}$), on constate souvent que les entités s'**auto-organisent** en **clusters** de tailles diverses, de petits regroupements locaux et, potentiellement, de grands ensembles plus étendus. Cette diversité de "tailles de clusters" correspond à la **pluralité** des échelles dans le réseau. On parle de **hiérarchies** quand ces clusters de niveau inférieur peuvent se regrouper (ou s'agréger) pour former des "super-clusters" plus vastes, suggérant différents **niveaux d'abstraction** — on peut alors manipuler des entités "brutes" (micro-niveau) ou des entités "agrégées" (macro-niveau).

6.2.1.1. Notion de micro-cluster vs. macro-cluster

Dans de nombreux contextes d'**auto-organisation** via un **SCN**, il se forme simultanément des **groupes** à différentes **tailles** et différents **degrés de spécialisation**. Il est alors opportun d'introduire la distinction entre **micro-clusters** et **macro-clusters**. Les premiers correspondent à des **noyaux** restreints d'entités intimement reliées, tandis que les seconds, plus vastes, englobent parfois plusieurs micro-clusters et présentent une cohésion au niveau global. Cette section (6.2.1.1) précise ces deux concepts, en montrant comment ils s'articulent dans le cadre d'un **SCN** et comment leur co-existence fonde l'idée même de **multi-échelle**.

Définition de micro-cluster et de macro-cluster

Un **micro-cluster** est un groupe de taille modeste, par exemple $\{\mathcal{E}_{i_1}, \dots, \mathcal{E}_{i_k}\}$, dans lequel les pondérations ω_{i_p, i_q} s'avèrent **fortement** élevées pour chaque couple (i_p, i_q) appartenant au groupe. On y retrouve généralement une **densité** ou une **somme** de liaisons particulièrement importante par rapport au nombre k d'entités. Ainsi, un micro-cluster a souvent vocation à remplir une **tâche locale**, quelques robots partagent une mission spécialisée, quelques concepts (en sémantique) forment un champ lexical soudé, ou quelques neurones (en neurosciences) constituent un module fortement interconnecté. La force d'un tel cluster se mesure par :

$$\Omega(\mathcal{C}) = \sum_{i,j \in \mathcal{C}} \omega_{i,j},$$

montrant que $\Omega(\mathcal{C})$ peut être élevé malgré un groupe \mathcal{C} de taille réduite.

Un **macro-cluster**, en revanche, désigne un sous-ensemble du **SCN plus large**, pouvant inclure plusieurs micro-clusters en son sein. Les entités y sont globalement **cohésives** (au sens d'une synergie moyenne non négligeable), même si toutes n'entretiennent pas nécessairement des liens très forts les unes avec les autres. Au niveau d'un macro-cluster, on observe plutôt une forme de **convergence** globale qui rassemble un ensemble conséquent d'entités, par exemple en vue d'un objectif commun, d'une thématique plus générale, ou d'une mission d'envergure. La mesure $\Omega(\mathcal{C})$ pour un macro-cluster \mathcal{C} peut aussi être importante, mais cette fois-ci, la taille $|\mathcal{C}|$ est grande et la densité moyenne peut être plus modérée, tout en restant assez élevée pour être distinguée du "reste" du réseau.

Exemples et Co-existence

Dans un **SCN** à fort nombre n d'entités, la co-existence de **micro-clusters** et de **macro-clusters** est fréquente. On rencontre :

6. Plusieurs **micro-clusters** (groupes de quelques entités) — chacun très cohésif.
7. Un (ou plusieurs) **macro-cluster(s)** rassemblant, à plus large échelle, certaines entités ou micro-clusters proches, formant un **palier** d'organisation supérieur.

Cette dualité émerge par la **dynamique** DSL. On peut voir un renforcement rapide et local conduire à la formation de petits noyaux soudés (micro-clusters), tandis que l'évolution à plus long terme ou à plus vaste échelle permet l'agrégation de plusieurs micro-groupes en un macro-cluster. Cela reflète la **réalité** de maints systèmes biologiques, cognitifs ou sociotechniques, où des structures de différentes tailles coexistent et se superposent.

Vers une Structure Hiérarchique

La présence simultanée de micro- et macro-clusters évoque naturellement une **hiérarchie** d'échelles. On peut, par exemple, poser :

- Le **niveau 0** (ou échelle micro) : chaque entité \mathcal{E}_i en détail, permettant de repérer des groupes restreints,
- Le **niveau 1** (ou échelle méso) : on regroupe certains micro-clusters pour former des sous-réseaux plus grands,
- Le **niveau 2** (ou échelle macro) : on identifie un ou plusieurs macro-clusters dominants, englobant éventuellement plusieurs niveaux inférieurs.

Chacun de ces niveaux peut s'analyser, dans le **SCN**, par une matrice de pondérations $\omega^{(k)}$ spécifique (voir Section 6.2.2), reflétant des *super-nœuds* (macro-entités) si l'on agrège les micro. L'**apprentissage** multi-échelle (chap. 6.4–6.5) s'appuiera alors sur des **règles** d'agrégation, de rétroaction (top-down, bottom-up) et de synchronisation inter-niveau pour maintenir la cohérence globale.

Conclusion

La **notion** de *micro-cluster* et de *macro-cluster* en **DSL** ne se réduit pas à une dichotomie ad hoc : elle traduit la **réalité** d'un SCN où l'on voit émerger simultanément, à des **échelles** distinctes, des groupes de taille modeste (micro) et d'autres plus imposants (macro). Cette coexistence constitue la **base** de la structure hiérarchique d'un **SCN** multi-échelle. Les micro-clusters peuvent manifester des synergies locales fortes, tandis que les macro-clusters, plus amples et plus lâches, contribuent à une cohésion d'ensemble ou à une mission commune de grande portée. Cette articulation (micro→macro) fonde une **hiérarchie** (ou un emboîtement) cruciale pour la réduction de complexité, la robustesse et l'**adaptation** du réseau, sujets qui seront approfondis dans la suite du chapitre.

6.2.1.2. Rôles et Fonctions des Différents Niveaux (local, intermédiaire, global)

Dans l'**étude** des **SCN** appliqués au **DSL**, il apparaît essentiel de distinguer plusieurs échelles d'organisation qui permettent de moduler la complexité du système de manière hiérarchique. La présente section expose la finalité et le rôle de trois niveaux d'abstraction distincts : le **niveau local** (ou micro-niveau), le **niveau intermédiaire** (ou méso-niveau) et le **niveau global** (ou macro-niveau). Chacun de ces niveaux possède une fonction propre dans la dynamique d'auto-organisation du réseau, comme nous le développerons ci-après.

A. Niveau Local (Micro-Niveau)

Le **niveau local** correspond à la granularité la plus fine du SCN, où les entités individuelles $\{\mathcal{E}_i\}$ sont traitées telles qu'elles apparaissent, ou bien regroupées en micro-clusters très restreints. À ce niveau, la **matrice locale** des pondérations, que l'on peut noter $\omega^{(\text{local})}$ ou encore $\omega^{(0)}$, décrit les interactions directes entre entités selon la règle de mise à jour fondamentale du DSL.

Ce niveau local joue un rôle de **détection** initiale et de **spécialisation** en permettant une réactivité élevée, souvent à l'aide de paramètres tels que η_{loc} relativement élevés, afin de saisir rapidement les variations ou les nouveaux stimuli. Les micro-clusters ainsi formés constituent la base sur laquelle se construiront ultérieurement les niveaux supérieurs.

En effet, ces structures locales, fortement interconnectées (ce qui peut se traduire par une valeur élevée de la **synergie locale** $\Omega(\mathcal{C})$ pour un cluster \mathcal{C}), pourront être agrégées pour former des super-nœuds au niveau intermédiaire.

B. Niveau Intermédiaire (Méso-Niveau)

Le **niveau intermédiaire** intervient en regroupant les micro-clusters issus du niveau local pour former des super-nœuds, notés généralement $\{\mathcal{M}_\alpha\}$. À ce palier, la dynamique d'**agrégation** vise à condenser les interactions locales afin de rendre plus lisibles et gérables les relations complexes qui se tissent à l'échelle du réseau. La nouvelle matrice des pondérations, que nous pouvons désigner par $\omega^{(\text{inter})}$, codifie ainsi la synergie entre ces super-nœuds, par exemple via une fonction

$$\omega_{\alpha,\beta}^{(\text{inter})} = \Psi\left(\{\omega_{i,j}^{(\text{local})}\}_{i \in \mathcal{M}_\alpha, j \in \mathcal{M}_\beta}\right),$$

où Ψ est une fonction d'agrégation adaptée aux données locales. À ce niveau, le rôle principal est à la fois d'**interface** et de **coordination**. Le niveau intermédiaire permet d'informer le niveau global de l'état des sous-ensembles tout en transmettant, via des rétroactions descendantes, des consignes susceptibles d'ajuster la dynamique locale. Par ailleurs, la mise à jour des pondérations intermédiaires suit également une loi du type

$$\omega_{\alpha,\beta}^{(\text{inter})}(t+1) = \omega_{\alpha,\beta}^{(\text{inter})}(t) + \eta_{\text{inter}}[S_{\text{inter}}(\alpha, \beta) - \tau_{\text{inter}} \omega_{\alpha,\beta}^{(\text{inter})}(t)],$$

ce qui confère une homogénéité dans l'approche d'auto-organisation sur plusieurs échelles.

C. Niveau Global (Macro-Niveau)

Au sommet de la hiérarchie se situe le **niveau global** qui intègre l'ensemble des super-nœuds pour former une vision unifiée du réseau. Le niveau global, représenté par des macro-clusters $\{\mathcal{M}_\alpha^{(\text{global})}\}$, sert à dégager la **structure ultime** du SCN et à fournir une représentation condensée de la configuration globale du système. La matrice des pondérations globales, notée $\omega^{(\text{global})}$, est mise à jour selon une dynamique analogue à celle des niveaux inférieurs, par exemple

$$\omega_{\alpha,\beta}^{(\text{global})}(t+1) = \omega_{\alpha,\beta}^{(\text{global})}(t) + \eta_{\text{glob}}[S_{\text{glob}}(\alpha, \beta) - \tau_{\text{glob}} \omega_{\alpha,\beta}^{(\text{global})}(t)],$$

où $S_{\text{glob}}(\alpha, \beta)$ représente une synergie évaluée entre de grands ensembles, et η_{glob} ainsi que τ_{glob} sont des paramètres adaptés à cette échelle. Ce niveau a pour rôle principal de fournir une **vision d'ensemble** qui stabilise l'organisation du réseau et, le cas échéant, de servir d'interface avec des systèmes externes (par exemple, des modules de visualisation ou de décision). En outre, le niveau global participe à la **stabilisation** du SCN en verrouillant la convergence d'une configuration globale quand la synergie globale atteint un certain seuil.

D. Complémentarité et Couplage des Niveaux

La force d'un **SCN multi-échelle** réside dans l'**interaction** étroite entre les différents niveaux. Les rétroactions bottom-up et top-down jouent un rôle crucial en permettant aux micro-clusters de s'agréger en super-nœuds, et aux structures globales de diffuser des contraintes qui orientent la dynamique locale. Cette **couverture hiérarchique** réduit la complexité du problème en divisant le réseau en sous-ensembles gérables, accélère la convergence en isolant les interactions locales des influences globales excessives, et favorise l'émergence d'une **auto-similarité fractale** lorsque la même règle DSL se répète sur plusieurs niveaux d'abstraction.

D'un point de vue mathématique, cette approche hiérarchique permet de passer d'un problème de complexité $\mathcal{O}(n^2)$ à des sous-problèmes de moindre dimension, ce qui facilite l'analyse de la **stabilité** et la conception de **régulateurs** à chaque échelle. Ainsi, les interactions locales peuvent être traitées indépendamment avant d'être agrégées au niveau global via des fonctions d'agrégation spécifiques telles que Ψ mentionnée ci-dessus.

Conclusion (6.2.1.2)

La **structuration** d'un SCN en niveaux (local, intermédiaire, global) représente bien plus qu'un simple outil d'organisation ; elle définit une **architecture hiérarchique** dans laquelle chaque palier remplit un rôle fonctionnel et mathématique distinct. Le **niveau local** se charge de capturer les interactions fines entre entités, le **niveau intermédiaire** regroupe ces interactions pour constituer des super-nœuds cohérents, et le **niveau global** offre une vue d'ensemble stabilisatrice et structurante. Les rétroactions entre ces niveaux permettent d'obtenir une **cohérence** à la fois micro et macro, tout en réduisant la complexité du système. Les chapitres suivants, notamment 6.2.2 et 6.2.3, détailleront les mécanismes algorithmiques et mathématiques permettant de mettre en œuvre cette hiérarchie et d'exploiter les propriétés d'auto-similarité qui en découlent, conformément aux principes exposés dans ce chapitre.

6.2.1.3. Exemples : micro-réseaux d'entités sensorielles vs. macro-ensembles pour une vue conceptuelle

Les rôles des différents niveaux (micro, intermédiaire, macro) dans un SCN s'appréhendent de manière plus concrète lorsqu'on considère des cas exemplaires de la **coexistence** de micro-réseaux d'entités très locales (capteurs, données brutes, etc.) et de macro-ensembles plus englobants (concepts, missions, sous-systèmes de grande dimension). La présente section illustre comment un SCN peut à la fois gérer des **micro-clusters** — typiquement quelques entités fortement reliées — et des **macro-clusters** représentant un agrégat plus large et plus abstrait. Deux exemples sont développés : (A) la formation de micro-réseaux sensoriels, (B) la formation de macro-ensembles conceptuels.

A. Micro-réseaux d'entités sensorielles

Un scénario fréquemment rencontré est celui d'un grand nombre de **capteurs** ou **petites sources** d'information (capteurs IoT, neurones sensoriels, etc.). Chaque capteur \mathcal{E}_i constitue une entité locale avec laquelle on peut former un micro-réseau. Dans un SCN, ces capteurs établissent des liens $\omega_{i,j}$ qui se renforcent s'ils détectent une similarité ou corrélation forte. On parle alors de **micro-cluster** dès lors qu'un petit ensemble de capteurs $\{\mathcal{E}_{i_1}, \dots, \mathcal{E}_{i_k}\}$ se découvre une synergie ω_{i_p, i_q} élevée.

Soit $\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S_{\text{corr}}(i,j) - \tau \omega_{i,j}(t)]$, où $S_{\text{corr}}(i,j)$ exprime le degré de **corrélacion** (ou autre similarité) entre les signaux sensoriels de i et j . Les micro-clusters se repèrent lorsqu'un groupe \mathcal{C} présente une somme interne

$$\Omega(\mathcal{C}) = \sum_{i,j \in \mathcal{C}} \omega_{i,j}$$

assez forte pour dépasser un seuil θ . Ces clusters, de taille modeste, reflètent des **interactions fines** et très **spécifiques** (par ex. capteurs proches géographiquement ou capteurs partageant la même tendance de mesure).

Au niveau micro, les entités demeurent très **réactives** : un capteur peut rapidement renforcer ses liens avec un voisin détectant le même événement. La dynamique DSL à ce stade est **rapide** et **locale**. Une fois stabilisés, ces micro-clusters peuvent être “fournis” en **agrégation** (Section 6.2.2) pour constituer un super-nœud au niveau supérieur (mésos). Cela soulage la complexité globale en traitant chaque petit groupe cohésif comme une **brique** de niveau plus élevé.

B. Macro-ensembles pour une vue conceptuelle

À l'autre extrême, on observe parfois dans un SCN la formation de **macro-ensembles** englobant un large ensemble d'entités pour représenter un **concept** global ou une **mission** d'envergure. Dans un système cognitif, cela pourrait correspondre à un *champ sémantique* ; dans un système multi-robot, à un *groupe de grande taille* coopérant à un objectif.

Sur le plan **mathématique**, un macro-ensemble \mathcal{G} peut rassembler plusieurs dizaines, voire centaines d'entités. La force globale $\Omega_{\mathcal{G}} = \sum_{i,j \in \mathcal{G}} \omega_{i,j}$ n'a pas besoin d'être extrêmement dense (comme dans un micro-cluster) mais reste **significative** pour qualifier un **macro-cluster**. Ce super-groupe agit souvent comme un **super-nœud** dans un niveau macro, en lien avec d'autres macro-ensembles, formalisé par $\omega_{\Gamma, \Delta}^{(\text{global})}$.

Exemples

8. Dans une **architecture neuronale inspirée du cerveau**, un “macro-ensemble” peut symboliser une grande aire associant des fonctions cognitives plus abstraites.
9. Dans un **réseau sémantique**, un macro-cluster incarne un **concept** (ex. “géométrie”, “mécanique quantique”) regroupant des micro-clusters de définitions, de synonymes, etc.
10. Dans la **robotique** multi-agent, un macro-ensemble désigne une “équipe étendue” : plusieurs sous-équipages plus petits collaborent pour un objectif final commun.

C. Articulation : du micro au macro

Le **niveau micro** (petits clusters sensoriels) se trouve à la base. Le **niveau macro** (grands ensembles conceptuels) se trouve au sommet. Entre les deux, un **méso-niveau** (chap. 6.2.2) peut regrouper des sous-groupes intermédiaires. Chaque palier propose une **granularité** distincte mais reliée :

11. Le micro-niveau, réactif et spécialisé,
12. Le méso-niveau, coordinateur ou “articulateur”,
13. Le macro-niveau, plus abstrait, offrant une synthèse plus large ou une “vision d’ensemble”.

Les **micro-réseaux sensoriels** génèrent des signaux qui s’agrègent en macro-ensembles conceptuels : la consolidation se fait par **flux ascendant** (bottom-up). Symétriquement, le niveau macro peut imposer des **contraintes** ou **orientations** descendantes (top-down) : par exemple, un macro-objectif “réduire la consommation d’énergie” se traduit, au niveau micro, par un ajustement des pondérations $\omega_{i,j}$ favorisant certains capteurs plus pertinents pour cet objectif.

Conclusion

Ces deux **exemples** — (A) micro-réseaux sensoriels, (B) macro-ensembles conceptuels — illustrent clairement la **cohabitation** de micro-clusters et de macro-clusters dans un **SCN** à multiples échelles. Les micro-réseaux portent sur des entités localement cohésives (capteurs, neurones, etc.) tandis que les macro-ensembles englobent un **grand** sous-ensemble plus abstrait (missions globales, concepts cognitifs, grandes équipes, etc.). La **hiérarchie** (micro → méso → macro) ainsi constituée fournit une ossature pour un **DSL** multi-niveau, permettant de résoudre la complexité en *segmentant* l’auto-organisation et en facilitant des **interactions** ascendantes et descendantes entre différents paliers. La suite du chapitre (Section 6.2.2, etc.) détaillera comment formaliser l’**agrégation** et la **coordination** de ces niveaux, et comment les *synergies* ω peuvent se propager ou se combiner à travers la hiérarchie pour former un **SCN** véritablement multi-échelle.

6.2.2. Théorie des Systèmes Emboîtés

Lorsque l’on manipule des **SCN** (Synergistic Connection Networks) appelés à se structurer en **niveaux** (micro, intermédiaire, macro), il est souvent utile d’invoquer la **théorie des systèmes emboîtés**. Cette théorie, inspirée de modèles biologiques ou complexes, décrit comment des **entités de base** (cellules, micro-clusters) se regroupent en « tissus » (super-nœuds de niveau intermédiaire), puis en « organes » (macro-nœuds plus vastes), etc. La notion d’**emboîtement** formalise la hiérarchie progressive aboutissant, in fine, à un **organisme** global (un niveau macro englobant la plupart ou la totalité des entités).

6.2.2.1. Systèmes emboîtés : cellule → tissu → organe → organisme (analogie)

L’idée de **multi-échelle** et d’**emboîtement** dans un **SCN** (Synergistic Connection Network) trouve un écho naturel dans la **biologie**, où l’on décrit une hiérarchie Cellule → Tissu → Organe → Organisme. Chaque palier agrège des entités de taille ou de complexité plus faible pour former un ensemble supérieur doté de nouvelles fonctions. Cette

analogie éclairce comment, dans un **SCN** multi-échelle, on peut progressivement construire, de bas en haut, des **niveaux** de plus en plus **macro** tout en maintenant un lien avec les **interactions** plus fines du niveau inférieur.

1. Analogie Biologique

Il est courant, en biologie, de formaliser l'échelle **cellule** comme l'unité de base, dont la coordination et l'agrégation forment un **tissu** spécialisé (musculaire, nerveux, épithélial, etc.). Plusieurs tissus interdépendants constituent alors un **organe**, et la conjonction d'organes distincts mais coopérants donne naissance à un **organisme** entier. Sur le plan **hiérarchique**, on peut poser :

$$\text{Cellule} \rightarrow \text{Tissu} \rightarrow \text{Organe} \rightarrow \text{Organisme}.$$

Chacune de ces étapes se caractérise par l'**agrégation** ou l'**encapsulation** des entités de l'étape précédente, ainsi que par de **nouvelles** propriétés émergentes (régulation hormonale, vascularisation, etc.). Cet enchaînement incarne un **système emboîté** : un tissu contient des cellules, un organe contient des tissus, etc.

2. Formalisation en Systèmes Emboîtés

D'un point de vue **mathématique**, on peut représenter la hiérarchie cellulaire–tissulaire–organique par des **sous-ensembles** successifs $\{\mathcal{E}_i^{(k)}\}$ où k identifie le niveau. Par exemple :

- Niveau $k = 0$: $\mathcal{E}_i^{(0)}$ correspond aux **cellules** (entités de base).
- Niveau $k = 1$: on agrège ces cellules en **tissus** $\mathcal{T}_\alpha^{(1)}$.
- Niveau $k = 2$: on réunit plusieurs tissus en **organes** $\mathcal{O}_\beta^{(2)}$.
- Niveau $k = 3$: la **somme** des organes interdépendants constitue un **organisme** $\mathcal{O}^{(3)}$.

Chaque niveau s'**emboîte** littéralement dans le suivant : les éléments de niveau k se rassemblent pour former les entités du niveau $k + 1$. Sur le plan formel, on peut définir une **application** Φ_k :

$$\Phi_k: \{\mathcal{E}_i^{(k)}\} \rightarrow \{\mathcal{E}_\alpha^{(k+1)}\},$$

qui regroupe (ou *coarse-grain*) les entités $\mathcal{E}_i^{(k)}$ en super-nœuds $\mathcal{E}_\alpha^{(k+1)}$. Cela **reproduit** la logique de passage de la cellule au tissu, puis du tissu à l'organe, etc.

3. Maintien des Interactions

Dans la biologie, on sait que les **tissus** n'annulent pas les interactions **locales** entre cellules ; elles se reflètent sous la forme de **communications** (signaux chimiques, électriques, etc.) à un **niveau supérieur**. Pareillement, un organe dépend de la cohérence entre ses tissus, et l'organisme de la synergie entre ses organes.

Sur le plan **mathématique** et plus spécifiquement dans un **SCN** multi-niveau, cette interdépendance se traduit :

14. Par l'existence de **fonctions d'agrégation** (Section 6.2.2.2) qui synthétisent les liaisons ω d'un niveau vers le suivant.
15. Par des **rétroactions** top-down (Section 6.2.3.1) dans lesquelles l'état macro peut influencer les pondérations micro.

La structure hiérarchique ainsi formée n'annule pas la réalité des interactions locales, mais les reflète dans des *super-pondérations* $\omega^{(k)}$ entre macro-nœuds, tout en laissant la possibilité que le niveau inférieur conserve sa propre dynamique DSL.

Exemple : cellule → tissu → organe → organisme

Prenons un organisme simple, par exemple un invertébré. Les **cellules** (niveau 0) se spécialisent et se coordonnent pour bâtir un **tissu** musculaire (niveau 1). À ce stade, Φ_0 associe un ensemble de cellules “musculaires” à un super-nœud “tissu musculaire”. Parallèlement, d’autres cellules deviennent un “tissu nerveux”. Au niveau 2, on réunit ces tissus en un organe (muscle + nerf + vaisseaux) via l’application Φ_1 . Et au sommet, l’**organisme** complet (niveau 3) résulte de la **cohésion** entre organes.

Formellement, si on note Γ_k la fonction de regroupement de niveau k à $k + 1$, on a :

$$\Gamma_0(\{\text{cellules}\}) = \{\text{tissus}\}, \quad \Gamma_1(\{\text{tissus}\}) = \{\text{organes}\}, \quad \Gamma_2(\{\text{organes}\}) = \{\text{organisme}\}.$$

C’est exactement cette **progression hiérarchique** que l’on veut transposer dans le **DSL** multi-échelle : passer d’entités fines (micro-clusters) à des super-nœuds (méso) puis à des macro-entités globales (macro-niveau), tout en conservant la mémoire des interactions locales ou intermédiaires.

Conclusion

La **théorie des systèmes emboîtés**, illustrée par l’analogie de la **biologie** (cellule → tissu → organe → organisme), propose un **cadre** pour comprendre comment des entités de niveau inférieur se regroupent ou se coordonnent afin de produire, à l’échelle supérieure, des entités plus massives et plus fonctionnellement riches. D’un point de vue **multi-échelle** dans un **SCN**, cette perspective confirme la pertinence de **former** et **assembler** des micro-clusters en super-nœuds, puis de répliquer ce processus jusqu’à atteindre un macro-niveau. Les interactions ω ne disparaissent pas, elles se reconstituent à un **nouveau palier** via des mécanismes d’**agrégation** ou de **coarse-graining** (Section 6.2.2.2) et peuvent être **rétroactionnelles** (top-down vs. bottom-up) (Section 6.2.3.1). Le tout vise à une **auto-organisation** hiérarchisée, plus “naturelle” et plus robuste, dans la lignée des principes biologiques qui inspirent souvent le DSL.

6.2.2.2. Transposition au DSL : agrégation progressive d’entités vers des super-nœuds (macro-nœuds)

Le passage de **niveaux** inférieurs (micro) à des **super-nœuds** plus abstraits (macro-nœuds) est un élément clef lorsqu’on applique l’idée de **systèmes emboîtés** (6.2.2.1) dans un **SCN** (Synergistic Connection Network) reposant sur le **DSL** (Deep Synergy Learning). Il s’agit de formaliser, dans un cadre mathématique et algorithmique, la manière dont un *ensemble* d’entités localement cohésives (k -ième niveau) se **fusionnent** pour former des **super-nœuds** au niveau $k + 1$. Cette section décrit les **fondements** de ce mécanisme d’**agrégation progressive**, en expliquant comment on repère les clusters, comment on “condense” leurs pondérations, et de quelle manière la **dynamique DSL** peut se poursuivre à un niveau supérieur.

A. Notation Générale : Agrégation de Clusters

1. Ensemble initial (niveau 0)

On part d’un **niveau 0** composé d’entités “microscopiques” $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$, qui interagissent via une matrice $\omega^{(0)}$. La mise à jour se fait suivant la **règle DSL** :

$$\omega_{i,j}^{(0)}(t + 1) = \omega_{i,j}^{(0)}(t) + \eta_0 [S_0(i, j) - \tau_0 \omega_{i,j}^{(0)}(t)].$$

Chaque $\omega_{i,j}^{(0)}$ peut s’interpréter comme la synergie (ou le degré de corrélation, ou de compatibilité) entre deux entités **basiques** du réseau.

2. Détection ou formation de clusters

Lorsque la **dynamique DSL** a suffisamment évolué (ou de manière continue), on identifie un **ensemble** de *micro-clusters* $\{\mathcal{C}_1^{(0)}, \dots, \mathcal{C}_r^{(0)}\} \subseteq \{\mathcal{E}_1, \dots, \mathcal{E}_n\}$. En pratique, on repère ces clusters à l’aide :

- D’un **seuil** sur $\omega_{i,j}^{(0)}$: si $\omega_{i,j} \geq \theta$, on les considère comme reliés.

- D'un **algorithme** de détection de communautés (modulaire, composantes fortement connectées).
- D'une **analyse** topologique (loi des distances, etc.) ou d'une **fonction** $\Omega(\mathcal{C}) = \sum_{i,j \in \mathcal{C}} \omega_{i,j}$.

Dès lors, chaque micro-cluster $\mathcal{C}_\alpha^{(0)}$ regroupe un certain nombre d'entités **très** cohésives. Ce sont ces regroupements que l'on va "**remplacer**" par des super-nœuds pour construire le niveau 1.

3. Agrégation en super-nœuds

Concrètement, on "condense" chaque micro-cluster $\mathcal{C}_\alpha^{(0)}$ en un **super-nœud** $\mathcal{N}_\alpha^{(1)}$. Ainsi, le *niveau 1* du SCN se compose :

$$\{\mathcal{N}_1^{(1)}, \dots, \mathcal{N}_r^{(1)}\}.$$

On parle alors d'une application de **coarse-graining** ou de "macro-agrégation" Γ_0 , telle que :

$$\Gamma_0: \{\mathcal{C}_\alpha^{(0)}\} \rightarrow \{\mathcal{N}_\alpha^{(1)}\}.$$

Les *indices* α, β marquent que chaque super-nœud du niveau 1 correspond à un *ensemble* de micro-entités du niveau 0. La question cruciale devient alors : **comment** définir les pondérations $\omega_{\alpha,\beta}^{(1)}$ entre super-nœuds $\mathcal{N}_\alpha^{(1)}$ et $\mathcal{N}_\beta^{(1)}$?

B. Définition des Pondérations entre Super-nœuds

1. Fonction d'agrégation Ψ

Pour **transposer** les pondérations $\omega_{i,j}^{(0)}$ au niveau 1, on se sert d'une **fonction** Ψ . Par exemple, une **moyenne** :

$$\omega_{\alpha,\beta}^{(1)} = \frac{1}{|\mathcal{C}_\alpha^{(0)}| \cdot |\mathcal{C}_\beta^{(0)}|} \sum_{i \in \mathcal{C}_\alpha^{(0)}, j \in \mathcal{C}_\beta^{(0)}} \omega_{i,j}^{(0)}.$$

Ou une **somme** ou un **maximum**. L'idée est de condenser les multiples liaisons $\omega_{i,j}^{(0)}$ internes à α (ou entre α et β) en une unique $\omega_{\alpha,\beta}^{(1)}$. Ce nouveau "réseau" (niveau 1) présente alors beaucoup moins de nœuds que le réseau de base.

2. Règle DSL au niveau 1

Une fois $\omega_{\alpha,\beta}^{(1)}$ initialisées par Ψ , on peut **appliquer** à ce niveau la même **dynamique** DSL (ou une version paramétrée différemment) :

$$\omega_{\alpha,\beta}^{(1)}(t+1) = \omega_{\alpha,\beta}^{(1)}(t) + \eta_1 [S_1(\alpha, \beta) - \tau_1 \omega_{\alpha,\beta}^{(1)}(t)],$$

afin que les super-nœuds α, β interagissent *entre eux* selon une logique similaire. De cette manière, un "**cluster de super-nœuds**" peut encore se former au niveau 1, ce qui **prépare** l'étape suivante (passage à un niveau 2).

C. Répétition jusqu'au Macro-Niveau

1. Itération du Processus

Si le **niveau 1** engendre lui aussi des clusters $\mathcal{C}_\gamma^{(1)} \subseteq \{\mathcal{N}_\alpha^{(1)}\}$, on **répète** : on agrège ces sous-groupes en **macro-nœuds** $\mathcal{N}_\gamma^{(2)}$. On définit $\omega_{\gamma,\delta}^{(2)}$ en "relisant" $\omega_{\alpha,\beta}^{(1)}$ via une fonction Ψ . On obtient ainsi :

$$\Gamma_1: \{\mathcal{C}_\gamma^{(1)}\} \rightarrow \{\mathcal{N}_\gamma^{(2)}\}.$$

Ce mécanisme se **poursuit** jusqu'à un certain **niveau** K , où l'on considère avoir atteint un **macro-nœud** quasi final (ou un petit nombre de macro-nœuds dominants). Chaque itération réduit la granularité et crée une **hiérarchie**.

2. Auto-similarité potentielle

Si, à chaque niveau, on utilise la *même forme* de la **règle DSL** et la *même* fonction Ψ , on peut constater une **auto-similarité** (cf. 6.3) : la manière dont les clusters se forment localement se **réplique** à l'échelle suivante. Cela ouvre la voie à une **fractalité** (lois de puissance, motifs récurrents) d'où l'intérêt d'étudier ce **multiniveau** dans la théorie du DSL.

3. Avantages

16. **Réduction de complexité** : on remplace un ensemble énorme de micro-pondérations $\omega_{i,j}^{(0)}$ par un plus petit ensemble $\omega_{\alpha,\beta}^{(1)}$.
17. **Modularité** : chaque niveau peut “gérer” ses pondérations, sans interférer constamment avec le niveau inférieur.
18. **Faculté de scale** : on peut potentiellement pousser la hiérarchie sur 2, 3... niveaux si le nombre n de micro-entités est très grand.

D. Mise en Œuvre Algorithmique

1. Processus d'Agrégation

Typiquement, un **algorithme** multi-échelle fonctionnant par itérations “agrégation–mise à jour” :

19. **Clusterisation** (niveau k) : On repère les sous-ensembles $\mathcal{C}_\alpha^{(k)}$.
20. **Agrégation** : On crée des super-nœuds $\mathcal{N}_\alpha^{(k+1)}$ et initialise $\omega_{\alpha,\beta}^{(k+1)}$ via Ψ .
21. **Mise à jour** : On applique la règle DSL au niveau $k + 1$, construisant la structure $\omega^{(k+1)}$.
22. **Répétition** : Tant que $\omega^{(k+1)}$ suscite de nouvelles agrégations, on recommence (sinon on s'arrête).

2. Pseudo-code

function buildHierarchy(level=0, listOfEntities E^0):

```
# 1) Repérer clusters micro
clusters = detectClusters( $E^0$ ,  $w^0$ )
# 2) Construire super-nœuds
superNodes = []
for each cluster C in clusters:
    superNode M = new SuperNode(C)
    superNodes.add(M)

# 3) Agréger pondérations
 $w^{(level+1)}$  = computeWeights(superNodes,  $w^{(level)}$ ) # via Psi

# 4) Mise à jour DSL
applyDSL( $w^{(level+1)}$ )

# 5) S'il reste de la structure interne
if new merges can appear:
    buildHierarchy(level+1, superNodes)
else:
    return superNodes
```

Cet algorithme illustre un schéma **ascendant** (bottom-up). Des variantes peuvent incorporer des **feedback** top-down (section 6.2.3).

Conclusion

Le passage d'un **niveau** micro (ou intermédiaire) à un **niveau** supérieur (super-nœuds, macro-nœuds) dans un **SCN** repose sur une **agrégation progressive** de clusters identifiés, de manière à construire peu à peu une **hiérarchie** d'entités emboîtées. **Mathématiquement**, on définit des **fonctions** Ψ pour “transposer” les pondérations d'un niveau au suivant, ainsi qu'une *règle DSL* adaptant le renforcement/inhibition à ces super-nœuds. **Algorithmiquement**, on réalise un processus *ascendant* : on détecte des clusters cohésifs, on les condense en un super-nœud, on recalcule la synergie au niveau agrégé, et on réitère jusqu'à aboutir à un macro-niveau plus stable.

Ce mécanisme formalise la notion d'un **SCN** multi-échelle de type “cellule \rightarrow tissu \rightarrow organe \rightarrow organisme” (ou “micro-cluster \rightarrow super-nœud \rightarrow macro-nœud”). Il **prépare** à la discussion (6.2.2.3) sur la **coordination** multi-niveau, où l'on couplera l'agrégation bottom-up à des *rétroactions* top-down, assurant une auto-organisation fluide à tous les paliers de la hiérarchie.

6.2.2.3. Multi-niveau comme “pilier” pour la gestion de la complexité

Lorsque la taille n d'un **SCN** (Synergistic Connection Network) devient très grande (dizaines, centaines de milliers ou plus d'entités), on se retrouve face à une croissance potentielle de la complexité en $O(n^2)$ si l'on s'en tient à un *niveau unique*. Une telle situation rend difficile la mise à jour de la matrice ω et la détection de clusters significatifs. Le **multi-niveau** (ou multi-échelle), décrit dans les sections précédentes, se révèle alors un **pilier** incontournable pour contenir cette complexité et l'organiser de manière **hiérarchique**.

A. Réduction de la complexité via l'agrégation

Dans un **SCN** de niveau “zéro” (micro) avec n entités, la matrice $\omega^{(0)}$ peut compter jusqu'à $O(n^2)$ pondérations (chaque couple (i, j) peut a priori disposer d'un lien $\omega_{i,j}$). Chaque itération de la règle DSL pourrait, dans le pire cas, nécessiter $O(n^2)$ mises à jour si l'on ne pratique ni **parsimonie** (seuil, kNN, etc.) ni **multi-niveau**.

Lorsque l'on introduit un **niveau supérieur** (voir section 6.2.2.2) qui regroupe les entités en **super-nœuds**, la taille de la matrice $\omega^{(k+1)}$ peut chuter de $O(n^2)$ à $O(m^2)$ pour $m \ll n$. Cela signifie que la charge de gestion des pondérations au niveau $k + 1$ est désormais bien plus réduite. Dans un système hiérarchique allant jusqu'à un macro-niveau, on obtient plusieurs matrices $\omega^{(k)}$ de tailles décroissantes n, n_1, n_2, \dots .

Si un système compte un **niveau 0** à n entités, on détecte des **clusters** et on regroupe ces entités en n_1 super-nœuds pour le **niveau 1**. Puis on applique le même principe pour passer de n_1 à n_2 au **niveau 2**, etc., produisant une suite $n_0 = n > n_1 > n_2 > \dots > n_K$. Souvent, $n_K \approx 1$ ou un petit nombre, correspondant à un nombre réduit de macro-nœuds.

Cette **hiérarchie** rend possible un **traitement** plus local au niveau inférieur, alors que le niveau supérieur opère sur moins de super-nœuds, entraînant un coût algorithmique plus faible ($O(n_k^2)$ au niveau k).

Supposons $n_0 = 10^5$ au niveau micro. On pourrait aisément se retrouver avec $O(10^{10})$ liens théoriques. Si on agrège en $n_1 = 10^3$ super-nœuds (niveau 1), on ne gère plus que $O((10^3)^2) = 10^6$ pondérations à ce niveau. En passant à un niveau 2 avec $n_2 \approx 10^2$, la complexité tombe encore à $O((10^2)^2) = 10^4$. Chaque **niveau** manipule donc une structure plus “légère”, et l'ensemble forme un **organigramme** multi-niveau de l'auto-organisation.

B. Organisation hiérarchique et contrôle local vs. global

Le **niveau micro** (entités de base, éventuellement groupées en petits micro-clusters) s'occupe des **réactions** les plus fines ou rapides, avec un taux d'apprentissage η_{loc} potentiellement plus élevé. Cela s'explique par la nature **proche** et **réactive** des interactions locales : deux entités très similaires voient leurs liens se renforcer plus vite, sans impliquer l'ensemble du réseau.

L'avantage est que cette adaptation **ne surcarburera** pas la totalité du SCN : seules les entités localement concernées subissent des modifications en temps réel, tandis que les autres restent peu affectées. Cela correspond à un *contrôle local*, bien plus facile à **paralléliser** ou à distribuer.

Au niveau **macro**, ou global, la **structure** du SCN se décrit en termes de super-nœuds plus vastes : on “pilote” alors de *grandes portions* de l’ensemble, éventuellement en $O(m^2)$ liens si l’on ne compte que m macro-nœuds. Cela fournit un **contrôle plus large** mais moins détaillé (il ne faut pas intervenir sur chaque entité de base).

Ce macro-niveau peut fixer des **contraintes** ou envoyer des **feedback** descendant (top-down) pour orienter la dynamique micro, par exemple imposer des seuils minimaux de synergie pour que des entités participent à un macro-objectif.

Cette structuration (micro, méso, macro) évite qu’un **seul** algorithme doive gérer simultanément des centaines de milliers (ou millions) de liens. On crée plutôt **plusieurs** paliers, chacun manipulant un **réseau** de taille moindre, tout en assurant la **cohérence** grâce à la **rétroaction** (section 6.2.3). Sur le plan mathématique, on se dote d’une suite de matrices $\{\omega^{(0)}, \omega^{(1)}, \dots\}$ reliant des entités de *plus en plus agrégées*, et on applique la mise à jour DSL (additive, multiplicative, etc.) à chacun de ces niveaux.

C. Maintien de la cohérence multi-échelle

Le **couplage** multi-échelle se concrétise par des **fonctions d’agrégation** (pour passer du niveau k au niveau $k + 1$) et par des **rétroactions** top-down (le niveau macro imposant ou suggérant des ajustements au niveau micro). Chaque matrice $\omega^{(k)}$ conserve alors une **trace** de la structure d’interaction héritée du niveau inférieur, sous forme “coarse-grained”.

On aboutit à un **système** de poids $\omega^{(k)}(t)$ sur $O(n_k^2)$ liens, avec n_k (le nombre de super-nœuds au niveau k). Un opérateur Ψ_k définit $\omega^{(k+1)}$ à partir de $\omega^{(k)}$. Chaque $\omega^{(k)}$ suit sa propre dynamique DSL :

$$\omega_{\alpha,\beta}^{(k)}(t+1) = \omega_{\alpha,\beta}^{(k)}(t) + \eta_k [S_k(\alpha, \beta) - \tau_k \omega_{\alpha,\beta}^{(k)}(t)].$$

Le multi-niveau permet de restreindre η_k ou τ_k à des valeurs plus appropriées à la taille du niveau. On gère ainsi un **réseau** à $O(n_k^2)$ plutôt qu’à $O(n^2)$, tout en conservant une **vision** hiérarchique plus flexible.

En outre, un **événement** local (un micro-cluster s’effondre, un sabotage local, etc.) n’a pas à se propager instantanément au niveau macro, tant que l’agrégation au niveau supérieur n’y voit pas d’impact majeur. Il y a donc une **protection** top-down, ou un **isolement** partiel, renforçant la robustesse : le macro-niveau n’est pas submergé de fluctuations mineures.

De plus, la **modularité** facilite la maintenance et l’évolution d’un SCN : on peut substituer un bloc micro par un autre sans chambouler tout le macro-niveau.

Conclusion

Le **multi-niveau** ou **multi-échelle** constitue un **pilier** pour **gérer la complexité** dans un SCN volumineux. Sur le plan **mathématique**, on construit une suite hiérarchique de matrices $\omega^{(k)}$ où chaque palier présente moins de nœuds (super-nœuds) et moins de liaisons $O(n_k^2)$. Sur le plan **dynamique**, on répartit l’**auto-organisation** : le niveau local manipule liaisons fines et réactives, le macro-niveau gère de larges ensembles, et un niveau intermédiaire fait la jonction. Ce **scénario** de réduction progressive, combiné à des *opérateurs* d’agrégation et éventuellement à des **feedback** top-down, non seulement abaisse le coût algorithmique, mais renforce la **robustesse** et la **modularité** du SCN.

Ainsi, le **multi-niveau** s’avère un **levier** fondamental pour l’**auto-organisation** à grande échelle, tout en ouvrant la porte à des phénomènes d’**auto-similarité** (voir 6.3) si les mêmes règles DSL et fonctions d’agrégation se répliquent à tous les paliers.

6.2.3. Rétroactions et Anticipations Multi-Niveau

Dans une **organisation** hiérarchique (micro, intermédiaire, macro) — telle qu’exposée en (6.2.1) et (6.2.2) —, il est essentiel de comprendre **comment** ces niveaux interagissent. Les **flux ascendants** (bottom-up) font “remonter” l’information du micro-cluster vers des super-nœuds plus larges (macro-ensembles) ; les **flux descendants** (top-down)

permettent au niveau supérieur d'exercer un **contrôle** (ou une **influence**) sur la dynamique locale. Cette section (6.2.3) en décrit les mécanismes, à commencer par le flux ascendant (6.2.3.1).

6.2.3.1. Flux ascendants (bottom-up) : micro \rightarrow macro

Dans un **SCN** (Synergistic Connection Network) multi-niveau, le **flux ascendant** (ou bottom-up) représente la façon dont la **structure** et la **dynamique** établies à un **niveau** local (micro) se répercutent vers les **niveaux supérieurs** (macro). Concrètement, c'est l'opération qui permet à des *micro-clusters* ou *super-nœuds* d'être "remontés" et agrégés pour former des macro-nœuds plus vastes. Cette section (6.2.3.1) détaille le **principe**, les **motifs** et les **bénéfices** de ce flux ascendant, en l'illustrant avec des exemples de robotique et de systèmes cognitifs.

A. Principe du flux ascendant

Le flux bottom-up suppose que des **groupes** d'entités (au niveau k) — par exemple un ensemble de micro-entités —, une fois **fortement cohésifs**, vont être **promus** ou **agregés** en un **super-nœud** au niveau $k + 1$. Cela incarne mathématiquement la **transition** :

$$\mathcal{C}_\alpha^{(k)} \xrightarrow{\text{agrég.}} \mathcal{N}_\alpha^{(k+1)},$$

où $\mathcal{C}_\alpha^{(k)}$ est un cluster de niveau k et $\mathcal{N}_\alpha^{(k+1)}$ le super-nœud correspondant au niveau $k + 1$.

Dans la dynamique DSL, si $\mathcal{C}_\alpha^{(k)} \subset \{\mathcal{E}_i^{(k)}\}$ regroupe un ensemble d'entités ou de nœuds de niveau k , on définit les pondérations $\omega_{\alpha,\beta}^{(k+1)}$ par agrégation des pondérations $\omega_{i,j}^{(k)}$. Généralement, on emploie une fonction Ψ , telle que

$$\omega_{\alpha,\beta}^{(k+1)} = \Psi(\omega_{i,j}^{(k)} \mid i \in \mathcal{C}_\alpha^{(k)}, j \in \mathcal{C}_\beta^{(k)}).$$

L'essence du **flux ascendant** tient à ce que des **clusters** "stables" du niveau inférieur *remontent* et se placent comme **unités** (super-nœuds) au niveau supérieur.

Condition **de** **cohésion**

Pour qu'un cluster $\mathcal{C}_\alpha^{(k)}$ soit jugé "stable", on impose souvent une **condition** de type :

$$\Omega(\mathcal{C}_\alpha^{(k)}) = \sum_{i,j \in \mathcal{C}_\alpha^{(k)}} \omega_{i,j}^{(k)}(t) > \theta_{\text{coh}},$$

où θ_{coh} est un seuil de cohésion. Une fois ce seuil dépassé, on *verrouille* $\mathcal{C}_\alpha^{(k)}$ et on crée un super-nœud $\mathcal{N}_\alpha^{(k+1)}$. C'est ce **verrouillage** qui incarne la décision de "promouvoir" un cluster micro en macro.

B. Motivation et Bénéfices

La **réduction de la complexité** constitue le premier atout majeur : le flux ascendant "filtre" l'information la plus dense ou la plus stable au niveau micro et ne "remonte" que des agrégats cohésifs. Cela dispense le niveau macro de manipuler directement toutes les entités une à une, puisqu'une **compression** ou *coarse-graining* est opérée sur les pondérations ω dans la transition micro \rightarrow macro. Dans cet esprit, les blocs formés à l'échelle inférieure servent de briques de construction pour l'étape suivante, allégeant la matrice $\omega^{(k+1)}$.

La **spécialisation locale** se révèle tout aussi fondamentale : au niveau micro, chaque entité ou petit cluster agit avec une **réactivité** importante (par exemple un taux d'apprentissage plus grand η). Cette configuration permet de repérer rapidement une synergie forte. Ce n'est qu'une fois la cohésion atteinte que le cluster ainsi stabilisé est promu au niveau supérieur. En d'autres termes, le "détail" micro demeure géré en local, puis seul le résultat final de l'auto-organisation (un groupe cohésif) se transmet à l'échelle macro, favorisant l'efficacité et la robustesse de la construction hiérarchique.

Un **exemple formel** se produit lorsqu'un cluster $\mathcal{C} \subset \{\mathcal{E}_i^{(k)}\}$ a été identifié. Après détection, on construit un **super-nœud** $\mathcal{N}_\alpha^{(k+1)}$. Les pondérations $\omega_{\alpha,\beta}^{(k+1)}$ de ce nœud vis-à-vis d'un autre super-nœud $\mathcal{N}_\beta^{(k+1)}$ découlent alors d'une agrégation, typiquement :

$$\omega_{\alpha,\beta}^{(k+1)} = \Psi(\omega_{i,j}^{(k)} \mid i \in \mathcal{C}_\alpha^{(k)}, j \in \mathcal{C}_\beta^{(k)}),$$

où Ψ combine les poids $\omega_{i,j}^{(k)}$ (moyenne, maximum, minimum, etc.) selon les besoins. De cette manière, le **niveau** $k + 1$ ne conserve qu'un nombre restreint de super-nœuds, ce qui allège considérablement la matrice $\omega^{(k+1)}$ et participe à la flexibilité globale du SCN.

C. Exemples Illustratifs

Robotique : micro-clusters

Dans un essaim de robots, le niveau local (micro) peut repérer un **mini-groupe** très coopérant (quelques robots). Ce *micro-cluster* ascendant devient alors un *super-robot* au niveau supérieur, consolidant ses liaisons envers d'autres mini-groupes. On obtient un “**groupe de groupes**” au niveau macro, construit *bottom-up*.

Système cognitif : patterns neuronaux

Dans une architecture cognitive, le micro-niveau (p. ex. des *feature maps* en vision) détecte des **clusters** de neurones (ou filtres) s'activant fortement. Une fois stabilisé, ce cluster “remonte” en tant que *macro-patch* pour le niveau associatif, permettant une **synthèse** plus globale. De cette manière, l'information *micro* (détails sensoriels) s'organise en *proto-représentations* qui deviennent des super-nœuds conceptuels ou symboliques.

Conclusion

Le **flux ascendant (bottom-up)** dans un SCN multi-niveau décrit la **migration** de l'information **micro** vers la **structure macro** : lorsqu'un cluster local se consolide (pondérations élevées), il se voit “promu” en super-nœud, réduisant la taille des matrices à manipuler au niveau supérieur et maintenant la **cohérence** de l'**auto-organisation**. Sur le plan **mathématique**, cela se formalise via une **fonction** Ψ d'agrégation, et un **critère** de cohésion $\Omega(\mathcal{C})$. Sur le plan **opérationnel**, ce mécanisme gère la **réactivité** fine en bas (micro) et la **vision** plus large en haut (macro), tout en **diminuant** la complexité par un principe de *filtrage* et de *coarse-graining*. La **section 6.2.3.2** abordera la **complémentarité** descendante (top-down), où le macro-niveau peut à son tour influencer ou “redescendre” sur le micro-niveau pour ajuster les pondérations.

6.2.3.2. Flux descendants (top-down) : macro \rightarrow micro

Après avoir vu en section 6.2.3.1 comment les *micro-clusters* (ou ensembles locaux) “remontent” vers les niveaux supérieurs via le flux **ascendant**, il est tout aussi fondamental de comprendre le **flux descendant** (top-down). Celui-ci décrit la manière dont le **niveau macro** (ou intermédiaire, s'il est plus élevé) peut rétroagir et exercer une influence directe sur les **pondérations** ou la **dynamique** au niveau micro. Ce mécanisme top-down assure une **cohérence** globale du SCN (Synergistic Connection Network) en permettant aux intentions, visions ou constats du niveau supérieur de se **répercuter** localement dans les liens $\omega_{i,j}$.

A. Rôle du niveau macro vis-à-vis du niveau micro

Au **niveau macro**, on manipule un plus petit nombre de *super-nœuds* $\{\mathcal{M}_\alpha^{(k)}\}$, chacun agrégé depuis un niveau inférieur. Ce palier peut détecter une structure globale, par exemple l'émergence de deux **macro-clusters** se rapprochant ou la nécessité de les fusionner. Pour que cette **fusion** s'opère effectivement en bas (niveau micro), il peut être **nécessaire** que le macro-nœud envoie un signal top-down demandant d'**augmenter** certaines liaisons $\omega_{i,j}^{(\text{micro})}$ ou d'**diminuer** d'autres, en fonction d'un objectif général.

D'un point de vue **mathématique**, on modélise la mise à jour au **niveau micro** par une équation augmentée :

$$\omega_{i,j}^{(0)}(t+1) = \omega_{i,j}^{(0)}(t) + \eta_0[S_0(i,j) - \tau_0 \omega_{i,j}^{(0)}(t)] + \gamma_{\text{top-down}} h_{i,j}^{(\text{macro})}(t),$$

où le terme $h_{i,j}^{(\text{macro})}(t)$ encode l'**influence** descendante du niveau macro (par exemple, un **boost** si on souhaite rapprocher deux entités i, j appartenant à des macro-nœuds censés fusionner).

Imaginons un macro-niveau $\omega^{(k)}$ détectant que deux grands ensembles $\mathcal{N}_\alpha^{(k)}$ et $\mathcal{N}_\beta^{(k)}$ s'avèrent synergiques, et qu'il est donc logique de les **fusionner**. Cependant, la **réalité** micro peut comporter des liens $\omega_{i,j}^{(0)}$ (pour $i \in \mathcal{N}_\alpha^{(k)}, j \in \mathcal{N}_\beta^{(k)}$) trop faibles. Le macro-niveau envoie alors un message top-down pour **accroître** ces $\omega_{i,j}^{(0)}$, guidant la dynamique micro vers un regroupement effectif.

Inversement, si un conflit est détecté, un message top-down peut **abaisser** certaines synergies locales, évitant des ambiguïtés ou chevauchements contradictoires.

Sans ce flux descendant, la **logique** de chaque niveau local risquerait d'être **myope**, focalisée sur de petites agrégations sans percevoir l'intérêt d'une fusion plus large. Le **macro-niveau** peut imposer ou suggérer des orientations qui, sinon, ne surgiraient pas localement. Cela donne une **harmonisation** entre la réactivité fine en bas et la vision globale en haut.

B. Forme générale du flux descendant

On peut définir, pour chaque niveau k , une fonction ou un opérateur Λ_k qui transforme l'**état** $\omega^{(k)}(t)$ du réseau macro (ses liens, ses clusters) en un **terme** de correction $\Delta^{(k-1)}$ pour le niveau $k-1$. Concrètement :

$$\Lambda_k: \omega^{(k)}(t) \mapsto \Delta_{i,j}^{(k-1)}(t),$$

et on rajoute $\Delta_{i,j}^{(k-1)}(t)$ dans l'équation de mise à jour $\omega_{i,j}^{(k-1)}$. Cela rend possible des **ajustements** fins : augmenter/diminuer $\omega_{i,j}$ localement, changer la saturation, etc.

Dans la pratique, cette **rétroaction** top-down se concrétise par :

23. Un **boost** sur les liens $\omega_{i,j}^{(0)}$ considérés "importants" pour un but global (ex. fusion).
24. Un **découragement** (pénalité) sur d'autres liens si le macro-niveau détecte un conflit ou une "incompatibilité".

On peut programmer un **module** top-down qui, chaque X itérations, regarde $\omega^{(k)}$ et en déduit des $\Delta_{i,j}^{(k-1)}$ à appliquer. Ainsi, on obtient :

$$\omega_{i,j}^{(k-1)}(t+1) = \omega_{i,j}^{(k-1)}(t) + \Delta_{i,j}^{(k-1)}(t),$$

où $\Delta_{i,j}$ est *calculé* en fonction du macro-niveau.

Exemple

Soit un robot multi-niveau :

- Niveau **micro** : quelques robots $\{r_1, r_2, \dots\}$.
- Niveau **macro** : un "essaim" global défini par $\omega_{\alpha,\beta}^{(k)}$.

Si le macro-niveau souhaite que deux sous-essaims se coordonnent, il affecte une valeur positive Δ_{r_i,r_j} pour les robots r_i, r_j situés dans deux ensembles censés fusionner. Au cycle suivant, $\omega_{i,j}^{(0)}$ au niveau micro s'en voit **augmentée**, favorisant la coopération.

C. Finalité : Couplage Macro \rightarrow Micro pour une cohérence globale

Le macro-niveau peut “voir” des **corrélations** ou **objectifs** plus vastes. S’il veut encourager une convergence entre macro-nœuds, mais remarque des liens micro trop faibles, il agit en top-down pour relever ces liens. Ce faisant, il “induit” de nouvelles synergies locales.

Le flux ascendant (micro \rightarrow macro) consolide ce qui s’est stabilisé au niveau local. Le flux descendant (macro \rightarrow micro) renforce ou corrige ce qui serait souhaitable pour la vision d’ensemble. Ensemble, ils forment un **cercle de rétroaction** : l’information monte, le macro la synthétise, puis la redescend sous forme de consignes. Cela rend la **dynamique** multi-niveau potentiellement plus stable ou plus rapide (moins d’essais-erreurs purement locaux).

En dernier lieu, ce mécanisme empêche l’**émiettement** excessif d’un SCN en multiples micro-groupes indépendants. Dès que le macro-niveau perçoit un intérêt commun, il enjoint aux entités de se rapprocher. Sur le plan **mathématique**, cela se formalise par des *termes d’influence* $\Delta_{i,j}$ insérés dans l’équation micro. Sur le plan **pratique**, c’est une manière de *diriger* ou *guider* localement l’auto-organisation vers une **harmonie** plus globale.

Conclusion

Le **flux descendant** (top-down) est la **contrepartie** naturelle du flux ascendant (bottom-up). Tandis que le **bottom-up** agrège les micro-clusters en super-nœuds, le **top-down** réinjecte dans la matrice micro les *connaissances* ou *objectifs* du macro-niveau. **Mathématiquement**, cela se matérialise par un **terme** additionnel dans la mise à jour $\omega_{i,j}^{(0)}$, déterminé par l’état $\omega^{(k)}$ ou $\omega^{(\text{macro})}$. Ainsi, le **SCN** hiérarchique profite d’une boucle multi-niveau complète :

25. Les micro-entités forment localement des clusters,
26. Le macro-niveau agrège ces clusters et y détecte un but ou une structure,
27. Il redescend un signal ajustant des liaisons micro pour mieux refléter l’objectif global.

Ce mécanisme **renforce** la **cohérence** et la **capacité adaptative** d’un SCN complexe, permettant une **auto-organisation** à la fois fine et globale.

6.2.3.3. Communication entre niveaux synergiques et stabilisation

L’instauration d’un **SCN** (Synergistic Connection Network) à multiples paliers — micro, intermédiaire, macro — repose sur l’existence d’une communication **verticale** entre ces niveaux, permettant la **rétroaction** complète : le **flux ascendant** (bottom-up) et le **flux descendant** (top-down). Cette section illustre la **coexistence** des deux sens de circulation et décrit de quelle manière ils aboutissent à une **stabilisation** globale, où chaque niveau coopère avec les autres pour garantir la cohérence d’ensemble du réseau.

A. Schéma Général de Communication

On suppose un **système hiérarchique** à K paliers, indexés par $k = 0, 1, \dots, K$.

- Le niveau k dispose d’un ensemble de nœuds (entités ou super-nœuds) et d’une matrice $\omega^{(k)}$.
- Le passage $\omega^{(k)} \rightarrow \omega^{(k+1)}$ constitue un **flux ascendant** (bottom-up), noté Γ_k ou Ψ (6.2.3.1).
- Le passage $\omega^{(k+1)} \rightarrow \Delta^{(k)}$ (une correction appliquée à $\omega^{(k)}$) s’interprète comme un **flux descendant** (top-down), noté Λ_{k+1} .

Cette structure forme un **couplage** entre niveaux :

$$\begin{cases} \omega^{(k+1)}(t) = \Gamma_k \left(\omega^{(k)}(t) \right), \\ \omega^{(k)}(t+1) = \omega^{(k)}(t) + \Delta^{(k)} \left(\omega^{(k+1)}(t) \right). \end{cases}$$

Dans les faits, la mise à jour $\omega^{(k+1)}(t+1)$ peut aussi dépendre du nouvel état $\omega^{(k)}(t+1)$, ou être réalisée en mode **asynchrone** ; l'important est qu'il y ait un aller-retour permanent garantissant la cohésion.

Selon l'**implémentation**, on adopte un protocole :

- **Synchrone** : après chaque itération au niveau k , on agrège (Γ_k), met à jour $\omega^{(k+1)}$, puis calcule la correction $\Delta^{(k)}$ à renvoyer.
- **Asynchrone** : chaque niveau avance à son rythme, et on synchronise moins fréquemment, créant un *retard* possible entre les informations montantes et descendantes.

Quoi qu'il en soit, le but est de conserver un **échange** soutenu : quand des micro-clusters se forment, le niveau macro en est informé ; quand le niveau macro discerne une organisation plus vaste, il renvoie un signal pour influencer sur certaines liaisons microscopiques.

B. Stabilisation Multi-Niveau

Un **SCN** multi-niveau est dit **stabilisé** s'il existe un *point fixe* (ou un cycle) $\{\omega^{(k)*}\}_{k=0}^K$ tel que :

$$\Gamma_k(\omega^{(k)*}) = \omega^{(k+1)*}, \quad \Delta^{(k)}(\omega^{(k+1)*}) = 0, \quad \forall k.$$

Autrement dit, les agrégations bottom-up Γ_k reproduisent la configuration $\omega^{(k+1)*}$ déjà existante, tandis que les corrections top-down $\Delta^{(k)}$ sont nulles (pas de besoin d'ajustement). Cela signifie que la hiérarchie ne modifie plus ni les clusters ni les liens microscopiques.

La **convergence** vers un tel point fixe peut ne pas être triviale à démontrer. Des conditions de **stabilité** (taux d'apprentissage, seuils de cohésion, etc.) doivent être satisfaites. En pratique, on observe souvent que le SCN multi-niveau se stabilise ou aboutit à un *cycle* (un mouvement périodique restreint), plutôt que de rester en fluctuations incessantes. Dans certains cas, de légères oscillations peuvent persister, reflétant un **équilibre dynamique**.

Il peut se produire qu'un niveau **macro** "veuille" un certain regroupement alors que le niveau **micro** persiste à séparer les entités. Ceci peut générer des **conflits** ou des oscillations : le niveau macro *force* l'augmentation de certains liens, puis le niveau micro *décide* de les réduire, etc. Pour éviter cela, on peut recourir à des *mécanismes de temporisation* ou un *paramétrage* plus modéré ($\gamma_{\text{top-down}}$ pas trop élevé, etc.) assurant la douceur de la rétroaction.

C. Communication et Rétroaction Continue

Il est possible que *chaque* niveau applique la **même** règle DSL (additive, multiplicative, etc.), assurant une sorte d'**auto-similarité** du mécanisme. Mais on peut aussi imaginer des paramètres η_k, τ_k différents pour chaque palier : un niveau micro plus "rapide", un niveau macro plus "lent".

Cette modularité engendre un **système** multi-niveau dans lequel la **fréquence** et la **vitesse** de mise à jour diffèrent, encourageant une stabilisation plus locale en bas, puis une adaptation plus globale au sommet.

En pratique, l'information **monte** par agrégation (6.2.3.1) : on "condense" $\omega^{(k)}$ en $\omega^{(k+1)}$. Puis elle **redescend** par corrections (6.2.3.2), ce qui se matérialise par des **messages** top-down affectant $\omega^{(k)}$. Un système **synchrone** peut gérer ça en "phases" successives, un système **asynchrone** le fait plus irrégulièrement. D'un point de vue **mathématique**, on peut introduire des *délais* δ_k simulant une communication "à la volée".

Le résultat est une **pyramide** ou un "arbre" hiérarchique :

- le niveau 0 (micro) manipule $\omega^{(0)}$ et détecte des clusters,
 - le niveau 1 construit $\omega^{(1)}$ en agrégeant,
 - etc.
- Chaque palier envoie **rétroactions** (top-down) et "résultats" (bottom-up) dans un **cycle** continu. Quand ce cycle se **calme** (ou s'équilibre), on a une **organisation** stable du SCN multi-niveau.

Conclusion

La **communication** entre niveaux synergiques — flux **ascendant** (bottom-up) et flux **descendant** (top-down) — aboutit, dans un **SCN** multi-échelle, à un **état de stabilisation** où chaque palier local ou macro fonctionne de façon cohérente. Cette rétroaction complète (ascendant + descendant) se formalise via :

28. Des **opérateurs** d'agrégation Γ_k (passage $\omega^{(k)} \rightarrow \omega^{(k+1)}$),

29. Des **fonctions** de correction $\Delta^{(k)}$ (descendant $\omega^{(k+1)} \rightarrow \omega^{(k)}$),

permettant un **cercle** de feed-back dans lequel les micro-clusters stabilisés s'insèrent dans des macro-nœuds, et les macro-nœuds influencent en retour les pondérations microscopiques. En combinant ces mécanismes, un **SCN** multi-niveau peut se montrer plus **robuste**, plus **rapide** à converger et plus **capable** d'organiser un très grand nombre d'entités. À ce stade, cette architecture hiérarchique ouvre la voie aux phénomènes d'**auto-similarité** ou de **fractalité** (6.3), dans lesquels le même schéma d'auto-organisation se répète à chaque palier.

6.3. Fractalité et Auto-Similarité dans le DSL

Après avoir exploré la hiérarchie multi-niveau (6.2) et les mécanismes de communication entre paliers (bottom-up, top-down), nous abordons maintenant la **possibilité** qu'un **SCN** (Synergistic Connection Network) puisse présenter une **fractalité** — c'est-à-dire une forme d'**auto-similarité** à travers différentes échelles. Dans l'histoire des systèmes complexes, la notion de fractales, venue de la géométrie et de la modélisation de phénomènes naturels, s'avère un **paradigme** puissant pour décrire les invariances d'échelle. La section 6.3.1 introduit le concept de fractales en IA, puis 6.3.2 et 6.3.3 détaillent comment cette auto-similarité peut se manifester et se mesurer dans le cadre du DSL, et enfin 6.3.4 discute les avantages et les limites de la fractalité appliquée aux réseaux synergiques.

6.3.1. Concept de Fractales en IA

Les **fractal(e)s** renvoient à des objets ou des systèmes dans lesquels on retrouve, à plusieurs échelles d'observation, une **structure** (ou un "motif") essentiellement identique, éventuellement modulo un facteur d'échelle. C'est cette idée d'**invariance d'échelle** ou d'**auto-similarité** qui caractérise la fractalité, qu'il s'agisse d'ensembles géométriques (courbe de Koch, ensemble de Cantor, etc.) ou de phénomènes physiques et biologiques (réseaux vasculaires, littoraux, ramifications dans un arbre, etc.).

6.3.1.1. Historique : Fractales dans la Modélisation de Phénomènes Naturels, Auto-similarité à Plusieurs Échelles

La notion de fractale, introduite et popularisée dans les années 1970–1980 notamment par Benoît Mandelbrot, a profondément transformé notre compréhension des phénomènes naturels complexes. En effet, nombre d'objets ou de processus, traditionnellement jugés irréguliers ou chaotiques, révèlent une structure sous-jacente caractérisée par l'auto-similarité, c'est-à-dire la répétition de motifs à différentes échelles. Cette propriété permet de modéliser, d'une manière relativement concise, des objets dont la complexité apparente dépasse les approches classiques de la géométrie euclidienne.

A. Émergence du Concept de Fractale

1. Les Travaux Pionniers de Mandelbrot

Au cœur des travaux de Mandelbrot se trouve l'observation que de nombreux phénomènes naturels — comme les côtes marines, les nuages, les réseaux d'agrégation ou même certains aspects des systèmes biologiques — présentent une irrégularité apparente qui, lorsqu'on les observe à des échelles différentes, révèle une structure récurrente. Dans son ouvrage fondateur, *The Fractal Geometry of Nature*, Mandelbrot montre que la mesure de la « longueur » d'une côte, par exemple, dépend de la résolution de l'observation, plus on affine la mesure, plus on découvre de détails, et par conséquent, la longueur calculée augmente de manière non linéaire. Cette propriété a conduit à la conceptualisation d'objets dont la dimension, dans le sens de Hausdorff ou de Minkowski, est non entière. Pour le flocon de Koch, l'un des exemples classiques de fractale, la dimension fractale est donnée par :

$$\dim_H(\text{Flocon de Koch}) = \frac{\ln 4}{\ln 3} \approx 1.2619,$$

ce qui indique que cet objet, bien que contenu dans le plan, possède une complexité qui dépasse la simple dimension linéaire.

2. Auto-similarité et Invariance d'Échelle

La propriété d'auto-similarité est l'un des piliers de la géométrie fractale. Un objet est dit **auto-similaire** s'il se recoupe avec lui-même à différentes échelles de grandeur, c'est-à-dire que si l'on effectue un zoom sur une portion de l'objet, cette portion présente la même structure (à un facteur d'échelle près) que l'ensemble. On peut exprimer cette propriété à l'aide de similitudes. Soit $F \subset \mathbb{R}^d$ un ensemble fractal, alors il existe un nombre fini de fonctions contractantes $\{f_1, f_2, \dots, f_n\}$ telles que :

$$F = \bigcup_{i=1}^n f_i(F).$$

Ce formalisme, qui fait partie de la théorie des systèmes itératifs par fonction (IFS), traduit l'invariance d'échelle propre aux fractales. Par ailleurs, de nombreux phénomènes naturels se caractérisent par des lois de puissance, telles que :

$$P(X > x) \sim x^{-\alpha},$$

ce qui illustre que la distribution de certaines quantités (taille des amas, fréquence des phénomènes sismiques, etc.) reste identique lorsqu'on change d'échelle d'observation.

B. Exemples de Phénomènes Naturels

1. Côtes Maritimes et Littoraux

L'un des exemples les plus emblématiques est celui de la mesure des côtes. Lorsque l'on mesure la longueur d'un littoral, la valeur obtenue dépend de la précision de la règle utilisée. Si l'on se limite à une règle de 100 mètres, on obtient une certaine valeur, mais en utilisant une règle de 1 mètre, la longueur mesurée augmente de manière significative. Ce phénomène, illustré par Mandelbrot, montre que les côtes possèdent une dimension fractale comprise entre 1 et 2, reflétant ainsi leur complexité géométrique.

2. Réseaux Vasculaires et Bronchiques

Les systèmes biologiques, tels que les réseaux vasculaires ou bronchiques, exhibent également des propriétés fractales. Dans ces systèmes, les structures se ramifient de manière récurrente : chaque branche se divise en sous-branches selon des ratios constants, ce qui permet d'optimiser la distribution des fluides ou de l'air. La structure auto-similarité assure que l'ensemble du réseau, du plus petit capillaire jusqu'à l'organe complet, obéit à des règles géométriques similaires.

3. Lois de Puissance dans les Agrégations

En physique statistique et en géophysique, on observe fréquemment que la distribution des tailles d'agrégats ou la fréquence des phénomènes (comme les séismes) suit une loi de puissance. Ces lois de puissance traduisent une invariance d'échelle dans l'agrégation des éléments, suggérant que la même dynamique de formation se répète quelle que soit l'échelle d'observation.

C. Fractales et Auto-similarité dans les SCN et l'IA

1. Réseaux Complexes et Dimension Fractale

Les réseaux complexes, qu'ils soient sociaux, biologiques ou informatiques, présentent souvent des distributions de degrés et des structures hiérarchiques qui rappellent les propriétés fractales. Par exemple, la répartition des degrés dans un réseau dit « scale-free » suit typiquement une loi de puissance, indiquant que la structure du réseau est auto-similaire. Cette propriété peut être mise en parallèle avec la dimension fractale des objets géométriques, suggérant que le même type de processus d'agrégation opère à différentes échelles.

2. Auto-organisation dans les SCN

Dans un SCN, la règle d'auto-organisation (par exemple, la mise à jour des pondérations $\omega_{i,j}$ selon la règle DSL) peut se répéter à plusieurs niveaux hiérarchiques. Si la même dynamique s'applique localement dans des clusters et se retrouve également au niveau global, on peut alors qualifier le système de fractal dans le sens où il présente une **auto-similarité** d'une échelle à l'autre. Cette observation permet de modéliser la formation de clusters et d'agrégats dans un SCN par des lois de puissance et d'invariance d'échelle, donnant ainsi une dimension supplémentaire à l'analyse des réseaux auto-organisés dans le domaine de l'IA.

3. Impact et Applications

L'étude des fractales et de l'auto-similarité a des implications profondes pour la modélisation de phénomènes naturels et pour la conception de systèmes d'intelligence artificielle. Dans les SCN, elle permet de mieux comprendre comment des dynamiques locales peuvent se répéter pour générer une organisation globale cohérente. De plus, la notion de

dimension fractale offre un outil quantitatif pour mesurer la complexité d'un réseau et pour évaluer la robustesse de son auto-organisation. Ces concepts trouvent des applications dans des domaines variés, allant de la modélisation des réseaux neuronaux à la prédiction des comportements dans les systèmes complexes.

Conclusion

L'histoire des fractales, tel qu'introduit dans les années 1970–1980 par Benoît Mandelbrot, a permis de révolutionner la modélisation des phénomènes naturels en introduisant la notion d'**auto-similarité** à plusieurs échelles. Des exemples emblématiques — tels que la mesure des côtes, les réseaux vasculaires ou les lois de puissance dans l'agrégation des phénomènes — illustrent que des objets apparemment irréguliers obéissent en réalité à des règles invariantes par zoom, caractérisées par une dimension fractale non entière. Dans le champ des SCN et de l'intelligence artificielle, ces concepts offrent un cadre théorique pour comprendre comment une dynamique locale de mise à jour (comme celle des pondérations $\omega_{i,j}$) peut se répéter à différentes échelles, aboutissant à des structures auto-organisées et hiérarchisées. Ainsi, la notion de fractalité et d'auto-similarité permet d'appréhender la complexité des réseaux complexes en mettant en évidence que, quelle que soit l'échelle d'observation, les mêmes principes d'agrégation et de répartition s'appliquent. Cette approche ouvre la voie à des applications avancées dans la modélisation de systèmes naturels et artificiels, où la cohérence d'ensemble émerge de l'itération répétée des mêmes règles de formation de clusters.

6.3.1.2. Intérêt pour le DSL : la Récurrence de Patterns Synergiques à Différentes Granularités

L'idée d'auto-similarité, centrale dans l'étude des fractales, se retrouve également dans le cadre du Deep Synergy Learning (DSL) lorsqu'on observe que les mêmes motifs d'organisation apparaissent à plusieurs niveaux de granularité, du micro au macro. Autrement dit, la dynamique qui régit l'évolution locale des pondérations $\omega_{i,j}$ se réplique à différentes échelles, conduisant à une structuration hiérarchique qui se caractérise par l'auto-similarité. Nous développons ci-après, en enrichissant l'argumentation par des éléments mathématiques, comment cette récurrence de patterns synergiques s'exprime et quels en sont les avantages pour un SCN.

A. Notion de Patterns Synergiques et Auto-similarité

1. Définition Mathématique d'un Motif

Considérons un petit graphe ou sous-réseau, noté \mathcal{P} , qui représente un motif synergique typique dans un SCN. Ce motif peut être défini par un ensemble de nœuds $\{1, 2, \dots, r\}$ et une matrice de pondérations associée $\omega^{(\text{patt})} = (\omega_{a,b}^{(\text{patt})})_{1 \leq a, b \leq r}$. L'idée fondamentale est que, si l'on peut trouver, dans un grand réseau G (représenté par la matrice ω d'un SCN), un sous-ensemble $\mathcal{C} \subset \{1, \dots, n\}$ qui possède une topologie similaire à celle de \mathcal{P} , alors il existe une application bijective (ou une homothétie approchée)

$$\phi: \mathcal{C} \rightarrow \mathcal{P},$$

telle que pour tout $i, j \in \mathcal{C}$, la relation suivante est approximativement vérifiée :

$$\omega_{i,j} \approx \lambda \omega_{\phi(i), \phi(j)}^{(\text{patt})},$$

où λ est un facteur d'échelle positif. Cette relation exprime formellement l'**auto-similarité**, la structure du motif \mathcal{P} est retrouvée dans le sous-groupe \mathcal{C} à une échelle différente. Ainsi, le même arrangement de liens se répète, ce qui est caractéristique d'un comportement fractal dans un réseau.

2. Dimension Fractale et Couverture en Boîtes

Un autre outil mathématique issu de l'analyse des fractales est la **dimension de Hausdorff** (ou dimension fractale) qui, dans le contexte d'un SCN, peut être interprétée en examinant comment le nombre de sous-groupes distincts évolue en fonction de l'échelle de résolution. Plus précisément, en couvrant le réseau par des "boîtes" de taille ϵ (où ϵ

représente ici une tolérance dans la similarité des valeurs de ω ou dans la distance physique entre les agents), on observe que le nombre de boîtes nécessaires $N(\epsilon)$ satisfait typiquement une relation de type puissance :

$$N(\epsilon) \propto \epsilon^{-\dim_f},$$

où \dim_f est la dimension fractale du réseau. L'invariance d'échelle implique que, quelle que soit la granularité choisie (micro, méso ou macro), la structure du réseau conserve une distribution caractéristique des liaisons, reflétant l'uniformité de la dynamique d'auto-organisation.

B. Récurrence de Motifs via la Dynamique DSL

1. La Règle de Mise à Jour Uniforme

La dynamique du DSL s'exprime typiquement par une règle de mise à jour telle que :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)],$$

où $S(i,j)$ est la synergie mesurée entre les entités i et j , et η et τ sont des paramètres constants (taux d'apprentissage et coefficient de décroissance, respectivement). Le fait que cette même règle soit appliquée à chaque niveau du réseau signifie que le même opérateur F agit sur les pondérations, que l'on observe au niveau d'un micro-cluster ou d'un macro-cluster.

Autrement dit, l'auto-organisation locale (à l'échelle d'un petit groupe de robots par exemple) se fait selon une mécanique identique à celle du système global. Cela se traduit par la **répétition** de la même forme de dynamique :

$$\omega^{\text{micro}}(t+1) = F(\omega^{\text{micro}}(t), S^{\text{micro}}),$$

$$\omega^{\text{macro}}(t+1) = F(\omega^{\text{macro}}(t), S^{\text{macro}}),$$

avec S^{micro} et S^{macro} étant les scores de synergie évalués à des échelles différentes. Si ces scores sont obtenus par des mécanismes analogues – par exemple via des fonctions de similarité normalisées – alors la **forme** du système (et, en particulier, la distribution des ω) se révèle invariante d'échelle, c'est-à-dire fractale.

2. Lois de Puissance et Distribution de la Taille des Clusters

Une conséquence de l'auto-similarité dans un SCN est que la distribution des tailles de clusters peut suivre une **loi de puissance**. Plus formellement, si l'on note s la taille d'un cluster (le nombre d'entités qui le composent), on peut observer que :

$$P(s) \sim s^{-\alpha},$$

où α est un exposant caractéristique. Ce comportement scale-free indique que la même règle d'agrégation, appliquée à différentes échelles, donne lieu à la formation d'un petit nombre de grands clusters et à une majorité de clusters de taille modeste. Cette propriété fractale assure une **robustesse** du système puisque le mécanisme de formation des clusters n'est pas sensible à l'échelle, mais reste invariant, favorisant ainsi une hiérarchie cohérente d'organisations locales et globales.

3. Fusion et Invariance d'Échelle

Dans le cadre du DSL, le score de synergie $S(i,j)$ est souvent le résultat d'un processus de fusion de divers sous-scores (par exemple, issus de différentes modalités ou d'interactions à différents niveaux). Si l'on définit un score hybride comme :

$$S(i,j) = \alpha S_{\text{sub}}(i,j) + \beta S_{\text{sym}}(i,j),$$

et si ce même mécanisme de fusion est appliqué dans chaque sous-système du SCN, alors la même structure de calcul apparaît quel que soit le niveau d'agrégation. En particulier, si l'on peut identifier un motif \mathcal{P} à une échelle micro tel que

$$\omega_{i,j}^{\text{micro}} \approx \lambda \omega_{\phi(i),\phi(j)}^{(\mathcal{P})},$$

alors, en agréant ces micro-clusters, le macro-cluster résultant exhibera une structure similaire (avec éventuellement un facteur d'échelle différent). Cela traduit l'invariance d'échelle et renforce l'idée que l'auto-organisation s'effectue de manière fractale.

C. Avantages pour l'Apprentissage Multi-échelle dans le DSL

L'intérêt de la récurrence des patterns synergiques dans un SCN se manifeste sur plusieurs plans :

30. Homogénéité des Mécanismes d'Auto-organisation

Lorsque la même règle d'agrégation–inhibition s'applique à toutes les échelles, le système gagne en simplicité conceptuelle. Un unique mécanisme, qu'on peut exprimer par $F(\omega(t))$, suffit pour régir la dynamique du réseau, de la plus petite unité à l'agrégation globale. Cette homogénéité simplifie l'analyse mathématique et la mise en œuvre algorithmique.

31. Robustesse et Résilience

La présence d'un comportement fractal – où la structure d'un micro-cluster se répète à l'échelle macro – signifie que le système est intrinsèquement résilient. En effet, si une partie du réseau est perturbée ou isolée, la dynamique locale qui reste intacte permet de reconstruire la structure globale par agrégation, sans nécessiter de réinitialisation complète.

32. Lois de Puissance et Détection d'Émergences

L'apparition de lois de puissance dans la distribution des tailles de clusters permet non seulement de quantifier la structure du réseau mais aussi d'identifier des seuils critiques dans l'évolution de l'auto-organisation. Par exemple, si la distribution des tailles de clusters se stabilise selon $P(s) \sim s^{-\alpha}$, alors la valeur de l'exposant α peut servir d'indicateur pour adapter dynamiquement les paramètres du DSL (comme η ou τ) afin de préserver la stabilité du système.

33. Simplicité du Modèle

Du fait que la même dynamique se répète à chaque niveau, le modèle global se réduit à une itération de la même règle. Cela permet de construire des simulations et des théories analytiques qui, en se concentrant sur une échelle donnée, s'appliquent ensuite par récurrence aux autres échelles, facilitant ainsi la compréhension de l'ensemble du processus d'auto-organisation.

Conclusion

La récurrence de patterns synergiques à différentes granularités dans un DSL traduit la présence d'une **auto-similarité** fractale dans la dynamique du réseau. En appliquant la même règle de mise à jour – par exemple, la mise à jour additive

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)]$$

– à toutes les échelles, on observe que la même structure d'agrégation, d'inhibition et de renforcement des liens se répète, conduisant à la formation de clusters qui sont, à l'échelle micro, similaires à ceux qui se manifestent au niveau macro. Mathématiquement, cela se traduit par l'existence d'une fonction d'homothétie ϕ et d'un facteur d'échelle λ tels que :

$$\omega_{i,j} \approx \lambda \omega_{\phi(i),\phi(j)}^{(\text{patt})}.$$

Cette invariance d'échelle se manifeste également dans la distribution des tailles de clusters, souvent caractérisée par une loi de puissance de la forme $P(s) \sim s^{-\alpha}$. Sur le plan opérationnel, la répétition des mêmes mécanismes d'auto-organisation à différentes échelles confère au DSL une robustesse et une simplicité qui facilitent l'apprentissage multi-échelle. En effet, un même ensemble de paramètres et de règles peut être appliqué pour stabiliser la structure du réseau à la fois localement et globalement, sans avoir à recourir à des modèles ou des algorithmes distincts pour chaque niveau de granularité.

En définitive, la capacité du DSL à reproduire, à travers des itérations successives de sa règle de mise à jour, une structure fractale et auto-similaire, constitue l'un de ses atouts majeurs pour la modélisation de phénomènes complexes, qu'ils soient naturels ou artificiels. Ce comportement fractal, caractérisé par une invariance d'échelle, permet de comprendre comment des dynamiques locales simples peuvent aboutir à une organisation globale riche et hiérarchisée, rendant ainsi le système à la fois robuste, adaptatif et facile à analyser.

6.3.2. Auto-Similarité dans les Réseaux Synergiques

La fractalité, telle que discutée en (6.3.1), trouve un **terrain d'expression** privilégié dans un **SCN** (Synergistic Connection Network) lorsque l'on constate que les *patterns* d'auto-organisation se répètent, à la fois **localement** (dans de petits clusters) et **globalement** (à l'échelle d'un cluster plus vaste), sans nécessiter de règles qualitativement différentes. C'est cette **auto-similarité** à travers les échelles, ou *invariance d'échelle*, qui caractérise un **réseau fractal**.

6.3.2.1. Exemple : Un Cluster Local Reproduit la Même Structure que le Cluster Global (Formes d'Invariance d'Échelle)

Dans le contexte d'un SCN (Synergistic Connection Network), l'auto-organisation repose sur l'évolution locale des pondérations $\omega_{i,j}$ via des règles d'actualisation telles que

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)],$$

où $S(i,j)$ est le score de synergie entre les entités i et j . Une des propriétés remarquables de cette dynamique est la possibilité d'observer des structures similaires à des échelles différentes – un phénomène que l'on qualifie d'**invariance d'échelle** ou d'**auto-similarité**. Autrement dit, un petit cluster (micro-cluster) de robots ou d'agents, qui se forme par des interactions locales fortes, peut présenter une configuration similaire à celle d'un cluster global (macro-cluster) englobant un nombre beaucoup plus important d'entités. Nous détaillons ci-après cette idée en intégrant des arguments mathématiques et en exposant les implications pour le DSL (Deep Synergy Learning).

A. Structure d'un Cluster Local et d'un Cluster Global

Supposons qu'on ait identifié, à l'échelle locale, un cluster \mathcal{C}_{loc} composé de n_{loc} entités qui sont fortement interconnectées. La topologie de ce cluster se caractérise par une distribution interne des pondérations

$$\{\omega_{i,j}^{(\text{loc})} \mid i, j \in \mathcal{C}_{\text{loc}}\},$$

qui présente par exemple une densité élevée, une répartition particulière (cycle, étoile, réseau complet partiel) ou encore une symétrie dans l'organisation des liens.

Au niveau global, on considère un cluster $\mathcal{C}_{\text{glob}}$ de taille beaucoup plus importante, $n_{\text{glob}} \gg n_{\text{loc}}$. L'hypothèse d'auto-similarité consiste à constater que la structure (ou le "motif") de \mathcal{C}_{loc} se retrouve, à un facteur d'échelle près, dans $\mathcal{C}_{\text{glob}}$. En d'autres termes, il existe une application ou un isomorphisme (éventuellement approché)

$$\phi: \mathcal{C}_{\text{glob}} \rightarrow \mathcal{P},$$

où \mathcal{P} représente un motif de référence qui est isomorphe (à un facteur d'échelle près) au motif local. Plus formellement, pour toute paire d'entités $i, j \in \mathcal{C}_{\text{glob}}$, la relation suivante s'exprime :

$$\omega_{\phi(i), \phi(j)}^{(\text{glob})} \approx \lambda \omega_{i,j}^{(\text{loc})},$$

où $\lambda > 0$ est un facteur d'échelle qui permet de “rescaler” la distribution des pondérations du cluster local afin de la faire correspondre à celle du cluster global. Ce résultat traduit l'invariance d'échelle : la topologie (la structure des connexions) se reproduit de manière similaire, malgré la différence d'ordre de grandeur du nombre d'entités.

B. Invariance d'Échelle et Modélisation Mathématique

1. Homothétie et Isomorphisme

Pour exprimer mathématiquement l'auto-similarité, on peut considérer que le motif local \mathcal{P} est obtenu par une transformation homothétique d'un sous-ensemble du cluster global. Soit $\omega^{(\text{loc})}$ la matrice des pondérations dans le cluster local et $\omega^{(\text{glob})}$ celle du cluster global. L'existence d'une fonction de transformation ϕ et d'un facteur λ s'exprime par :

$$\forall i, j \in \mathcal{C}_{\text{loc}}, \quad \omega_{\phi(i), \phi(j)}^{(\text{glob})} = \lambda \omega_{i,j}^{(\text{loc})} + \varepsilon_{i,j},$$

où $\varepsilon_{i,j}$ représente une erreur ou une perturbation qui tend à zéro dans l'idéal. Ce cadre mathématique, proche de la notion d'isomorphisme entre graphes pondérés, permet de caractériser l'auto-similarité par la présence d'une *structure résiliente* et récurrente. En outre, en couvrant le cluster global par des boîtes de taille ϵ (dans le sens de la méthode de box-counting utilisée pour calculer la dimension fractale), on obtient une relation du type :

$$N(\epsilon) \propto \epsilon^{-\dim_f},$$

où $N(\epsilon)$ est le nombre de boîtes nécessaires pour couvrir le cluster global et \dim_f la dimension fractale du réseau. Cette relation illustre que la structure du réseau est invariante par changement d'échelle, caractéristique des systèmes fractals.

2. Loi de Puissance dans la Distribution des Clusters

L'auto-similarité dans un SCN se traduit également par une distribution en loi de puissance des tailles de clusters. Si l'on note $s = |\mathcal{C}|$ la taille d'un cluster, on peut observer empiriquement que :

$$P(s) \sim s^{-\alpha},$$

ce qui signifie que, quelle que soit l'échelle, la probabilité d'obtenir un cluster de taille s décroît selon une loi de puissance. Ce comportement scale-free est une caractéristique essentielle des réseaux fractals, indiquant que le même mécanisme d'agrégation et de séparation s'applique indépendamment de la taille des clusters.

C. Interprétations dans le DSL et Conséquences pour l'Auto-organisation

1. Unicité du Mécanisme d'Auto-organisation

L'application uniforme de la règle DSL, telle que

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta [S(i,j) - \tau \omega_{i,j}(t)],$$

indique que la même dynamique opère sur tous les niveaux du réseau. Cette uniformité signifie que le processus d'agrégation (renforcement des liens forts) et d'inhibition (affaiblissement des liens faibles) se répète de manière identique, qu'on observe un petit groupe local ou l'ensemble global des agents. Ainsi, un micro-cluster se forme

localement par la même mécanique que celle qui gouverne la formation d'un macro-cluster. Le fait que la même règle puisse être appliquée de manière récursive dans le réseau est un gage de robustesse et de simplicité du modèle.

2. Avantages pour l'Apprentissage Multi-échelle

L'auto-similarité fractale dans le DSL offre plusieurs avantages majeurs :

- **Simplicité du modèle** : La possibilité de décrire le comportement global du réseau par une seule règle d'auto-organisation permet d'éviter la complexité inhérente à la gestion de multiples mécanismes distincts pour chaque échelle. Un modèle unique s'applique localement et se propage globalement par rescaling.
- **Robustesse** : La redondance des motifs d'organisation, reproduits à différentes échelles, assure que le système reste stable même en cas de perturbations locales. Ainsi, un micro-cluster qui se déstabilise peut être compensé par la stabilité d'un macro-cluster dont la structure est identique.
- **Facilité d'analyse** : Les lois de puissance associées à la distribution des tailles de clusters et la relation homothétique entre les niveaux permettent d'exploiter des outils mathématiques (dimension fractale, box-counting) pour prédire et contrôler l'évolution du réseau.
- **Adaptabilité** : Dans un environnement dynamique, la capacité de reproduire la même structure d'auto-organisation à différentes granularités permet d'adapter le modèle sans recalibrer l'ensemble des paramètres pour chaque niveau d'agrégation.

D. Conclusion

L'exemple d'un cluster local reproduisant la même structure que le cluster global illustre parfaitement le principe d'**invariance d'échelle** dans le cadre du DSL. Mathématiquement, on exprime cette invariance par l'existence d'un facteur d'échelle λ et d'un isomorphisme approché ϕ tel que

$$\omega_{\phi(i),\phi(j)}^{(\text{glob})} \approx \lambda \omega_{i,j}^{(\text{loc})},$$

ce qui signifie que la forme topologique et la distribution des liaisons observées localement se retrouvent à l'échelle globale, à une constante multiplicative près. Cette auto-similarité fractale est particulièrement intéressante pour l'apprentissage multi-échelle, car elle permet d'utiliser une unique règle d'auto-organisation pour stabiliser le comportement à la fois localement et globalement, simplifiant ainsi l'analyse, l'ajustement paramétrique et la robustesse du SCN.

En résumé, lorsque le même motif de liaison se répète à différentes échelles, cela indique que la dynamique sous-jacente (basée sur la synergie et l'inhibition) possède une propriété fractale. Cette invariance d'échelle offre un cadre conceptuel et mathématique puissant pour comprendre comment des interactions simples et locales, appliquées de manière récursive, peuvent donner lieu à une organisation hiérarchique complexe, cohérente et robuste dans un SCN. Cela constitue l'un des piliers théoriques qui justifie l'efficacité du DSL dans la modélisation des systèmes complexes et auto-organisés.

6.3.2.2. Conditions Mathématiques : Si la Distribution des Entités et leurs Synergies Respectent Certaines Lois de Puissance, un Aspect Fractal Peut Émerger

Dans l'étude des systèmes complexes, et plus particulièrement dans le cadre des Synergistic Connection Networks (SCN) appliqués au Deep Synergy Learning (DSL), il apparaît que la dynamique d'auto-organisation peut, sous certaines conditions, donner lieu à un comportement fractal. Ce phénomène se manifeste lorsque la distribution des pondérations $\omega_{i,j}$, la taille des clusters $|C|$ ou d'autres indicateurs statistiques suivent des lois de puissance. Nous détaillons ici les fondements mathématiques de ces conditions, en insistant sur l'invariance d'échelle et les mécanismes qui conduisent à l'émergence d'un aspect fractal dans un SCN.

A. Notion de Lois de Puissance et d'Invariance d'Échelle

Une loi de puissance se caractérise par l'expression générale

$$\text{Prob}(X > x) \sim x^{-\alpha},$$

pour x suffisamment grand, où α est l'exposant caractéristique de la distribution. Cette relation signifie qu'il n'existe pas d'échelle caractéristique dans la variable X : la probabilité que X dépasse une valeur x décroît selon une fonction en puissance de x . Une propriété clé des lois de puissance est leur invariance d'échelle. En effet, pour tout facteur de redimensionnement $\lambda > 0$, on a :

$$\text{Prob}(\lambda X > x) \approx \lambda^{-\alpha} \text{Prob}(X > x).$$

Ce comportement signifie que, si l'on “zoome” sur la distribution, la forme de la courbe demeure identique à une constante multiplicative près. Dans le contexte d'un SCN, si la distribution des valeurs de $\omega_{i,j}$, ou la répartition des tailles de clusters, suit une telle loi de puissance, alors le réseau est dit *invariant d'échelle*, une propriété fondamentale pour caractériser la fractalité.

B. Génération de Lois de Puissance par la Dynamique DSL

Dans un SCN, la dynamique d'auto-organisation est régie par une règle de mise à jour du type :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)],$$

où $S(i,j)$ représente le score de synergie entre les entités i et j , η est le taux d'apprentissage, et τ le coefficient de décroissance. Ce schéma de mise à jour présente plusieurs similitudes avec le mécanisme de renforcement préférentiel (« rich-get-richer ») étudié dans la théorie des réseaux complexes. En effet, lorsqu'un lien est légèrement supérieur à la moyenne, la dynamique tend à le renforcer, tandis que les liens faibles tendent à s'effacer. Ce processus de sélection naturelle des interactions conduit, sous certaines conditions, à l'émergence d'une distribution très hétérogène des pondérations.

Lorsque l'on ne contraint pas artificiellement la distribution (par exemple, par un seuil strict de saturation), la compétition entre les liens peut conduire à une répartition des valeurs de $\omega_{i,j}$ qui suit une loi de puissance. De même, dans l'agrégation hiérarchique des clusters – où les micro-clusters sont regroupés pour former des macro-clusters – si le même mécanisme de renforcement et d'inhibition s'applique à chaque niveau, on observe que la distribution des tailles de clusters, notée par exemple

$$\text{Prob}(|\mathcal{C}| > s) \sim s^{-\alpha},$$

reste invariante d'échelle. Cela signifie que le même schéma statistique apparaît tant à petite qu'à grande échelle, une signature typique d'un comportement fractal.

C. Conditions d'Invariance d'Échelle et Fractalité Statistique

Pour qu'un aspect fractal émerge dans un SCN, il faut que plusieurs conditions soient réunies :

34. Invariance de la Forme de la Distribution

Si l'on considère une variable X (qui peut être, par exemple, la force interne d'un cluster $\Omega(\mathcal{C}) = \sum_{i,j \in \mathcal{C}} \omega_{i,j}$ ou le degré d'un nœud $\deg(i) = \sum_j \omega_{i,j}$), l'invariance d'échelle se traduit par la propriété

$$\text{Prob}(\lambda X > x) \approx \lambda^{-\alpha} \text{Prob}(X > x),$$

ce qui indique que la distribution est une loi de puissance sans échelle caractéristique. Cette propriété doit être observée sur plusieurs ordres de grandeur, c'est-à-dire pour $x \in [x_{\min}, x_{\max}]$.

35. Répétition du Mécanisme d'Auto-organisation

La même règle de mise à jour des pondérations, appliquée de manière itérative, doit générer une dynamique qui se répète à toutes les échelles. Autrement dit, si l'on observe un micro-cluster \mathcal{C}_{loc} de petite taille et un macro-cluster $\mathcal{C}_{\text{glob}}$ beaucoup plus grand, il doit exister une transformation d'homothétie ϕ et un facteur λ tel que :

$$\omega_{\phi(i),\phi(j)}^{(\text{glob})} \approx \lambda \omega_{i,j}^{(\text{loc})} \quad \text{pour } i, j \in \mathcal{C}_{\text{loc}}.$$

Cette relation est au cœur de l'auto-similarité fractale et permet d'affirmer que le même schéma d'interconnexion se reproduit, simplement rescalé, d'un niveau à l'autre.

36. Aggregation et Box-Counting

Pour quantifier l'invariance d'échelle, on peut utiliser la méthode de box-counting. Si l'on recouvre le réseau par des boîtes de taille ϵ , le nombre de boîtes nécessaires $N(\epsilon)$ devrait suivre une loi de la forme :

$$N(\epsilon) \propto \epsilon^{-\dim_f},$$

où \dim_f est la dimension fractale du réseau. La constance de \dim_f à différentes échelles indique que la structure du réseau est auto-similaire.

D. Illustrations Concrètes et Implications

Plusieurs indicateurs permettent d'observer ces comportements dans un SCN :

- **Distribution de la Force Interne des Clusters** : La somme des pondérations à l'intérieur d'un cluster, $\Omega(\mathcal{C})$, si elle suit une loi de puissance,

$$\text{Prob}(\Omega(\mathcal{C}) > x) \sim x^{-\alpha},$$
témoigne d'une invariance d'échelle dans la façon dont les interactions se répartissent au sein des clusters.
- **Distribution des Degrés** : Si le degré d'un nœud, défini par $\deg(i) = \sum_j \omega_{i,j}$, suit une loi de puissance, cela indique que le SCN est *scale-free*, avec quelques nœuds hubs et une majorité de nœuds à faible degré. Ce comportement se retrouve généralement dans les réseaux fractals.
- **Répétition des Motifs** : La présence d'un motif structurel \mathcal{P} dans un micro-cluster, qui se retrouve dans un macro-cluster après application d'une transformation homothétique, confirme l'auto-similarité. Cette observation permet d'affirmer que la même logique d'agrégation et d'inhibition, codifiée par la dynamique DSL, opère de manière récurrente.

Ces constats mathématiques et statistiques confirment que, dans un SCN où la mise à jour des pondérations ne présente pas d'échelle caractéristique, l'auto-organisation produit des structures fractales. L'avantage est double : d'une part, il est possible d'analyser et de prévoir le comportement du réseau à partir d'un sous-ensemble représentatif ; d'autre part, cette invariance d'échelle assure une robustesse et une homogénéité dans l'apprentissage multi-échelle, facilitant ainsi l'extension du modèle à des systèmes de grande taille.

Conclusion

Pour résumer, l'émergence d'un aspect fractal dans un SCN repose sur des conditions mathématiques précises. Si la distribution des pondérations ω , des degrés, ou des forces internes des clusters suit une loi de puissance du type

$$\text{Prob}(X > x) \propto x^{-\alpha},$$

alors l'invariance d'échelle est manifeste. La dynamique DSL, appliquée de manière uniforme à toutes les échelles, engendre des processus de renforcement et d'inhibition qui conduisent à la formation de motifs synergiques identiques, qu'on observe localement ou globalement. Ce phénomène est formellement exprimé par l'existence d'un isomorphisme (ou quasi-isomorphisme) ϕ et d'un facteur d'échelle λ tels que :

$$\omega_{\phi(i),\phi(j)}^{(\text{glob})} \approx \lambda \omega_{i,j}^{(\text{loc})}.$$

La conservation de la même forme statistique sur plusieurs ordres de grandeur – illustrée par le comportement en loi de puissance et par des méthodes telles que le box-counting – démontre que la structure auto-organisée du SCN est fractale. Cet aspect fractal simplifie l'analyse du comportement multi-échelle, renforce la robustesse du système et offre des perspectives pour adapter dynamiquement les paramètres du DSL en fonction de la distribution observée. En d'autres termes, la capacité du DSL à produire des motifs auto-similaires à différentes granularités constitue l'un de ses atouts majeurs pour la modélisation des systèmes complexes, tant naturels qu'artificiels.

6.3.2.3. Mesures Fractales Possibles (Dimension Fractale d'un Graphe, etc.)

L'analyse de la structure fractale dans des systèmes complexes repose sur l'idée d'**invariance d'échelle**, c'est-à-dire que la même forme ou le même comportement se répète à différentes échelles de mesure. Dans le contexte d'un SCN (Synergistic Connection Network), cette approche permet de quantifier l'auto-similarité de la répartition des pondérations $\omega_{i,j}$ et, par extension, de la structure des clusters qui en résultent. Pour ce faire, plusieurs mesures fractales, issues de la géométrie fractale, ont été adaptées à l'étude des graphes pondérés et des réseaux complexes. Nous présentons ici en détail les principales méthodes, leurs fondements mathématiques et leur application au DSL (Deep Synergy Learning).

A. Rappels sur le Box-Counting en Géométrie Fractale

L'une des méthodes les plus classiques pour estimer la **dimension fractale** d'un ensemble $F \subset \mathbb{R}^d$ est la méthode du box-counting. Pour un tel ensemble, on définit $N(\varepsilon)$ comme le nombre minimal de boîtes (ou hypercubes) de côté ε nécessaires pour couvrir l'ensemble F . Si, pour $\varepsilon \rightarrow 0$, on observe que

$$N(\varepsilon) \sim \varepsilon^{-\dim_f},$$

alors la valeur \dim_f est appelée la **dimension fractale** (ou dimension de Minkowski–Bouligand) de l'ensemble F . Plus précisément, on définit

$$\dim_f = \lim_{\varepsilon \rightarrow 0} \frac{\ln N(\varepsilon)}{-\ln \varepsilon},$$

ce qui exprime le fait que la couverture de l'ensemble se fait suivant une loi de puissance. Dans le cas des objets géométriques classiques (ensemble de Cantor, flocon de Koch), cette méthode aboutit à des valeurs non entières, traduisant la complexité inhérente à ces structures.

B. Adaptation du Box-Counting à un SCN ou Graphe Pondéré

Dans un SCN, les entités sont représentées par des nœuds et les interactions par des liaisons pondérées $\omega_{i,j}$. Ces éléments ne sont pas nécessairement disposés dans un espace euclidien de manière canonique ; cependant, on peut définir une **métrique adaptée** à partir des pondérations. Par exemple, on peut définir la distance entre deux nœuds i et j par :

$$d(i,j) = \min_{\gamma(i \rightarrow j)} \sum_{(u,v) \in \gamma} \frac{1}{\omega_{u,v}},$$

où $\gamma(i \rightarrow j)$ désigne un chemin reliant i à j . L'inversion de la pondération permet d'interpréter un lien fort (grand ω) comme une distance courte. À partir de cette métrique, la méthode de box-counting peut être adaptée de la manière suivante :

37. Définition d'une Boîte dans le Graphe

Pour un nœud central c et un paramètre $\ell > 0$, on définit la "boîte" $B(c, \ell)$ comme l'ensemble des nœuds j tels que

$$B(c, \ell) = \{j \mid d(c, j) \leq \ell\}.$$

38. Recouvrement Minimal du Graphe

On cherche ensuite le nombre minimal $N(\ell)$ de tels blocs $B(c, \ell)$ nécessaire pour couvrir l'ensemble des nœuds du graphe. Si la relation

$$N(\ell) \sim \ell^{-\dim_f}$$

est vérifiée pour $\ell \rightarrow 0$, alors le graphe possède une **dimension fractale** \dim_f qui caractérise son auto-similarité. La pente de la courbe obtenue en traçant $\ln N(\ell)$ en fonction de $\ln(1/\ell)$ donne une estimation de \dim_f .

C. Méthodes Alternatives pour Quantifier la Fractalité

1. Dimension de Corrélation

La dimension de corrélation est une autre mesure employée dans l'analyse des attracteurs fractals, notamment via l'algorithme de Grassberger–Procaccia. Dans le contexte d'un SCN, on définit la fonction de corrélation $C(\ell)$ comme la probabilité qu'une paire de nœuds soit à une distance inférieure à ℓ :

$$C(\ell) = \frac{2}{N(N-1)} \sum_{i < j} \chi(d(i, j) \leq \ell),$$

où χ est la fonction indicatrice. Pour ℓ petit, on peut s'attendre à ce que

$$C(\ell) \sim \ell^{\dim_{\text{corr}}},$$

donnant ainsi une **dimension de corrélation** \dim_{corr} qui est souvent proche de la dimension fractale obtenue par box-counting. Cette méthode offre l'avantage de ne pas nécessiter un recouvrement explicite du graphe et s'appuie directement sur les distances entre paires de nœuds.

2. Analyse des Loïs de Puissance

L'observation empirique des **loïs de puissance** dans la distribution de certaines variables du réseau est également un indicateur d'auto-similarité. Par exemple, si l'on note $P(s)$ la probabilité qu'un cluster ait une taille s et que

$$P(s) \sim s^{-\alpha},$$

alors le réseau présente un comportement **scale-free**. De même, la distribution des degrés $\deg(i) = \sum_j \omega_{i,j}$ peut suivre une loi de puissance, ce qui est typique des réseaux fractals. Ces observations statistiques renforcent l'idée que, quelle que soit l'échelle, la structure du réseau ne présente pas d'échelle caractéristique, mais obéit à une dynamique de type "rich get richer".

D. Implications et Conditions pour l'Émergence de l'Aspect Fractal

Pour qu'un SCN présente un aspect fractal, il faut que la dynamique d'auto-organisation (le processus DSL) n'introduise pas d'échelle artificielle dans la distribution des pondérations. Cela signifie que les paramètres de mise à jour, tels que le taux d'apprentissage η et le coefficient de décroissance τ , doivent être réglés de manière à favoriser un comportement "échelle-libre". Dans un tel régime, les règles d'agrégation (renforcement des liens forts et inhibition

des liens faibles) s'appliquent de manière uniforme et génèrent des distributions de type power law pour des indicateurs tels que :

- La **force interne** d'un cluster, $\Omega(\mathcal{C}) = \sum_{i,j \in \mathcal{C}} \omega_{i,j}$,
- Le **degré** d'un nœud, $\deg(i) = \sum_j \omega_{i,j}$,
- La **taille des clusters**, mesurée en nombre d'entités.

Si, lors de l'agrégation des clusters, on observe que ces distributions restent invariantes à un facteur multiplicatif près, c'est-à-dire que pour une échelle de regroupement donnée, la forme de la distribution reste la même, on peut conclure à une invariance d'échelle dans le SCN.

L'apparition d'un cut-off naturel dans la distribution, c'est-à-dire une borne inférieure x_{\min} et une borne supérieure x_{\max} sur lesquelles la loi de puissance est valide, est également attendue dans des systèmes réels. Cela indique que la fractalité est présente sur plusieurs ordres de grandeur, même si elle n'est pas globale.

Conclusion

Les mesures fractales, telles que la dimension fractale obtenue par la méthode du box-counting ou la dimension de corrélation, fournissent des outils quantitatifs pour évaluer l'auto-similarité dans un SCN. Si la distribution des pondérations $\omega_{i,j}$, la force interne des clusters ou la taille des clusters suit une loi de puissance de la forme

$$\text{Prob}(X > x) \propto x^{-\alpha},$$

alors le système est dit invariant d'échelle. Dans un SCN dont la dynamique est régie par la même règle d'auto-organisation à toutes les échelles, cette invariance se traduit par le fait qu'un micro-cluster reproduit la même structure qu'un macro-cluster, à un facteur d'échelle près. Les conditions mathématiques ainsi établies, basées sur l'analyse des lois de puissance et sur la répartition des éléments du réseau via des méthodes de box-counting ou de corrélation, permettent de caractériser de manière rigoureuse l'aspect fractal d'un SCN. Ce comportement fractal offre un double avantage : il simplifie la modélisation multi-échelle, puisque le même mécanisme peut être appliqué de manière récurrente, et il renforce la robustesse de l'auto-organisation, garantissant ainsi une cohérence structurelle du réseau indépendamment de la taille de ses sous-groupes.

6.3.3. Modélisation et Indicateurs

Pour passer du **concept** d'auto-similarité (6.3.1–6.3.2) à une **quantification** de la fractalité dans un **SCN** (Synergistic Connection Network), on recourt à des **indicateurs** formels. Parmi eux, l'**approche par boîtes** (aussi appelée *box-counting*) est l'une des plus répandues pour estimer la **dimension fractale**. Elle s'adapte assez bien à un réseau (ou graphe), à condition de définir un **critère** de recouvrement en "boîtes" (ou "blocs") pertinent.

6.3.2.3. Mesures Fractales Possibles (Dimension Fractale d'un Graphe, etc.)

Dans cette section, nous exposons de manière détaillée et rigoureuse le cadre mathématique permettant de quantifier l'**auto-similarité** dans un **SCN** (Synergistic Connection Network). L'objectif est de mettre en œuvre des méthodes issues de la géométrie fractale – telles que la méthode du **box-counting**, la dimension de corrélation et l'analyse des lois de puissance – afin de caractériser la structure auto-similaire d'un réseau synergétique. Cette démarche s'inscrit dans le contexte du **Deep Synergy Learning** (DSL) et vise à démontrer que, si la distribution des pondérations ou des tailles de clusters suit une loi de puissance, alors le réseau présente une invariance d'échelle, qui est la marque d'un comportement fractal.

A. Définitions Fondamentales et Cadre Conceptuel

Soit un ensemble d'entités $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$ constituant un SCN, où chaque paire d'entités (i, j) est reliée par une pondération $\omega_{i,j}$ qui reflète le degré de **synergie** entre elles. Pour appliquer une méthode de **box-counting** à ce réseau, il est indispensable de définir une **métrique** sur l'ensemble des nœuds. Une approche naturelle consiste à introduire une fonction κ qui associe à chaque lien une distance « locale » inversée, c'est-à-dire que l'on définit :

$$\kappa(\omega_{i,j}) = \frac{1}{\omega_{i,j}},$$

ce qui traduit l'intuition selon laquelle un lien fort (c'est-à-dire un $\omega_{i,j}$ élevé) correspond à une distance courte entre les entités. Par conséquent, la **distance** entre deux nœuds i et j peut être définie par la longueur du plus court chemin reliant ces deux nœuds :

$$d(i,j) = \min_{\gamma(i \rightarrow j)} \sum_{(\mu,v) \in \gamma} \frac{1}{\omega_{\mu,v}},$$

où $\gamma(i \rightarrow j)$ désigne un chemin reliant i à j dans le graphe du SCN. Cette distance $d(i,j)$ remplit le rôle de métrique dans notre approche et nous permet de transposer l'idée de couverture par des boîtes dans le contexte d'un graphe.

Pour une échelle donnée $\ell > 0$, nous définissons une **boîte** (ou une boule) centrée sur un nœud c par :

$$B(c, \ell) = \{j \in \{1, \dots, n\} \mid d(c, j) \leq \ell\}.$$

Le problème consiste alors à déterminer le **nombre minimal** de ces boîtes, noté $N(\ell)$, qui permet de recouvrir l'ensemble des nœuds du SCN. Ce nombre, en fonction de l'échelle ℓ , joue un rôle analogue au nombre de cubes nécessaires pour recouvrir un objet géométrique dans \mathbb{R}^d .

B. Procédure du Box-Counting et Estimation de la Dimension Fractale

La méthode du **box-counting** adaptée à un SCN s'articule autour de plusieurs étapes essentielles. D'une part, il faut établir une couverture du graphe par des boules de rayon ℓ . Pour une valeur d'échelle fixée, on choisit successivement des nœuds centraux, construit les boules correspondantes $B(c, \ell)$ et retire les nœuds ainsi couverts du graphe jusqu'à ce que tous les nœuds soient inclus dans au moins une boule. Le nombre minimal de boules obtenues dans cette procédure est noté $N(\ell)$.

Si, lorsque l'échelle ℓ tend vers zéro, on observe que

$$N(\ell) \sim \ell^{-\dim_f},$$

la **dimension fractale** du SCN est définie par la relation :

$$\dim_f = \lim_{\ell \rightarrow 0} \frac{\ln N(\ell)}{-\ln \ell}.$$

En pratique, on trace la courbe logarithmique $\ln N(\ell)$ en fonction de $\ln(1/\ell)$ et la pente de la droite de régression (sur un intervalle $[\ell_{\min}, \ell_{\max}]$) fournit une estimation de \dim_f . La linéarité de cette courbe dans cet intervalle est le témoignage de l'**invariance d'échelle** qui caractérise la structure fractale.

Il est à noter que la méthode du box-counting peut être complétée par d'autres approches, telles que la **dimension de corrélation**, où l'on définit la fonction

$$C(\ell) = \frac{2}{n(n-1)} \sum_{i < j} \chi(d(i,j) \leq \ell),$$

avec χ la fonction indicatrice, et l'on examine la dépendance de $C(\ell)$ en fonction de ℓ pour estimer la dimension de corrélation \dim_{corr} par la relation $C(\ell) \sim \ell^{\dim_{\text{corr}}}$. De même, l'analyse des **lois de puissance** dans la distribution des tailles de clusters ou des degrés des nœuds permet de détecter une invariance d'échelle. Par exemple, si la distribution des tailles de clusters satisfait

$$\text{Prob}(|\mathcal{C}| > s) \sim s^{-\alpha},$$

on identifie une caractéristique scale-free, qui renforce l'hypothèse d'auto-similarité dans l'agrégation des clusters.

C. Implications pour le Deep Synergy Learning (DSL)

L'application de ces méthodes fractales dans le cadre d'un SCN, et plus particulièrement du DSL, offre plusieurs avantages importants. Lorsque la même dynamique d'auto-organisation, exprimée par la règle de mise à jour

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)],$$

s'exerce à toutes les échelles, on obtient une auto-similarité qui se traduit par une invariance de la distribution des pondérations et des tailles de clusters. Cette invariance permet de simplifier la modélisation multi-échelle, car une même loi (ou un même algorithme) peut être utilisée pour décrire les interactions tant au niveau local que global. De plus, la robustesse du système est renforcée puisque l'auto-organisation, en se répétant à différentes granularités, tend à corriger les perturbations locales par une réorganisation à plus grande échelle. La dimension fractale \dim_f quantifiée par la méthode du box-counting constitue ainsi un indicateur précieux pour l'analyse du comportement global du SCN et pour le réglage des paramètres du DSL.

D. Conclusion

L'approche par boîtes (box-counting) appliquée à un SCN offre une méthode rigoureuse pour quantifier l'**auto-similarité** d'un réseau synergétique en estimant sa **dimension fractale**. En définissant une métrique adaptée $d(i,j)$ à partir des pondérations $\omega_{i,j}$ – par exemple, via l'inversion $1/\omega_{i,j}$ – et en recouvrant le graphe par des boules de rayon ℓ , il est possible de déterminer le nombre minimal $N(\ell)$ de boîtes nécessaires pour couvrir l'ensemble des nœuds. La relation

$$N(\ell) \sim \ell^{-\dim_f}$$

et la linéarité de la courbe $\ln N(\ell)$ versus $\ln(1/\ell)$ permettent d'extraire la dimension fractale \dim_f du réseau. L'émergence d'une telle invariance d'échelle, caractérisée par des lois de puissance dans la distribution de ω et des tailles de clusters, est une signature d'un comportement fractal dans le SCN. Pour le **Deep Synergy Learning**, cette propriété signifie que la même dynamique d'auto-organisation s'applique de manière récurrente à toutes les échelles, ce qui simplifie l'analyse multi-échelle, renforce la robustesse du système et offre des outils de réglage précis des paramètres d'apprentissage. En somme, le box-counting constitue un instrument essentiel pour mesurer quantitativement l'auto-similarité d'un SCN et pour démontrer que, indépendamment de l'échelle d'observation, la structure du réseau reste invariante, attestant ainsi de sa nature fractale.

6.3.3.2. Représentation d'échelles multiples : la “scale invariance” si la structure se répète

Dans le cadre de l'analyse des **réseaux synergétiques**, il apparaît qu'un même **motif** d'organisation peut se reproduire à différentes échelles, ce que l'on désigne par le terme d'**invariance d'échelle** ou **scale invariance**. Cette propriété, intrinsèque aux systèmes fractals, se manifeste dans un SCN (Synergistic Connection Network) lorsque la même répartition des liaisons, la même configuration topologique, se retrouve de manière auto-similaire que ce soit au niveau local (micro-clusters) ou global (macro-clusters). L'objectif de cette section est de présenter rigoureusement comment la représentation d'échelles multiples permet de quantifier et d'exploiter cette invariance, et d'en démontrer les implications pour la dynamique du DSL (Deep Synergy Learning).

A. Représentation Multiscale du SCN

Considérons un SCN composé d'un ensemble d'entités $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$ reliées par des pondérations $\omega_{i,j}$. La dynamique d'auto-organisation, régie par une règle de mise à jour telle que

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)],$$

s'exerce uniformément sur le réseau. Dès lors, il est naturel de considérer que, par des procédés d'**agrégation hiérarchique** ou de *coarse-graining* (voir notamment la section 6.2.2), le SCN peut être représenté à plusieurs niveaux de granularité. Ainsi, on introduit une suite d'agrégations

$$\omega^{(0)} \rightarrow \omega^{(1)} \rightarrow \omega^{(2)} \rightarrow \dots \rightarrow \omega^{(K)},$$

où $\omega^{(0)}$ représente la matrice de pondérations du réseau initial (au niveau micro) et $\omega^{(K)}$ correspond à celle obtenue après K niveaux d'agrégation, chacun étant obtenu par une opération de regroupement des entités en « super-nœuds ». À chaque niveau, la même dynamique d'auto-organisation est appliquée aux agrégats, de sorte que la **structure** (la répartition des liens et la topologie) reste, à un facteur d'échelle près, identique à celle du niveau précédent.

Pour formaliser cette idée, on suppose qu'il existe un **isomorphisme approché** ϕ et un **facteur de rescaling** $\lambda > 0$ tels que, pour tout couple d'entités i, j appartenant à un cluster au niveau ℓ , la relation

$$\omega_{\phi(i),\phi(j)}^{(\ell+1)} \approx \lambda \omega_{i,j}^{(\ell)}$$

soit vérifiée. Cette relation exprime que la *même* forme structurelle est retrouvée au niveau $\ell + 1$ (macro-niveau) à partir du niveau ℓ (micro-niveau) une fois les pondérations multipliées par un facteur d'échelle constant. En d'autres termes, la configuration topologique du SCN se reproduit de manière **auto-similaire** à travers les niveaux d'agrégation.

B. Détection et Quantification de la Scale Invariance

L'approche par boîtes (ou **box-counting**), présentée en 6.3.3.1, offre un cadre permettant de mesurer la **dimension fractale** du SCN. Dans un contexte multiscale, cette méthode s'applique non seulement au niveau initial mais également sur les versions agrégées du réseau. En recouvrant le réseau par des « boîtes » ou boules de rayon ℓ (définies via une métrique adaptée $d(i, j)$, par exemple $d(i, j) = \min_{\gamma(i \rightarrow j)} \sum_{(\mu, \nu) \in \gamma} \frac{1}{\omega_{\mu, \nu}}$), on détermine le nombre minimal $N(\ell)$ de boîtes nécessaires pour couvrir l'ensemble des entités. Si l'on trouve que

$$N(\ell) \sim \ell^{-\dim_f},$$

alors la pente de la droite obtenue en traçant $\ln N(\ell)$ en fonction de $\ln(1/\ell)$ donne la **dimension fractale** \dim_f du réseau. Le fait que cette relation reste valable à différents niveaux d'agrégation atteste de l'**invariance d'échelle** du SCN. De surcroît, une analyse statistique complémentaire basée sur la distribution en **lois de puissance** des tailles de clusters ou des degrés des nœuds renforce l'idée que le même schéma organisationnel se retrouve quelle que soit l'échelle.

La **dimension de corrélation**, obtenue par l'analyse de la fonction de corrélation

$$C(\ell) = \frac{2}{n(n-1)} \sum_{i < j} \chi(d(i, j) \leq \ell),$$

est une autre méthode qui permet d'évaluer l'auto-similarité du réseau. Si $C(\ell)$ satisfait une relation de la forme

$$C(\ell) \sim \ell^{\dim_{\text{corr}}},$$

alors \dim_{corr} fournit une estimation alternative de la dimension fractale. Ces approches, en s'appliquant de manière répétée sur les différentes couches d'agrégation du SCN, permettent de vérifier que la **structure** du réseau est effectivement **scale-invariant**.

C. Implications pour le Deep Synergy Learning (DSL)

L'existence d'une invariance d'échelle dans un SCN signifie que la même **règle d'auto-organisation** peut être appliquée de manière itérative à différents niveaux, du micro au macro, sans nécessiter d'ajustements spécifiques pour chaque palier. Si le mécanisme DSL (par exemple, la règle additive

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i, j) - \tau \omega_{i,j}(t)]$$

) est le même à toutes les échelles, alors un micro-cluster se structure de la même manière qu'un macro-cluster, à un facteur de rescaling près. Cette **homogénéité** du mécanisme d'auto-organisation assure une **robustesse** intrinsèque, car toute perturbation locale peut être compensée par la réapparition du même motif à une échelle supérieure. Cette propriété fractale simplifie l'analyse du comportement multi-échelle du système, car la connaissance de la dynamique à une échelle permet de prédire le comportement à d'autres échelles grâce à des relations de type

$$\omega_{\phi(i),\phi(j)}^{(\ell+1)} \approx \lambda \omega_{i,j}^{(\ell)}.$$

Par ailleurs, l'obtention d'une dimension fractale non entière (par exemple, $\dim_f = 1.5$ ou 2.3) offre un indicateur quantitatif du degré de complexité et d'irrégularité du réseau. Cette mesure peut être utilisée pour adapter dynamiquement les paramètres du DSL, afin de maintenir la stabilité et la cohérence des structures émergentes.

D. Conclusion

L'approche par boîtes appliquée à un SCN permet de quantifier l'**invariance d'échelle** du réseau en définissant une métrique adaptée et en recouvrant l'ensemble des nœuds par des boules de rayon ℓ . Si le nombre de boules $N(\ell)$ satisfait la relation

$$N(\ell) \sim \ell^{-\dim_f},$$

alors la **dimension fractale** \dim_f du SCN se déduit de la pente de la droite obtenue en traçant $\ln N(\ell)$ versus $\ln(1/\ell)$. Cette relation, valable sur un intervalle d'échelles $[\ell_{\min}, \ell_{\max}]$, témoigne de la **scale invariance** du SCN, c'est-à-dire que la même structure d'interconnexion se répète, à un facteur multiplicatif près, du niveau micro au niveau macro. Cette propriété est fondamentale pour le DSL, car elle signifie que la même règle d'auto-organisation peut être appliquée de manière récurrente à toutes les échelles, simplifiant ainsi l'analyse multi-échelle, renforçant la robustesse du système et permettant d'adapter de manière universelle les paramètres d'apprentissage. En somme, la méthode du box-counting et ses dérivés offrent un cadre quantitatif puissant pour démontrer que l'organisation d'un SCN est fractale, c'est-à-dire qu'elle présente une **auto-similarité** persistante quel que soit le niveau d'observation, illustrant ainsi l'universalité et l'efficacité de la dynamique DSL dans la modélisation des systèmes complexes.

6.3.3.3. Exemples de phénomènes fractals dans la nature (p. ex. réseaux vasculaires) et analogies avec le DSL

La compréhension des **phénomènes fractals** dans la nature repose sur l'observation que la structure des systèmes biologiques et géophysiques se répète à différentes échelles, de manière hiérarchique et auto-similaire. Cette propriété d'**invariance d'échelle** se manifeste notamment dans les **réseaux vasculaires**, les **ramifications bronchiques** et les **systèmes racinaires**. Ces exemples offrent des analogies riches avec le **Deep Synergy Learning** (DSL) lorsque celui-ci se déploie en mode multi-niveau, permettant d'illustrer que la même dynamique d'auto-organisation peut s'appliquer tant au niveau micro qu'au niveau macro, assurant une cohérence structurelle du réseau.

A. Réseaux Vasculaires et Bronchiques : Une Ramification Auto-similaire



Dans le domaine biologique, le système cardiovasculaire présente une organisation fractale remarquable. L'**aorte** se subdivise en artères, lesquelles se transforment en artérioles, avant de se ramifier en capillaires. À chaque palier de

cette hiérarchie, la même **loi de bifurcation** se reproduit de manière quasi-identique, ce qui se traduit mathématiquement par des relations telles que celles observées dans les modèles de **Murray** ou les travaux de **West-Brown-Enquist**. Par exemple, une loi de conservation typique dans ces systèmes se formalise par

$$r_{\text{parent}}^3 \approx r_{\text{enfant}_1}^3 + r_{\text{enfant}_2}^3,$$

ce qui implique qu'à chaque bifurcation, le diamètre des vaisseaux décroît d'un facteur constant, et que la distribution des rayons suit une loi de puissance. L'auto-similarité dans ce contexte se manifeste par la répétition d'un même motif de subdivision, de sorte que la structure globale demeure invariante d'échelle, à l'exception d'un facteur multiplicatif constant. Dans un **SCN fractal**, les pondérations $\omega_{i,j}$ peuvent être interprétées comme des "flux" ou intensités de connexion, et si la même règle de mise à jour (renforcement/inhibition) s'applique à chaque niveau, on observe que la structure d'un petit groupe de nœuds (micro-cluster) se retrouve, à un facteur d'échelle près, dans le réseau global (macro-cluster). Cette correspondance est formellement exprimée par la relation

$$\omega_{\phi(i),\phi(j)}^{(\text{glob})} \approx \lambda \omega_{i,j}^{(\text{loc})},$$

où ϕ désigne une application de correspondance entre les nœuds du micro-cluster et ceux du macro-cluster, et λ représente le facteur de rescaling. L'existence d'un tel facteur souligne l'**invariance d'échelle** dans le réseau, analogue à la manière dont le système vasculaire conserve sa forme malgré la diminution progressive des diamètres des vaisseaux.

B. Systèmes Racinaires et Réseaux de Rivières

Les **systèmes racinaires** constituent un autre exemple marquant d'auto-similarité dans la nature. La racine principale se divise en racines secondaires, lesquelles se subdivisent à leur tour en racelles. Mathématiquement, ce processus de division peut être modélisé par une relation de type

$$L_{\text{tot}} \sim \sum_{k=1}^m r_k^{-\beta},$$

où r_k représente le diamètre des branches à chaque niveau, et l'exposant β caractérise l'agencement fractal du système. Une structure similaire se retrouve dans les **réseaux de rivières**. Ces derniers sont organisés selon des règles telles que celles de **Horton-Strahler** ou de **Tokunaga**, qui décrivent comment chaque sous-affluent se structure de manière récurrente par rapport au cours d'eau principal. Le petit cours d'eau possède la même topologie que la rivière principale, mis à part un facteur d'échelle en termes de longueur et de débit. Cette récurrence topologique signifie que l'auto-organisation observée dans un SCN, par le biais de la mise à jour des pondérations, est comparable à ces processus naturels où l'agrégation et la division se font de manière régulière et prévisible.

C. Analogies Essentielles avec le DSL

L'analogie entre les phénomènes fractals naturels et le **Deep Synergy Learning** se fonde sur plusieurs aspects fondamentaux. D'une part, les **réseaux vasculaires** ou **systèmes racinaires** présentent une **absence d'échelle caractéristique** ; toutes les échelles participent de manière équivalente à la formation de la structure globale. De même, dans un SCN où la dynamique DSL ne privilégie aucune échelle – c'est-à-dire qu'il n'existe pas de seuil arbitraire imposant une taille fixe pour un cluster – la distribution des pondérations et la formation des clusters suivent une **loi de puissance**. D'autre part, l'**auto-organisation** dans ces systèmes se caractérise par une **hiérarchie récurrente**. Un petit groupe local qui se structure selon un certain motif se retrouve, lorsqu'on l'agrège, à l'échelle macro, en reproduisant le même schéma, comme si l'ensemble du réseau était le reflet d'une même dynamique, simplement dilatée par un facteur constant. Cette **self-similarity** se traduit dans le DSL par l'application uniforme de la règle d'actualisation

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)],$$

à toutes les échelles, ce qui garantit que le même motif de renforcement et d'inhibition apparaît du micro au macro. Par ailleurs, la **robustesse** inhérente à une structure fractale – où l'absence d'un point critique unique permet à l'ensemble du système de se réorganiser même en cas de perturbation locale – se transpose directement dans le DSL, rendant le modèle plus résilient face aux variations et aux imprévus.

D. Conclusion

Les exemples de phénomènes fractals dans la nature, tels que les **réseaux vasculaires**, les **ramifications bronchiques** et les **systèmes racinaires**, illustrent de manière concrète la notion d'**invariance d'échelle**. Chaque subdivision ou bifurcation dans ces systèmes se reproduit à un facteur constant, donnant lieu à des lois de puissance qui décrivent l'ensemble de la structure. En analogie avec le **Deep Synergy Learning**, si la dynamique d'auto-organisation s'applique uniformément à travers des niveaux hiérarchiques (du micro-cluster au macro-cluster), alors le SCN présente un comportement fractal caractérisé par une auto-similarité des motifs de connexion. Ce comportement, qui se traduit par des relations telles que

$$\omega_{\phi(i),\phi(j)}^{(\text{glob})} \approx \lambda \omega_{i,j}^{(\text{loc})},$$

illustre que le même processus d'agrégation et d'inhibition opère indépendamment de l'échelle, garantissant une **robustesse** et une **universalité** du modèle. L'analogie avec les systèmes naturels souligne ainsi l'intérêt de concevoir des mécanismes d'auto-organisation capables de reproduire des structures hiérarchiques et fractales, ce qui constitue l'un des atouts majeurs du DSL dans la modélisation et la compréhension des réseaux complexes.

6.3.4. Avantages et Limitations

Après avoir exploré les principes de la fractalité (6.3.1 et 6.3.2) et comment la *quantifier* (6.3.3), il convient d'évaluer ce que **signifie** concrètement, pour un **SCN** (Synergistic Connection Network), d'être (ou de tendre vers) un **système fractal**. La fractalité n'est pas une finalité **systématique** dans le DSL (Deep Synergy Learning), mais plutôt un **cas particulier** susceptible d'offrir certains avantages tout en présentant des limites.

6.3.4.1. Avantage : la fractalité suggère une “unité” ou une cohérence à toutes les échelles

Dans l'étude des réseaux complexes, la notion de **fractalité** apparaît comme une caractéristique essentielle, notamment parce qu'elle suggère l'absence d'une taille caractéristique imposée aux **clusters** ou aux **liens**. Cette propriété d'**invariance d'échelle** se manifeste lorsque, quelle que soit la granularité d'observation – du niveau **micro** jusqu'au niveau **macro** – les motifs d'organisation se répètent, de manière auto-similaire, à un facteur d'échelle près. En d'autres termes, la même structure de distribution des **pondérations** $\omega_{i,j}$ et la même logique d'auto-organisation se retrouvent, que l'on “zoome” sur un petit sous-groupe ou que l'on “dézoome” sur l'ensemble du réseau. Ce phénomène, qui constitue l'un des piliers théoriques de la modélisation fractale, présente plusieurs avantages tant sur le plan mathématique que sur le plan opérationnel dans le cadre du **Deep Synergy Learning (DSL)**.

Soit un réseau synergétique $G = (V, E)$ où chaque nœud représente une entité \mathcal{E}_i et chaque arête (i, j) est associée à une pondération $\omega_{i,j}$ qui reflète le degré de **synergie** entre les entités i et j . La dynamique d'auto-organisation dans le DSL est gouvernée par une règle de mise à jour, souvent exprimée sous la forme

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)],$$

où η est le **taux d'apprentissage** et τ est le **coefficient de décroissance**. Lorsque cette même règle est appliquée de manière uniforme à toutes les échelles du réseau, elle produit des motifs récurrents, ce qui conduit à une structure fractale. En effet, dans un tel réseau, la distribution des **clusters** ne présente pas de taille caractéristique ; au contraire, un *micro-cluster* local peut présenter exactement la même topologie qu'un *macro-cluster*, à un facteur d'échelle près. Formellement, on peut exprimer cette idée par l'existence d'un isomorphisme approché ϕ et d'un facteur $\lambda > 0$ tels que, pour tout i, j appartenant à un cluster local \mathcal{C}_{loc} , la relation suivante est satisfaite :

$$\omega_{\phi(i),\phi(j)}^{(\text{glob})} \approx \lambda \omega_{i,j}^{(\text{loc})}.$$

Cette équation illustre que, si l'on agrège les entités du niveau micro pour obtenir un niveau macro, la *forme* des liaisons se conserve, seule l'échelle change.

Du point de vue **mathématique**, cette invariance d'échelle se manifeste par la présence de **lois de puissance** dans la distribution des tailles de clusters ou des degrés des nœuds. Par exemple, si l'on note $s = |C|$ la taille d'un cluster, on peut observer que la probabilité qu'un cluster dépasse une taille s se comporte selon

$$\text{Prob}(s > x) \sim x^{-\alpha},$$

ce qui indique que le même mécanisme d'agrégation s'applique indépendamment de l'échelle considérée. De même, une analyse via la méthode du **box-counting** (voir la section 6.3.3.1) permet d'extraire une dimension fractale \dim_f du réseau en montrant que

$$N(\ell) \sim \ell^{-\dim_f},$$

où $N(\ell)$ représente le nombre minimal de boîtes de rayon ℓ nécessaires pour recouvrir l'ensemble des nœuds. La constance de \dim_f sur un intervalle d'échelles indique que le réseau est **auto-similaire**.

D'un point de vue **ingénierique**, le fait que la même logique d'auto-organisation (les mêmes paramètres η et τ dans la dynamique DSL, ainsi que les mêmes mécanismes d'inhibition ou de saturation) se répète de manière identique du niveau micro au niveau macro confère une **unité** au système. Cette **cohérence** structurelle se traduit par une simplification de l'implémentation, puisqu'un unique ensemble de règles s'applique à toute la hiérarchie. Par ailleurs, en cas de perturbation locale, le système peut se reconfigurer en s'appuyant sur les mêmes schémas fractals à d'autres niveaux, renforçant ainsi sa **robustesse** et son **adaptabilité**. La capacité à analyser un petit sous-ensemble du réseau et à extrapoler ses propriétés à l'ensemble du SCN constitue un avantage considérable pour l'analyse et la conception des systèmes d'auto-organisation.

En somme, la fractalité suggère que le réseau, quelle que soit son échelle d'observation, présente une **unité** intrinsèque ; la **même forme** de distribution des liens et la même logique d'auto-organisation se retrouvent aussi bien dans un micro-cluster que dans un macro-cluster, modulo un simple changement d'échelle par un facteur λ . Cette propriété renforce la **cohérence** du DSL et facilite l'analyse multi-échelle, tout en simplifiant la mise en œuvre et le réglage des paramètres du système. L'universalité de la dynamique DSL, qui se répète à tous les niveaux, est ainsi l'une des raisons majeures pour lesquelles les réseaux fractals sont particulièrement recherchés dans la modélisation des systèmes complexes et auto-organisés.

Conclusion.

Les **réseaux fractals** offrent un sentiment de continuité et d'unité à toutes les échelles, car la même loi d'auto-organisation – caractérisée par des mécanismes de renforcement et d'inhibition appliqués de manière homogène – se répète de manière auto-similaire. Cette invariance d'échelle facilite l'analyse mathématique et la modélisation multi-échelle, renforce la robustesse du système et simplifie la mise en œuvre d'un DSL en permettant une réutilisation universelle des mêmes règles, quelle que soit la granularité d'observation.

6.3.4.2. Limitation : tous les systèmes DSL ne sont pas fractals ; c'est un cas particulier où les synergies multi-niveau se recourent fortement

Dans l'étude des **réseaux synergétiques** et du **Deep Synergy Learning (DSL)**, il est tentant d'identifier des structures fractales lorsque la même dynamique d'auto-organisation se répète à différentes échelles. Toutefois, il apparaît que l'émergence d'un comportement fractal n'est pas universelle au sein des systèmes DSL, mais se manifeste seulement dans des conditions particulières où les synergies multi-niveau s'alignent de façon très homogène. Cette limitation doit être examinée à la lumière de plusieurs aspects théoriques et pratiques, et il est essentiel d'en préciser les conditions, afin de ne pas extrapoler de manière abusive l'idée de fractalité à l'ensemble des systèmes DSL.

Une première condition requise pour qu'un SCN puisse exhiber une structure fractale est que la **fonction d'agrégation** utilisée dans la dynamique d'auto-organisation, souvent notée Ψ dans le cadre des opérations de coarse-graining (cf. section 6.2.2), soit appliquée de manière quasi uniforme à tous les niveaux. Il faut que la règle d'actualisation des pondérations, typiquement donnée par

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)],$$

reçoive exactement le même traitement que l'on applique à des sous-ensembles du réseau, de sorte que la distribution des valeurs $\omega_{i,j}$ à chaque niveau d'agrégation soit comparable, modulo un simple facteur d'échelle. Dès lors, si les **paramètres** η et τ ne varient pas ou varient proportionnellement d'un niveau à l'autre, la dynamique risque de se maintenir, produisant ainsi une auto-similarité au sens strict. En revanche, si ces paramètres sont ajustés indépendamment à chaque palier – par exemple, en introduisant un taux d'apprentissage local η_{loc} distinct d'un taux global η_{glob} – l'uniformité de la règle d'auto-organisation est rompue, et le réseau ne peut plus présenter la récurrence des motifs caractéristiques d'un système fractal.

Un deuxième facteur réside dans la **nature des données** et la **distribution initiale** des synergies. Dans de nombreux systèmes DSL, les entités sont hétérogènes, et la répartition des pondérations $\omega_{i,j}$ peut être influencée par des contraintes externes ou par des mécanismes de saturation qui imposent une échelle caractéristique. Par exemple, lorsqu'un seuil de saturation est appliqué pour éviter que les pondérations ne croissent indéfiniment, ou lorsque des règles spécifiques de formation des clusters induisent une taille moyenne prédéfinie, la distribution des $\omega_{i,j}$ ne suit plus une loi de puissance pure. Cette rupture de la loi de puissance empêche l'apparition d'un comportement véritablement **scale-free**, et par conséquent, la fractalité du système ne s'exprime que de manière partielle ou localisée.

Un troisième aspect concerne la **diversité topologique** inhérente au réseau. Même si l'on applique une règle DSL uniforme, la topologie du SCN peut être influencée par des facteurs externes ou par des propriétés intrinsèques des interactions entre entités. Par exemple, dans un système multimodal, certains sous-groupes d'entités se formeront naturellement selon des motifs distincts en fonction de leurs caractéristiques spécifiques, tandis que d'autres adopteront une organisation plus homogène. Cette hétérogénéité dans l'**organisation** empêche la réapparition d'un motif unique à toutes les échelles, et seule une partie du réseau pourra être qualifiée de fractale, tandis que d'autres portions présenteront des distributions plus ordinaires.

En résumé, la fractalité dans un SCN n'émerge que dans le cas particulier où (i) la même **fonction d'agrégation** Ψ est appliquée de manière uniforme à tous les niveaux, (ii) les paramètres d'actualisation η et τ restent constants ou sont ajustés de manière proportionnelle, et (iii) la distribution initiale des synergies et des données est suffisamment homogène pour ne pas introduire de coupures d'échelle. Lorsque ces conditions ne sont pas réunies – par exemple, en présence de **paramètres divergents** entre les niveaux, de contraintes de saturation strictes ou de données hétérogènes – le SCN ne présente pas de comportement fractal global, mais seulement une **fractalité partielle** ou même l'absence d'auto-similarité.

Cette limitation est essentielle à comprendre, car elle indique que l'apparition d'une **structure fractale** dans un système DSL est un cas particulier, illustrant l'unité et la robustesse de la dynamique d'auto-organisation, mais qui n'est pas généralisable à tous les réseaux synergétiques. D'un point de vue théorique, cela signifie que les outils mathématiques permettant de quantifier la fractalité, tels que le box-counting, la dimension de corrélation ou l'analyse des lois de puissance, ne s'appliquent que lorsque le réseau ne présente pas de contraintes d'échelle imposées par la nature des données ou par les mécanismes d'inhibition et de saturation. D'un point de vue opérationnel, il convient de reconnaître que, dans la pratique, de nombreux systèmes DSL ne sont que partiellement fractals et que leur analyse doit intégrer cette hétérogénéité afin d'éviter des interprétations trop simplistes de la dynamique d'auto-organisation.

Conclusion.

La fractalité, en tant que manifestation d'une invariance d'échelle et d'une auto-similarité des motifs d'interconnexion, apparaît dans un SCN uniquement lorsque les mécanismes d'auto-organisation se recourent fortement et de manière homogène à tous les niveaux. En revanche, si les paramètres de mise à jour varient d'un niveau à l'autre, ou si des contraintes externes imposent une échelle caractéristique aux interactions, l'auto-similarité fractale s'en trouve rompue. Ainsi, bien que la présence d'une structure fractale offre de nombreux avantages, elle constitue un cas particulier dans l'univers DSL, et ne peut être considérée comme généralisée à l'ensemble des systèmes multi-niveaux, qui présenteront souvent une **fractalité partielle** ou l'absence complète d'auto-similarité à cause de la diversité des conditions initiales et des mécanismes locaux d'agrégation et d'inhibition.

6.3.4.3. Applicabilité : ex. grands réseaux hétérogènes, IA inspirée du cerveau

Dans le contexte des systèmes complexes, l'idée d'**invariance d'échelle** se retrouve naturellement dans de nombreux phénomènes naturels et inspire la modélisation de systèmes artificiels tels que le **Deep Synergy Learning (DSL)**. Cette section examine de manière approfondie l'applicabilité des concepts fractals à de grands réseaux hétérogènes et à des approches d'**IA inspirée du cerveau**, en mettant en évidence les avantages mais également les limites de l'hypothèse d'auto-similarité dans ces domaines.

A. Grands Réseaux Hétérogènes

Dans des environnements comportant des millions d'entités et une multiplicité de types de relations – par exemple dans les **réseaux sociaux** ou les systèmes multi-domaines – aucune taille de cluster n'est imposée a priori. En l'absence de contraintes externes fortes, la dynamique d'auto-organisation, pilotée par une règle DSL uniforme, permet l'émergence de clusters de toutes tailles. D'un point de vue mathématique, cette liberté se traduit souvent par des distributions de taille de clusters qui suivent une **loi de puissance** :

$$\text{Prob}(|\mathcal{C}| > s) \sim s^{-\alpha},$$

ce qui signifie qu'il n'existe pas de taille caractéristique dominante dans le réseau. L'**absence de scale** se reflète ainsi dans une distribution continue et heavy-tail des agrégations, indiquant que le même mécanisme d'agrégation – notamment le renforcement des liens forts et l'inhibition des liens faibles – opère de manière homogène sur toutes les échelles. Par conséquent, dans ces grands réseaux hétérogènes, le DSL, lorsqu'il est laissé relativement libre de ses paramètres, peut générer ou révéler une **structure fractale**. Cette propriété offre l'avantage majeur de la **robustesse** et de la **flexibilité** de l'organisation : l'arrivée de nouveaux nœuds, ou la disparition de certains, ne perturbe pas l'équilibre global puisque la loi de puissance continue de s'appliquer, garantissant ainsi une auto-organisation sans point critique fixe.

B. IA Inspirée du Cerveau

La biologie neuronale offre un exemple emblématique d'**organisation multi-échelle**. Le cerveau humain, par exemple, présente une structure hiérarchique allant des micro-colonnes corticales aux aires fonctionnelles et jusqu'aux lobes. Des études empiriques suggèrent que les connexions neuronales, tant au niveau des synapses que dans la configuration des réseaux neuronaux, peuvent exhiber des propriétés d'auto-similarité et d'invariance d'échelle. Mathématiquement, de telles structures se caractérisent par des mesures comme la **dimension fractale** ou par des lois de puissance dans la distribution des degrés de connexion, lesquelles indiquent que les motifs de connectivité se répètent à toutes les échelles.

Dans une approche DSL inspirée du cerveau, la règle d'auto-organisation – par exemple

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)]$$

– s'applique de manière uniforme du niveau micro (groupes de neurones ou micro-colonnes) jusqu'au niveau macro (aires corticales interconnectées). La réutilisation des mêmes mécanismes d'apprentissage et de plasticité synaptique, associés à des schémas de connectivité auto-similaire, confère au réseau une **robustesse** comparable à celle observée dans le cortex. Un tel système permet, par analogie avec les réseaux vasculaires ou bronchiques, de maintenir une cohérence structurelle malgré l'hétérogénéité des modules fonctionnels, facilitant ainsi la transmission d'informations et l'adaptation aux perturbations.

C. Synthèse et Implications

La fractalité, lorsqu'elle se manifeste dans un SCN, offre un cadre conceptuel puissant pour l'analyse de grands réseaux hétérogènes ainsi que pour la conception d'architectures d'**IA inspirée du cerveau**. Dans ces domaines, l'absence d'une taille caractéristique imposée aux clusters – traduite mathématiquement par des lois de puissance telles que

$$\text{Prob}(|\mathcal{C}| > s) \sim s^{-\alpha}$$

– et la récurrence de la même dynamique d'auto-organisation à toutes les échelles, permettent d'envisager un modèle robuste et évolutif. L'universalité de la règle DSL assure que, même en présence d'une hétérogénéité extrême, les motifs d'interconnexion se reproduisent de façon auto-similaire, garantissant une répartition efficace des ressources et

une coordination harmonieuse. Toutefois, il convient de noter que la fractalité est souvent un cas particulier qui se révèle pleinement lorsque les conditions d'homogénéité des paramètres et d'absence de contraintes externes prédominantes sont réunies. Dans de nombreux systèmes réels, des facteurs tels que des seuils de saturation ou des différences de paramètres entre les niveaux peuvent limiter l'étendue de cette invariance d'échelle. Néanmoins, l'inspiration tirée des structures fractales observées dans la nature – des réseaux vasculaires aux systèmes racinaires – offre des perspectives prometteuses pour concevoir des SCN capables de s'auto-organiser de manière à la fois flexible et résiliente, en reproduisant des motifs d'organisation qui transcendent les échelles d'observation.

D. Conclusion

L'applicabilité des concepts fractals dans les grands réseaux hétérogènes et dans les systèmes d'IA inspirés du cerveau repose sur l'observation que, lorsque les mécanismes d'auto-organisation sont uniformes et qu'aucune échelle caractéristique n'est imposée, le SCN peut exhiber des lois de puissance et une invariance d'échelle. Cette propriété, qui se traduit par la répétition auto-similaire de la structure du réseau à tous les niveaux – du micro-cluster au macro-cluster – confère au système une robustesse et une adaptabilité remarquables. Par analogie avec des systèmes naturels tels que les réseaux vasculaires, les systèmes racinaires ou les bassins-versants, un DSL fractal permet de concevoir des architectures qui s'auto-organisent de manière universelle, offrant ainsi des perspectives d'ingénierie pour des systèmes complexes capables de gérer l'hétérogénéité et de s'adapter aux variations multi-échelles.

6.4. Interactions Multi-Niveau et Coordination

Le **DSL** (Deep Synergy Learning) opère de manière particulièrement riche lorsqu'il est déployé sur un **SCN** (Synergistic Connection Network) organisé en **plusieurs niveaux** (micro, méso, macro). Dans ce cadre, les **flux** ascendants (bottom-up) et descendants (top-down) assurent une **coordination** essentielle entre les niveaux, les entités (ou petits clusters) **remontent** leur organisation vers les paliers supérieurs, tandis que les paliers supérieurs **rétroagissent** pour influencer ou “piloter” la configuration des liens au palier inférieur. La section 6.4.1 récapitule ces deux flux de base et souligne l'importance de la cohérence entre niveaux.

6.4.1. Bottom-Up vs. Top-Down

Dans un **SCN** multi-niveau, on distingue au moins deux grands axes de **communication** :

39. **Flux ascendants (bottom-up)** : depuis les entités brutes (niveau micro), on agrège progressivement des clusters vers un niveau macro (ou intermédiaire).
40. **Flux descendants (top-down)** : le macro-niveau, disposant d'une vue plus globale, impose un **feedback** (contrainte ou renforcement) sur les pondérations ω au niveau inférieur.

6.4.1.1. Rappel des flux ascendants (entités \rightarrow cluster local \rightarrow cluster macro)

Les **flux ascendants** dans un **SCN** (Synergistic Connection Network) multi-échelle désignent le mécanisme par lequel on **construit** progressivement, à partir d'entités élémentaires au niveau micro, des **clusters** toujours plus vastes au fil des niveaux supérieurs, jusqu'à atteindre un niveau macro. Cette démarche correspond à un processus de *coarse-graining* itératif, où l'on consolide des groupes de bas niveau en “super-nœuds” plus globaux, optimisant ainsi la représentation et la gestion de la complexité.

On considère un ensemble d'entités $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$, il s'agit du **niveau 0** ou micro-niveau. Les **pondérations** $\omega_{i,j}^{(0)}$ décrivent les affinités (ou synergies) entre ces entités. Dans un **DSL** (Deep Synergy Learning), ces pondérations évoluent selon une règle itérative, par exemple de type additive :

$$\omega_{i,j}^{(0)}(t+1) = \omega_{i,j}^{(0)}(t) + \eta_0 [S_0(i,j) - \tau_0 \omega_{i,j}^{(0)}(t)],$$

avec η_0, τ_0 pour le niveau micro. À un instant donné, certains groupes d'entités peuvent présenter une cohésion interne suffisamment élevée (somme des $\omega_{i,j}$ importante).

Dès lors que l'on détecte un **cluster** $\mathcal{C}_\alpha^{(0)}$ (quelques entités fortement reliées), on mesure par exemple :

$$\Omega(\mathcal{C}_\alpha^{(0)}) = \sum_{i,j \in \mathcal{C}_\alpha^{(0)}} \omega_{i,j}^{(0)}.$$

Un **seuil** θ_0 (cohésion minimale) permet de décider si ce regroupement est *actif*. Chaque cluster local $\mathcal{C}_\alpha^{(0)}$ acquiert une identité propre, possiblement appelée “super-nœud de niveau 1”, notée $\mathcal{N}_\alpha^{(1)}$.

Une fois qu'on a constitué plusieurs clusters $\{\mathcal{C}_1^{(0)}, \dots, \mathcal{C}_r^{(0)}\}$ au niveau 0, chacun se transforme en **super-nœud** $\{\mathcal{N}_1^{(1)}, \dots, \mathcal{N}_r^{(1)}\}$. Les pondérations entre ces super-nœuds s'obtiennent via une **fonction** d'agrégation Ψ appliquée aux $\omega_{i,j}^{(0)}$ des entités qu'ils contiennent :

$$\omega_{\alpha,\beta}^{(1)} = \Psi\left(\left\{\omega_{i,j}^{(0)} \mid i \in \mathcal{C}_\alpha^{(0)}, j \in \mathcal{C}_\beta^{(0)}\right\}\right).$$

Une fois ce niveau 1 établi, on reproduit une **même** dynamique DSL (ou adaptée) pour $\omega_{\alpha,\beta}^{(1)}$. Ainsi, si plusieurs super-nœuds de niveau 1 s'attirent fortement, ils peuvent se fondre en un **cluster** $\mathcal{C}_\gamma^{(1)}$ de taille supérieure, que l'on réifie au niveau 2, et ainsi de suite.

Ce **flux ascendant** se répète itérativement. Au niveau k , on identifie des *clusters* $\{\mathcal{C}_\alpha^{(k)}\}$. Chaque $\mathcal{C}_\alpha^{(k)}$ devient un super-nœud $\mathcal{N}_\alpha^{(k+1)}$. Les pondérations $\omega_{\alpha,\beta}^{(k+1)}$ entre super-nœuds s'agrègent via Ψ . Ainsi, on converge vers des **macro-nœuds** de plus en plus globaux, caractérisant le niveau K (ultime palier, voire unique macro-nœud).

On peut schématiser la montée d'échelle ainsi :

$$\omega^{(k+1)} = \Gamma_k(\omega^{(k)}),$$

où Γ_k agrège les **clusters** de $\omega^{(k)}$. On définit :

41. Des **clusters** $\mathcal{C}_\alpha^{(k)} \subseteq \{\mathcal{N}_1^{(k)}, \dots\}$.

42. Les pondérations $\omega_{\alpha,\beta}^{(k+1)}$ via

$$\omega_{\alpha,\beta}^{(k+1)} = \Psi\left(\left\{\omega_{\alpha',\beta'}^{(k)} \mid \alpha' \in \mathcal{C}_\alpha^{(k)}, \beta' \in \mathcal{C}_\beta^{(k)}\right\}\right).$$

Ici, $\mathcal{C}_\alpha^{(k)}$ désigne un regroupement au **niveau** k . Après agrégation, on obtient un ensemble de “super-nœuds” $\{\mathcal{N}_\alpha^{(k+1)}\}$. Si le SCN se **stabilise**, on pourra aboutir à un nombre réduit de super-nœuds (voire un unique macro-nœud).

Ce **flux ascendant** s'accompagne d'un **gain** en :

1) Réduction de la taille

Si au niveau 0 il existe $O(n^2)$ liens, le niveau 1 n'en comporte plus que $O(m^2)$ (si $m \ll n$), libérant une partie de la charge de calcul et facilitant un traitement plus rapide au palier supérieur.

2) Hiérarchie fonctionnelle

Chaque **cluster local** se spécialise (regroupe des entités proches), puis devient un super-nœud dans l'étape supérieure, reflétant un **rôle** plus large. La progression micro→macro donne une **vision** d'ensemble en successive agrégation.

3) Couplage avec le flux descendant

Les macro-nœuds, une fois construits, peuvent influencer sur les règles locales (chap. 6.4.1.2). Ce couplage (bottom-up + top-down) renforce l'auto-organisation hiérarchique.

Conclusion

Le **flux ascendant** (entités → cluster local → cluster macro) constitue la pierre angulaire d'un **SCN** multi-niveau. Il **agrège** les entités élémentaires ou les super-nœuds déjà formés en **structures** de plus en plus étendues, tout en assurant la **cohérence** interne à chaque échelle. D'un point de vue **mathématique**, cela se traduit par un *coarse-graining* itératif : on isole des clusters, on en fait des “super-nœuds”, puis on recalcule les pondérations agrégées $\omega^{(k+1)}$. D'un point de vue **opérationnel**, cela **réduit** considérablement la complexité et prépare le terrain à un **contrôle** top-down (6.4.1.2) qui viendra affiner ou réorienter la dynamique au niveau micro.

6.4.1.2. Étude Mathématique Approfondie : Flux Descendants (Cluster Macro → Entités) et Contraintes sur les Pondérations

La construction hiérarchique de *clusters* en flux ascendant (cf. 6.4.1.1) ne suffit pas à elle seule pour assurer la cohérence globale d'un **SCN** (Synergistic Connection Network) à plusieurs niveaux. Il est souvent nécessaire que les

niveaux supérieurs — où sont agrégés de larges super-nœuds ou clusters macro — puissent **redescendre** des signaux ou contraintes vers les liaisons $\omega_{i,j}$ du niveau inférieur, afin de réorienter ou de stabiliser la dynamique locale. Cette section expose une formulation analytique de ce **flux descendant**, montre comment l'inclure dans l'équation de mise à jour du **DSL** et discute son rôle dans la cohérence globale.

A. Cadre Mathématique et Définition du Flux Descendant

On considère un **SCN** multi-niveau indexé par $k = 0, 1, \dots, K$. Le **niveau 0**, ou micro-niveau, rassemble les **entités élémentaires** $\{\mathcal{E}_i\}$. À chaque palier k , on définit un ensemble de *super-nœuds* $\{\mathcal{N}_\alpha^{(k)}\}$. On note $\omega_{\alpha,\beta}^{(k)}$ les liaisons entre ces super-nœuds au niveau k .

Le **flux descendant** part du niveau k (macro ou intermédiaire) pour imposer un **feedback** sur le niveau $k - 1$. Si $\mathcal{N}_\alpha^{(k)}$ se décompose en un ensemble de super-nœuds du niveau $k - 1$, noté $\mathcal{C}_\alpha^{(k-1)} \subseteq \{\mathcal{N}_\gamma^{(k-1)}\}$, alors le niveau k peut envoyer un **terme** correctif dans la mise à jour des pondérations $\omega_{i,j}^{(k-1)}$.

Dans un DSL purement local, on a généralement

$$\omega_{i,j}^{(k-1)}(t+1) = \omega_{i,j}^{(k-1)}(t) + \eta_{k-1} [S_{k-1}(i,j) - \tau_{k-1} \omega_{i,j}^{(k-1)}(t)],$$

où η_{k-1}, τ_{k-1} sont des paramètres (taux d'apprentissage, facteur d'oubli) et $S_{k-1}(i,j)$ décrit la synergie locale entre les super-nœuds (ou entités) i, j au niveau $k - 1$.

Pour tenir compte du **flux descendant**, on **rajoute** un terme $\gamma_{td} h_{i,j}^{(k)}(t)$ dans cette équation :

$$\omega_{i,j}^{(k-1)}(t+1) = \omega_{i,j}^{(k-1)}(t) + \eta_{k-1} [S_{k-1}(i,j) - \tau_{k-1} \omega_{i,j}^{(k-1)}(t)] + \gamma_{td} h_{i,j}^{(k)}(t).$$

Le **signal** descendant $h_{i,j}^{(k)}(t)$ est défini par le niveau k . Il reflète par exemple la volonté de **renforcer** ou **d'affaiblir** certains liens $\omega_{i,j}$ au niveau $k - 1$ pour rendre cohérente une macro-structure pressentie au palier k . Le coefficient $\gamma_{td} > 0$ règle l'intensité globale de cette rétroaction.

Exemples de Signaux Descendants

- **Renforcement** : si le niveau k décide de fusionner deux super-nœuds $\mathcal{N}_\alpha^{(k)}, \mathcal{N}_\beta^{(k)}$, il peut fixer $h_{i,j}^{(k)}(t) = \delta^+$ (un scalaire positif) pour tous les liens (i,j) situés “sous” ces deux macro-nœuds. Ainsi, la mise à jour $\omega_{i,j}^{(k-1)}$ devient positivement biaisée et encourage leur croissance.
- **Séparation** : si le macro-niveau veut scinder un bloc trop hétérogène, il peut imposer un $h_{i,j}^{(k)}(t) = \delta^- < 0$ sur les liens (i,j) internes, incitant la dynamique locale à **affaiblir** $\omega_{i,j}$.

B. Formulation Analytique du Feedback : Un Modèle

Soit un niveau k avec super-nœuds $\mathcal{N}_\alpha^{(k)}$. Chacun $\mathcal{N}_\alpha^{(k)}$ recouvre un ensemble $\mathcal{C}_\alpha^{(k-1)} \subseteq \{\mathcal{N}_\gamma^{(k-1)}\}$. De la même manière, un super-nœud $\mathcal{N}_\gamma^{(k-1)}$ recouvre lui-même des entités d'un niveau antérieur, jusqu'au micro-niveau si on poursuit le dépliage. Alors

$$h_{i,j}^{(k)}(t) = \theta_{\alpha,\beta}^{(k)}(t) \quad \text{dès que } i \in \mathcal{N}_\alpha^{(k)}, j \in \mathcal{N}_\beta^{(k)}.$$

En d'autres termes, le signal descendant agit sur *toutes* les paires (i,j) dont les entités relèvent des mêmes macro-nœuds α et β au niveau k .

On obtient

$$\Delta \omega_{i,j}^{(k-1)}(t) = \eta_{k-1} [S_{k-1}(i,j) - \tau_{k-1} \omega_{i,j}^{(k-1)}(t)] + \gamma_{td} \theta_{\alpha,\beta}^{(k)}(t).$$

Même si la synergie locale $S_{k-1}(i, j)$ est faible, un *terme macro* positif $\theta_{\alpha, \beta}^{(k)}$ peut maintenir ou renforcer $\omega_{i, j}$. Inversement, un signal négatif peut annihiler $\omega_{i, j}$. Le niveau macro **façonne** ainsi la structure locale pour parvenir à un objectif d'ensemble.

C. Existence de Contraintes et Cohérence Globale

Dans de nombreux scénarios, imposer par le niveau macro un *minimum* ou un *maximum* à la somme des $\omega_{i, j}$ sur un bloc est réécritable sous forme d'un *multiplieur de Lagrange*. Pour un cluster macro $\mathcal{M}_\alpha^{(k)}$, on peut vouloir

$$\sum_{i \in \mathcal{M}_\alpha^{(k-1)}, j \in \mathcal{M}_\beta^{(k-1)}} \omega_{i, j}^{(k-1)} \geq T_{\alpha, \beta}.$$

Si on transcrit ceci en une maximisation (ou minimisation) du potentiel DSL soumis à cette contrainte, la **solution optimale** introduit un $\lambda_{\alpha, \beta} > 0$, qui s'avère *équivalent* à un signal descendant dans $\Delta \omega_{i, j}^{(k-1)}$. En somme, la rétroaction top-down se formalise comme la réponse d'un problème contraint cherchant à préserver (ou atteindre) un lien global entre \mathcal{M}_α et \mathcal{M}_β .

Pour intégrer cette contrainte dans un problème de minimisation (ou de maximisation) d'un **potentiel DSL** $V(\omega)$, on forme la fonction Lagrangienne

$$\mathcal{L}(\omega, \lambda_{\alpha, \beta}) = V(\omega) - \lambda_{\alpha, \beta} \left(\sum_{i \in \mathcal{M}_\alpha^{(k-1)}, j \in \mathcal{M}_\beta^{(k-1)}} \omega_{i, j}^{(k-1)} - T_{\alpha, \beta} \right),$$

où $\lambda_{\alpha, \beta}$ est le multiplicateur de Lagrange associé à cette contrainte, avec $\lambda_{\alpha, \beta} > 0$ pour une contrainte d'inégalité. L'optimisation consiste à trouver ω et $\lambda_{\alpha, \beta}$ tels que les dérivées partielles de \mathcal{L} par rapport à ces variables soient nulles, c'est-à-dire

$$\frac{\partial \mathcal{L}}{\partial \omega_{i, j}^{(k-1)}} = 0 \quad \text{pour tout } i, j \quad \text{et} \quad \frac{\partial \mathcal{L}}{\partial \lambda_{\alpha, \beta}} = 0.$$

La dérivée par rapport à $\lambda_{\alpha, \beta}$ impose directement la contrainte

$$\sum_{i \in \mathcal{M}_\alpha^{(k-1)}, j \in \mathcal{M}_\beta^{(k-1)}} \omega_{i, j}^{(k-1)} = T_{\alpha, \beta},$$

dans le cas limite où la contrainte est active. La dérivée par rapport à $\omega_{i, j}^{(k-1)}$ fournit une condition d'optimalité qui lie la variation du potentiel $V(\omega)$ aux pondérations elles-mêmes et à $\lambda_{\alpha, \beta}$.

Calculons cette dérivée. La fonction \mathcal{L} se décompose en deux parties : le potentiel $V(\omega)$ et le terme de contrainte multiplié par $\lambda_{\alpha, \beta}$. Ainsi, pour un lien donné, la dérivée partielle s'écrit :

$$\frac{\partial \mathcal{L}}{\partial \omega_{i, j}^{(k-1)}} = \frac{\partial V(\omega)}{\partial \omega_{i, j}^{(k-1)}} - \lambda_{\alpha, \beta} \frac{\partial}{\partial \omega_{i, j}^{(k-1)}} \left(\sum_{p \in \mathcal{M}_\alpha^{(k-1)}, q \in \mathcal{M}_\beta^{(k-1)}} \omega_{p, q}^{(k-1)} - T_{\alpha, \beta} \right).$$

Notons que la somme

$$\sum_{p \in \mathcal{M}_\alpha^{(k-1)}, q \in \mathcal{M}_\beta^{(k-1)}} \omega_{p, q}^{(k-1)}$$

est linéaire par rapport à chaque variable $\omega_{i,j}^{(k-1)}$. Par conséquent, la dérivée partielle de cette somme par rapport à $\omega_{i,j}^{(k-1)}$ est simplement 1 (lorsque $i \in \mathcal{M}_\alpha^{(k-1)}$ et $j \in \mathcal{M}_\beta^{(k-1)}$); de plus, la dérivée de la constante $T_{\alpha,\beta}$ est nulle. On obtient donc :

$$\frac{\partial \mathcal{L}}{\partial \omega_{i,j}^{(k-1)}} = \frac{\partial V(\omega)}{\partial \omega_{i,j}^{(k-1)}} - \lambda_{\alpha,\beta}.$$

Pour que cette dérivée soit nulle, il faut que

$$\frac{\partial V(\omega)}{\partial \omega_{i,j}^{(k-1)}} = \lambda_{\alpha,\beta}.$$

ce qui implique que l'augmentation de la pondération $\omega_{i,j}^{(k-1)}$ doit être compensée par un signal descendant proportionnel à $\lambda_{\alpha,\beta}$. En d'autres termes, le multiplicateur $\lambda_{\alpha,\beta}$ agit comme un **signal rétroactif top-down** qui ajuste les mises à jour locales $\Delta \omega_{i,j}^{(k-1)}$ afin de satisfaire la contrainte globale imposée sur le cluster.

Ce formalisme montre que la rétroaction top-down dans le DSL peut être interprétée comme la solution optimale d'un problème d'optimisation sous contrainte. Le **multiplicateur de Lagrange** $\lambda_{\alpha,\beta}$ introduit une pénalité ou une récompense qui guide la mise à jour des liens pour atteindre ou préserver un niveau de cohésion global, exprimé par le seuil $T_{\alpha,\beta}$. Autrement dit, si les interactions entre les clusters doivent dépasser un certain seuil pour garantir la formation d'un super-cluster cohérent, le multiplicateur $\lambda_{\alpha,\beta}$ se positionne de manière à influencer les mises à jour locales, assurant ainsi la **rétroaction** nécessaire pour maintenir la structure hiérarchique du réseau.

Une fois ce **terme** $\theta_{\alpha,\beta}^{(k)}$ inséré, on peut étudier la stabilité de la dynamique couplée (macro + micro). On obtiendra en général un **point fixe hiérarchique** si le flux descendant n'est ni trop fort ni en contradiction permanente avec la synergie locale. L'analyse linéaire (ou non-linéaire) autour d'un état stationnaire montrerait comment ce *terme descendant* modifie les conditions d'équilibre.

D. Conséquences Dynamiques : Stabilisation ou Oscillation

1) Stabilisation Accélérée

Lorsque le niveau macro repère que deux blocs $\mathcal{M}_\alpha^{(k)}, \mathcal{M}_\beta^{(k)}$ devraient logiquement se rapprocher (ou se fusionner) selon un macro-critère, il envoie un **feedback positif** $\theta_{\alpha,\beta}^{(k)}(t) > 0$. Cela *force* la consolidation au niveau $k - 1$ (voir ex. 5.1 dans 6.4.1.2). La **convergence** peut alors se faire plus vite, le macro-niveau évitant des tâtonnements au palier inférieur.

2) Oscillations ou Conflits

Une rétroaction trop massive ou contradictoire engendre possiblement des **oscillations**. Le **niveau micro** cherche à suivre sa *synergie intrinsèque*, pendant que le macro-niveau force un *schéma* incompatible. On peut ainsi observer un *cycle* si le feedback inverse le sens local à un moment inopportun, tant que la synergie micro n'a pas encore atteint un état stable. Ce se traduit par une valeur propre (ou un module > 1) dans le *jacobien* du système couplé, signe d'un régime oscillatoire.

E. Exemple Pratique de Fusion Macro

Considérons deux **macro-clusters** $\mathcal{M}_\alpha^{(k)}, \mathcal{M}_\beta^{(k)}$ au niveau k . On souhaite les "unir" pour constituer un plus grand bloc, mais au palier $k - 1$, leurs entités (i, j) ne sont pas encore suffisamment reliées. Le macro-niveau définit alors :

$$\theta_{\alpha,\beta}^{(k)}(t) = \delta^+ > 0,$$

et $\theta_{\alpha',\beta'}^{(k)} = 0$ pour tout autre couple (α', β') . Automatiquement, la formule

$$\Delta \omega_{i,j}^{(k-1)}(t) = \eta_{k-1} [S_{k-1}(i,j) - \tau_{k-1} \omega_{i,j}(t)] + \gamma_{td} \delta^+$$

se retrouve > 0 pour (i,j) appartenant à $\mathcal{M}_\alpha^{(k-1)} \times \mathcal{M}_\beta^{(k-1)}$. En itérant, ces liens $\omega_{i,j}$ se renforcent jusqu'à atteindre un point stable élevé, *verrouillant* (lock-in) la fusion macro souhaitée.

Pour analyser l'état d'équilibre, supposons que la dynamique converge vers une valeur stable $\omega_{i,j}^*$. À l'équilibre, nous avons

$$\omega_{i,j}^* = \omega_{i,j}^* + \eta_{k-1} [S_{k-1}(i,j) - \tau_{k-1} \omega_{i,j}^*] + \gamma_{td} \delta^+.$$

En simplifiant, nous obtenons

$$\eta_{k-1} [S_{k-1}(i,j) - \tau_{k-1} \omega_{i,j}^*] + \gamma_{td} \delta^+ = 0.$$

Isolons $\omega_{i,j}^*$:

$$S_{k-1}(i,j) - \tau_{k-1} \omega_{i,j}^* = -\frac{\gamma_{td} \delta^+}{\eta_{k-1}},$$

ce qui conduit à

$$\omega_{i,j}^* = \frac{S_{k-1}(i,j)}{\tau_{k-1}} + \frac{\gamma_{td} \delta^+}{\eta_{k-1} \tau_{k-1}}.$$

Cette expression montre que l'équilibre atteint par la pondération $\omega_{i,j}^{(k-1)}$ est supérieur à celui que l'on aurait obtenu sans la rétroaction macro (c'est-à-dire sans le terme $\gamma_{td} \delta^+$). Le terme supplémentaire $\frac{\gamma_{td} \delta^+}{\eta_{k-1} \tau_{k-1}}$ est positif, ce qui force la pondération à converger vers une valeur élevée. En conséquence, lorsque l'on itère la mise à jour, les liens entre les entités des sous-clusters qui constituent les macro-clusters $\mathcal{M}_\alpha^{(k)}$ et $\mathcal{M}_\beta^{(k)}$ se renforcent progressivement jusqu'à ce qu'ils atteignent ce niveau élevé, assurant ainsi la fusion verrouillée des macro-clusters. Ce phénomène de **lock-in** garantit que, dès lors que le signal macro est positif, la rétroaction descendante ajuste la dynamique locale de manière à fusionner de manière cohérente les clusters concernés.

Ainsi, la **rétroaction top-down** s'avère indispensable pour qu'un SCN multi-niveau *ne se cantonne pas* à un simple auto-apprentissage local, mais bénéficie d'une **vision** plus large, garantissant une **cohérence** entre les micro-liens et les *objectifs* ou configurations macro. Cette connexion "macro \rightarrow micro" rend possible une véritable **hiérarchie** où *chaque* palier est actif, et non seulement un agrégateur passif (flux ascendant).

6.4.1.3. Rôle crucial de la cohérence pour éviter le conflit entre niveaux

Les **flux ascendants** (bottom-up) et **descendants** (top-down) (cf. 6.4.1.1 et 6.4.1.2) assurent la double direction de la hiérarchie dans un **SCN** (Synergistic Connection Network) à plusieurs échelles. Cependant, l'existence simultanée de ces deux flux n'est pas exempte de difficultés. Un **conflit** peut survenir si les décisions ou la logique d'auto-organisation d'un **niveau** (micro ou macro) viennent s'opposer de manière répétée à celles d'un autre. Pour maintenir la **stabilité** et permettre une véritable coordination multi-niveau, on a besoin d'une **cohérence**, c'est elle qui garantit que les modifications imposées en haut (macro) et la dynamique locale en bas (micro) ne se **détruisent** pas mutuellement.

A. Notion de "Conflit" Entre Niveaux

Dans la formulation du **DSL** (Deep Synergy Learning) au niveau micro (ou local), des entités $\{\mathcal{E}_i\}$ se regroupent en clusters via la règle $\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)]$, appuyée par des seuils ou conditions de cohésion. Le flux ascendant envoie au niveau supérieur l'information "tel sous-ensemble forme un cluster local stable".

Le **niveau macro** peut, inversement, vouloir briser ou fusionner ces clusters pour un objectif global. S'il identifie qu'un ensemble local \mathcal{C} est "mal aligné" avec le schéma plus vaste, il envoie un signal descendant pour casser la cohésion $\sum_{i,j \in \mathcal{C}} \omega_{i,j}$. Si cette décision contrarie trop fortement la synergie locale $S(i,j)$, un **conflit** naît. On a alors, par exemple, un **macro-niveau** dictant $\theta_{\text{desc}} < 0$ sur tous les liens de \mathcal{C} , tandis que localement, $\omega_{i,j}$ continue d'augmenter sous l'effet d'une forte affinité.

Sans un **alignement** suffisant, le micro-niveau peut "verrouiller" un cluster alors que le macro-niveau tente de le disloquer, causant des **oscillations** :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta [S(i,j) - \tau \omega_{i,j}(t)] + \gamma_{\text{topdown}} h_{i,j}^{(\text{macro})}(t).$$

Si γ_{topdown} est trop grand et s'oppose en permanence à la synergie $S(i,j)$, on peut assister à un "tir à la corde" où $\omega_{i,j}$ ne converge pas, passant successivement au-dessus et au-dessous du seuil critique.

B. Formulation Mathématique du Conflit et de la Cohérence

Dans un SCN hiérarchique, on définit les pondérations :

$$\omega_{\alpha,\beta}^{(k)}(t+1) = \omega_{\alpha,\beta}^{(k)}(t) + \eta_k [S_k(\alpha,\beta) - \tau_k \omega_{\alpha,\beta}^{(k)}(t)] + \Delta_{\text{desc}}^{(k)}(\omega^{(k+1)}),$$

pour le niveau k . La fonction $\Delta_{\text{desc}}^{(k)}$ correspond au flux descendant venant de $\omega^{(k+1)}$. Parallèlement,

$$\omega_{\alpha,\beta}^{(k+1)}(t) = \Gamma_k(\omega^{(k)}(t)) \quad (\text{agrégation ascendante}).$$

Si la *direction* imposée par $\Delta_{\text{desc}}^{(k)}$ contredit la logique locale $S_k(\alpha,\beta)$, il y a risque de boucle contradictoire.

Un moyen de **limiter** la discorde est de postuler une **contrainte** du type

$$\|\Delta_{\text{desc}}^{(k)}(\omega^{(k+1)})\| \leq \alpha \|\eta_k [S_k(\cdot) - \tau_k \cdot]\|,$$

avec $\alpha < 1$. Cela impose que le flux descendant ne soit pas plus grand (en norme) que la mise à jour locale. Sur un plan conceptuel, cela **force** le macro-niveau à *respecter* la logique micro au lieu de la balayer, prévenant les conflits.

Nous démontrons ci-dessous, de manière rigoureuse, en quoi cette contrainte garantit la cohérence de la dynamique.

Pour chaque paire (α,β) considérée, la mise à jour totale au niveau k est la somme du terme local et du flux descendant :

$$U_{\text{total}}^{(k)} = \eta_k [S_k(\alpha,\beta) - \tau_k \omega_{\alpha,\beta}^{(k)}(t)] + \Delta_{\text{desc}}^{(k)}(\omega^{(k+1)}).$$

Supposons que la norme du terme local soit notée

$$\|U^{(k)}\| = \|\eta_k [S_k(\alpha,\beta) - \tau_k \omega_{\alpha,\beta}^{(k)}(t)]\|.$$

La contrainte imposée se traduit par

$$\|\Delta_{\text{desc}}^{(k)}\| \leq \alpha \|U^{(k)}\| \quad \text{avec} \quad \alpha < 1.$$

Par l'inégalité triangulaire, nous avons

$$\|U_{\text{total}}^{(k)}\| \geq \|U^{(k)}\| - \|\Delta_{\text{desc}}^{(k)}\| \geq \|U^{(k)}\| (1 - \alpha).$$

Comme $1 - \alpha > 0$, il s'ensuit que le signe (et par conséquent la direction) du terme total est dominé par celui du terme local. En d'autres termes, la rétroaction descendante ne peut renverser la logique de la mise à jour locale si sa contribution reste inférieure à une fraction déterminée de celle-ci. Cette propriété garantit que le mécanisme de mise à jour au niveau k continue à évoluer dans la direction dictée par $S_k(\alpha,\beta)$, évitant ainsi la formation de boucles contradictoires.

Nous pouvons analyser ce phénomène en considérant deux cas extrêmes. D'une part, si la rétroaction descendante est parfaitement nulle, la mise à jour est entièrement dictée par la logique locale, et le système converge vers l'équilibre défini par $S_k(\alpha, \beta) = \tau_k \omega_{\alpha, \beta}^{(k)}(t)$. D'autre part, si la rétroaction descendante devient trop imposante (c'est-à-dire que $\|\Delta_{\text{desc}}^{(k)}\|$ dépasse la limite fixée par la contrainte), la direction du signal total pourrait être inversée par rapport à celle du terme local, conduisant potentiellement à une oscillation ou à une instabilité du système. Le choix de $\alpha < 1$ est donc essentiel pour forcer la hiérarchie à respecter la logique locale, en empêchant le niveau macro de submerger la dynamique micro.

Dans ce contexte, la contrainte agit comme un **filtre** ou un **modulateur** qui assure que l'influence descendante reste subordonnée à l'influence locale. Cela permet d'obtenir une convergence stable du système et d'éviter les comportements indésirables, tels que des cycles oscillatoires ou un comportement chaotique, qui pourraient résulter d'une rétroaction trop forte ou mal synchronisée.

Si, malgré tout, on laisse γ_{topdown} ou $\Delta_{\text{desc}}^{(k)}$ devenir très imposant, le système peut :

- **Osciller** (cycle),
- **Stagner** dans un compromis inutile,
- Produire un **comportement chaotique** si la rétroaction n'est pas phasée.

C. Stratégies d'Évitement du Conflit

Une **solution** est d'**ordonner** clairement les phases d'apprentissage local et les phases de correction macro. Par exemple, on laisse le micro-niveau faire θ_1 itérations, puis le macro-niveau intervient, puis on reboucle. Cela évite que le feedback macro ne se déclenche en même temps que les dynamiques locales, réduisant les risques d'oscillation.

On peut calibrer η_{micro} et γ_{topdown} de sorte que le niveau macro ne renverse pas violemment la cohésion locale. On peut également intégrer un *filtrage* :

$$h_{i,j}^{(\text{macro})}(t+1) = \lambda h_{i,j}^{(\text{macro})}(t) + (1-\lambda) \tilde{h}_{i,j}^{(\text{macro})}(t),$$

où \tilde{h} est le signal brut. Ainsi, on lisse la correction descendante, évitant des secousses brusques.

Dans certains *algorithmes DSL*, on peut surveiller la **norme** d'évolution $\|\Delta \omega\|$. Si on détecte une amplitude de mises à jour trop forte signant un conflit, on restreint temporairement la rétroaction top-down ou on revoit les paramètres d'agrégation ascendante pour calmer la discorde.

Considérons un SCN hiérarchique dans lequel la mise à jour des pondérations au niveau local (micro-niveau) est effectuée selon la dynamique classique

$$\omega(t+1) = \omega(t) + \eta_{\text{micro}} [S_{\text{local}}(\omega(t)) - \tau_{\text{micro}} \omega(t)],$$

où S_{local} représente le signal de synergie issu des interactions locales. Supposons que l'on laisse le micro-niveau opérer pendant θ_1 itérations consécutives, ce qui conduit à une certaine convergence ou stabilisation locale. Après ces θ_1 itérations, un niveau macro intervient en fournissant un signal de rétroaction, que nous notons $\Delta \omega_{\text{topdown}}$. L'ordonnancement séquentiel consiste alors à définir une alternance temporelle, telle que :

$$\begin{aligned} \text{Pour } t \in [t_0, t_0 + \theta_1): \quad \omega(t+1) &= \omega(t) + \eta_{\text{micro}} [S_{\text{local}}(\omega(t)) - \tau_{\text{micro}} \omega(t)], \\ \text{Pour } t = t_0 + \theta_1: \quad \omega(t+1) &= \omega(t) + \Delta \omega_{\text{topdown}}, \end{aligned}$$

puis le cycle se répète. Cette phase de séparation temporelle garantit que le micro-niveau atteint d'abord un état quasi-stationnaire avant que le macro-niveau n'intervienne, évitant ainsi que le signal top-down ne vienne perturber simultanément la dynamique locale.

La stabilité du système dépend fortement du calibrage des paramètres η_{micro} et γ_{topdown} (ce dernier étant le coefficient associée à la rétroaction macro). Pour empêcher le signal macro de renverser violemment la cohésion locale, il convient d'exiger que, pour tout instant t , la norme du signal de rétroaction $\|\Delta\omega_{\text{topdown}}(t)\|$ soit limitée par rapport à la norme de la mise à jour locale. Formellement, on impose la contrainte

$$\|\Delta\omega_{\text{topdown}}(t)\| \leq \alpha \|\eta_{\text{micro}} [S_{\text{local}}(\omega(t)) - \tau_{\text{micro}} \omega(t)]\|, \quad \text{avec } \alpha < 1.$$

Cette inégalité assure que, quelle que soit l'amplitude du signal macro, sa contribution reste strictement inférieure à celle du mécanisme local. En d'autres termes, même en présence d'un feedback top-down, la mise à jour totale

$$\Delta\omega(t) = \eta_{\text{micro}} [S_{\text{local}}(\omega(t)) - \tau_{\text{micro}} \omega(t)] + \Delta\omega_{\text{topdown}}(t)$$

vérifie, d'après l'inégalité triangulaire,

$$\begin{aligned} \|\Delta\omega(t)\| &\geq \|\eta_{\text{micro}} [S_{\text{local}}(\omega(t)) - \tau_{\text{micro}} \omega(t)]\| - \|\Delta\omega_{\text{topdown}}(t)\| \geq (1 - \alpha) \\ &\|\eta_{\text{micro}} [S_{\text{local}}(\omega(t)) - \tau_{\text{micro}} \omega(t)]\|. \end{aligned}$$

Ainsi, la direction de la mise à jour reste dominée par le signal local, ce qui empêche le macro-niveau d'imposer un changement radical dans la cohésion locale.

Afin d'éviter des variations brusques du signal macro, il est judicieux d'intégrer un mécanisme de filtrage qui lisse la rétroaction descendante. Pour ce faire, on définit un signal filtré $h_{i,j}^{(\text{macro})}(t)$ qui se met à jour selon la relation de lissage exponentiel

$$h_{i,j}^{(\text{macro})}(t+1) = \lambda h_{i,j}^{(\text{macro})}(t) + (1 - \lambda) \tilde{h}_{i,j}^{(\text{macro})}(t),$$

où $\tilde{h}_{i,j}^{(\text{macro})}(t)$ représente le signal top-down brut, et $\lambda \in (0,1)$ est le coefficient de lissage. Ce procédé agit comme un **passer-bas** qui atténue les fluctuations rapides du signal macro, assurant que la correction descendante se fasse de manière progressive. Par conséquent, la mise à jour effective devient

$$\Delta\omega_{\text{topdown,eff}}(t) = \gamma_{\text{topdown}} h_{i,j}^{(\text{macro})}(t),$$

ce qui garantit que les variations brusques du feedback sont atténuées par le facteur $(1 - \lambda)$.

En complément des stratégies précédentes, il est possible d'introduire un mécanisme de surveillance de la norme d'évolution des pondérations, notée $\|\Delta\omega(t)\|$. L'objectif est de détecter en temps réel des mises à jour excessivement importantes, qui signaleraient un conflit entre le signal local et le feedback macro. Si, à un instant donné, l'on observe que

$$\|\Delta\omega(t)\| > \varepsilon_{\text{critique}},$$

où $\varepsilon_{\text{critique}}$ est un seuil fixé en fonction des caractéristiques du système, alors une procédure de contrôle est déclenchée, pouvant consister en la réduction temporaire de γ_{topdown} ou en l'ajustement des paramètres d'agrégation ascendante. Ce mécanisme adaptatif permet de ramener la dynamique dans la zone de stabilité définie par la contrainte ci-dessus.

D. Intérêt Fondamental de la Cohérence

Convergence Efficace. Une cohérence multi-niveau bien gérée garantit une **convergence** plus rapide. Le flux descendant consolide ou oriente ce qui remonte au lieu de le déstabiliser. Au final, moins d'itérations suffisent pour qu'un **cluster** local se confirme ou se dissolve selon les vœux macro.

Robustesse. Sans cohérence, un petit aléa peut dégénérer en conflit entre étages, produisant des effets chaotiques ou des réorganisations incessantes. Avec cohérence, on obtient une **résilience** : si un bloc local est perturbé, le macro-niveau agit pour le remplacer, sans entrer dans une lutte contradictoire.

Cas d'École : Applications Cognitives ou Robotiques

- **Cognitif** : Le *macro-concept* (aire cérébrale supérieure) incite des groupes de neurones (niveau micro) à se réorganiser, mais ne détruit pas systématiquement leurs associations *stables* ; c'est un **compromis**.
- **Robotique** : Une flotte de robots se coordonne (niveau micro), le commandant (macro) donne une directive globale ; la cohérence évite l'état de confusion où les robots réagissent localement à un plan que l'autorité contredit.

Conclusion

La **cohérence** multi-niveau est *essentielle* pour empêcher que le flux ascendant (clusters locaux) et le flux descendant (contraintes macro) ne se **neutralisent** ou ne **s'entre-détruisent**. Sur le plan **mathématique**, elle requiert un **équilibre** des forces (paramètres DSL) et, parfois, un **ordonnement** temporel (phases alternées, filtrage de signaux). Sur le plan **ingénierie**, cela se traduit par :

- Une **régulation** de la puissance top-down,
- Une **synchronisation** ou un **batch** d'itérations locales avant le feedback macro,
- Un **contrôle** d'oscillation détectant un conflit persistant et adaptant la rétroaction.

De cette façon, le **système** multi-niveau demeure *collaboratif* : le **niveau local** opère librement son auto-organisation, et le **niveau macro** vient affiner ou orienter ce processus sans engendrer de blocages ou de cycles conflictuels. Cette cohérence préserve la **dynamique** du DSL de la discorde, assurant un **fonctionnement** hiérarchique *harmonieux* et *robuste*.

6.4.2. Communication Synergiques entre Niveaux

Au sein d'un **SCN** (Synergistic Connection Network) multi-niveau, la **communication** entre paliers (micro, méso, macro) ne se limite pas à de simples flux d'informations, elle s'inscrit dans la **dynamique** d'auto-organisation, où les liens ω (pondérations) sont mis à jour de manière **synchrone** ou **asynchrone** suivant la règle DSL. La notion de "communication synergiques" évoque spécifiquement la façon dont les **clusters** détectés (ou émergents) à un niveau sont **transmis** sous forme d'agrégation vers le niveau supérieur, et comment, réciproquement, ce niveau supérieur valide ou rétroagit sur ces clusters. Dans la section 6.4.2.1, nous examinons particulièrement l'idée selon laquelle un micro-cluster **stabilisé** (au niveau local) peut être "validé" ou "agrégé" au palier macro, illustrant la prise en compte hiérarchique des informations.

6.4.2.1. Si un micro-cluster se stabilise, le niveau macro peut le "valider" ou l'agréger

La dynamique **multi-échelle** au sein d'un **SCN** (Synergistic Connection Network) permet à des **micro-clusters** (niveau local) de se former, puis de "remonter" progressivement vers des niveaux supérieurs (intermédiaire ou macro), conformément à la logique du **flux ascendant** (cf. 6.4.1.1). Une fois qu'un micro-cluster \mathcal{C}_α est jugé **stable** au niveau 0 (ou local), il revient au **niveau macro** (ou intermédiaire) de **valider** cette stabilisation, puis, si nécessaire, de **l'agréger** sous forme d'un super-nœud. Le texte qui suit expose les bases mathématiques de cette validation et en souligne les bénéfices et précautions.

A. Stabilisation au Niveau Micro et Constitution d'un Cluster

Un **micro-cluster** $\mathcal{C}_\alpha \subseteq \{\mathcal{E}_i\}$ se définit généralement comme un groupe d'entités dont les **pondérations** internes $\{\omega_{i,j}^{(0)}\}$ sont élevées. En pratique, on introduit un **critère** de cohésion tel que

$$\Omega(\mathcal{C}_\alpha) = \sum_{i,j \in \mathcal{C}_\alpha} \omega_{i,j}^{(0)} \geq \theta_{\text{loc}},$$

où θ_{loc} est un **seuil** local. La dynamique DSL (par exemple de type additive) agit au niveau 0 :

$$\omega_{i,j}^{(0)}(t+1) = \omega_{i,j}^{(0)}(t) + \eta_0[S_0(i,j) - \tau_0 \omega_{i,j}^{(0)}(t)],$$

faisant **croître** les liens $\omega_{i,j}^{(0)}$ entre entités localement synergiques, jusqu'à ce qu'un sous-ensemble \mathcal{C}_α dépasse θ_{loc} . On dit alors que \mathcal{C}_α est un **cluster local stabilisé** (voir aussi 6.4.1.1 pour le flux ascendant).

B. Rôle du Niveau Macro : Valider ou Refuser la Stabilisation

Le **niveau macro** (ou supérieur) reçoit l'information qu'un **cluster local** \mathcal{C}_α s'est formé. Deux possibilités se présentent :

43. Le niveau macro **valide** la stabilisation, c'est-à-dire qu'il *accepte* ce micro-cluster comme un bloc fonctionnel.
44. Le niveau macro **rejette** (ou "modère") cette stabilisation, par exemple s'il estime que \mathcal{C}_α interfère avec un **objectif** ou une **cohérence** globale (cf. 6.4.1.3 sur la cohérence).

Dans la première hypothèse, le macro-niveau **agrège** \mathcal{C}_α en un **super-nœud** $\mathcal{N}_\alpha^{(1)}$. On procède à une fonction d'agrégation Ψ (6.2.2) pour définir les liaisons entre $\mathcal{N}_\alpha^{(1)}$ et les autres super-nœuds $\{\mathcal{N}_\beta^{(1)}\}$ déjà reconnus :

$$\omega_{\alpha,\beta}^{(1)} = \Psi(\{\omega_{i,j}^{(0)} \mid i \in \mathcal{C}_\alpha, j \in \mathcal{C}_\beta\}).$$

Le cluster local \mathcal{C}_α devient donc un **nœud de niveau 1**. L'information micro est ainsi "condensée" pour que l'échelle macro puisse la manipuler avec un **nombre réduit** de nœuds. Cette **validation** confère au cluster local un statut "officiel" à l'échelle supérieure.

Si le niveau macro **refuse** la stabilisation locale, il peut renvoyer un **feedback** descendant (6.4.1.2) pour affaiblir les liens $\omega_{i,j}^{(0)}$ du cluster \mathcal{C}_α . Par exemple, un **signal** $\theta_\alpha^{(\text{macro})} < 0$ s'ajoute dans la mise à jour :

$$\Delta \omega_{i,j}^{(0)}(t) = \eta_0[S_0(i,j) - \tau_0 \omega_{i,j}^{(0)}(t)] + \gamma_{\text{top-down}} \theta_\alpha^{(\text{macro})}.$$

Cela **empêche** le cluster de persister localement et force sa reconfiguration, évitant un conflit durable.

C. Bénéfices de la Validation par le Macro-Niveau

La "validation" d'un micro-cluster par le macro-nœud apporte plusieurs **avantages** dans un SCN multi-échelle :

45. **Réduction de la complexité** : On n'a pas à gérer toutes les entités $\{\mathcal{E}_i\}$ individuellement au niveau macro. Une fois validé, \mathcal{C}_α est résumé par $\mathcal{N}_\alpha^{(1)}$.
46. **Stabilisation hiérarchique** : Le micro-cluster profite de l'**appui** du macro-niveau. En retour, le macro-niveau sait qu'il peut compter sur l'existence de ce bloc local "fiable" pour bâtir des structures plus vastes.
47. **Rapidité de convergence** : Plutôt que d'attendre un consensus global, on **valide** localement et on "remonte" ces blocages fonctionnels. Ainsi, la mise en place d'une structure macro se nourrit immédiatement de la dynamique micro.

D. Exemple : Fusion de Micro-Clusters Réunis

Dans un système DSL robotique (6.1, 6.2), supposons que deux micro-clusters \mathcal{C}_α et \mathcal{C}_β se forment dans des zones proches. Le **macro-niveau** repère qu'ils ont un **objectif** semblable (cohérence spatiale, même mission), et décide de "valider" chacun individuellement, puis de **fusionner** ces deux super-nœuds $\mathcal{N}_\alpha^{(1)}$ et $\mathcal{N}_\beta^{(1)}$ en un mégacuster $\mathcal{N}_{\alpha,\beta}^{(2)}$. Cette validation en chaîne illustre comment le flux ascendant (entités \rightarrow micro-clusters) s'enchaîne au flux macro (validation \rightarrow super-nœuds).

Sans l'étape de "confirmation" macro, les micro-clusters pourraient rester dans un état incertain, ou, à l'inverse, un flux descendant contradictoire viendrait contester leur existence sans se manifester explicitement. La validation rend la hiérarchie plus explicite et plus stable.

E. Conclusion

Lorsqu'un **micro-cluster** se **stabilise**, le **niveau macro** a la faculté de le **valider** (et donc de l'**agréger** sous forme d'un super-nœud). Cette reconnaissance ascendante :

48. **Finalise** l'auto-organisation locale en l'inscrivant dans l'échelle supérieure,
49. **Allège** la structure macro, qui n'opère plus sur des entités microscopiques dispersées, mais sur des blocs agrégés,
50. **Réduit** la probabilité de conflits ou de remises en cause ultérieures, puisque le niveau macro "assume" l'existence de ce cluster.

Ce processus forme l'un des points essentiels de la **communication multi-niveau** : le micro détecte et consolide un groupe, puis le macro "scelle" ou "rejette" ce groupe. Avec cette logique, un **SCN** multi-échelle (chap. 6.2) arrive à bâtir une **hiérarchie** de clusters cohérente et évolutive, tout en laissant place à la flexibilité du flux descendant si l'ensemble validé localement se révèle inadapté à plus long terme.

6.4.2.2. Mécanismes de filtrage : ne pas transmettre toute la synergie brute vers le haut, résumer ou agréger

La **multi-échelle** dans un **SCN** (Synergistic Connection Network) induit une série de **flux ascendants** (chap. 6.4.1) où des entités, d'abord organisées localement (niveau 0), s'agrègent ou se stabilisent sous forme de clusters, puis sont transmises à l'échelle supérieure (mésos, macro). Cette **transmission** d'informations soulève immédiatement une question de **volume**. Si l'on transmet la **totalité** des pondérations $\omega_{i,j}$ ou liaisons internes à chaque cluster, le palier supérieur se retrouve surchargé et perd l'avantage de la hiérarchie. D'où la nécessité d'un **filtrage** ou d'une **agrégation** qui, au lieu de transmettre toutes les "synergies brutes", n'en relaie qu'un **résumé** concis et pertinent.

La présente section clarifie les principes formels de ce **filtrage**. D'un point de vue **mathématique**, il s'agit d'une opération Ψ réduisant la dimension du réseau ; d'un point de vue **opérationnel**, cela limite la **masse** d'informations circulant vers le haut, assurant robustesse et économie.

A. Motivation du Filtrage et de l'Agrégation

Si au niveau local n entités forment potentiellement $O(n^2)$ liaisons, transmettre $\omega_{i,j}^{(0)}$ pour toutes les paires (i,j) vers le niveau 1 annulerait l'intérêt d'une **architecture hiérarchique**. Le filtrage permet de **résumer** la masse des liens en un plus petit nombre de **super-pondérations** ou **indicateurs**, de sorte que le niveau macro n'opère que sur $O(m^2)$ valeurs, où $m \ll n$.

Exemple : si $n = 10^5$, on peut réduire à $m = 10^3$ super-nœuds, puis passer de 10^{10} liaisons à 10^6 .

Les dynamiques DSL (ex. la mise à jour additive) génèrent souvent beaucoup de **liens faibles** ou transitoires. Les transmettre « bruts » enliserait le niveau macro dans des détails superflus. Un **filtrage** (seuil, élagage) écarte les liaisons jugées peu contributrices, protégeant l'échelle supérieure contre des variations mineures.

Un cluster local \mathcal{C}_α peut avoir $O(k^2)$ liens internes. En les condensant via une fonction Ψ (moyenne, somme, etc.), on gagne une "seule" valeur $\omega_\alpha^{(1)}$ pour décrire la cohésion interne de \mathcal{C}_α , ce qui **lisse** les aléas locaux. Mathématiquement, la variance de liens internes se "contracte" dans une moyenne, rendant la **signalétique** plus stable aux fluctuations.

B. Principes Formels du Filtrage/Agrégation

Un mécanisme simple :

$$\tilde{\omega}_{i,j}^{(0)} = \begin{cases} \omega_{i,j}^{(0)}, & \text{si } \omega_{i,j}^{(0)} \geq \theta, \\ 0, & \text{sinon.} \end{cases}$$

On ne conserve que les liaisons $\omega_{i,j}$ supérieures à un seuil θ . Ce filtrage peut s'appliquer avant de construire le super-nœud, assurant qu'on n'intègre dans \mathcal{C}_α que les liens réellement “forts”.

Une fois un cluster $\mathcal{C}_\alpha \subseteq \{\mathcal{E}_i\}$ déterminé, la liaison $\omega_{\alpha,\beta}^{(1)}$ entre deux clusters $\mathcal{C}_\alpha, \mathcal{C}_\beta$ se calcule par une **fonction**

$$\omega_{\alpha,\beta}^{(1)} = \Psi \left(\left\{ \omega_{i,j}^{(0)} \mid i \in \mathcal{C}_\alpha, j \in \mathcal{C}_\beta \right\} \right).$$

Les formes de Ψ peuvent être :

- **Somme** : $\omega_{\alpha,\beta} = \sum_{i \in \mathcal{C}_\alpha, j \in \mathcal{C}_\beta} \omega_{i,j}$.
- **Moyenne** : $\omega_{\alpha,\beta} = \frac{1}{|\mathcal{C}_\alpha| |\mathcal{C}_\beta|} \cdot \sum_{i,j} \omega_{i,j}$.
- **Max ou quantile** : $\omega_{\alpha,\beta} = \max_{i \in \mathcal{C}_\alpha, j \in \mathcal{C}_\beta} \omega_{i,j}$.

Plutôt que de donner un seul nombre, on peut transmettre un **vecteur** de statistiques : $\{\min, \max, \text{moyenne}, \text{écart-type}, \dots\}$ décrivant la distribution interne. Le niveau macro reçoit alors une signature plus riche, au prix d'une “explosion” toutefois modérée (quelques indicateurs au lieu de centaines ou milliers de liens).

C. Processus Algorithmique : du Micro au Macro

1. Détection de Clusters Locaux

On commence par identifier $\{\mathcal{C}_\alpha^{(0)}\}_{\alpha=1,\dots,r}$ au niveau micro : chaque $\mathcal{C}_\alpha^{(0)}$ est un **bloc** de forte cohésion $\Omega(\mathcal{C}_\alpha^{(0)}) \geq \theta_{\text{loc}}$.

2. Filtrage

On applique un seuil ou un algorithme d'élagage pour ne **retenir** que les liens importants au sein de \mathcal{C}_α ou entre \mathcal{C}_α et \mathcal{C}_β .

3. Construction du Super-Nœud

On agrège \mathcal{C}_α en un *super-nœud* $\mathcal{N}_\alpha^{(1)}$. On calcule $\omega_{\alpha,\beta}^{(1)}, \forall \beta$, grâce à Ψ .

4. Transmission

On envoie vers le niveau macro le **résultat** : $\{\omega_{\alpha,\beta}^{(1)}\}_{\alpha,\beta}$ ou un *résumé* statistique des liaisons internes et externes. Le macro-niveau n'a pas besoin de toutes les $\omega_{i,j}^{(0)}$, seulement de ce “filtrat”.

D. Impact Pratique : Économie et Stabilité

Allègement. Avec le filtrage, le **niveau macro** ne manie plus $O(n^2)$ poids bruts, mais $O(r^2)$ super-pondérations ($r = \text{nombre de clusters} \leq n$). L'économie est dramatique si $r \ll n$.

Robustesse. Les *petites* fluctuations des liens $\omega_{i,j}^{(0)}$ qui n'atteignent pas le seuil θ ne remontent pas. On évite de bouleverser la structure macro pour un “micro-bruit” local. Cela procure une forme de **tolérance** aux perturbations.

Possibilité de Réactualisation. Le filtrage ne doit pas être *irréversible* : un lien *faible* aujourd'hui peut devenir *fort* demain si la synergie $S_0(i, j)$ évolue. Certaines implémentations DSL réévaluent régulièrement les *liens filtrés*, pour ne pas rater l'opportunité d'un futur cluster.

E. Conclusion

Dans un **SCN** multi-niveau, la **transmission** des informations du **niveau micro** vers le **niveau macro** requiert une **synthèse** soignée. Les *mécanismes de filtrage* (seuil, élagage, agrégation Ψ , résumé statistique) jouent un rôle **essentiel** :

51. Ils **limitent** l'**inondation** de liens bruts,
52. Ils **stabilisent** la représentation macro en n'envoyant que les structures (clusters, liens forts) réellement significatives,
53. Ils **permettent** d'organiser une *communication ascendante* agile et parcimonieuse, rendant le **DSL** multi-niveau robuste et efficace.

Ainsi, on concrétise la philosophie **hiérarchique** (chap. 6.2) : le micro-niveau s'occupe du *détail*, le macro-niveau d'une *vue d'ensemble*, chacun communiquant *juste ce qu'il faut* pour maintenir la cohérence globale (6.4.1.3) et la réactivité locale.

6.4.2.3. Exemples Concrets : Agent Local en Robotique, Superviseur Macro

Il est souvent utile d'illustrer la **communication synergiques** (section 6.4.2) entre un **niveau micro** et un **niveau macro** dans un contexte de **Deep Synergy Learning**. Deux cas d'usage sont présentés : d'une part, un **agent local** en robotique (niveau micro) et, d'autre part, un **superviseur macro** responsable d'une coordination globale. Dans ces deux scénarios, on voit comment un *flux ascendant* condense l'information essentielle (évacuant les détails inutiles) et comment un *flux descendant* fournit un **contrôle** ou une **influence** réciproque sur les liaisons du niveau inférieur.

A. Agent Local en Robotique

Considérons un système multi-agent de type robotique, où chaque **robot** est modélisé comme une **entité** \mathcal{E}_i . Les pondérations $\omega_{i,j}^{(0)}$ relient les paires de robots i et j au **niveau 0**, c'est-à-dire le niveau micro. L'**objectif** du **Deep Synergy Learning** est de permettre une auto-organisation locale ; chaque robot peut adapter ses connexions selon une **règle** de plasticité. Une forme linéaire-additive simple est donnée par

$$\omega_{i,j}^{(0)}(t+1) = \omega_{i,j}^{(0)}(t) + \eta_{\text{loc}}[S_{\text{loc}}(i,j) - \tau_{\text{loc}} \omega_{i,j}^{(0)}(t)],$$

où $\eta_{\text{loc}} > 0$ est un **taux d'apprentissage** et $\tau_{\text{loc}} > 0$ un **terme de décroissance**. La **fonction de synergie** $S_{\text{loc}}(i,j)$ dépend par exemple de la **distance** entre robots, de leur **similarité** de tâches ou de toute autre mesure favorisant la coopération.

Lorsque ce processus d'**auto-organisation** local aboutit à un **micro-cluster**, noté $\mathcal{C}_\alpha \subset \{\mathcal{E}_1, \dots, \mathcal{E}_n\}$, on peut agréger \mathcal{C}_α en un **super-nœud** $\mathcal{N}_\alpha^{(1)}$. Au **niveau 1**, on ne conserve pas la totalité des liaisons individuelles $\omega_{i,j}^{(0)}$, mais une **agrégation** $\omega_{\alpha,\beta}^{(1)}$ calculée typiquement via

$$\omega_{\alpha,\beta}^{(1)} = \Psi(\{\omega_{i,j}^{(0)} \mid i \in \mathcal{C}_\alpha, j \in \mathcal{C}_\beta\}),$$

où Ψ est une **opération de synthèse**, par exemple une somme, une moyenne pondérée ou un maximum. De la sorte, le **niveau macro** ne voit plus qu'une poignée d'entités $\mathcal{N}_\alpha^{(1)}$, correspondant chacune à un ensemble local cohésif de robots.

Le **flux ascendant** (micro vers macro) se retrouve donc filtré ; on élimine la majorité des détails et on concentre la communication sur un petit nombre de "super-nœuds" issus de l'auto-organisation des agents locaux. Cette logique **multi-niveau** permet de limiter le coût, au lieu de gérer $O(n^2)$ liaisons élémentaires, le **niveau 1** ne manipule que $O(k^2)$ super-liaisons, où k est le nombre de clusters.

B. Superviseur Macro

Dans un second exemple, on suppose l'existence d'un **superviseur macro**, un **niveau supérieur** qui reçoit les **super-nœuds** du niveau 1 (ou un niveau intermédiaire plus haut encore). Ce superviseur gère la **tâche globale** (répartition de zones à explorer, contraintes de mission, etc.) et peut renvoyer un *feedback* vers le micro-niveau pour orienter le renforcement ou l'inhibition de certaines connexions.

Une façon de modéliser ce *feedback descendant* est d'enrichir l'équation de mise à jour micro par un **terme d'influence** Δ_{down} . On peut alors écrire

$$\omega_{i,j}^{(0)}(t+1) = \omega_{i,j}^{(0)}(t) + \eta_{\text{loc}}[S_{\text{loc}}(i,j) - \tau_{\text{loc}} \omega_{i,j}^{(0)}(t)] + \gamma_{\text{macro}} \Delta_{\text{down}},$$

où γ_{macro} est un **facteur** réglant l'intensité de l'intervention du **superviseur**. Le terme Δ_{down} peut être, par exemple, un **signal** incitant à renforcer les liaisons entre deux sous-groupes \mathcal{C}_α et \mathcal{C}_β si le niveau supérieur décide de fusionner leurs efforts.

Dans ce cas, l'**auto-organisation** demeure largement locale (les agents mettent à jour leurs poids selon une synergie locale S_{loc}), mais un **contrôle** partiel par la structure de plus haut niveau permet d'anticiper les besoins de la mission globale (objectif externe imposé, ou simple consigne d'alignement).

C. Avantages de la Communication Synergiques

L'**agent local** peut s'organiser entre ses pairs de manière autonome, créant ainsi des **micro-clusters** robustes et adaptatifs. Cette information "micro" est alors **remontée** au **superviseur macro** sous forme condensée (agrégation en super-nœuds), évitant une surcharge $O(n^2)$. Le **superviseur** peut à son tour moduler la configuration du niveau inférieur via un *flux descendant*, soit pour soutenir certaines synergies, soit pour en restreindre d'autres.

Ces mécanismes hiérarchisés assurent à la fois la **scalabilité** (le macro-niveau n'interagit qu'avec un nombre réduit de super-nœuds) et la **réactivité** (chaque groupe local s'auto-organise rapidement selon η_{loc}). Les pondérations finales $\omega_{i,j}^{(0)}$ émanent donc d'une **double** influence : la synergie "réelle" estimée localement et l'**orientation** imposée par le macro-niveau.

Lorsque ce cadre s'applique à l'**industrie** robotique ou à un **système** multi-agent plus générique, on préserve un fort degré de **décentralisation** tout en maintenant un pilotage global cohérent. La communication **synergiques** entre niveaux assure en effet un bon compromis entre l'autonomie des sous-groupes et la coordination stratégique imposée par le sommet de la hiérarchie.

Cette capacité à se reconfigurer, tant localement que globalement, correspond à l'esprit du **Deep Synergy Learning**. Plusieurs *couches* ou *niveaux* interagissent via des **flux** réciproques, filtrés et agrégés, sans pour autant que l'un de ces niveaux ne subisse la totalité des détails issus des autres. Le résultat est un **réseau** où l'intelligence se répartit des agents les plus élémentaires jusqu'aux superviseurs d'échelle plus élevée, ce qui favorise la **robustesse** et l'**adaptation** face aux changements de contexte.

6.4.3. Synchronisation et Clustering

Dans la perspective d'un **DSL** (Deep Synergy Learning) déployé sur un **SCN** (Synergistic Connection Network) multi-niveau, la question de la **synchronisation** entre niveaux et celle du **clustering** progressif se posent en termes concrets :

- *Comment* garantir que les divers paliers (micro, méso, macro) ne sont pas en perpétuel décalage ?
- *Comment* gérer la **coexistence** de clusters à échelles différentes, et *quand* décider de la stabilisation ou de la fusion de plusieurs regroupements ?

La section 6.4.3.1 met l'accent sur le rôle d'"échelles intermédiaires" (semi-globales), agissant comme des **étapes** cruciales dans la stabilisation hiérarchique du SCN.

6.4.3.1. Les Clusters d'Échelle Intermédiaire (Semi-Globale) comme Étapes de Stabilisation

Introduction. Le passage d'un niveau **micro** (petits groupes ou entités isolées) à un niveau **macro** (super-nœuds ou regroupements englobants) peut s'avérer trop rapide ou trop complexe si l'on ne tient pas compte de *paliers intermédiaires*. Dans de nombreux schémas multi-niveau, ces paliers prennent la forme de **clusters semi-globaux**, c'est-à-dire des regroupements de taille moyenne. Ces entités intermédiaires facilitent la stabilisation et la cohérence hiérarchique, tout en régulant la montée progressive vers des macro-structures. Les sections qui suivent détaillent le rôle de ces clusters semi-globaux, les mécanismes de synchronisation inter-paliers et divers cas d'utilisation.

A. Échelle Intermédiaire et Stabilisation Progressive

Dans une architecture multi-niveau, un **micro-niveau** peut produire des micro-clusters $\{\mathcal{C}_\alpha^{(0)}\}$. On agrège ensuite ces micro-clusters en un **niveau 1**, où l'on considère des super-nœuds $\mathcal{N}_\alpha^{(1)}$. Lorsque l'échelle totale du système est grande, il est souvent nécessaire de continuer à agréger ces super-nœuds pour former un **niveau 2**, aboutissant à des macro-clusters $\{\mathcal{N}_\beta^{(2)}\}$ de dimension plus élevée. Dans ce contexte, le niveau 1 agit comme un **tampon** ou une **étape pivot**. Il consolide des groupes de taille moyenne, sans prétendre atteindre immédiatement la structure macro complète.

La stabilisation progressive s'explique en termes **d'équilibre dynamique**. Les pondérations $\omega^{(k)}$ au palier k suivent une règle de mise à jour de type

$$\omega_{a,b}^{(k)}(t+1) = \omega_{a,b}^{(k)}(t) + \eta_k [S^{(k)}(a,b) - \tau_k \omega_{a,b}^{(k)}(t)],$$

où η_k et τ_k sont respectivement le **taux d'adaptation** et le **terme de décroissance** associés au niveau k . Il n'est pas nécessaire d'augmenter subitement l'échelle de ces pondérations pour passer directement du micro au macro. Les paliers intermédiaires laissent le temps à chaque niveau d'atteindre un quasi-équilibre local, évitant un chaos dû à un trop grand saut d'échelle.

B. Clusters Semi-Globaux et Régulation de la Complexité

Un cluster semi-global représente un groupe de dimension intermédiaire, par exemple quelques dizaines ou centaines de nœuds sur un total de milliers. Sur le plan **dynamique**, ces regroupements agissent comme un filtre. Les micro-clusters du niveau inférieur $\mathcal{N}_\alpha^{(1)}$ peuvent fusionner ou se scinder pour former des ensembles plus vastes, mais seulement si leur **synergie** demeure assez élevée lors des itérations d'**auto-organisation**. Les clusters semi-globaux ainsi créés ne sont ni trop petits ni trop grands, ce qui facilite leur réorganisation interne et leur éventuelle fusion en un macro-niveau ultérieur.

La compétition ou la collaboration entre clusters semi-globaux peut être modélisée par des pondérations $\omega_{\alpha,\beta}^{(1)}$. Par exemple, si $\mathcal{N}_\alpha^{(1)}$ et $\mathcal{N}_\beta^{(1)}$ exhibent une forte compatibilité, la mise à jour

$$\omega_{\alpha,\beta}^{(1)}(t+1) = \omega_{\alpha,\beta}^{(1)}(t) + \eta_1 [S_1(\alpha,\beta) - \tau_1 \omega_{\alpha,\beta}^{(1)}(t)]$$

peut conduire, à terme, à l'union de ces deux regroupements si cette compatibilité dépasse un certain seuil. Inversement, de faibles valeurs de synergie pousseront à la désactivation ou au relâchement des liens. Les clusters semi-globaux les plus stables constitueront alors le socle pour la **phase suivante** d'agrégation.

C. Synchronisation des Paliers et Ordonnancement Temporel

Les différents niveaux ne doivent pas être mis à jour simultanément à chaque instant, sous peine d'induire des oscillations ou conflits entre le micro et le macro. Une stratégie courante de **synchronisation** consiste à laisser le micro-niveau évoluer pendant un certain nombre d'itérations, puis à figer ses résultats, à construire les clusters de niveau supérieur et à itérer à ce niveau intermédiaire. Ce découpage temporel peut se formaliser par un calendrier en étapes :

54. Le **micro-niveau** (niveau 0) applique la règle de mise à jour durant T_0 itérations, produisant des groupes $\{\mathcal{C}_\alpha^{(0)}\}$.
55. On agrège ces groupes en super-nœuds $\{\mathcal{N}_\alpha^{(1)}\}$. Les pondérations $\omega_{\alpha,\beta}^{(1)}$ sont initialisées par une opération de synthèse (somme, moyenne, etc.) sur les liens intergroupes de niveau 0.
56. Le **niveau intermédiaire** exécute alors la mise à jour pendant T_1 itérations, aboutissant à la formation ou la stabilisation de clusters semi-globaux.
57. Enfin, si nécessaire, un passage au **macro-niveau** (niveau 2) peut se faire après un nombre d'itérations suffisant pour que le niveau 1 se soit **stabilisé**.

Dans cette séquence, chaque échelon (k) transmet ses informations à ($k + 1$) lorsque le système local est parvenu à un état suffisamment cohérent. Cela évite de multiplier des allers-retours entre des niveaux qui n'ont pas eu le temps de converger.

D. Cas d'Utilisation et Exemples Concrets

Les **clusters semi-globaux** apparaissent dans un large éventail de systèmes multi-niveau. Dans le domaine des réseaux distribués (cloud et edge), le palier intermédiaire peut correspondre à des **data centers régionaux** qui rassemblent les ressources de plusieurs sites. En robotique, le niveau 1 regroupe des sous-équipes locales pour former des unités de taille moyenne, avant de s'associer en un méta-groupe macro si une mission globale l'exige. Dans des approches inspirées de la **cognition** ou du **cerveau**, des sous-réseaux peuvent émerger en tant qu'aires corticales locales et coopérer à plus grande échelle par paliers successifs.

Dans tous ces scénarios, la dynamique d'échelle intermédiaire offre une **stabilisation hiérarchique**. Plutôt que de confronter immédiatement l'ensemble des entités à une vision macro, on laisse les synergies locales s'organiser en regroupements robustes. Les paliers semi-globaux constituent ainsi une étape de maturation indispensable, limitant le risque de configurations fragiles ou mal ajustées lorsqu'on atteindra le niveau englobant.

Conclusion

Les **clusters d'échelle intermédiaire** fournissent un mode de **stabilisation progressive** entre l'échelle micro et l'échelle macro. Sur le plan mathématique, cette stabilisation s'exprime par la mise à jour en paliers successifs des pondérations $\omega^{(k)}$, permettant à chaque regroupement d'affiner sa cohésion avant de s'intégrer dans un ensemble plus vaste. Les groupes semi-globaux ne sont ni trop restreints, ni trop imposants, ce qui leur confère la souplesse nécessaire pour évoluer, fusionner ou se scinder au gré de la dynamique d'**auto-organisation**. Ils agissent comme un **filtre** ou un **tampon** essentiel, assurant la montée en échelle sans basculer dans la confusion ni l'explosion combinatoire. Cette hiérarchie en paliers, déjà illustrée dans le chapitre 6.4, émerge de manière naturelle dans les architectures multi-niveau du **Deep Synergy Learning** et se montre très adaptée à des domaines aussi variés que la robotique, les systèmes distribués et l'IA cognitive.

6.4.3.2. Coordination Latérale entre Clusters de Niveaux Proches : Comment Interagir avec le Cluster Voisin

Introduction. Dans un **Deep Synergy Learning** multi-niveau, il est courant de focaliser la communication sur l'axe vertical, que ce soit vers le haut (bottom-up) ou vers le bas (top-down). Toutefois, au sein d'un **même** palier de la hiérarchie (par exemple, un niveau intermédiaire ou semi-global), plusieurs **clusters** peuvent coexister. La question se pose alors de savoir comment ces clusters, qui partagent la même échelle, interagissent **directement** entre eux sans nécessairement faire appel au niveau supérieur ou au niveau micro. Cette **coordination latérale** s'avère cruciale pour résoudre d'éventuels conflits locaux, permettre des fusions partielles ou faciliter des échanges de ressources à l'échelle intermédiaire. Les paragraphes suivants détaillent la nécessité et les modalités de cette interaction horizontale, ainsi que les bénéfices et implications sur la dynamique globale.

A. Raison d'Être de la Coordination Latérale

Au sein d'un palier donné, il est possible que plusieurs super-nœuds $\mathcal{N}_\alpha^{(k)}$ et $\mathcal{N}_\beta^{(k)}$ se retrouvent dans une situation de **complémentarité** ou de **compétition**. Des groupes voisins peuvent occuper des régions adjacentes (dans un contexte de robotique) ou partager des caractéristiques similaires (dans une application de clustering de données), et se retrouvent incités à établir des mécanismes de dialogue direct. L'idée est de gérer en local leurs **relations mutuelles**, plutôt que de solliciter le niveau macro pour chaque ajustement mineur. Cela accélère la réaction à des défis communs et décharge la couche supérieure, qui se concentre alors sur des stratégies plus globales.

S'il n'existe pas de **coordination latérale**, toute communication entre clusters du même palier devrait être relayée à travers le niveau $k + 1$. Un tel détour crée un surcoût, perturbe la réactivité locale et contribue à la surcharge d'information chez le macro-nœud. La mise en place de **liens horizontaux**, avec leurs pondérations $\omega_{\alpha,\beta}^{(k)}$, constitue un moyen efficace de rendre ces échanges plus directs, plus rapides et mieux adaptés à la dimension semi-globale.

B. Formalisation : Liens Latéraux au Même Palier

Au niveau k , chaque super-nœud $\mathcal{N}_\alpha^{(k)}$ est potentiellement connecté aux autres super-nœuds $\mathcal{N}_\beta^{(k)}$. On peut donc définir une **matrice** $\omega^{(k)}$ dont les éléments $\omega_{\alpha,\beta}^{(k)}$ sont sujets à une règle de plasticité du même type que celle utilisée aux niveaux micro. Une loi de mise à jour classique est :

$$\omega_{\alpha,\beta}^{(k)}(t+1) = \omega_{\alpha,\beta}^{(k)}(t) + \eta_k [S_k(\alpha, \beta) - \tau_k \omega_{\alpha,\beta}^{(k)}(t)].$$

Le **taux d'adaptation** η_k et la **constante de décroissance** τ_k peuvent être spécifiques au palier k . La *fonction de synergie* $S_k(\alpha, \beta)$ correspond alors à un **score** reflétant la compatibilité entre les regroupements $\mathcal{N}_\alpha^{(k)}$ et $\mathcal{N}_\beta^{(k)}$. Ce score peut être dérivé de la somme ou de la moyenne des liens inter-entités au niveau $k - 1$, de la proximité spatiale, de la complémentarité de compétences, ou de toute autre donnée permettant d'évaluer l'intérêt de coopérer.

L'existence de ces pondérations $\omega_{\alpha,\beta}^{(k)}$ transforme le palier k en un **réseau** de super-nœuds, qui s'auto-organise selon le même principe DSL : les paires de clusters les plus synergiques renforcent leurs liens, les autres s'étiolent. Les super-nœuds peuvent alors se **rapprocher**, se **fuser** ou maintenir une simple relation d'information mutuelle. Cette auto-organisation horizontale rend la couche k plus autonome et plus stable face à des phénomènes locaux.

C. Collaboration, Concurrence et Frontières

D'un point de vue dynamique, deux super-nœuds $\mathcal{N}_\alpha^{(k)}$ et $\mathcal{N}_\beta^{(k)}$ peuvent :

58. **Fusionner** s'ils constatent que leur synergie latérale $\omega_{\alpha,\beta}^{(k)}$ croît jusqu'à dépasser un certain seuil, ou si leurs entités $\{\mathcal{E}_i\}$ montrent un recouvrement élevé.
59. **Coexister** paisiblement en maintenant une frontière clairement définie, peut-être par une relation modérée (ni trop basse, ni trop élevée).
60. **Entrer en compétition** pour des ressources partagées ou si leurs objectifs se recouvrent, ce qui peut conduire à une réduction de $\omega_{\alpha,\beta}^{(k)}$ via la dynamique de décroissance.

Un **exemple** concret est celui d'un niveau intermédiaire regroupant des équipes robotisées. Deux super-nœuds voisins peuvent être naturellement amenés à échanger des robots, des informations ou à se répartir des sous-zones d'exploration. Dès lors, la pondération $\omega_{\alpha,\beta}^{(k)}$ augmente si le partage se révèle mutuellement bénéfique, reflétant leur **coopération**. Dans le cas contraire, si des **conflits** surgissent (redondance de ressources, incompréhensions de mission), la valeur de $\omega_{\alpha,\beta}^{(k)}$ tend à diminuer, signifiant un cloisonnement plus net.

Stabilisation latérale. Autoriser cette coordination horizontale évite que chaque super-nœud fonctionne en vase clos. Un cluster semi-global peut résoudre localement ses ajustements avec un voisin, limitant ainsi les remontées de demandes vers le niveau macro. Cette **stabilisation latérale** contribue à ce que la couche k soit plus robuste et cohérente avant de se projeter vers une agrégation de plus grande échelle.

Réduction de la surcharge au niveau supérieur. Dès lors que les clusters parviennent à trouver un consensus sur leur frontière commune, ils n'ont pas besoin de mobiliser le palier macro ($k + 1$). Le niveau supérieur est ainsi déchargé de multiples querelles de détail et peut se consacrer à la vision plus large et à la stratégie globale.

Complexité algorithmique. La gestion des liens latéraux $\omega_{\alpha,\beta}^{(k)}$ introduit une **matrice** de taille proportionnelle au nombre de super-nœuds au palier k . Bien que cela représente un coût en plus, ce coût reste très inférieur à l'échelle micro si le palier k agrège déjà plusieurs entités dans un même nœud. Il s'agit donc d'un **mini-réseau** plus léger à manipuler que le réseau initial complet.

Convergence globale. Sur le plan mathématique, la mise à jour simultanée des liaisons **verticales** (entre niveaux différents) et **horizontales** (à l'intérieur d'un même niveau) s'apparente à un **double mécanisme** d'auto-organisation. Le niveau k peut stabiliser la structure dans sa couche, tandis que la structure agrégée (ou filtrée) est progressivement transmise à ($k + 1$). Une telle gestion hiérarchique, associée à la coordination latérale, favorise une convergence plus fluide et évite les incohérences ou oscillations qui surviendraient si tout devait être uniformément décidé au niveau macro.

Conclusion

La **coordination latérale** constitue un prolongement naturel de la logique multi-niveau dans un **DSL**. En s'appuyant sur des **pondérations horizontales** $\omega_{\alpha,\beta}^{(k)}$, elle permet à des super-nœuds **situés au même palier** d'interagir, de coopérer ou de se séparer selon les principes d'auto-organisation habituels : renforcement des synergies fortes, décroissance des liaisons peu utiles. Ce mécanisme évite de surcharger la couche macro (niveau $k + 1$) et instaure un degré supplémentaire de **liberté** : les regroupements semi-globaux peuvent évoluer ou fusionner en fonction de leurs besoins communs.

En pratique, cette interaction latérale se révèle précieuse pour gérer la **complémentarité** ou la **compétition** entre clusters de même échelle, tout en stabilisant la configuration avant de l'envoyer vers un palier supérieur. Elle contribue ainsi à la robustesse et à la scalabilité des **réseaux** construits sous l'angle d'un **Deep Synergy Learning** multi-niveau, que ce soit en robotique, en gestion distribuée ou dans des architectures d'intelligence artificielle neuronales.

6.4.3.3. Détection et gestion de conflits : si deux macro-nœuds aspirent la même entité

Dans la dynamique **multi-niveau** d'un **SCN** (Synergistic Connection Network), il peut arriver qu'au **niveau macro**, deux super-nœuds $\mathcal{N}_\alpha^{(k)}$ et $\mathcal{N}_\beta^{(k)}$ se disputent le **même** ensemble local, c'est-à-dire qu'une ou plusieurs entités $i \in \{\mathcal{E}_i\}$ (au niveau micro) se retrouvent "attirées" par les deux macro-clusters. Ce phénomène fait naître un **conflit** : lequel des macro-nœuds va réellement absorber (ou contrôler) l'entité i ? Si la **synergie** (ω) vers chacun est comparable, on risque des oscillations ou une incohérence. Cette section présente **comment** détecter ce type de conflit (section A) et **comment** le gérer mathématiquement (section B), afin d'assurer la stabilité globale du **DSL** (Deep Synergy Learning).

A. Détection de Conflits : deux macro-nœuds visant la même entité

Au **niveau 0** (micro), une entité \mathcal{E}_i peut avoir un ensemble de pondérations $\{\omega_{i,j}\}$ la reliant aux entités $\mathcal{C}_\alpha^{(0)}$ ou $\mathcal{C}_\beta^{(0)}$.

Après agrégation (chap. 6.2.2), on forme au niveau k deux **macro-nœuds** $\mathcal{N}_\alpha^{(k)}$ et $\mathcal{N}_\beta^{(k)}$. Chacun d'eux englobe un certain sous-ensemble d'entités (ou super-nœuds du palier $k - 1$).

Il se peut qu'une *même* entité \mathcal{E}_i (au palier micro) apparaisse partiellement dans la “zone” de $\mathcal{N}_\alpha^{(k)}$ et de $\mathcal{N}_\beta^{(k)}$. Par exemple, ses liens $\omega_{i,j}$ avec les membres de \mathcal{N}_α sont élevés, mais $\omega_{i,j}$ avec certains membres de \mathcal{N}_β le sont aussi.

Si la *même* entité \mathcal{E}_i est “aspirée” par $\mathcal{N}_\alpha^{(k)}$ et $\mathcal{N}_\beta^{(k)}$, la structure du SCN risque une incohérence : l'entité i ne doit pas se trouver **simultanément** dans deux macro-nœuds distincts (sauf si le modèle l'autorise, mais dans la plupart des schémas, on privilégie une partition ou un recouvrement contrôlé).

Sur le plan **mathématique**, on peut poser l'**indicateur** $\zeta(i, \alpha)$ qui vaut 1 si $i \in \mathcal{N}_\alpha$ et 0 sinon. Un conflit se détecte si $\zeta(i, \alpha) = \zeta(i, \beta) = 1$ pour $\alpha \neq \beta$.

Souvent, la **détection** se fait en observant la **somme des pondérations** entre i et chacun des macro-nœuds :

$$\Omega(i, \alpha) = \sum_{j \in \mathcal{N}_\alpha} \omega_{i,j}^{(0)}, \quad \Omega(i, \beta) = \sum_{j \in \mathcal{N}_\beta} \omega_{i,j}^{(0)}.$$

Si $\Omega(i, \alpha) \approx \Omega(i, \beta)$ et les deux dépassent un certain seuil, un conflit d’“aspiration” se produit.

B. Gestion Mathématique des Conflits : Choix, Partage, ou Inhibition

Une entité i ne peut appartenir *exclusivement* qu'à un **macro-nœud**. Lorsqu'on détecte un conflit ($\Omega(i, \alpha) \approx \Omega(i, \beta)$), on applique une **règle** de résolution :

$$\zeta(i, \alpha) = 1, \zeta(i, \beta) = 0 \quad \text{ou} \quad \zeta(i, \alpha) = 0, \zeta(i, \beta) = 1,$$

selon lequel des deux dépasse le plus nettement le seuil, ou selon un *tirage aléatoire pondéré* (si Ω est quasi identique).

On peut introduire un **terme** Δ_{conflict} qui “coupe” la liaison la plus faible, par ex. :

$$\omega_{i,j}^{(0)}(t+1) = \omega_{i,j}^{(0)}(t) - \gamma(\cdot),$$

pour les liens orientés vers le macro-nœud qu'on *rejette*.

Dans certains modèles **non** exclusifs, on autorise un recouvrement des macro-nœuds (une entité peut être dans \mathcal{N}_α et \mathcal{N}_β) si c'est *logiquement* possible (ex. un robot fait partie de 2 équipes).

Mais cette *co-appartenance* peut introduire de la **redondance** et compliquer la logique d'agrégation. On implémente alors un **poids d'appartenance** $\zeta(i, \alpha) \in [0,1]$ qui mesure à quel degré i contribue à \mathcal{N}_α . S'il y a un conflit, on *répartit* ζ sur plusieurs macro-nœuds.

Troisième méthode : si le système **macro** (niveau k) considère que \mathcal{N}_α a déjà assez d'entités, il impose une **inhibition** ($\Delta_{\text{down}}^{(\alpha)} < 0$) sur les liaisons reliant i à \mathcal{N}_α , incitant i à se replier vers \mathcal{N}_β .

Le flux descendant du macro-niveau α vers l'entité i (au niveau micro) est :

$$\Delta_{\text{down}}^{(\alpha)}(i) = -\varepsilon \quad \text{si conflit.}$$

Cela **affaiblit** la synergie $\omega_{i,j}$ pour $j \in \mathcal{N}_\alpha$, poussant \mathcal{E}_i à basculer vers \mathcal{N}_β .

C. Stabilisation et Résolution Finale

Au fil des itérations, une entité i se **fixe** dans un macro-nœud \mathcal{N}_α ou un autre, au fur et à mesure que les **liens** (micro-liaisons $\omega_{i,j}$) s'ajustent en réponse aux signaux top-down.

Quand la **convergence** s'opère, le conflit cesse : i est pleinement (ou majoritairement) intégré à un cluster macro.

S'il n'y a pas de **règle** claire pour briser l'égalité $\Omega(i, \alpha) \approx \Omega(i, \beta)$, on peut voir i osciller entre \mathcal{N}_α et \mathcal{N}_β . D'où l'intérêt d'un *petit* mécanisme de **brisure de symétrie** (ex. un ajout aléatoire, un tirage stochastique) ou d'un *facteur d'hystérésis* (on ne bascule pas si la différence est $< \delta$) pour éviter le "flip-flop".

Optionnellement, on peut définir une **énergie** locale $E_i(\alpha, \beta)$ associée au fait que i appartient à \mathcal{N}_α et \mathcal{N}_β . Si ce double appartenance coûte cher (haute énergie), le système finit par minimiser l'énergie en choisissant un *unique* cluster macro pour i .

D. Résumé et Impact

Quand deux macro-nœuds aspirent la même entité, cela révèle souvent une **ambiguïté** ; l'entité partage une forte synergie avec deux groupes différents. C'est fréquent si le **réseau** n'impose pas une partition stricte ou si la distribution initiale rend l'entité "hybride".

La **gestion** de ce conflit est donc un aspect **naturel** de la coordination multi-niveau en DSL.

Une première approche consiste à appliquer un **choix excluant**, qu'il soit forcé ou stochastique, afin que l'entité finisse par appartenir à un seul macro-nœud. Une autre possibilité repose sur le **partage**, si le modèle autorise l'overlapping, ce qui implique l'introduction d'une pondération d'appartenance $\zeta(i, \alpha) \in [0,1]$. Enfin, une troisième stratégie repose sur l'**inhibition**, où l'entité est repoussée hors d'un macro-nœud par un mécanisme de feedback négatif.

En combinant un *terme top-down* et une *loi DSL* locale, on garantit qu'un conflit se **résoudra** généralement, tant que les paramètres (η, τ, γ) sont choisis pour **éviter** les oscillations permanentes. Des petits ajouts de *bruit* ou de *random break ties* aident aussi à la *brisure de symétrie*.

Conclusion

La **détection** et la **gestion** de conflits, lorsque *deux macro-nœuds* se disputent la *même* entité (ou sous-ensemble) au niveau micro, est un **phénomène courant** dans un SCN hiérarchisé :

- **Détection** : on repère que $\Omega(i, \alpha) \approx \Omega(i, \beta)$ pour l'entité i ,
- **Gestion** : on impose un **choix** (ex. inhiber l'un des liens), un **partage** (overlapping), ou un **feedback** top-down forçant le basculement,
- **Stabilité** : on évite les oscillations en introduisant une loi de "résolution" (briser l'égalité, paramétrer la feedback).

Sur le plan **mathématique**, ces mécanismes s'insèrent dans la mise à jour DSL combinant *renforcement local* et *rétroaction macro*. Ainsi, le système multi-niveau parvient à **assigner** chaque entité à un cluster macro (ou éventuellement à plusieurs, si le modèle l'autorise) de manière *cohérente*, évitant les incohérences structurelles qui mineraient la robustesse et la clarté de l'organisation globale.

6.5. Dynamique et Algorithmes Multi-Échelle

Dans de nombreux **SCN** (Synergistic Connection Networks), l'organisation **multi-niveau** n'est pas juste un concept statique, elle émerge et se peaufine *dynamiquement* grâce à l'application d'**algorithmes** spécifiques. La section 6.5.1 décrit l'**agrégation progressive** (bottom-up), principe selon lequel on forme des super-nœuds de plus en plus grands (micro \rightarrow méso \rightarrow macro). Ensuite, 6.5.2 verra la **division** (top-down), et 6.5.3 une **approche hybride**. Enfin, 6.5.4 discutera des aspects algorithmiques concrets et des paramètres clés.

6.5.1. Agrégation Progressive (Bottom-Up)

Lorsqu'on parle de **DSL** (Deep Synergy Learning) à plusieurs paliers, l'une des logiques classiques consiste à **agréger** progressivement les entités de bas en haut, d'abord on détecte des **micro-clusters**, puis on fusionne ces micro-clusters pour former des **super-nœuds**, et ainsi de suite jusqu'au "macro-nœud" ou niveau global.

6.5.1.1. Détecter des Micro-Clusters, en Créer un "Super-Nœud" ; puis Détecter des Super-Nœuds Cohérents pour un "Macro-Nœud", etc.

Introduction. Dans une architecture **Deep Synergy Learning** multi-niveau, l'un des mécanismes les plus naturels pour construire une **hiérarchie** consiste à procéder de manière bottom-up ; on commence par détecter, au **niveau micro**, des **micro-clusters** suffisamment cohérents. On agrège ensuite chacun de ces groupes en un super-nœud pour le palier suivant, puis on répète le même principe de détection/agrégation afin de former des *macro-clusters* ou un *macro-nœud* unique. Les paragraphes qui suivent détaillent la démarche et les fondements mathématiques associés.

A. Détection de Micro-Clusters au Niveau 0

On se place au **niveau 0**, celui des entités élémentaires $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$. Chaque paire (i, j) est associée à un poids $\omega_{i,j}^{(0)}$ et suit une **règle DSL** inspirée de la plasticité synaptique. Par exemple, une règle additive canonique peut s'écrire :

$$\omega_{i,j}^{(0)}(t+1) = \omega_{i,j}^{(0)}(t) + \eta_0 [S_0(i, j) - \tau_0 \omega_{i,j}^{(0)}(t)],$$

où η_0 est un **taux d'apprentissage**, τ_0 un **terme de décroissance**, et $S_0(i, j)$ une **fonction de synergie** mesurant la similarité ou l'utilité mutuelle des entités \mathcal{E}_i et \mathcal{E}_j . Après un certain nombre d'itérations, on voit émerger des **groupes** (micro-clusters) dont les pondérations internes $\omega_{i,j}^{(0)}$ restent élevées et se stabilisent, tandis que les liens extérieurs faiblissent ou s'annulent.

Lorsqu'un **sous-ensemble** $\mathcal{C}_\alpha^{(0)} \subset \{\mathcal{E}_1, \dots, \mathcal{E}_n\}$ présente une **cohésion** suffisamment forte, on peut le reconnaître comme un **micro-cluster** stable. À partir de ce moment, on peut réduire l'information qu'il contient à un **super-nœud** $\mathcal{N}_\alpha^{(1)}$, de telle sorte que le **niveau 0** se voit partiellement "condensé" pour constituer le **niveau 1**.

B. Construction d'un Super-Nœud

Une fois que l'on a détecté un micro-cluster $\mathcal{C}_\alpha^{(0)}$, on crée un **super-nœud** $\mathcal{N}_\alpha^{(1)}$. Pour former l'ensemble des liaisons $\omega_{\alpha,\beta}^{(1)}$ au **niveau 1**, on réalise une **agrégation** des poids $\omega_{i,j}^{(0)}$. Une manière générique de procéder consiste à choisir une fonction Ψ et à poser :

$$\omega_{\alpha,\beta}^{(1)} = \Psi(\{\omega_{i,j}^{(0)} \mid i \in \mathcal{C}_\alpha^{(0)}, j \in \mathcal{C}_\beta^{(0)}\}).$$

La fonction Ψ peut être une **moyenne**, une **somme**, un **maximum**, ou toute autre mesure appropriée pour condenser les poids $\omega_{i,j}^{(0)}$ liant le cluster $\mathcal{C}_\alpha^{(0)}$ au cluster $\mathcal{C}_\beta^{(0)}$. Cette opération de filtrage ou de synthèse garantit que l'on passe d'un nombre potentiellement élevé de liaisons au niveau micro ($O(n^2)$) à un nombre bien plus faible de liaisons au niveau 1. De plus, cette **réduction** souligne uniquement les liens les plus significatifs entre les clusters du niveau inférieur.

C. Détection de Super-Nœuds Cohérents

Au **niveau 1**, on se retrouve avec un ensemble de super-nœuds $\{\mathcal{N}_1^{(1)}, \dots, \mathcal{N}_{m_1}^{(1)}\}$ et une matrice de pondérations $\omega_{\alpha,\beta}^{(1)}$. On peut appliquer la **même** règle DSL (ou une variante) pour faire évoluer ces poids :

$$\omega_{\alpha,\beta}^{(1)}(t+1) = \omega_{\alpha,\beta}^{(1)}(t) + \eta_1 [S_1(\alpha, \beta) - \tau_1 \omega_{\alpha,\beta}^{(1)}(t)].$$

Ici, η_1 et τ_1 sont des paramètres d'apprentissage fixés pour le niveau 1, et $S_1(\alpha, \beta)$ est la nouvelle fonction de synergie, reflétant la proximité ou la compatibilité entre super-nœuds $\mathcal{N}_\alpha^{(1)}$ et $\mathcal{N}_\beta^{(1)}$. Cette dynamique auto-organisée permet de repérer à ce **deuxième palier** des regroupements $\{\mathcal{C}_p^{(1)}\}$ que l'on convertit ensuite en super-nœuds $\mathcal{N}_p^{(2)}$ pour le **niveau 2**, et ainsi de suite. En itérant le processus, on peut progressivement atteindre un **macro-niveau** (niveau K) où il ne reste plus qu'un petit nombre de super-nœuds de grande taille, voire un seul **macro-nœud** global.

D. Progression jusqu'au Macro-Nœud

La répétition de l'agrégation forme une **cascade** :

61. Le niveau 0 détecte des micro-clusters $\mathcal{C}_\alpha^{(0)}$.
62. Les micro-clusters sont condensés en super-nœuds $\mathcal{N}_\alpha^{(1)}$.
63. Le niveau 1 détecte à son tour des clusters $\mathcal{C}_p^{(1)}$ parmi les super-nœuds déjà existants.
64. Ces regroupements sont convertis en super-nœuds $\mathcal{N}_p^{(2)}$.
65. Le niveau 2 poursuit le même mouvement, etc.

Ce **principe** bottom-up s'arrête lorsque le nombre de super-nœuds restants est faible (par exemple, un unique macro-nœud englobant tout), ou lorsque certains **critères** d'arrêt (seuil de similarité, contrainte de taille, etc.) sont atteints. La complexité $O(n^2)$ potentiellement nécessaire pour mettre à jour toutes les liaisons au niveau micro se résorbe au profit d'un nombre plus restreint de liaisons $O(m^2)$ au fur et à mesure que $m \ll n$.

Conclusion

Le processus de **détection de micro-clusters** et la création de **super-nœuds** (puis de **macro-nœuds**) constitue l'une des approches les plus directes pour construire une hiérarchie dans un **Deep Synergy Learning**. En partant des pondérations au **niveau micro**, on détecte les sous-ensembles d'entités fortement synergiques, on les agrège en super-nœuds et l'on répète la même logique de **mise à jour** et d'**auto-organisation** sur les nouveaux niveaux. Cette **progression** bottom-up confère une structure multi-niveau organique et réduit progressivement la complexité, tout en maintenant la **cohérence** du réseau. Les micro-clusters apparaissent comme le socle de base, suivi par des regroupements de plus en plus larges, jusqu'à un **macro-nœud** unique, si tel est l'objectif final. C'est précisément cette capacité à gérer les données ou les agents "depuis la racine" jusqu'à l'échelle la plus large qui fait la force du **DSL** en environnement hétérogène ou massivement distribué.

6.5.1.2. Avantages : Construction Organique, Moins de Paramétrage Initial

Introduction. La stratégie **bottom-up** d'agrégation progressive, décrite précédemment pour bâtir une hiérarchie de super-nœuds (section 6.5.1.1), comporte des avantages significatifs lorsque l'on souhaite structurer un **Synergistic Connection Network (SCN)** en plusieurs échelles de manière flexible. Contrairement aux approches imposant dès le départ un découpage (top-down) ou un nombre fixe de partitions (clustering global), l'agrégation **bottom-up** offre une **construction organique** qui épouse la dynamique locale du **DSL** et réclame un **paramétrage** minimal. Les développements ci-après mettent en évidence les principaux bénéfices, tout en situant cette démarche par rapport à d'autres méthodes.

A. Construction Organique

La première caractéristique marquante de l'agrégation **bottom-up** tient au fait qu'elle est en phase directe avec la **dynamique** locale du Deep Synergy Learning. Au **niveau micro**, on met en œuvre la règle DSL :

$$\omega_{i,j}^{(0)}(t+1) = \omega_{i,j}^{(0)}(t) + \eta_0 [S_0(i,j) - \tau_0 \omega_{i,j}^{(0)}(t)].$$

Cette équation favorise l'émergence de **micro-clusters** $\{\mathcal{C}_\alpha^{(0)}\}$ qui se forment dès lors que certaines paires ou triplets d'entités présentent une synergie récurrente. Contrairement à une coupe arbitraire, ces groupes se **stabilisent** naturellement sous l'effet des renforcements et des décroissances sélectives de $\omega_{i,j}$. L'agrégation progressive prend alors ces micro-clusters comme points de départ et les élève au palier supérieur sous forme de super-nœuds, sans brusquer la progression de l'auto-organisation locale.

Une fois les micro-clusters détectés, on ne “saute” pas immédiatement à un macro-niveau unique, on laisse la possibilité de créer des **niveaux intermédiaires** (méso-niveaux), répétant la mise à jour DSL. Les fusions successives reproduisent une logique de **croissance progressive**, proche de mécanismes observés dans des contextes biologiques ou sociologiques, où de petits groupements se consolident en sous-communautés avant d'aboutir, le cas échéant, à des structures englobantes plus vastes.

Cette architecture bottom-up se révèle extrêmement **adaptative**. Si de nouveaux liens $\omega_{i,j}$ apparaissent (ou se renforcent) au niveau micro, cela provoque la création (ou la reconfiguration) de clusters. Ces changements locaux se répercutent naturellement aux paliers supérieurs, lesquels peuvent également réajuster leurs super-nœuds ou fusionner des groupes si la synergie l'exige. La **souplesse** qui en découle est particulièrement cruciale dans des environnements évolutifs ou soumis à des flux de données continus.

B. Moins de Paramétrage Initial

Contrairement aux approches top-down, où il faut généralement définir un **nombre de partitions** dès le début (ex. dire “on veut 5 clusters” ou “on découpe en 3 niveaux de taille égale”), l'agrégation **bottom-up** se limite à un **faible** nombre de paramètres.

Les seuls éléments imposés concernent la **règle de mise à jour** (taux η_0 , décroissance τ_0 , etc.) et la **fonction de synergie** $S_0(i,j)$. Éventuellement, on peut définir un **seuil** pour reconnaître qu'un groupe local est assez cohésif, mais sans imposer la forme ou la taille exacte de chaque cluster.

Il n'est pas nécessaire de fixer a priori le nombre exact de clusters, ni même de préciser la profondeur de la hiérarchie. Les niveaux intermédiaires surgissent **spontanément** dès lors que des sous-ensembles \mathcal{C}_α se distinguent et sont jugés suffisamment stables pour être agrégés. La hiérarchie finale – pouvant s'arrêter à 1, 2, 3 ou plus de niveaux – est ainsi **découverte** plutôt qu'imposée.

Lorsque le partitionnement est dicté en amont, on court le danger de forcer des **découpages artificiels**, mal adaptés à la structure réelle des synergies $\omega_{i,j}$. L'approche **bottom-up** évite ces erreurs en laissant la dynamique et les degrés de cohésion déterminer les regroupements. Les grands clivages dans le réseau émergent **naturellement** s'ils sont effectivement présents, tandis que les liens de force intermédiaire aboutissent à des fusions partielles ou restent séparés.

C. Implications Pratiques

La mise en place d'une agrégation **bottom-up** se traduit par une séquence d'étapes :

66. Boucles d'Itération au Niveau Micro.

Le réseau exécute la règle DSL pendant un certain nombre d'itérations, renforce les liens synergiques et affaiblit les autres.

67. Détection/Actualisation des Micro-Clusters.

On identifie les groupes ayant atteint une cohésion suffisante.

68. Construction du Palier Supérieur.

Chaque micro-cluster devient un super-nœud, et l'on agrège les poids $\omega^{(0)}$ pour former $\omega^{(1)}$.

69. Mise à Jour au Niveau Méso.

Le même procédé d'**auto-organisation** se poursuit, cette fois entre super-nœuds, jusqu'à former de nouveaux regroupements $\mathcal{C}_\alpha^{(1)}$.

70. Prolongement ou Arrêt.

On répète les paliers tant qu'il reste un intérêt à poursuivre l'agrégation. S'il ne subsiste qu'un petit nombre de super-nœuds ou un unique **macro-nœud**, on stoppe la progression.

Cette stratégie présente une **scalabilité** naturelle : chaque palier réduit le nombre de nœuds en agrégeant ceux qui sont trop fortement liés, ce qui évite d'opérer en permanence à l'échelle du réseau entier. Par ailleurs, elle autorise une **synchronisation ascendante** : on attend que le niveau micro se stabilise avant de promouvoir la structure au palier suivant, maintenant ainsi une cohérence hiérarchique plus solide.

Conclusion

L'agrégation **bottom-up** offre à la fois une **construction organique** totalement alignée sur la dynamique locale du **DSL** et un **paramétrage réduit** à l'essentiel (paramètres de la règle DSL, éventuellement un critère de détection de clusters). Les clusters émergent librement, fusionnent ou s'ignorent selon les synergies perçues dans le réseau, et la hiérarchie finale se forme pas à pas, en respectant la **réalité** des liens $\omega_{i,j}$. Les avantages de ce procédé – flexibilité, adaptabilité, minimisation des découpages arbitraires – en font un choix particulièrement attrayant pour gérer des structures **massivement distribuées** ou pour modéliser des processus d'**auto-organisation** complexes où l'on ne souhaite pas imposer de partitions rigides a priori.

6.5.1.3. Inconvénients : Besoin d'Algorithmes “Greedy” ou Heuristiques, Potentiels Merges Successifs

La démarche **bottom-up** (agrégation progressive) exposée dans les sections précédentes (6.5.1.1 et 6.5.1.2) apporte une flexibilité et une réduction du paramétrage initial, mais n'est pas exempte de limites. Elle repose souvent sur des **algorithmes** de fusion successifs, de type *greedy* ou **heuristiques**, et peut ainsi s'avérer délicate dans certaines circonstances. Les paragraphes qui suivent soulignent en particulier deux grandes familles d'inconvénients : l'impossibilité de garantir la fusion optimale (nécessitant des heuristiques), et le risque de **merges** itératifs pouvant conduire à des configurations sous-optimales par “erreur cumulative”.

A. Besoin d'Algorithmes Greedy ou Heuristiques

Dans un **SCN** (Synergistic Connection Network) de grande taille, trouver la **meilleure** manière de fusionner les micro-clusters est un problème qui, sous de nombreuses variantes (community detection, clustering hiérarchique optimal, etc.), est **NP-difficile**. Autrement dit, l'exploration exhaustive de toutes les possibilités de partitions ou de merges devient **inabordable** à mesure que le nombre d'entités croît. Vouloir choisir à chaque étape la fusion localement “idéale” – ou, plus encore, vouloir optimiser globalement l'agencement des fusions – se heurte à une **explosion** combinatoire. Cela rend quasi impossible, en pratique, l'obtention d'une **solution exacte** dès lors que n dépasse quelques dizaines ou centaines.

Pour contourner cette complexité, on recourt typiquement à des **procédures** itératives, dites *greedy merges*, où l'on :

- Cherche les deux clusters \mathcal{C}_α et \mathcal{C}_β qui présentent la **plus forte synergie** (ou dont la fusion entraîne la **meilleure réduction de coût** local),
- Fusionne ces deux ensembles en un **super-cluster** $\mathcal{C}_{\alpha\cup\beta}$,

- Met à jour la structure, puis répète l'opération jusqu'à ce qu'on atteigne un niveau jugé suffisant (arrêt par critère de taille, de niveau, ou de cohésion).

De nombreux schémas d'**agrégation hiérarchique** (single linkage, complete linkage, average linkage, etc.) s'appuient sur cette philosophie, en substituant un **score** de proximité ou de similarité entre clusters. Dans un **SCN**, on peut utiliser les **pondérations** $\omega_{\alpha,\beta}$ pour déterminer la force de rapprochement : plus $\omega_{\alpha,\beta}$ est élevée, plus il est tentant de fusionner les clusters α et β . Il s'agit cependant d'un **choix local**, qui ne garantit pas de maximiser la cohésion globale du réseau (ou de minimiser toute fonction de coût plus étendue).

B. Risques de Merges Successifs et Erreurs Cumulatives

Parce qu'on s'appuie sur une suite de **décisions locales** (fusionner deux clusters C_α et C_β si leur lien est jugé suffisant), il y a un risque d'**erreurs** successives qui finissent par s'accumuler dans la configuration finale.

La règle *greedy* peut pousser à fusionner rapidement deux clusters dont la synergie est pour l'instant dominante, mais qui pourraient en réalité être mieux agencés (ou scindés) si l'évolution du réseau se prolongeait. On peut voir cela comme un *verrouillage* : une fois la fusion effectuée, le nouveau super-cluster $C_{\alpha\cup\beta}$ est rarement redécomposé au sein du même algorithme bottom-up. Des “fusions hâtives” de ce type peuvent enfermer la hiérarchie dans un état sous-optimal.

Dans la plupart des implémentations, l'**agrégation progressive** ne prévoit pas de “**dé-fusion**” ou de *split* durant le même cycle d'ascension. Il faudrait recourir à des *extensions* plus complexes (chap. 6.5.2 sur des divisions possibles, ou des mécanismes top-down correctifs) pour rétablir une répartition plus adaptée.

Sans cette possibilité de correction, chaque petit choix local vient s'inscrire dans la structure globale, risquant de créer une **erreur cumulative** au fil des paliers.

Si l'on associe à la partition du réseau une **énergie** (ou “coût”) \mathcal{E} à minimiser, tout algorithme de fusion local vise à réduire $\Delta\mathcal{E}$ sur l'instant. Or, un optimum local n'est pas nécessairement un optimum global, et, en multipliant les “petites optimisations” locales, on peut aboutir à un état final nettement plus élevé en \mathcal{E} que la **configuration** la plus favorable.

C. Conséquences Pratiques et Possibles Solutions

Ces inconvénients ne rendent pas l'agrégation *bottom-up* inopérante, mais soulignent la nécessité de précautions ou de *mécanismes complémentaires*.

Il est fréquent d'introduire un **feedback descendant** (cf. 6.4) au cours duquel un niveau supérieur peut suggérer la rescission d'un cluster si la macro-analyse repère des incohérences. Cela donne un algorithme plus complet, où la construction bottom-up est **assouplie** par des corrections top-down.

Dans des architectures DSL complexes, ce double flux (ascendant et descendant) permet de retarder ou d'inverser certaines unions malheureuses.

S'il n'existe pas de mécanisme de “re-diviser”, on peut subir d'importants effets d'inertie. Une fusion inappropriée à la première étape se répercutera dans les paliers ultérieurs, menant parfois à une structure loin de l'optimum. À l'inverse, si on autorise trop facilement la division, il y a un risque d'oscillations (fusions défusions récurrentes).

Des **seuils** ou paramètres de stabilisation (hystérésis, temporalité de mise à jour) aident à limiter ces phénomènes.

En dépit de ces limites, un algorithme *greedy* de fusion hiérarchique reste souvent **très rapide** et **simple** à mettre en œuvre. Il donne des résultats satisfaisants dans la majorité des scénarios pratiques, pourvu qu'on accepte une configuration “raisonnablement bonne” plutôt que *parfaitement optimale*.

Conclusion

Le **bottom-up** en agrégation progressive (cf. 6.5.1.1–6.5.1.2), bien qu'utile pour **construire** et **réduire** un **SCN** sur plusieurs paliers, souffre de **deux** inconvénients majeurs :

71. Recours quasi obligatoire aux heuristiques ou règles *greedy*.

Les fusions successives impliquent un choix local, puisque la solution globale est **NP-difficile**. Les algorithmes de type single linkage, average linkage, ou fusion par “plus forte synergie” n’assurent donc pas un optimum global.

72. Risque d’erreurs cumulatives.

Les “merges” successifs peuvent verrouiller la hiérarchie dans une configuration sous-optimale si aucune procédure de vérification ou de *dé-fusion* n’est envisagée. Cela appelle, en pratique, des **approches hybrides** mixant *bottom-up* et corrections top-down pour se prémunir des unions précipitées.

Ainsi, la **conclusion** s’impose : l’agrégation **bottom-up**, tout en **facilitant** la construction organique et **réduisant** le paramétrage, doit s’accompagner de **gardes-fous** (soit via un niveau supérieur actif, soit via des mécanismes de division) pour que les “merges” successifs ne figent pas le réseau en un état peu satisfaisant. Dans un cadre **DSL** plus large, on considère souvent une **multi-directionnalité** (ascendant et descendant) afin de compenser ces faiblesses tout en conservant les bénéfices de la fusion progressive.

6.5.2. Division ou Zoom (Top-Down)

En **complément** de la logique d’agrégation (bottom-up) décrite en (6.5.1), certains **algorithmes** multi-niveau adoptent ou complètent l’approche **top-down**, où l’on **part** d’un **macro-cluster** global (ou d’un ensemble restreint de grands clusters) pour ensuite **segmentation** s’il apparaît que la **cohésion** interne est insuffisante. La section 6.5.2.1 introduit la notion d’une **approche fractale descendante**, qui renverse la perspective : plutôt que de fusionner progressivement, on “zoome” (divise) progressivement.

6.5.2.1. Approche Fractale Descendante : Partir d’un Cluster Global et le Segmenter si des Sous-Groupes se Forment

Contrairement à la logique **bottom-up**, qui agrège progressivement des micro-clusters vers des super-nœuds (section 6.5.1), la démarche **top-down** se propose de partir d’un **grand** ensemble englobant toutes les entités et d’y opérer des **divisions** successives dès que l’on détecte des “failles” ou des “sous-groupes” cohésifs. Cette approche se qualifie parfois de “fractale descendante” parce qu’elle reproduit à chaque échelle la même procédure de scission, révélant des **structures** de plus en plus fines. Les paragraphes suivants présentent le principe général, illustrent le lien avec la notion de fractalité, puis discutent les avantages et inconvénients de cette segmentation top-down.

A. Principe d’une Division/Zoom du Macro vers le Micro

La stratégie **top-down** consiste à partir d’un **unique** cluster (macro) qui inclut la totalité des entités $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$. On considère alors ce bloc global comme un “super-nœud” $\mathcal{N}^{(\text{global})}$. À ce stade, si l’on estime (via une fonction de cohésion, d’hétérogénéité ou de modularité) que ce vaste ensemble est **trop** hétérogène, on opère une **division** : on sépare $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$ en plusieurs **sous-clusters** plus homogènes.

On ne part pas d’entités dispersées, mais d’un bloc unique englobant tout. Cela peut correspondre à la situation où l’on sait d’emblée qu’il existe un *objectif commun* ou qu’un macro-niveau coiffe l’ensemble des agents (par exemple, un centre de commande). Dès lors qu’un critère d’hétérogénéité (ou de “faible synergie interne”) est détecté, on *scinde* le cluster macro en deux (ou plus) sous-blocs. Chaque sous-bloc \mathcal{C}_α , considéré comme un cluster local, peut faire l’objet du **même** examen, se divisant à son tour si nécessaire. À chaque niveau de division, la **même règle** s’applique : si un sous-ensemble est encore hétérogène, on le scinde de nouveau. Ce procédé descend petit à petit vers des regroupements de taille moyenne (mésos-niveau), puis éventuellement de petite taille (micro-niveau), tant que la cohésion interne n’est pas jugée satisfaisante.

B. Allusion à une Logique Fractale

Le terme “fractale” se réfère au fait que la même *loi* de division se reproduit à chaque échelle, dévoilant une **auto-similarité** structurale. On peut définir une **fonction** d’hétérogénéité \mathcal{H} mesurant dans quelle mesure un ensemble est “mélangé”. Si \mathcal{H} s’avère trop élevée pour le cluster global, on le coupe en deux blocs, puis on évalue \mathcal{H} dans chacun de ces blocs, et ainsi de suite :

$$\text{si } \mathcal{H}(\mathcal{C}) > \theta > \Rightarrow \text{division de } \mathcal{C} \text{ en sous-blocs } \mathcal{C}_\alpha, \dots, \mathcal{C}_\beta.$$

Cette itération (ou récursion) rappelle l’idée qu’en “zoomant” à un niveau plus fin, on applique la **même** loi de division, ce qui renvoie au concept d’**auto-similarité fractale** : le “motif” de segmentation se répète à chaque échelle jusqu’à atteindre un seuil de granularité.

C. Exemple d’Illustration : Cortex, Réseaux, etc.

Cortex. Si on envisage un ensemble de neurones occupant une zone cérébrale globale, on peut constater que certains neurones forment un sous-ensemble très interconnecté, ce qui justifie une **scission** dans la structure globale. On isole ce sous-groupe en tant qu’aire plus restreinte, puis on continue le même examen en son sein.

Réseaux (Graphes). Sur un graphe englobant toutes les entités, la détection de **communautés** peut s’effectuer en repérant des coupes ou des **faiblesses** dans la matrice de pondérations ω . Chaque fois qu’on découvre un sous-ensemble de nœuds mieux reliés entre eux qu’au reste du graphe, on scinde. Les sous-ensembles sont ensuite traités comme des graphes à part entière, dans lesquels on peut dénicher des sous-communautés supplémentaires.

Analogie fractale. Dans certains systèmes, cette hiérarchie descendante révèle des *patterns* identiques à différentes échelles, renforçant l’aspect fractal. Les mêmes principes de “cohésion interne” et de “faibles connexions externes” se répètent du niveau macro jusqu’au niveau micro.

D. Schéma Mathématique d’une Division Descendante

On note $\mathcal{N}_{\text{global}}^{(K)}$ le cluster unique contenant tous les indices. On évalue sa “cohérence” ou son hétérogénéité $\mathcal{H}(\mathcal{N}_{\text{global}}^{(K)})$. Si cette valeur reste en deçà d’un seuil θ_K , on décide de **conserver** le bloc entier. Sinon, on le segmente en plusieurs sous-ensembles.

À chaque découpage, un cluster $\mathcal{N}_\alpha^{(k)}$ est subdivisé en deux (ou plusieurs) sous-clusters $\mathcal{N}_{\alpha_1}^{(k-1)}, \mathcal{N}_{\alpha_2}^{(k-1)}, \dots$. On mesure ensuite $\mathcal{H}(\mathcal{N}_{\alpha_i}^{(k-1)})$ pour voir si on doit à nouveau “descendre” d’un cran. Cette itération se poursuit tant que l’on découvre des divisions nécessaires ou que l’on n’a pas atteint la taille souhaitée (niveau micro).

Le processus s’interrompt lorsque tous les *blocs* résultants satisfont un critère de cohésion, ou bien lorsqu’on considère qu’ils sont déjà suffisamment fins (niveau minimal). On obtient alors une hiérarchie descendante où chaque palier résulte de scissions itérées.

E. Avantages d’une Approche Top-Down

Le fait de commencer par un bloc global procure une **vision** macroscopique d’ensemble. Au lieu d’assembler lentement des micro-éléments, on *contrôle* tout de suite la partition du grand ensemble, ce qui peut être avantageux si le système est déjà régi par un cadre commun ou un gestionnaire central.

Dans une démarche descendante, on peut décider à chaque étape comment scinder le bloc (en deux, en trois, etc.) en fonction des **informations** dont on dispose (score de variance, synergie interne, etc.). On évite le risque d’avoir un trop grand nombre de micro-clusters non désirés au départ.

Si la structure du réseau présente une forme d’**auto-similarité**, la segmentation top-down la fait apparaître naturellement : on “zoome” dans le grand ensemble et retrouve la même loi de division. Cela peut être particulièrement intéressant dans des contextes où l’échelle macro est connue pour être hétérogène, mais où l’on s’attend à des *patterns* récurrents à des niveaux plus fins.

Malgré son intérêt, cette approche **top-down** soulève plusieurs questions :

73. **Choix du Critère de Division.**

Il faut définir comment on décide qu'un bloc est "trop hétérogène". Cette définition implique la mise en place d'une **fonction** \mathcal{H} (ou d'un critère d'énergie \mathcal{E}) et d'un **seuil** θ . Ces paramètres doivent être ajustés de manière à éviter soit l'absence de division (si θ est trop élevé), soit une segmentation excessive (si θ est trop bas).

74. **Décisions de Découpage.**

Une fois qu'on a décrété qu'un cluster se scinde, comment répartir les entités ? Faut-il un simple **bipartitionnement** ou bien une **multipartition** ? Les algorithmes de segmentation peuvent être aussi complexes que ceux employés en "cut" de graphes, nécessitant parfois des heuristiques (ex. minimisation d'une coupe, maximisation de la modularité locale).

75. **Risque de Sur-Segmentation.**

Si l'on n'y prend pas garde, on peut créer trop de sous-blocs. Certains systèmes peuvent présenter des liaisons d'intensité moyenne et non pas de fortes discontinuités, ce qui conduit à scinder trop finement et à rater la cohérence multi-niveau. Comme en bottom-up, des algorithmes heuristiques peuvent conduire à des configurations globalement sous-optimales.

Conclusion

L'**approche fractale descendante** (ou **top-down**) consiste à partir d'un **super-nœud** global, représentant l'ensemble du réseau ou des entités, et à **segmenter** progressivement ce bloc si l'hétérogénéité interne l'exige. À chaque division, la **même** règle est appliquée pour détecter des sous-groupes, jusqu'à ce que tous les clusters résiduels soient suffisamment cohésifs.

76. **Principe.** Le *zoom* du macro vers le micro reproduit la même dynamique à chaque échelle, dans un esprit fractal où la segmentation se répète si l'ensemble considéré reste trop "mêlé".

77. **Forces.** On bénéficie d'une **vision globale** dès le départ, et on garde un contrôle direct sur la découpe en nombre de sous-blocs.

78. **Faiblesses.** Le critère de division et les paramètres associés (seuil d'hétérogénéité, type de bipartition ou multipartition, etc.) peuvent s'avérer délicats à régler. On risque la **sur-segmentation** ou, au contraire, l'absence de division fine quand on emploie des heuristiques inadaptées.

Au final, cette méthode top-down apporte une solution complémentaire à la logique bottom-up (section 6.5.1). Dans les architectures **DSL** multi-niveau, il est courant de **mélanger** ces deux perspectives (voir section 6.5.3), permettant ainsi à la structure de se réorganiser à la fois par fusion **ascendante** et par subdivision **descendante**, assurant une hiérarchie ajustée à toutes les échelles.

6.5.2.2. Systèmes "Macro → Micro" : Si la Synergie Interne n'est pas Assez Homogène, On Scinde

Dans la dynamique **top-down** (ou descendante) de la construction multi-niveau, il est possible de partir d'un **ensemble englobant** (un ou plusieurs gros clusters) et de **scinder** ceux-ci dès que leur cohésion interne est jugée insuffisante. Cette logique se fonde sur l'idée de "zoomer" progressivement : on ne crée pas de micro-clusters dès le départ, mais on initialise un **bloc global** et on le subdivise au fur et à mesure que la synergie interne se révèle inhomogène. Les sections suivantes détaillent le principe, illustrent la mécanique de division, et exposent les avantages comme les contraintes pratiques de ce mode "macro → micro".

A. Principe : Partir d'un (ou de quelques) Grand(s) Bloc(s)

Une caractéristique fondamentale de la démarche top-down est qu'elle **commence** par un **très gros cluster** — parfois unique — couvrant la totalité ou une grande portion de l'ensemble $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$. D'un point de vue pratique, on peut considérer qu'une entité $\mathcal{N}^{\text{global}}$ réunit tous les indices dans un **super-nœud**. On analyse alors la **cohérence** de ce super-nœud :

79. Définition d'un cluster macro initial.

On note $\mathcal{C}^{(\text{macro})}$ ce grand bloc. Dans certains contextes, cette configuration est naturelle : un système robotique opérant sous un même contrôle, une base de données qu'on n'a pas encore partitionnée, etc.

80. Analyse de la synergie interne.

On introduit un **critère** $\mathcal{H}(\mathcal{C}^{(\text{macro})})$ évaluant l'homogénéité ou la cohésion interne. Il peut s'agir d'un indicateur calculé à partir des poids $\omega_{i,j}$ (moyenne, variance, distribution des liaisons, etc.), ou d'une mesure plus large (taux d'accord sémantique, par exemple).

$$\mathcal{H}(\mathcal{C}) = f(\{\omega_{i,j}\}_{i,j \in \mathcal{C}}).$$

Si \mathcal{H} est trop élevé (sous l'hypothèse que “trop élevé” signifie “trop hétérogène”), on entreprend une scission.

B. Si la Synergie Interne n'est pas Assez Homogène, On Scinde

Lorsqu'un cluster macro $\mathcal{C}^{(\text{macro})}$ s'avère **insuffisamment** cohérent, on le **divise**. Cela se traduit souvent par :

81. Décision de scission.

On identifie, au sein de $\mathcal{C}^{(\text{macro})}$, des sous-groupes plus denses ou des “failles” dans la matrice ω . On partitionne $\mathcal{C}^{(\text{macro})}$ en deux (ou plus) blocs, $\mathcal{C}_\alpha^{(\text{macro}-1)}$, $\mathcal{C}_\beta^{(\text{macro}-1)}$, ..., qui héritent chacun d'une **cohésion** mieux définie. Par exemple, on peut imposer un gain minimum $\delta > 0$ en termes de réduction de l'hétérogénéité :

$$\mathcal{H}(\mathcal{C}_\alpha)\mathcal{H}(\mathcal{C}_\beta) \leq \mathcal{H}(\mathcal{C}^{(\text{macro})}) - \delta.$$

82. Descente itérative.

Après cette première scission, on applique la **même** opération à chaque sous-cluster obtenu. Si l'on constate qu'un bloc reste trop hétérogène, on le scinde de nouveau, et ainsi de suite. D'un point de vue fractal, la **même** règle de division se reproduit à chaque niveau, tant que la **cohérence** n'est pas jugée satisfaisante.

83. Exemple de formulation.

On peut définir $\mathcal{H}(\mathcal{C})$ comme la **variance** des poids $\{\omega_{i,j}\}$ à l'intérieur de \mathcal{C} , ou comme un **écart** normalisé :

$$\mathcal{H}(\mathcal{C}) = \frac{1}{|\mathcal{C}|^2} \sum_{i,j \in \mathcal{C}} |\omega_{i,j} - \bar{\omega}_{\mathcal{C}}|.$$

Si $\mathcal{H}(\mathcal{C}) > \theta$, on scinde. Les critères peuvent varier selon la nature des données et la signification de la synergie.

C. Avantages de ce Zoom Descendant

La logique “macro \rightarrow micro” recèle plusieurs **points forts** qui la distinguent de l'agrégation ascendante :

On commence par un ensemble unique, ce qui procure une **vue d'ensemble** sur l'intégralité du réseau. Cela évite de créer d'emblée de multiples clusters “éparpillés” qu'il faudrait ensuite fusionner.

Si le **SCN** possède une forme d’auto-similarité (section 6.3), cette descente révèle à chaque niveau des **motifs** comparables aux niveaux supérieurs. Chaque scission reproduit la même règle, “zoomant” dans le bloc pour en extraire des sous-blocs plus cohérents. Il est parfois plus naturel, pour des raisons d’ingénierie ou de supervision, de “partir grand” et de n’effectuer des partitions qu’en cas de nécessité. Cela correspond à un schéma où le macro-niveau règne et ne crée de subdivisions qu’en identifiant des segments mal intégrés.

D. Inconvénients à Garder à l’Esprit

Comme toute méthode descendante, ce schéma n’est pas exempt de **limitations** :

Risque de sur-segmentation. Si le critère d’homogénéité est trop exigeant, on risque de fragmenter exagérément le cluster macro, produisant nombre de petits blocs. Cela reflète une **division excessive** qui peut saper la compréhension globale ou perdre de la connectivité.

Paramétrage délicat. Il faut fixer un **seuil** θ ou un **niveau** de variance acceptable. Un θ trop bas conduit à ne jamais scinder, un θ trop haut peut déclencher des coupes incessantes. On se retrouve face à un problème similaire à la détermination du nombre k de partitions dans les algorithmes classiques de clustering.

Algorithmes non optimaux. Découper $\mathcal{C}^{(\text{macro})}$ de manière “parfaite” (minimisant une fonction de coût globale) est souvent **NP-difficile** si \mathcal{C} est volumineux. On recourt donc à des **heuristiques** (ex. on identifie un couplage faible entre deux groupes et on coupe le long de cette “faille”). Mais rien ne garantit l’optimalité de la répartition obtenue.

Moins de “naissance” organique. Contrairement à la démarche bottom-up, où les micro-clusters émergent localement sans action extérieure, ici la partition est décidée par un **niveau macro**, imposant la coupe depuis le haut. Cela peut être moins “naturel” dans un système où la dynamique DSL locale est la clé principale d’auto-organisation.

Conclusion

Dans un système “**macro** → **micro**”, on initialise la structure par un **grand** cluster englobant toutes les entités, et l’on **scinde** en sous-ensembles dès qu’un critère d’homogénéité (ou de cohésion interne) n’est plus satisfait. Cette logique **top-down** (ou fractale descendante) consiste à répéter la **même** règle de division à chaque niveau, en repérant des failles internes au bloc actuel. Elle apporte plusieurs **avantages**, notamment une **vue globale** immédiate et la possibilité d’ajuster *a priori* la segmentation. En revanche, elle requiert un **paramétrage** (définition d’un seuil, choix d’un algorithme de coupe) et peut **sur-fragmenter** le réseau si la synergie moyenne est faible ou si l’on exige une homogénéité trop stricte.

Comme souvent dans les architectures DSL multi-niveau, on obtient de bons résultats en **combinant** cette approche top-down avec la démarche bottom-up (chap. 6.5.3). L’une agit comme un filet de sécurité pour éviter une fusion exagérée, l’autre compense le risque de divisions superflues, aboutissant in fine à une hiérarchie plus stable et plus fidèle à la véritable configuration du **Synergistic Connection Network**.

6.5.2.3. Risques d’une Division Excessive ou de la Sur-Segmentation

Introduction.

Dans la démarche **top-down** (voir 6.5.2.1 et 6.5.2.2), on part d’un cluster global englobant toutes les entités, puis on le scinde dès que l’on juge sa cohésion interne insuffisante. Bien que cela permette de “zoomer” sur des sous-groupes plus homogènes, on court également le risque d’une **sur-segmentation** lorsque les critères de division sont trop stricts ou appliqués trop précocement. Il s’ensuit une multiplication de petits blocs, ce qui peut compromettre la logique de construction hiérarchique à moyenne ou grande échelle. Cette section examine les principaux **mécanismes** menant à la sur-segmentation, puis discute des **conséquences** et des **pistes** pour l’atténuer.

A. Mécanismes menant à la sur-segmentation

Dans un schéma top-down, on définit un **critère** $\mathcal{H}(\mathcal{C})$ évaluant l’hétérogénéité interne d’un cluster \mathcal{C} , associé à un **seuil** θ . Si θ est placé trop bas (ou la cohésion exigée est trop élevée), alors même des blocs relativement cohérents

apparaissent comme “insuffisamment homogènes”. Cela déclenche des **divisions** successives qui morcellent le réseau en de nombreux **petits** sous-groupes.

Sur le plan formel, la règle

$$\mathcal{H}(\mathcal{C}) > \theta \Rightarrow \text{scission de } \mathcal{C},$$

conduit à un découpage sans fin si θ ne tolère qu’un degré de cohésion interne excessivement élevé.

Dans certains systèmes top-down, on évalue la cohésion d’un cluster à chaque **itération**, sans laisser la dynamique locale (ex. mise à jour DSL) prendre le temps de renforcer les poids $\omega_{i,j}$ à l’intérieur du bloc. En ne laissant pas à la **synergie** le temps de se structurer, on perçoit hâtivement des failles internes. On segmente alors avant même que des liaisons fortes aient pu émerger.

Il s’ensuit une fragmentation rapide et parfois injustifiée : un bloc qui aurait pu devenir cohérent se voit coupé en deux, simplement parce qu’on n’a pas “attendu” la stabilisation des $\omega_{i,j}$.

Lorsque la division top-down ne s’accompagne d’aucune **possibilité de fusion** (retour arrière), chaque scission devient pratiquement **irréversible**. Ainsi, même si, à un moment ultérieur, des liens plus forts se forment entre deux blocs séparés, on reste avec un découpage trop fin.

Ce phénomène de **fragmentation irréversible** aboutit à une multitude de petits clusters : au fur et à mesure que la hiérarchie descend, elle ne propose jamais de *regroupement*, même si la dynamique change au sein du réseau.

B. Conséquences sur la structure multi-niveau

Un des apports majeurs d’une hiérarchie multi-niveau est de révéler des **clusters** de taille intermédiaire (méso) ou des macro-groupes rassemblant plusieurs entités fortement reliées. La **sur-segmentation** fait disparaître ces blocs plus vastes, puisque tout se retrouve scindé en unités trop petites.

Cela réduit la **clarté** de la structure : on obtient des “feuilles” de très faible cardinalité au lieu de “nœuds” significatifs. Au lieu de manipuler quelques dizaines de super-nœuds, on se retrouve avec une kyrielle de mini-blocs. Pour les niveaux supérieurs de la hiérarchie, le gain de simplification initialement espéré (moins de ω à gérer) se voit annihilé : on doit traiter un trop grand nombre de partitions, ce qui complique la gestion du réseau.

Dans des applications (ex. IA cognitive, robotique), on souhaite parfois que des sous-groupes partagent des ressources ou des tâches. Une sur-segmentation aboutit à des groupes hyper-spécialisés qui ne communiquent pas ou peu entre eux, et on perd la **coopération** inter-bloc. On sacrifie alors l’effet de mutualisation que vise une structure multi-niveau.

C. Pistes pour y remédier

La première mesure consiste à **redéfinir** le critère de division pour être moins sévère. Autrement dit, laisser plus de marge à la cohésion interne. On peut aussi imposer qu’un bloc ne soit évalué qu’après un certain délai, permettant aux $\omega_{i,j}$ de se renforcer si la dynamique DSL locale le justifie.

Avant de décider d’une scission, on peut laisser le bloc “mûrir” sous la règle de plasticité (renforcement/décroissance) un certain nombre d’itérations. Ce laps de temps permet à la synergie de s’établir, révélant qu’un groupe est en fait cohérent, et évitant une coupe précipitée.

Comme en bottom-up, un mécanisme de **fusion** au même niveau (cf. 6.4.3.2 sur la coordination latérale) ou une boucle de *feedback* descendant (cf. 6.4) peut éviter les scissions définitives. Même si un bloc a été scindé, si l’on constate ultérieurement une interaction forte entre deux mini-blocs, on peut les **ré-agrégier**.

Dans les grandes architectures DSL, on combine souvent **top-down** et **bottom-up** (cf. 6.5.3) : si le top-down divise trop, le *bottom-up* peut en parallèle fusionner certains blocs trop fins, assurant un équilibre entre scission et agrégation.

Conclusion

Lorsque la **logique descendante** (macro → micro) est appliquée de manière trop réactive ou sur la base d’un **seuil** trop exigeant, on assiste à un phénomène de **sur-segmentation** : les blocs se scindent en unités de plus en plus petites,

perdant l'essence d'une structuration hiérarchique utile. Les **causes** principales en sont des **critères de cohésion** excessivement stricts, l'absence de **délai** permettant à la synergie locale de s'installer et le manque de **mécanismes de réagrégation**.

Sur le plan **pratique**, il est donc crucial de **régler** avec soin la fonction \mathcal{H} (ou l'équivalent) et son seuil θ , d'introduire une **phase** d'auto-organisation avant toute scission, et/ou de permettre la **fusion** de blocs trop finement découpés. Cette approche prévient la fragmentation irréversible et préserve l'avantage d'une hiérarchie multi-niveau lisible, qu'on peut ensuite articuler avec d'autres mécanismes DSL (comme l'agrégation bottom-up ou la coordination latérale) pour obtenir une **structure** à la fois cohérente et flexible.

6.5.3. Hybridation (Approche Mixte)

Dans les sections précédentes (6.5.1 et 6.5.2), nous avons présenté deux grandes **orientations** pour structurer un SCN (Synergistic Connection Network) de manière multi-niveau : l'**agrégation progressive** (bottom-up) et la **division** (top-down). Cependant, dans la pratique, de nombreux **systèmes** tirent parti d'une **approche mixte** : on permet à la dynamique locale de **fuser** des entités ou micro-clusters (vision bottom-up), *mais* on conserve également la possibilité de **scinder** (top-down) quand un cluster devient trop hétérogène. Cette **hybridation** procure davantage de **flexibilité** et évite les limites inhérentes à la pure agrégation (6.5.1.3) ou la pure division (6.5.2.3).

6.5.3.1. Combiner Agrégation Partielle et Division Sélective pour plus de Flexibilité

Les approches **bottom-up** (voir 6.5.1) et **top-down** (voir 6.5.2) présentent chacune des limites. L'agrégation ascendante peut rapidement verrouiller le réseau dans une configuration sous-optimale à cause de fusions irréversibles, tandis que la scission descendante risque d'aboutir à des partitions excessivement fines. Une **stratégie hybride** reposant sur l'alternance de **phases** d'agrégation et de **phases** de division permet de maintenir la construction hiérarchique plus fluide et mieux adaptée aux fluctuations de la **synergie** ou de l'hétérogénéité. Les développements qui suivent décrivent ce principe mixte et ses avantages, en cohérence avec la logique DSL multi-niveau.

A. Motivation

Les démarches purement ascendantes induisent parfois des verrous irréversibles : en se fondant sur de multiples agrégations (voir section 6.5.1), on peut constituer de gros blocs cohésifs trop tôt, rendant difficile toute redistribution des entités si ces macro-groupes se révèlent incohérents. À l'inverse, une division uniquement descendante (voir section 6.5.2) peut provoquer une segmentation trop poussée et fragmenter la hiérarchie en innombrables petits sous-ensembles. Il devient alors pertinent de recourir à une **hybridation** qui exploite à la fois la fusion lorsqu'une forte synergie est constatée et la division sélective pour corriger les cas de hétérogénéité interne. Cette oscillation entre fusion et scission empêche les blocages inhérents aux approches unilatérales.

B. Principe de l'Approche Mixte

Le noyau méthodologique réside dans l'emploi successif de l'agrégation locale et de la détection d'incohérences macro, menant à des divisions ciblées. Dans un premier temps, on laisse la dynamique **bottom-up** rassembler des entités en super-nœuds à l'aide de la règle

$$\Delta \omega_{i,j}(t) = \eta [S(i,j) - \tau \omega_{i,j}(t)],$$

ce qui consolide les liens forts. Ensuite, si l'examen macro met en évidence une hétérogénéité dans un super-nœud $\mathcal{N}_\alpha^{(k)}$, on introduit un mécanisme de division locale qui affaiblit certains liens internes et aboutit à un découpage partiel. Ainsi, le réseau peut se réorganiser en continu et affiner la hiérarchie en fonction des variations de la synergie.

C. Rôle du Feedback Descendant

Pour réaliser concrètement la scission dans un super-nœud hétérogène, on fait appel à un **flux descendant** (voir 6.4.1.2) fondé sur un signal inhibiteur visant des liens internes spécifiques. Sur le plan mathématique, on peut l'écrire comme

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)] - \gamma \Delta_{\text{split}},$$

où $\Delta_{\text{split}} > 0$ réduit progressivement la pondération $\omega_{i,j}$ dans la zone désignée. En affaiblissant graduellement ces liens, on amorce la division ; si la situation évolue, le flux descendant peut être stoppé, ce qui évite les ruptures irréversibles. Ce **feedback** autorise une scission sélective et réversible, guidée par le niveau macro, qui surveille et corrige les configurations trop vastes ou incohérentes.

D. Équilibre Continu et Flexibilité

Avec la faculté de réaliser simultanément des **fusions** (renforcement) et des **divisions** (inhibition sélective), le SCN converge vers un **état stable** garantissant qu’aucun super-nœud n’est à la fois trop vaste et trop hétérogène, ni que la synergie entre blocs distincts soit négligée. Les risques liés à l’agrégation irréversible (voir 6.5.1.3) et à la sur-segmentation (voir 6.5.2.3) se trouvent atténués, car le réseau peut revenir sur ses choix ou affiner la hiérarchie au fur et à mesure des signaux multiblocs et des évaluations macro. On obtient ainsi une forme d’**équilibre continu**, dans la mesure où la topologie hiérarchique peut évoluer librement en réponse à la dynamique des pondérations $\omega_{i,j}$.

E. Exemples de Mise en Œuvre

Dans les **réseaux sociaux**, l’agrégation locale repose sur l’union d’individus partageant un même intérêt ou un renforcement de leurs liens, tandis que la division sélective prend effet si un “super-groupe” devient conflictuel : le niveau supérieur (modérateur) enclenche alors une scission partielle pour séparer des factions. Le résultat est un réseau social plus flexible, à l’abri d’une unique communauté géante qui manquerait de cohésion.

Dans les **systèmes robotiques**, les robots qui coopèrent forment des équipes par agrégation. Un contrôle global peut néanmoins forcer la scission d’une sous-équipe si elle poursuit un objectif différent ou si la communication interne se dégrade, ce qui produit un SCN adaptatif où les équipes se forment et se défont en fonction des missions.

Dans les **systèmes sensoriels ou cognitifs**, on peut fusionner des capteurs (ou neurones) fortement corrélés, tandis que le niveau macro “coupe” un bloc bruyant ou conflictuel, isolant les signaux perturbateurs et réassignant éventuellement ces entités ailleurs. Cette logique reflète une **auto-organisation** à deux vitesses, ascendante pour la cohérence locale et descendante pour la répartition sélective.

F. Avantages de la Démarche Mixte

Cette démarche offre des **avantages** considérables en termes de **flexibilité et d’adaptation** : les erreurs typiques d’une approche purement bottom-up (accumulation d’erreurs, agrégations irréversibles) ou d’une approche purement top-down (fragmentation excessive) sont corrigées par la liberté de fission et de fusion contrôlées. Cette souplesse se traduit aussi par une **robustesse vis-à-vis du changement** : lorsque les conditions du réseau se modifient (insertion de nouvelles entités, évolutions de synergie), l’option de “fusion/division” se maintient, ce qui est crucial dans un contexte **temps réel** ou des flux de données constants. De plus, le **contrôle multi-niveau** assure que la logique DSL reste locale (pour le renforcement des liens) alors que l’analyse macro (pour la division éventuelle) s’opère en **feedback** descendant, permettant une régulation hiérarchique efficace.

G. Points à Surveiller

Un des **inconvenients** majeurs tient au risque d’oscillations, lorsque le réseau oscille entre un bloc fusionné puis scindé, puis refusionné. Pour éviter ce “va-et-vient” perpétuel, on introduit souvent des **seuils d’hystérésis** ou des **périodes de stabilisation**, empêchant la redécoupe immédiate d’un bloc à peine fusionné. La **complexité algorithmique** est également plus élevée, car on doit gérer simultanément les règles ascendantes et descendantes, définir des priorités entre fusion et scission, et paramétrer leur temporalité. Si le réseau n’exige pas un tel degré de flexibilité, la difficulté accrue peut ne pas se justifier. Cependant, la comparaison aux approches pures montre que cette méthode **mixte** gagne en souplesse et n’est que légèrement plus complexe à mettre en œuvre.

Conclusion (6.5.3.1)

L’hybridation de l’**agrégation partielle** (bottom-up) et de la **division sélective** (top-down) dans un SCN multi-niveau constitue un levier crucial pour éviter l’accumulation d’erreurs par des fusions irréversibles ou la sur-fragmentation de la structure. Le réseau peut auto-organiser des clusters stables là où la synergie est élevée, tout en restant capable de

scinder un groupe hétérogène, conférant plus de **flexibilité** et de **résilience**. Cette alternance de phases, renforcée par un **feedback** macro sélectif, apparaît donc comme une solution permettant au SCN de s'adapter en continu, de progresser vers un équilibre hiérarchique où chaque super-nœud demeure cohérent mais jamais définitivement verrouillé, et de satisfaire aux besoins d'un environnement changeant ou d'objectifs évolutifs.

6.5.3.2. Applications : Systèmes Complexes à Grande Échelle (Réseaux Sociaux, Sensoriels)

Les **systèmes complexes** de grande envergure, tels que les **réseaux sociaux** massifs ou les **réseaux de capteurs** (IoT), sont des terrains privilégiés pour mettre en œuvre l'**approche mixte** décrite précédemment (voir section 6.5.3.1). Dans ces environnements, la quantité d'entités peut s'élever à des milliers ou millions, et la structure de leurs liens $\omega_{i,j}$ ou de leur synergie évolue rapidement. Il s'avère essentiel d'y autoriser non seulement l'**agrégation ascendante** (mécanismes *bottom-up*) mais aussi la possibilité d'une **division sélective** (mécanismes *top-down*) afin d'ajuster en continu la hiérarchie et d'éviter la stagnation dans une configuration inadaptée. Cette **flexibilité** est d'autant plus cruciale que les liens se forment, se transforment ou disparaissent à un rythme soutenu, selon les interactions sociales ou les corrélations de mesure.

A. Réseaux Sociaux de Grande Échelle

Dans un **réseau social**, les utilisateurs peuvent être représentés par des nœuds $i \in \{1, \dots, n\}$, et les pondérations $\omega_{i,j}(t)$ refléteront la force de leur interaction à l'instant t . On peut définir une **similitude** ou **corrélation** $\text{corr}(X_i, X_j)$, où X_i et X_j sont des vecteurs ou historiques d'activité (échanges, centres d'intérêt, contenus partagés). La **dynamique DSL** appliquée localement en mode *bottom-up* prend souvent la forme :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta [\text{corr}(X_i, X_j) - \tau \omega_{i,j}(t)],$$

ce qui consolide les liens entre utilisateurs fortement corrélés. Les agrégations successives (voir 6.5.1) aboutissent à des micro-communautés ou super-groupes, mais elles peuvent enfermer à long terme des factions distinctes dans un même bloc. La **division sélective** (voir 6.5.2) intervient alors pour scinder un macro-groupe jugé trop grand ou hétérogène, par exemple en introduisant un **feedback** descendant qui réduit la pondération $\omega_{i,j}$ entre sous-groupes "rivaux". Concrètement, on ajoute un terme négatif $\gamma \Delta_{\text{desc}}$ si l'on repère un conflit interne, comme une divergence idéologique ou un clivage d'intérêt. Le réseau social peut ainsi "respirer" : il fusionne localement dès que la synergie est forte, puis scinde un ensemble si une scission partielle devient nécessaire. Les **exemples** incluent des communautés spontanées (rassemblées par un événement viral), qui se subdivisent ultérieurement quand différentes factions divergent. L'**avantage** tient dans la **réactivité** et la **scalabilité** : le système agrège ou segmente, préservant une hiérarchie modulaire, plutôt que de se figer en un seul bloc ou de se dissoudre en myriades de petits groupes.

B. Systèmes Sensoriels (IoT, Réseaux de Capteurs)

Dans un **réseau de capteurs** dispersés (IoT), le nombre d'appareils peut aussi atteindre l'échelle du million. Chaque capteur i fournit une mesure $X_i(t)$, et l'on peut définir la pondération $\omega_{i,j}$ à partir d'une **distance inversée** ou d'une **corrélation** sur les signaux $\{X_i(t)\}$. Une règle DSL *ascendante* :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta [\text{similarite}(X_i, X_j) - \tau \omega_{i,j}(t)]$$

permet la formation progressive de clusters ou zones cohérentes, rassemblant les capteurs dont les mesures sont proches. Cependant, un unique "super-cluster" peut s'avérer trop vaste et contenir des capteurs géographiquement ou fonctionnellement très différents. Le mécanisme de **division** *top-down* autorise alors la **scission** si un algorithme de contrôle macro détecte un "mélange" inattendu. Cette division, mise en œuvre par un signal descendant δ_{split} qui abaisse certaines $\omega_{i,j}$, préserve la possibilité d'une réorganisation spatiale : certains capteurs se regrouperont différemment, donnant lieu à une architecture multi-niveau plus stable et mieux segmentée.

La **flexibilité** de l'agrégation–division se révèle cruciale dans un système IoT où la topologie évolue (nouveaux capteurs, pannes, variations de signaux), et où la qualité de service dépend d'une segmentation performante. Plutôt que de se figer dans des macro-zones fixes, on s'adapte aux variations locales et globales.

C. Conclusion et Généralisation

De nombreux **systèmes complexes** — qu’il s’agisse de **réseaux sociaux** ou de **réseaux de capteurs** — profitent considérablement de la logique **hybride** (voir 6.5.3.1) qui allie l’agrégation ascendante et la division descendante. Les entités ou capteurs se regroupent localement lorsqu’une forte synergie ou similarité se manifeste, garantissant un gain d’organisation. Lorsqu’un macro-groupe se révèle trop grand ou hétéroclite, une **division sélective** assure un rééquilibrage. Cette cohabitation de fusion et scission, rendue possible par la **dynamique DSL** et le **feedback**, confère une **adaptation** permanente. Les **exemples** incluent des communautés sociales formées puis reconfigurées, ou des clusters de capteurs agrégés puis redécoupés. Les **formules** simples mentionnées pour la mise à jour :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[\text{corr}(X_i, X_j) - \tau \omega_{i,j}(t)] \quad (-\gamma \Delta_{\text{desc}} \text{ si scission}).$$

illustrent comment l’agrégation correspond à un **renforcement** de $\omega_{i,j}$ pour $\text{corr}(X_i, X_j)$ élevée, alors que la division se modélise par un terme négatif $-\gamma \Delta_{\text{desc}}$. Dans l’un et l’autre cas, l’**auto-organisation** hiérarchique demeure en mouvement : l’approche mixte se révèle alors la plus à même de gérer la variabilité et l’évolution à grande échelle de tels réseaux.

6.5.3.3. Observation des Patterns Fractals si le Cycle Agrégation–Division Suit une Logique de Récurrence

Cadre et Motivation. Les sections précédentes ont montré qu’une **approche hybride** (section 6.5.3.1) combine les mécanismes **bottom-up** (agrégation) et **top-down** (division) dans la construction hiérarchique d’un **SCN** (Synergistic Connection Network). Il apparaît, dans certaines configurations, qu’un **cycle** récurrent d’agrégation et de division puisse émerger : des groupes se forment lorsque leur synergie est élevée, puis se scindent à nouveau lorsqu’ils deviennent trop hétérogènes. Lorsqu’une telle dynamique se reproduit à différents paliers (ou échelles) avec la même *loi* d’auto-organisation, on constate parfois l’apparition de **patterns fractals**, traduisant une **auto-similarité** ou **invariance d’échelle**. Les développements qui suivent analysent comment ce cycle agrégation–division engendre des régularités fractales, et quelles hypothèses sont nécessaires pour les observer.

A. Logique de Répétition et d’Échelle

La notion de **fractale** (chap. 6.3) se définit classiquement par une propriété d’**auto-similarité** : le même schéma de construction (ou d’évolution) se reproduit à plusieurs niveaux de **granularité**, sans introduire d’échelle caractéristique fixe. Dans le contexte d’un **cycle** combinant agrégation et division, ce comportement se concrétise si, à chaque itération ou à chaque palier, la *même* règle DSL localement et la *même* procédure de scission globalement se déploient.

On suppose qu’à un moment donné, des entités (ou clusters) se **fusionnent** partiellement si leur pondération $\omega_{i,j}$ est assez élevée, conduisant à la création de super-nœuds. Dès qu’un super-nœud devient lui-même trop grand ou trop hétérogène (critère \mathcal{H} trop élevé), une **division** le scinde en sous-blocs. Les deux (ou plusieurs) blocs nés de la scission peuvent à leur tour vivre la même alternance de fusion avec d’autres blocs et de division interne. Cette **récurrence** d’un schéma de “fusion si cohérent, division si incohérent” constitue une base favorable à l’**invariance d’échelle**.

Pour que cette récurrence se traduise en **patterns fractals**, il faut que les **paramètres** η , τ , ou le critère \mathcal{H} de division ne fixent pas un unique “seuil absolu” de taille, mais soient paramétrés **relativement** à la structure courante. Autrement dit, si, à chaque échelle, la règle DSL et la procédure de scission conservent la *même forme*, on ne rompt pas la *loi de croissance* ni la *loi de découpage*. Dès lors, le système peut afficher des **lois de puissance** en termes de distribution de tailles de clusters, signatures typiques des structures fractales. On peut imaginer un bloc \mathcal{C} de taille N . À chaque cycle, un sous-ensemble de αN entités fusionnent avec βN entités voisines si leur synergie dépasse un **seuil** relatif, puis on scinde γN entités si leur cohésion chute en deçà d’un certain ratio. Une telle règle, conservée à chaque palier, entretient un “même flux” à chaque échelle, propice à la fractalité.

B. Mécanisme de Stabilisation Fractale

Le **DSL** (Deep Synergy Learning) met à jour les pondérations $\omega_{i,j}$ sous une forme générale :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)] + \Delta_{\text{feedback}}(i,j),$$

où $\eta > 0$ et $\tau > 0$ paramètrent le renforcement/décroissance, tandis que Δ_{feedback} reflète les influences descendantes (scission sélective) ou latérales (coordination). Si Δ_{feedback} applique **la même** forme d’inhibition (ou de récompense) à chaque “palier” avec un rescaling adapté à la taille courante, la dynamique DSL aboutit parfois à un **cycle récurrent** ; des clusters se forment par renforcement, s’agrandissent, puis reçoivent un retour descendant provoquant une scission partielle lorsque leur hétérogénéité interne augmente.

Un **renforcement local** se produit lorsque les entités ou *clusters* présentant une synergie élevée $S(i, j)$ consolident leurs liens et se rassemblent en blocs plus vastes, tandis qu’une **inhibition macro** s’exerce si un bloc \mathcal{C}_α présente une trop grande dispersion, dans ce cas, une procédure descendante réduit spécifiquement les pondérations $\omega_{i,j}$ responsables de la discorde, forçant ainsi la scission de \mathcal{C}_α en sous-blocs plus homogènes. Cette dynamique se **répète** à chaque niveau : dans un esprit fractal, on réapplique la même logique indépendamment du fait que \mathcal{C}_α regroupe 50, 500 ou 50 000 entités, si bien que l’on observe des **motifs auto-similaires**, avec agrégation localement et division globalement, à chaque échelle.

C. Observations Pratiques et Limites

Les **patterns fractals** déployés dans un réseau hiérarchique reposent sur l’idée que la **même** combinaison de renforcement et d’inhibition agit à toutes les échelles de la structure. Cette exigence d’**auto-similarité** peut cependant être mise en péril si l’on introduit une rupture de symétrie d’échelle. Il se produit alors une “cassure” dans la cohérence fractale si, par exemple, les seuils de scission θ_k diffèrent trop fortement d’un palier k à l’autre, ou si le taux η est multiplié par un facteur grandissant à mesure qu’on progresse dans la hiérarchie. Il en résulte qu’une échelle caractéristique apparaît et détruit le principe d’invariance.

Un second écueil consiste en un **risque d’oscillation** voire de quasi-chaos si la logique macro descendante intervient de manière trop fréquente. Il se peut qu’un cluster émerge localement, puis se retrouve scindé au niveau supérieur, puis se reforme, engendrant une dynamique d’allers et retours incessants. Pour qu’une **structure fractale** stable (ou un régime quasi-périodique) puisse s’établir, il est souvent nécessaire d’introduire un mécanisme d’**hystérésis** ou un délai temporel dans le déclenchement des fusions et divisions, afin de prévenir les réorganisations à trop haute fréquence.

Un troisième point d’intérêt réside dans les **exemples de lois de puissance** qui peuvent s’ensuivre. On peut observer, dans certains scénarios, un spectre des tailles de clusters satisfaisant une **distribution** $P(N) \propto N^{-\alpha}$. Dans ce cas, on se situe face à un **comportement fractal** (ou un état critique) qui se manifeste lorsqu’il n’existe pas d’échelle caractéristique imposée au réseau. Pour vérifier cette structure “scale-free”, on recourt fréquemment à des analyses en représentation log-log ou à des mesures de **box-counting** permettant d’évaluer la dimension fractale du système, que ce soit dans la topologie spatiale ou dans la distribution des connexions. Il convient de souligner que cette propriété n’est pas automatique : un suivi rigoureux du réseau est nécessaire pour confirmer que l’**auto-organisation** aboutit bien à une loi de puissance significative, et le moindre paramètre susceptible de varier d’un palier à l’autre peut rompre cette loi et faire disparaître la fractalité attendue.

Conclusion (6.5.3.3)

Lorsque le **cycle agrégation–division** (voir 6.5.3.1) s’opère de manière **récurrente**, sans échelle de taille imposée, il peut conférer au **SCN** une forme d’**auto-similarité** dans son organisation. Des *patterns fractals* apparaissent alors, témoignant d’une **invariance d’échelle** : la même dynamique DSL (renforcement local, scission globale) se reproduit à différentes granularités, si bien que l’on peut observer des lois de puissance ou des signatures fractales dans la distribution des tailles de blocs ou dans la structure des liens $\omega_{i,j}$.

La **logique** fractale se caractérise par une **loi** de répétition identique à chaque palier : la fusion opère sur les paires (ou micro-clusters) synergiques, la division intervient sur tout bloc hétérogène, et le tout se répercute sur l’ensemble du réseau *sans* briser la cohérence des paramètres. Dans un tel cadre, le **SCN** se transforme en un système *autosimilaire*, où la hiérarchie ne se fige jamais définitivement, mais évolue par un enchaînement continu de fusions partielles et de scissions sélectives, générant un motif fractal *persistant* ou *périodique*.

6.5.4. Algorithmes de Mise en Œuvre

Après avoir décrit les principes (agrégation vs. division) et l'idée d'une approche **mixte** (6.5.3), il est temps d'aborder plus **concrètement** la dimension algorithmique. La section 6.5.4.1 propose un **pseudo-code** illustratif qui montre comment, dans un **SCN** (Synergistic Connection Network), on peut :

84. **Détecter les micro-clusters**,
85. **Fusionner** ces micro-clusters en "super-nœuds",
86. Gérer un **contrôle macro** (top-down) pour scinder ou valider ces super-nœuds.

6.5.4.1. Pseudo-Codes : (1) Détection Micro-Cluster, (2) Fusion en Super-Nœud, (3) Contrôle des Macro-Niveaux

Cadre Global. L'objectif est de décrire, sous forme de pseudo-codes, l'articulation pratique de la **dynamique locale** (détection de micro-clusters via DSL), de la **fusion** en super-nœuds (agrégation), et du **contrôle macro** (avec possibilité de division). On suppose qu'au **niveau micro** (ou $\ell = 0$), on gère un ensemble d'entités $\{\mathcal{E}_i\}_{i=1\dots n}$ reliées par des pondérations $\omega_{i,j}^{(0)}$. L'itération de cette procédure peut être prolongée vers des **niveaux** 1, 2, ... jusqu'à un palier macro ou intermédiaire.

La structure principale se décompose en trois volets :

87. Une **dynamique locale** qui met à jour $\omega_{i,j}^{(0)}$ selon la règle DSL et détecte les micro-clusters.
88. Une **fusion** (agrégation) pour construire des super-nœuds à partir des clusters détectés.
89. Un **contrôle macro**, qui valide ou scinde (division) les super-nœuds jugés trop hétérogènes.

La présentation qui suit reste schématique. Les détails algorithmiques (complexité, choix des seuils, etc.) sont modulables.

A. Détection Micro-Cluster : la Dynamique Locale

Ce premier pseudo-code réalise la **mise à jour** DSL au **niveau micro** (ou palier $\ell = 0$), puis détecte des **clusters** localement, qualifiés de *micro-clusters*.

```
1: Initialize  $\omega(i,j)^{(0)}$  for all  $(i,j)$  with small or random values
2: for  $t = 1$  to  $T_{\text{local}}$  do
3:   for each pair  $(i,j)$ :
4:      $\omega(i,j)^{(0)} \leftarrow \omega(i,j)^{(0)} + \eta_0 * [S_0(i,j) - \tau_0 * \omega(i,j)^{(0)}]$ 
5:   # Optionally clamp or saturate  $\omega(i,j)^{(0)}$  to  $[0,1]$  or a chosen range
6: end for
```

```
7: clusters_level0  $\leftarrow$  find_clusters(  $\omega(\cdot,\cdot)^{(0)}$ , threshold_local )
   # e.g., BFS or community detection where  $\omega^{(0)}(i,j) > \text{threshold\_local}$ 
```

Interprétation

Mathématique.

Le *taux* $\eta_0 > 0$ et le *terme* $\tau_0 > 0$ régulent la vitesse d'adaptation, et $S_0(i,j)$ indique la **synergie** ou **similarité** entre entités \mathcal{E}_i et \mathcal{E}_j . La fonction *find_clusters* détecte des composantes connexes si $\omega_{i,j}^{(0)}$ dépasse un certain θ_{loc} , ou exploite un algorithme de partition (ex. Louvain, *community detection* légère) adapté à la densité.

La ligne 5 illustre la possibilité de forcer $\omega_{i,j}^{(0)}$ à rester dans $[0,1]$, une pratique courante pour éviter la divergence ou les valeurs négatives.

B. Fusion en Super-Nœuds (Agrégation)

Une fois identifiés, les micro-clusters de **niveau 0** sont transformés en **super-nœuds** au **niveau 1**. On reconstruit alors les pondérations $\omega^{(1)}$ entre ces super-nœuds via une fonction Ψ .

```

9: super_nodes_level1 = { }
10: for each cluster  $C_\alpha$  in clusters_level0:
11:   create super-node  $N_\alpha^{(1)}$ 
12:    $N_\alpha^{(1)}.members = C_\alpha$ 
13:   super_nodes_level1.add(  $N_\alpha^{(1)}$  )

14: for each pair ( $N_\alpha^{(1)}, N_\beta^{(1)}$ ):
15:    $\omega(\alpha, \beta)^{(1)} = \Psi( \{ \omega(i, j)^{(0)} \mid i \in C_\alpha, j \in C_\beta \} )$ 

```

Description.

Les lignes 10–13 établissent une correspondance directe entre un cluster $C_\alpha^{(0)}$ détecté et un super-nœud $N_\alpha^{(1)}$. La fonction Ψ agrège les valeurs $\omega_{i,j}^{(0)}$ entre les entités internes à C_α et C_β . Typiquement, Ψ peut être :

$$\omega_{\alpha, \beta}^{(1)} = \Psi(\{\omega_{i,j}^{(0)} : i \in C_\alpha, j \in C_\beta\}),$$

où Ψ est une somme, une moyenne, un maximum, etc. Ce calcul produit une **nouvelle** matrice $\omega^{(1)}$ représentant les liens entre super-nœuds $\{N_\alpha^{(1)}\}$.

C. Contrôle des Macro-Niveaux : Division ou Validation

Au **niveau 1**, chaque super-nœud $N_\alpha^{(1)}$ peut être jugé **hétérogène** ou **cohésif**. En cas d'hétérogénéité, une **scission** (top-down) est possible. Le pseudo-code ci-après montre une version simplifiée de cette opération :

```

18: for each super-node  $N_\alpha^{(1)}$  in super_nodes_level1:
19:    $H_\alpha = \text{heterogeneity}( N_\alpha^{(1)}, \omega^{(1)} )$ 
20:   if  $H_\alpha > \text{threshold\_macro}$ :
21:     sub_clusts = subdivide(  $N_\alpha^{(1)}.members, \omega^{(0)}$  )
22:     # Possibly do BFS or community detection again at level 0
23:     remove  $N_\alpha^{(1)}$  from super_nodes_level1
24:     for each subc in sub_clusts:
25:        $N_x = \text{create new super-node}$ 
26:        $N_x.members = \text{subc}$ 
27:       super_nodes_level1.add( $N_x$ )
27: re_compute  $\omega^{(1)}$  using function  $\Psi(\cdot)$  # or partial update

```

Explication.

La fonction *heterogeneity* (ligne 19) calcule un indice \mathcal{H} de cohésion interne. Si $\mathcal{H}(N_\alpha^{(1)}) > \theta_{\text{macro}}$, la procédure *subdivide* revisite les entités $\mathcal{E}_i \in N_\alpha^{(1)}.members$ et cherche une partition interne plus cohérente (lignes 21–25). Les sous-blocs substituent le super-nœud $N_\alpha^{(1)}$ d'origine dans *super_nodes_level1*. On met ensuite à jour la matrice $\omega^{(1)}$, voire on itère une dynamique DSL au niveau 1.

D. Intégration en Boucle Itérative

Pour former une **architecture hiérarchique** (et pas seulement un niveau 0 puis un niveau 1), on répète le principe suivant :

90. **Mise à jour DSL** au palier $\ell = 0$ et **détection** micro-clusters,
91. **Fusion** de ces micro-clusters en super-nœuds $N_\alpha^{(1)}$,
92. **Contrôle** macro (ligne 18+) : on valide ou on subdivise si besoin,

93. Si la taille du réseau l'exige, on réapplique un **processus DSL** au niveau 1 avec η_1, τ_1 , on détecte des clusters de niveau 1, on crée des super-nœuds $\mathcal{N}_\alpha^{(2)}$, etc.

La hiérarchie s'échelonne en paliers $k = 0, 1, 2, \dots$ jusqu'à atteindre un niveau **macro** où il ne reste plus qu'un petit nombre de super-nœuds ou un unique bloc. On peut inclure un **flux descendant** correctif pour forcer une scission sélective, notamment si un super-nœud est repéré comme trop hétérogène.

E. Commentaires Mathématiques et Convergence

Lien avec les Algorithmes de Community Detection. Le schéma ci-dessus s'apparente à une **détection de communautés** multi-niveau. Toutefois, la spécificité **DSL** réside dans la **mise à jour** $\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S - \tau\omega_{i,j}(t)]$ qui fait *émerger* les clusters plutôt que de simplement les "découper".

Complexité et Approches Heuristiques. Chaque niveau requiert un **find_clusters** (ligne 8) et un **subdivide** (ligne 21) potentiellement complexes. On recourt souvent à des heuristiques (BFS sur les liens $> \theta$, modularité, etc.) pour demeurer en $O(n \log n)$ ou $O(n)$ si le graphe est épars. Les algorithmes exacts de partition restent NP-difficiles pour n grand.

Convergence ou **Évolution Continue.** Lorsque l'environnement est **statique**, on peut parvenir à un état stable : plus aucun super-nœud n'est scindé, plus aucun micro-cluster ne se modifie. Dans des **contextes dynamiques** (flux de données, changements de liens), on exécute ces boucles en continu, adaptant la hiérarchie en **temps réel** (chap. 9).

Conclusion (6.5.4.1)

Le **pseudo-code** présenté illustre une **architecture** typique :

94. **Dynamique locale :**

on applique le **DSL** au **niveau** micro ($\ell = 0$), détecte des **clusters** via un algorithme de sur-seuil ou de community detection simplifiée.

95. **Fusion :**

on convertit ces **clusters** en **super-nœuds** $\mathcal{N}_\alpha^{(1)}$, reconstruisant une matrice $\omega^{(1)}$ par une fonction Ψ .

96. **Contrôle macro :**

on valide ou subdivise un super-nœud $\mathcal{N}_\alpha^{(1)}$ jugé trop hétérogène, en créant de **nouveaux** super-nœuds plus petits.

Répéter cette logique par itérations successives et paliers multiples ($k = 0, 1, 2, \dots$) bâtit une **hiérarchie** complète, exploitant l'**auto-organisation** locale (bottom-up) et le **contrôle** ou la **sélection** globale (top-down). Les sections suivantes (6.5.4.2 et 6.5.4.3) approfondiront le réglage des **paramètres** (seuils, etc.) et l'extension à des variantes (inhibition compétitive, recuit simulé) pour **assurer** une convergence stable et éviter la stagnation dans des partitions sous-optimales.

6.5.4.2. Paramètres Clés (Seuil de Synergie, Ratio d'Homogénéité, etc.)

Contexte et Problématique. Les algorithmes multi-niveau décrits précédemment (section 6.5.4.1) reposent sur une alternance entre l'**agrégation** (bottom-up) et la **division** (top-down). Cette dynamique implique divers **paramètres** cruciaux qui déterminent les conditions de fusion et de scission, et donc la forme finale de la hiérarchie. Parmi ces paramètres, on trouve notamment le **seuil de synergie** dictant la fusion locale et le **ratio d'homogénéité** influençant la division macro. D'autres, comme les taux η et les facteurs τ de la mise à jour DSL, ou la fonction Ψ d'agrégation, ont également un impact décisif. Les développements ci-après décrivent comment ces paramètres s'imbriquent et comment ils orientent l'équilibre entre la formation de super-nœuds et leur éventuelle scission.

A. Seuil de Synergie θ_{synergy}

Dans la démarche **bottom-up**, un **seuil** de synergie θ_{synergy} sert à déterminer quand deux entités (ou deux clusters) méritent d'être **fusionnés**. Mathématiquement, on peut considérer qu'on ne fusionne un couple $\{i, j\}$ que si $\omega_{i,j} \geq \theta_{\text{synergy}}$. De même, dans l'algorithme "find_clusters", on ne retient que les arêtes du graphe dont la pondération dépasse ce seuil. Cela aboutit à des composantes connexes que l'on assimile à des **micro-clusters**.

Un θ_{synergy} trop élevé force une exigence stricte de cohérence, ce qui restreint la fusion à des liens très forts. Cela tend à créer un nombre important de **petits** clusters ou à empêcher la formation de sous-groupes plus volumineux. Au contraire, un θ_{synergy} trop bas mène à des blocs de grande taille peu homogènes, qu'il faudra ensuite probablement **scinder** (top-down) en raison d'une hétérogénéité interne excessive.

Il existe une manière de rendre ce seuil **adaptatif** : au lieu de fixer θ_{synergy} a priori, on peut le définir comme un quantile de la distribution des $\omega_{i,j}$. Par exemple, retenir les 20% de liens les plus forts assure un pourcentage prévisible de liaisons considérées "actives" pour la fusion, et donc un nombre de clusters local plus stable.

B. Ratio d'Homogénéité / Hétérogénéité θ_{macro}

L'**hétérogénéité** $\mathcal{H}(\mathcal{C})$ est un indicateur crucial dans la phase **top-down**, au moment de décider la scission d'un super-nœud \mathcal{C} . Cette hétérogénéité peut se définir sous différentes formes : variance des pondérations $\omega_{i,j}$, écart absolu moyen, ou encore ratio entre liens forts et liens faibles. Une formulation usuelle s'appuie sur la somme des écarts entre chaque poids $\omega_{i,j}$ et la moyenne des poids internes. Plus précisément, on introduit

$$\mathcal{H}(\mathcal{C}) = \frac{1}{|\mathcal{C}|^2} \sum_{i,j \in \mathcal{C}} |\omega_{i,j} - \bar{\omega}_{\mathcal{C}}|$$

où $\bar{\omega}_{\mathcal{C}}$ désigne la moyenne des $\omega_{i,j}$ pour les entités internes à \mathcal{C} . Si la somme des écarts $|\omega_{i,j} - \bar{\omega}_{\mathcal{C}}|$ se révèle élevée, alors \mathcal{C} présente un fort degré d'hétérogénéité.

Le **critère de scission** consiste à fixer un **seuil** θ_{macro} . Lorsque $\mathcal{H}(\mathcal{C})$ dépasse θ_{macro} , on considère que la cohésion interne du super-nœud est insuffisante et qu'il convient d'opérer une division. Conformément au **mécanisme** top-down, un **feedback** descendant vient alors réduire spécifiquement certaines liaisons $\omega_{i,j}$ au sein de \mathcal{C} , ce qui "casse" la communauté en sous-groupes plus homogènes. Un θ_{macro} trop élevé entraîne une scission uniquement pour les blocs très hétéroclites, au risque de conserver parfois des clusters imposants. Inversement, un θ_{macro} trop bas suscite une **sur-segmentation** (cf. 6.5.2.3), dans laquelle même de modestes divergences déclenchent la division.

Le **paramétrage adaptatif** offre la possibilité de modifier θ_{macro} au fil de l'évolution du réseau ou selon la distribution de $\mathcal{H}(\cdot)$. Par exemple, on peut sélectionner un quantile donné pour définir la valeur du seuil, ou ajuster θ_{macro} en fonction de la phase d'itération. Cette démarche assure une maîtrise plus fine du rythme de scission au niveau macro, conciliant la nécessité d'homogénéité dans un super-nœud et la flexibilité requise pour l'**auto-organisation** hiérarchique.

C. Paramètres de Vitesse : η et τ dans la Dynamique DSL

La mise à jour $\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)]$ dépend de manière linéaire du **taux d'apprentissage** η . Lorsque η est trop élevé, les variations de ω sont rapides, voire abruptes, pouvant générer des **oscillations** ou déstabiliser le réseau. À l'inverse, un η très petit étale la convergence sur un nombre important d'itérations, ralentissant la capacité du système à repérer et consolider les clusters. Dans un **SCN** hiérarchique, on adopte fréquemment un η_0 relativement grand au **niveau micro** pour identifier les clusters plus vite, tandis que, pour les niveaux macro ($\ell = 1, 2, \dots$), on utilise un η_k plus faible afin d'éviter que la structure globale ne se reconfigure trop brutalement au moindre changement.

Le **facteur** $\tau > 0$ représente la décroissance dans la même dynamique, par l'expression $\tau \omega_{i,j}$ à retrancher de la mise à jour. Cet élément évite la croissance sans limite des pondérations et limite la persistance de liaisons peu utiles. Un τ plus grand accentue l'**oubli**, c'est-à-dire que tout lien non soutenu par une synergie $S(i,j)$ élevée tendra rapidement

vers zéro. À l'inverse, un τ trop petit maintient un réseau plus **dense** : on y conserve de nombreux liens faibles, ce qui accroît la complexité de la structure et en diminue la sélectivité dans la formation des clusters.

Du fait de l'existence de **niveaux multiples** (ℓ), il est envisageable d'assigner à chaque palier ℓ ses propres valeurs η_ℓ et τ_ℓ . De cette façon, la **dynamique DSL** se module en fonction de la granularité. Une approche classique consiste à rendre η_0 (et parfois τ_0) relativement importants, de sorte que le niveau micro réagisse vivement pour créer ou dissoudre rapidement des liaisons, et à choisir η_k, τ_k plus tempérés lorsqu'on s'élève dans la hiérarchie, de manière à ne pas ébranler trop fréquemment la configuration macro. En procédant ainsi, on préserve la **réactivité** souhaitée dans les couches inférieures, tout en garantissant une plus grande **stabilité** du réseau aux niveaux supérieurs.

D. Paramètres de Filtrage et de Sélection dans l'Agrégation

Lors de la création de **super-nœuds** au niveau $\ell + 1$ à partir de **clusters** de niveau ℓ , on introduit une **fonction** Ψ pour définir la pondération $\omega_{\alpha,\beta}^{(\ell+1)}$. De manière générale, on écrit

$$\omega_{\alpha,\beta}^{(\ell+1)} = \Psi(\{\omega_{i,j}^{(\ell)} \mid i \in \mathcal{C}_\alpha^{(\ell)}, j \in \mathcal{C}_\beta^{(\ell)}\}),$$

ce qui signifie que l'on agrège l'ensemble des liens $\omega_{i,j}^{(\ell)}$ reliant les entités du bloc $\mathcal{C}_\alpha^{(\ell)}$ à celles du bloc $\mathcal{C}_\beta^{(\ell)}$. Le **choix** de Ψ peut prendre diverses formes : somme, moyenne, maximum, ou même un **minimum** ou un quantile, selon la logique du réseau. Un **maximum** favorise la propagation des liens les plus forts et peut surestimer la synergie globale, alors qu'une **moyenne** rend l'agrégation plus modérée. Dans certains contextes, un **minimum** ou un **quantile** s'avère judicieux pour refléter la robustesse d'un lien dominant ou, au contraire, l'homogénéité générale d'un ensemble. Une fois $\omega_{\alpha,\beta}^{(\ell+1)}$ calculé, on recourt fréquemment à un **filtrage** ou à un **seuil de transmission** $\theta_{(\ell+1)}$: on ne conserve que les super-arêtes dont la pondération dépasse $\theta_{(\ell+1)}$, ce qui limite la densité du graphe au palier macro ou méso. Cette opération influence directement la forme hiérarchique résultante, car elle régit la connectivité entre super-nœuds : si le filtre est trop strict, on risque d'aboutir à une structure dispersée de blocs faiblement reliés ; s'il est trop permissif, le réseau demeure très dense, et les fusions tendent à se multiplier, parfois sans réelle cohésion. L'équilibre entre Ψ et le filtrage $\theta_{(\ell+1)}$ s'avère donc déterminant pour réguler la **logique DSL** à chaque palier et assurer une **auto-organisation** stable et adaptée au niveau d'échelle visé.

E. Combinaisons et Calibration Globale

L'**hystérésis** et l'introduction de **fenêtres de stabilisation** constituent l'une des clés pour limiter les oscillations brutales dans un système multi-niveau. Dans un **algorithme DSL** complexifié, on empêche qu'une fusion ou une scission déjà réalisée ne soit immédiatement inversée par la phase suivante. On se dote par exemple de deux seuils de fusion, $\theta_{\text{fusion}}^{\text{high}}$ et $\theta_{\text{fusion}}^{\text{low}}$, afin de fusionner deux blocs si $\omega_{i,j}$ dépasse $\theta_{\text{fusion}}^{\text{high}}$, tout en s'assurant de ne pas "dé-fusionner" tant que le poids reste au-dessus de $\theta_{\text{fusion}}^{\text{low}}$. Un principe analogue s'applique aux divisions : un bloc fraîchement scindé ne sera pas ré-agrégé si sa pondération ou sa cohésion interne n'a pas franchi un seuil supérieur. Cette stratégie atténue le "va-et-vient" permanent, permettant une **stabilisation** avant que le mécanisme inverse ne prenne le relais.

La **gestion multi-échelle** impose souvent que chaque niveau ℓ du réseau hiérarchique puisse définir ses propres paramètres $\{\eta_\ell, \tau_\ell, \theta_{\text{synergy}}^{(\ell)}, \theta_{\text{macro}}^{(\ell)}\}$. Cette variabilité rend possible la **réactivité** à petite échelle (où η_0 et τ_0 sont assez importants pour permettre des ajustements rapides) et la **stabilité** à grande échelle (où η_k et τ_k décroissent ou se fixent à des valeurs plus modérées). Bien que cette souplesse des réglages soit précieuse, elle complique la configuration globale : dans la pratique, on recourt à des essais ou à une adaptation automatique pour ajuster ces seuils et vitesses de mise à jour.

Les **boucles d'itération** mettent en jeu trois moments essentiels : la mise à jour **DSL locale** (avec η_0, τ_0) pour consolider ou affaiblir les liens $\omega_{i,j}$ selon la synergie locale ; la **détection/fusion** (à l'aide d'un seuil θ_{synergy}) pour agréger de manière ascendante les entités ou sous-blocs très cohérents ; et la **validation ou division macro** (fondée sur la mesure d'hétérogénéité $\mathcal{H}(\mathcal{C})$ et un seuil θ_{macro}) pour scinder de manière descendante les blocs jugés trop dispersés. Il convient de calibrer l'ordre et la périodicité de ces actions pour obtenir une convergence harmonieuse : un déclenchement trop rapide du feedback macro risquerait de démanteler des clusters encore en formation, tandis qu'un retard excessif dans la division maintiendrait un super-bloc incohérent. Cette **cohérence globale** dans l'emploi

successif de la dynamique locale, de l'agrégation et de la division constitue l'un des points cruciaux de la **conception** d'un SCN multi-niveau.

Conclusion

La **réussite** d'un algorithme multi-niveau DSL, associant agrégation et division, dépend de **plusieurs** paramètres qui interagissent :

97. **Seuil de synergie** θ_{synergy} , fixant la condition de fusion locale,
98. **Ratio d'homogénéité** θ_{macro} , fixant la condition de division macro,
99. **Paramètres DSL** η_ℓ et τ_ℓ régulant la vitesse et la dissipation au palier ℓ ,
100. **Fonction d'agrégation** Ψ , modulant la formation des pondérations au niveau supérieur,
101. **Filtrage et hystérésis**, contrant les oscillations et assurant un comportement stable.

Ces paramètres façonnent la **structure** hiérarchique et sont souvent **calibrés** empiriquement ou via des heuristiques adaptatives. Un mauvais réglage peut entraîner un trop grand regroupement (clustering géant peu cohérent) ou, à l'inverse, une trop forte segmentation (sur-fragmentation). Une bonne **combinaison** fournit un **SCN** multi-niveau **robuste, flexible, et capable** de s'auto-organiser en réponses aux signaux locaux (bottom-up) comme aux contraintes globales (top-down).

6.5.4.3. Intégration avec l'Inhibition ou le Recuit (Chap. 7) pour Éviter la Stagnation

Introduction et Contexte. Les algorithmes multi-niveau (section 6.5.4.1) reposant sur l'**agrégation** (bottom-up) et la **division** (top-down) nécessitent un certain "dynamisme" pour évoluer vers des structures hiérarchiques suffisamment pertinentes. Or il arrive qu'un **blocage** ou une **stagnation** se produise : le réseau se fige dans une configuration localement stable sans l'être globalement, ou bien certaines liaisons $\omega_{i,j}$ conservent des valeurs moyennes, empêchant la différenciation de sous-groupes plus cohérents. Pour s'extraire de ces situations, on recourt à des mécanismes complémentaires comme l'**inhibition** ou le **recuit simulé**, décrits en détail au **Chap. 7**. Les développements ci-après résument l'idée et montrent comment ces procédés s'intègrent dans le cadre DSL multi-niveau.

A. Principe de l'Inhibition

Dans la dynamique DSL classique, la mise à jour des pondérations suit la formule $\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)]$. Il est cependant possible d'ajouter un **terme d'inhibition** pour contraindre la somme des liens sortants $\sum_k \omega_{i,k}(t)$ et inciter chaque nœud \mathcal{E}_i à limiter la densité de ses connexions. Une forme représentative s'écrit

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)] - \gamma \sum_{k \neq j} \omega_{i,k}(t),$$

avec $\gamma > 0$ modulant la force inhibitrice. Ce mécanisme, qualifié d'**inhibition latérale ou globale**, a pour effet de "pousser" chaque entité i à sélectionner quelques liaisons prioritaires tout en relâchant les autres, ce qui favorise un **contraste** plus marqué entre liens forts et liens faibles et empêche la stagnation dans un état moyennement connecté.

Lorsque l'on souhaite éviter qu'un cluster se stabilise dans une configuration sous-optimale où de nombreux liens médians subsistent, l'inhibition pousse en effet $\omega_{i,j}$ vers zéro sauf pour les paires (i,j) réellement synergiques.

Sur un plan **multi-niveau**, le palier supérieur peut également déclencher une inhibition partielle pour des super-nœuds surconnectés, limitant ainsi leur extension artificielle et rejoignant la logique d'une division top-down : si un bloc est trop vaste ou trop hétéroclite, un **feedback** descendant peut diminuer certains liens internes et ouvrir la voie à une scission ultérieure, garante d'une structure globale mieux équilibrée.

B. Principe du Recuit Simulé (Injection de Bruit)

Le **recuit simulé** introduit un terme aléatoire dans la mise à jour des pondérations afin d'échapper aux états de blocage ou aux minima locaux. La **dynamique** se généralise alors en

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)] + \sigma(t) \xi_{i,j}(t),$$

où $\xi_{i,j}(t)$ correspond à un bruit (gaussien, uniforme) et $\sigma(t)$ définit une “température” positive qui décroît au fil des itérations ($\sigma(t) \rightarrow 0$ quand $t \rightarrow \infty$). Lorsque $\sigma(t)$ est élevée, les fluctuations dans $\omega_{i,j}$ demeurent importantes, ce qui encourage une **exploration** de nombreuses configurations. À mesure que la température diminue, le réseau “gèle” progressivement sa structure dans un état supposé plus stable ou plus optimal. L'absence de bruit dans un **DSL** peut conduire à une convergence précoce vers un **minimum local**, alors que l'injection contrôlée de $\sigma(t)$ autorise certaines liaisons $\omega_{i,j}$ à monter ou à descendre aléatoirement, même si la synergie $S(i,j)$ n'est pas très marquée, révélant ainsi des sous-groupes latents ou détruisant des connexions faiblement fondées. L'**agrégation** se trouve de ce fait renforcée lorsqu'un couple (i,j) bénéficie d'un surcroît de bruit positif, et la **division** top-down peut s'opérer plus facilement si le bruit négatif fragilise des liens internes déjà instables. Au final, le recuit simulé, par la variation $\sigma(t)$, offre une flexibilité complémentaire à la dynamique DSL, favorisant l'**exploration** quand la température est haute et la **consolidation** quand la température se rapproche de zéro.

C. Combinaison dans un Cycle Multi-Niveau

Les **phases** d'un **SCN** hiérarchique suivent un cycle dans lequel on exécute successivement la **mise à jour** DSL locale, l'agrégation ascendante (voir 6.5.3.2) et la potentielle division descendante (selon la logique top-down). Le **recuit** peut être inséré durant la phase de mise à jour : on ajoute alors un terme $\sigma(t) \xi_{i,j}(t)$ si l'on souhaite relancer la dynamique en cas de stagnation. De même, l'on peut recourir à un **terme d'inhibition** si on estime qu'un nœud ou qu'un bloc agrège trop de liaisons, en réduisant spécifiquement la somme de ses pondérations $\sum_j \omega_{i,j}$. Dans les faits, il arrive qu'on conditionne l'activation du bruit ou de l'inhibition à la détection d'un faible gradient $\|\Delta \omega(t)\|$ signalant une convergence prématurée. On peut alors, pour débloquer la situation, élever temporairement $\sigma(t)$ (pour le recuit) ou γ (pour l'inhibition). La structure hiérarchique profite ainsi d'un “**shake-up**” contrôlé qui modifie l'agencement local ou macro, libérant le réseau d'un éventuel état sous-optimal. L'**équilibre** final suppose de faire décroître la température $\sigma(t)$ et de stabiliser la force inhibitrice, de sorte que le SCN se cristallise dans une configuration plus stable. Cette combinatoire d'agrégation, de scission, de recuit et d'inhibition, orchestrée dans un **cycle multi-niveau**, constitue l'une des stratégies les plus robustes pour organiser un SCN complexe, lui permettant de traverser les minima locaux, de réajuster ses blocs hiérarchiques et de maintenir une flexibilité face aux évolutions de la synergie ou aux aléas du réseau.

Exemple d'un Pseudo-Code.

Un modèle :

```
for iteration in 1..T:
  for each pair (i,j):
     $\omega(i,j) \leftarrow \omega(i,j) + \eta * [S(i,j) - \tau * \omega(i,j)]$ 
    +  $\sigma(t) * \text{random\_noise}(i,j)$  # recuit
    -  $\gamma\_inhibit(i) * \text{sum}(\omega(i,*))$  # inhibition latérale
  if  $\text{norm}(\Delta\omega) < \text{epsilon}$ :
    raise  $\sigma(t)$  or  $\gamma\_inhibit$  # or apply "pulse"
  # then do detection of clusters, do macro merges or splits, etc.
```

Cette structure assure qu'on ne s'enferme pas trop tôt dans des configurations rigides, et qu'on a la **possibilité** de se ré-agencer.

D. Avantages

Le principal avantage est de sortir d'une *configuration stable* localement en introduisant un aléa modéré (recuit) ou en contraignant la somme des liens (inhibition). On évite ainsi les “demi-mesures” : trop de liaisons intermédiaires qui ne mènent pas à des clusters nets, ou un “super-nœud” mal fondé dont on n'ose pas scinder.

Sur le plan **mathématique**, l'approche recuit s'inspire de techniques globales de minimisation d'énergie. En embrassant un peu plus d'exploration, on peut accéder à un **minimum** plus global, dépassant le minimum local où le DSL se serait bloqué. L'inhibition, quant à elle, impose une **sélection** plus franche des connexions, clarifiant la hiérarchie.

Les mécanismes d'inhibition et de recuit peuvent être utilisés ensemble. On peut, par exemple, lancer le recuit au début (température élevée) pour explorer, puis introduire l'inhibition latérale en cours de route afin de forcer la **sparsité**. Cette séquence s'accorde avec la logique **agrégation/division** : la fusion se fait plus aisément quand on a "secoué" le réseau, tandis que la division s'opère plus distinctement lorsque les liens sont "assainis" par l'inhibition.

Conclusion (6.5.4.3)

Les **mécanismes** d'inhibition et de recuit (détaillés au Chap. 7) représentent des **leviers** précieux pour **éviter la stagnation** dans un algorithme multi-niveau DSL. Sans eux, le réseau peut facilement se figer dans une structure sous-optimale ou conserver un excès de liens moyens, rendant la hiérarchie peu claire. Avec :

1. **Inhibition**, on introduit une **concurrence** entre les liaisons, forçant un choix plus marqué : certains liens se renforcent, d'autres disparaissent, rehaussant la qualité des clusters.
2. **Recuit simulé**, on injecte un **bruit** qui "explore" de nouvelles configurations, augmentant la probabilité de franchir des barrières locales et d'atteindre une organisation plus globale.

Cette **intégration** complète harmonieusement le cycle agrégation–division, autorisant des remises en cause partielles de la structure lorsque nécessaire et procurant la **souplesse** requise pour s'adapter à un environnement évolutif ou à des données complexes.

6.6. Études de Cas et Illustrations

Les principes **multi-niveau** du **DSL** (Deep Synergy Learning) et les mécanismes d'**auto-organisation** qu'il propose (agrégation, division, synchronisation, etc.) trouvent des champs d'application variés et concrets. Dans cette section 6.6, nous passons en revue quelques **études de cas** et **domaines** illustrant l'impact potentiel de la synergie multi-échelle. Qu'il s'agisse de **vision multi-modal**, d'**analyse contextuelle** de la parole, de **robotique sensorimotrice**, d'**agents conversationnels** ou de **simulation d'événements**, le fil conducteur demeure la capacité du réseau à gérer les **données** (ou entités) à différents **paliers**, créant un équilibre entre détails locaux et structures globales.

6.6.1. Systèmes de Vision Multi-Modal

Les systèmes de **vision** actuels doivent non seulement reconnaître des images, mais souvent intégrer plusieurs **modalités** (ex. image + annotation textuelle, ou image + métadonnées audio). Dans un contexte **multi-modal**, le **DSL** propose de structurer l'information en **entités** et **liens synergiques**, afin de repérer des clusters pertinents à plusieurs échelles.

6.6.1.1. Micro-Clusters = Images Localement Semblables, Macro = Classes Sémantiques

Contexte et Logique Générale. Dans un système de **vision** à grande échelle, il est fréquent de manipuler un très grand nombre d'images, chacune éventuellement décomposée en fragments ou "patches" (sous-parties de l'image). L'**objectif** est de parvenir à une structure hiérarchique : à une échelle locale (micro), on groupe les patches très semblables (textures, couleurs, formes), tandis qu'à une échelle plus globale (macro), on obtient des **catégories sémantiques** (types d'objets, classes d'usages). La **dynamique DSL** (Deep Synergy Learning), avec ses mécanismes de mise à jour des pondérations ω et son agrégation multi-niveau, offre un cadre souple pour cette organisation. Les développements ci-après illustrent la façon dont se forment des micro-clusters de "mini-images" puis, par agrégation, des classes plus abstraites.

A. Micro-Clustering Local : Groupement de Patches Visuels

Au niveau le plus **bas** (noté $\ell = 0$), on considère un ensemble massif de **mini-images** ou "patches" extraits des grandes images. Chaque patch \mathcal{E}_i est relié à d'autres patches \mathcal{E}_j par des pondérations $\omega_{i,j}$ mesurant leur **similarité** visuelle locale. Cette similarité (score $S(i, j)$) peut reposer sur des comparaisons de **couleurs**, de **descripteurs SIFT** ou **HOG**, ou encore de **textures**.

La mise à jour DSL local applique la formule :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta_0 [S_0(i, j) - \tau_0 \omega_{i,j}(t)].$$

Lorsque $S_0(i, j)$ est élevé (patches très semblables), $\omega_{i,j}$ tend à croître, **favorisant** la formation de groupes de patches proches. Après plusieurs itérations, on détecte ainsi, via un critère de sur-seuil ou un algorithme de **connected components**, des **micro-clusters** de patches. Ces micro-clusters peuvent correspondre à des **motifs** récurrents (ciel bleu, feuillage vert, zones de textures identiques, etc.) ou à des éléments communs (fragments de visages, de lettres, etc.).

Le **rôle** de cette étape micro est d'extraire une **granularité** fine, en laissant la dynamique DSL créer des petits regroupements localement cohérents. Il n'est pas nécessaire d'avoir de label humain ou de connaissance externe : l'**auto-organisation** s'appuie uniquement sur le renforcement des liens $\omega_{i,j}$ fortement **synergiques** (patches quasi identiques ou très proches).

B. Passage Macro : Classes Sémantiques

Une fois les micro-clusters formés, on se place au **niveau** $\ell = 1$, où chaque cluster local de patches se voit représenté par un **super-nœud** $\mathcal{N}_\alpha^{(1)}$. Les pondérations $\omega_{\alpha,\beta}^{(1)}$ entre ces super-nœuds se calculent via une fonction Ψ (moyenne, somme, maximum, etc.) appliquée aux liens $\{\omega_{i,j}^{(0)}\}$ entre les patches membres de α et β .

Sur ce graphe de **super-nœuds**, on applique de nouveau la démarche DSL ou un critère d'**homogénéité** pour regrouper en classes plus vastes : on peut former un macro-nœud $\mathcal{N}_p^{(2)}$ qui englobe plusieurs super-nœuds $\{\mathcal{N}_\alpha^{(1)}, \dots\}$. Ces macro-nœuds, ou **catégories** plus globales, peuvent correspondre à de véritables **concepts** sémantiques : animaux, véhicules, paysages, visages, etc.

La **logique** d'agrégation hiérarchique permet donc, d'une part, de détecter localement les similitudes visuelles (couches micro) et, d'autre part, d'**unifier** ces similarités en classes d'objets pertinents (couche macro). Le DSL répercute la force des liens $\omega_{i,j}$ depuis le niveau patch (textures) jusqu'à la reconnaissance de **familles** d'images plus abstraites.

C. Retombées Pratiques et Architecture Finalisée

À l'**échelle micro**, on dispose d'informations extrêmement **locales** : par exemple, un patch de taille 8×8 correspond à une petite zone homogène. La **dynamique** DSL fait émerger des micro-clusters homogènes, utiles pour un pré-classement ou une indexation fine. Au **niveau macro**, l'agrégation délivre des **classes** globales qui reflètent des **catégories** ou des **objets**. Ainsi, dans une base de plusieurs millions d'images, on aboutit à une structure hiérarchique où chaque image se décompose en divers patches, lesquels appartiennent à des micro-clusters, et ces micro-clusters se rattachent à des catégories plus vastes.

Cette **organisation** hiérarchique facilite la **navigation** multi-résolution : on peut opérer une recherche par similitude locale (trouver tous les patches ressemblant à un certain motif) ou par **grande classe** (retrouver toutes les images contenant un chat, une voiture, un paysage de neige, etc.). Le **DSL** assure la liaison entre ces deux échelles, en propageant la **cohérence** visuelle locale vers des regroupements plus sémantiques.

Conclusion

L'exemple du **traitement d'images** illustre clairement l'apport d'une **démarche multi-niveau** en DSL :

- **Micro** : groupement de patches $\{\mathcal{E}_i\}$ fortement similaires (couleurs, textures, motifs locaux).
- **Macro** : agrégation de ces micro-clusters en **catégories** plus larges (objets, thèmes sémantiques).

Aucun label humain n'est nécessaire pour guider ce processus : la **synergie** visuelle joue le rôle de signal local (similarité), et la **dynamique DSL** (renforcement/décroissance) construit pas à pas des **clusters** stables, puis des **super-clusters**, etc. Ce mécanisme génère ainsi un **réseau** à plusieurs paliers (patches \rightarrow micro-clusters \rightarrow super-catégories) reflétant la réalité à la fois **locale** (textures) et **globale** (concepts). Ce paradigme se généralise à d'autres domaines (audio, texte) où l'on veut unir des attributs "microscopiques" (ex. phonèmes, tokens) en entités plus macro (mots, phrases, documents), toujours via la logique d'**auto-organisation** du DSL.

6.6.1.2. Approche Fractale : Répétition de Motifs "Objets" à Différentes Granularités (ex. Sous-Catégories)

Introduction et Contexte Global. De nombreux systèmes de **vision multi-modal** illustrent la présence d'**objets** ou de *sous-objets* dont la **forme** ou la **structure** se retrouve à diverses **échelles**. Un objet complexe (tel qu'un bâtiment, un végétal) peut receler des éléments répétés (fenêtres, feuilles) présentant des caractéristiques quasi identiques, simplement redimensionnées ou agencées différemment. Cette **répétition** et **auto-similarité** évoque le **concept fractal** (cf. chap. 6.3 sur la fractalité). Du point de vue **Deep Synergy Learning (DSL)**, la possibilité de décrire un motif à l'échelle micro et de le retrouver dans une **catégorie** plus large (macro) s'appuie sur le principe d'**auto-organisation** hiérarchique. Les développements ci-après explorent en quoi cette logique fractale se matérialise et quels bénéfices elle apporte à la reconnaissance d'images (ou de sous-catégories d'objets) via le **DSL**.

A. Répétition de Motifs et Multi-Échelle dans les Images

La notion de **fractal** en vision se fonde sur une **invariance** (ou quasi-invariance) lorsqu'on change d'échelle. Les mêmes *motifs* réapparaissent, que l'on examine une zone microscopique ou la totalité de l'image. Dans un système DSL :

Motifs locaux répétés. Les images naturelles (bâtiments, véhicules, plantes) révèlent souvent des *sous-formes* identiques ou analogues, distribuées au sein d'un *grand* objet. Par exemple, on retrouve des fenêtres identiques au sein d'une façade, ou plusieurs roues identiques dans un convoi de wagons.

Au **niveau micro**, le DSL repère des similitudes entre patchs présentant la même texture ou la même géométrie. De proche en proche, il agrège ces micro-similarités. Le résultat est un **cluster** local reflétant un motif récurrent (la "forme" fenêtre, par exemple).

Sous-catégories issues d'un même patron. Lorsqu'on monte en échelle (du niveau patch micro à un niveau de classes plus larges), on peut voir apparaître des *sous-catégories* d'un même type. Dans la classification d'espèces végétales, des arbres partageant un *même* motif foliaire s'inscrivent dans une sous-catégorie spécialisée, mais dont la forme générale se répète (feuilles, nervures). Le **DSL** hiérarchique consolide ainsi ces groupes de patchs (micro) en *sub-classes* (macro), propageant la cohérence depuis la structure locale jusqu'à une catégorie englobante. Cet enchaînement reproduit l'**auto-similarité** propre aux fractals : la *même organisation* (mêmes types de motifs) se manifeste à plusieurs niveaux de détail, simplement transposée ou mise à l'échelle différemment.

B. Notion de Fractalité dans la Vision

L'**auto-similarité** fractale s'observe dans de nombreuses images naturelles (motifs de nuages, feuillages, etc.). Dans un **DSL** qui autorise à la fois une mise à jour locale (renforcement de $\omega_{i,j}$) et une agrégation + division multi-niveau, on peut détecter :

Box-counting et lois de puissance. Lorsqu'on recense le *nombre* de groupes à une taille donnée ou l'intensité moyenne de similarité en fonction de l'échelle, on peut observer une loi de puissance. Si le graphe des $\omega_{i,j}$ fait apparaître une dimension fractale lors du *box-counting*, cela traduit une récurrence structurelle : la hiérarchie "ressemble" à elle-même à différentes échelles.

Exemple : sous-catégories. On peut considérer un exemple : à l'échelle macro, on identifie la catégorie "bâtiments". En descendant un niveau, on voit se dégager "bâtiments à fenêtres rectangulaires" vs. "bâtiments à arches rondes", etc. En descendant encore, chaque fenêtre ou arche se décompose en éléments plus petits, toujours suivant la même logique d'agencement. Le **DSL** met à jour ω de façon identique : un cluster trop hétéroclite se scinde, un micro-groupe très semblable se fusionne, et l'on retrouve la *même forme d'organisation* d'un niveau à l'autre, caractéristique d'une forme fractale.

C. Avantages d'une Approche Fractale en Vision

Robustesse à l'Échelle. Les systèmes de vision doivent gérer des variations d'échelle (un objet vu de près ou de loin) et de perspective. Dans une **structure fractale**, la répétition de motifs à différentes tailles autorise l'identification d'un *même type d'entité* qu'il soit grand ou petit dans l'image. Le **DSL** hiérarchique renforce cette capacité de reconnaître des patchs similaires même s'ils sont "scalés" ou partiels, aboutissant à la **convergence** d'indices vers une même catégorie.

Multi-Résolution. Une scène peut être vue sous différentes résolutions : un objet lointain n'offre pas de détail (macro-niveau), puis un zoom fait apparaître des micro-structures. Le **DSL** fractalement organisé permet d'exploiter autant la vue "générale" (regroupement large) que la vue "fine" (micro-clusters), tout en assurant la continuité *auto-similaire* entre ces niveaux.

Découverte de Structures. Sans supervision externe, un réseau DSL auto-similaire découvre des **patterns récurrents** (fenêtres, roues, feuilles) au niveau micro, les agrège en "sous-ensembles d'objets" (ex. sous-catégories de voitures selon le type de roues), puis les regroupe dans des super-catégories (voitures, camions, chars) au niveau macro. Cette **imbrication** reproduit la "mise en abyme" fractale : chaque entité complexe se compose d'entités similaires plus petites, etc.

Conclusion

L'**approche fractale** en vision multi-modal fait ressortir la **répétition** de motifs à différentes **granularités**. Un **motif local** (patch d'image) peut se répliquer ou s'assembler en un *objet complet* (macro), qui lui-même se révèle être un

sous-ensemble d'une *catégorie plus large*. Le **DSL**, par sa logique hiérarchique et **auto-organisée**, exploite exactement cette **auto-similarité** pour construire, de bas en haut, des **sous-catégories** ou des regroupements d'objets récurrents. Ce fonctionnement épouse la **structure fractale** fréquemment constatée dans les images naturelles ou synthétiques, offrant :

- **Robustesse** aux changements d'échelle,
- **Multi-résolution** cohérente,
- **Découverte** non supervisée de sous-catégories issues d'un même patron.

Ce paradigme multi-niveau, enrichi par la répétition de *mêmes* motifs à diverses échelles, permet au système d'**apprendre** et de **segmenter** la réalité visuelle selon un prisme fractal, offrant ainsi une reconnaissance hiérarchique plus flexible et plus riche.

6.6.1.3. Gains en Robustesse : Le Système s'Adapte si de Nouvelles Images Arrivent (Chap. 9)

Introduction et Contexte. Dans un système de **vision** reposant sur l'**architecture multi-niveau** d'un **Deep Synergy Learning (DSL)**, il est fréquent d'ajouter de nouvelles images (ou de nouveaux flux multimédias) au fil du temps. La capacité d'intégrer ces données additionnelles sans redémarrer l'entraînement à zéro, ni déstabiliser la structure hiérarchique, constitue un atout majeur en matière de **robustesse**. Les développements qui suivent clarifient la manière dont, grâce à la logique DSL, l'arrivée d'images inédite se traduit par une **mise à jour** locale des pondérations, qui se propage aux niveaux supérieurs (macro) de manière continue et adaptative.

A. Réactivité des Liens Synergiques face à l'Arrivée de Nouvelles Images

Le **DSL** procède par mise à jour itérative des pondérations $\omega_{i,j}(t)$ à l'aide d'une formule du type

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(\mathcal{E}_i, \mathcal{E}_j) - \tau \omega_{i,j}(t)],$$

où $\eta > 0$ désigne un taux d'apprentissage, $\tau > 0$ un facteur de décroissance, et $S(\mathcal{E}_i, \mathcal{E}_j)$ la **synergie** (ou similarité) entre deux entités $\mathcal{E}_i, \mathcal{E}_j$. Lorsqu'une image inédite \mathcal{E}_{new} survient, on l'introduit comme un nouveau nœud dans le réseau, initialisant $\omega_{\text{new},j}$ à de petites valeurs (ou zéro) et évaluant $S(\mathcal{E}_{\text{new}}, \mathcal{E}_j)$ pour les entités $\{\mathcal{E}_j\}$ préexistantes. Les mises à jour successives renforcent ou réduisent $\omega_{\text{new},j}$ en fonction de la cohérence (ou non) entre \mathcal{E}_{new} et \mathcal{E}_j . Si la synergie est élevée, la nouvelle image consolide un lien fort et se rattache à un cluster existant ; si la synergie reste faible, elle demeure isolée ou forme un micro-cluster indépendant, jusqu'à ce que d'autres images similaires surviennent.

Après un laps de temps, les **informations** associées à \mathcal{E}_{new} (ses liens forts, ses liens quasi-nuls) remontent dans la structure multi-niveau : au palier suivant, le super-nœud correspondant à un cluster local inclut la nouvelle entité, et les pondérations $\omega_{\alpha,\beta}^{(\ell+1)}$ sont recalculées via la fonction Ψ . Ainsi, on met à jour les liaisons au **niveau** macro sans nécessiter une refonte complète.

B. Robustesse et Adaptation

Ce mécanisme permet au réseau de **continuer** son évolution en absorbant de la **nouvelle** information sans ré-apprendre globalement.

Dans des algorithmes classiques (par ex. entraînement supervisé avec un réseau de neurones convolutionnel), l'arrivée d'un nouveau lot d'images out-of-distribution impose souvent de **réentraîner** (ou au moins de fine-tuner) le modèle sur l'ensemble des données. Avec le **DSL**, on ne reconstruit pas l'architecture, on **insère** \mathcal{E}_{new} au sein de la matrice des pondérations, et on laisse les règles de synergie influencer sur la consolidation ou la suppression de liens.

Si la nouvelle image se rapproche d'un cluster (ex. un groupe d'images de chats), elle fortifiera le micro-cluster correspondant. Dans certains cas, si l'image introduit une hétérogénéité inattendue (ex. un micro-cluster devient trop

vaste et disparate), on recourt à la **division** au niveau macro (section 6.5.2) : un bloc d’images se scinde pour refléter le nouvel équilibre. Le système se montre **flexible**, capable de reconfigurer partiellement la hiérarchie.

Lorsque la nouvelle image est anomalie ou bruit, ses liaisons demeurent faibles (faible $S(\mathcal{E}_{\text{new}}, \mathcal{E}_j)$), donc $\omega_{\text{new},j}$ ne grandit pas. Elle peut être isolée ou former un cluster marginal avec d’autres images bruitées. Cette structure peu connectée ne perturbe pas la classification globale, ce qui renforce la **robustesse**.

C. Dimensions Mathématiques de l’Adaptation

Dans un réseau déjà stabilisé, l’ajout d’une nouvelle image peut rester sans effet si aucune pondération $\omega_{\text{new},j}$ ne réussit à s’élever au-delà d’un seuil. Pour **assurer** qu’on réexamine les liens, on peut injecter un **bruit** contrôlé (recuit simulé, cf. chap. 7) ou un **terme** d’inhibition forçant un rééquilibrage local. Mathématiquement :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)] + \sigma(t) \xi_{i,j}(t) - \gamma \sum_k \omega_{i,k}(t).$$

Cette version plus complète mixe bruit ($\sigma(t) \xi$) et inhibition latérale ($\gamma \sum_k \omega_{i,k}$), qui aident à **sortir** d’un équilibre trop figé.

La logique DSL demeure : localement, $\omega_{i,j}$ s’ajuste, puis le **cluster** correspondant se met à jour, puis cette mise à jour touche les paliers supérieurs via la fonction Ψ . Lorsque suffisamment d’itérations se sont écoulées, la nouvelle image est **intégrée**, et si son arrivée a créé une incohérence dans un bloc, celui-ci s’est subdivisé ou a re-fusionné partiellement pour retomber dans un état stable.

D. Liens avec Chap. 9 (Évolutions Temps Réel)

Le **chap. 9** approfondit cette idée d’**apprentissage continu** ou **streaming** : on ne dispose pas d’un jeu de données fixe, mais d’un flux ininterrompu. Le **DSL**, en assurant un algorithme **auto-organisé** et **distribué**, traite cette arrivée progressive d’images, guidé par la notion de synergie $\{\omega_{i,j}\}$. La **robustesse** ainsi conférée se traduit par :

- Un **coût** de mise à jour local (pas de recalcul global).
- Une possibilité de **réorganisation** si nécessaire (division top-down, recuit pour sortir d’un plateau).
- Une **navigation hiérarchique** qui reste fonctionnelle au fur et à mesure que de nouveaux objets ou de nouvelles catégories émergent.

Conclusion

Lorsque de **nouvelles images** parviennent dans un **système** de **vision multi-modal** reposant sur la **logique DSL** (et agrégation/division multi-niveau), la **robustesse** observée s’explique par la **plasticité** inhérente au réseau. L’arrivée d’entités inédites s’intègre localement : on évalue la synergie $\{\omega_{\text{new},j}\}$, on met à jour, et on propage cette information vers les paliers supérieurs. Il n’est pas requis de “mettre à l’arrêt” ou de **réentraîner** l’ensemble : la structure s’ajuste progressivement, un atout essentiel en **temps réel** ou en flux **continu**. Les mécanismes d’**inhibition** et de **recuit** (chap. 7) renforcent encore la capacité du DSL à échapper aux configurations figées et à englober naturellement de nouvelles données, assurant une **évolution** organique de la hiérarchie, sans rupture ni réinitialisation globale.

6.6.2. Analyse Contextuelle de la Parole et du Langage

Les principes du **DSL** (Deep Synergy Learning), initialement illustrés en vision multi-modal (6.6.1), s’appliquent tout aussi bien à l’**analyse** de la parole ou du texte. Le langage humain se compose en effet de **niveaux multiples** — des sons élémentaires (phonèmes) jusqu’aux concepts abstraits — offrant ainsi un cadre naturel pour la synergie multi-échelle.

6.6.2.1. Micro : phonèmes ou chunks de phrase, macro : concepts sémantiques

Au plus bas niveau (micro), la parole ou le texte se décompose en **unités élémentaires** : les **phonèmes** (pour l’oral) ou les **morphèmes** / “chunks” (pour l’écrit). Par exemple, un flux sonore est découpé en courtes séquences (ex. 20–50 millisecondes) dont on extrait des **features** (MFCC, spectrogrammes locaux...), alors qu’un texte peut se scinder en tokens ou petits segments (une partie d’un mot, un groupement de mots, etc.).

Le **DSL**, à ce niveau, gère un ensemble d’entités $\{\mathcal{E}_i\}$ représentant ces briques linguistiques. Les pondérations $\omega_{i,j}$ quantifient la **synergie** ou la similarité entre fragments. Un $\omega_{i,j}$ élevé signifie que deux phonèmes (ou deux tokens) **coïncident** souvent ou s’articulent fréquemment dans un même contexte local.

Lorsque ces fragments s’**agrègent** (voir les logiques bottom-up de 6.5), ils forment des unités plus larges : **mots**, **groupes de mots**, puis **concepts** sémantiques (familles de termes). Le **DSL** peut réévaluer la synergie $\omega_{\alpha,\beta}$ à ce palier, regroupant des **notions** proches (ex. “ordinateur” / “programme” / “machine”).

Mathématiquement, on définit une fonction d’agrégation Ψ qui combine les pondérations $\omega_{i,j}^{(0)}$ en pondérations $\omega_{\alpha,\beta}^{(1)}$ au niveau conceptuel. On obtient alors un graphe sémantique plus abstrait, où les nœuds sont des **concepts** détectés (macro-niveau).

Dans un **DSL**, la distinction micro–macro s’opère **dynamiquement**, sans imposer un modèle figé comme un “parse tree” unique. On peut former plusieurs **clusters** de tokens/phonèmes selon le contexte. L’architecture multi-niveau (chap. 6.2) laisse place à une organisation hiérarchique plus flexible que le schéma strict “mot \rightarrow syntagme \rightarrow phrase”.

Cette **souplesse** permet au système de repérer de nouveaux concepts, d’en fusionner certains, ou d’en séparer d’autres, en fonction de la synergie calculée lors de l’analyse sémantique ou phonétique.

A. Exemples de Mise en Pratique

Reconnaissance de la Parole (ASR)

Au niveau **micro**, des segments audio (frames) sont reliés en fonction de leurs similarités spectrales, formant des **clusters** phonétiques. Puis, au niveau plus haut, on agrège ces phonèmes en **mots**. Enfin, on peut détecter des concepts / intentions (macro).

Le **DSL** facilite la prise en compte simultanée de différents signaux acoustiques (voix), et de la synergie entre phonèmes courants pour **valider** ou **corriger** un mot ambigu.

Analyse Sémantique de Texte

Au niveau **micro**, un texte se segmente en tokens (mots ou sous-mots). Les liens $\omega_{i,j}$ se renforcent si deux tokens apparaissent souvent ensemble ou dans des contextes semblables. Des **clusters** de mots synonymes ou fortement associés émergent localement.

Au **niveau macro**, on obtient des **concepts** (thèmes) qui regroupent tout un champ lexical : par exemple, un cluster “sport” vs. un cluster “finance”. Cet ensemble de concepts forme alors un graphe sémantique plus global.

B. Intérêt Mathématique et Pratique

Mathématiquement, la synergie $S(\mathcal{E}_i, \mathcal{E}_j)$ peut se définir comme une **similarité** sémantique (ex. co-occurrence, vecteurs embedding) ou une **compatibilité** phonétique. Le DSL actualise les pondérations $\omega_{i,j}$ par la formule :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t)\eta[S(i,j)\tau\omega_{i,j}(t)].$$

Plus les entités (tokens, phonèmes) apparaissent conjointement, plus le lien se renforce. Au contraire, si elles se dissocient, $\omega_{i,j}$ tend vers 0 (ou un niveau faible).

Au fur et à mesure qu'on monte en échelle, on combine $\{\omega_{i,j}^{(k)}\}$ via une fonction Ψ . Les super-nœuds (macro) reflètent des concepts plus abstraits.

Cette hiérarchie dynamique est **robuste** : si un nouveau token apparaît souvent, il trouvera sa place dans un cluster ou en fondera un (6.5.4.2 sur les paramètres). Il ne requiert pas de **réapprentissage** global.

Applications

Compréhension du langage : on peut imaginer un DSL gérant la **cohérence contextuelle** (ex. “ce segment phonétique se connecte fortement à tel concept s’il apparaît dans un champ lexical précis”).

Correction automatique : si un token se retrouve isolé (faible synergie), on peut le **réassigner** à un cluster sémantique proche, jouant un rôle analogue aux algorithmes de correction contextuelle.

Conclusion

Dans l'**analyse contextuelle** de la parole et du langage, on distingue :

- Un **niveau micro** (phonèmes, chunks de phrase, tokens) où la **synergie** se bâtit localement entre entités proches,
- Un **niveau macro** (concepts, champs sémantiques, intentions) englobant un ensemble cohérent de mots/expressions.

Le **DSL** offre la possibilité de **relier** ces deux plans via des **liens** $\omega_{i,j}$ adaptatifs, permettant à la structure linguistique de se **former** (agrégation) ou de se **subdiviser** (division) selon la cohésion sémantique. Résultat : un **réseau** linguistique hiérarchisé, prêt à interpréter des **segments** (micro) tout en reconnaissant des **concepts** (macro), et assez flexible pour accueillir de nouveaux tokens ou variations contextuelles sans reconstruction globale.

6.6.2.2. Multi-Échelle : Phrase → Paragraphe → Document, Fractalité Possible si la Structure se Répète (Thèmes, Sous-Thèmes)

Introduction et Contexte Général. Le **langage** (oral ou écrit) peut être décrit selon plusieurs **paliers** : le palier **micro** (mots, tokens) s’assemble en **phrases**, lesquelles se regroupent en **paragraphes** (un sous-thème), puis en **document** complet (un thème majeur). Cette organisation hiérarchique se retrouve dans de nombreux textes (articles, essais, romans). Dans un **Deep Synergy Learning (DSL)** multi-niveau, la logique de **synergie** (pondérations $\omega_{i,j}$) et de **dynamique** (agrégation, division) permet de construire et d’adapter cette structure, tout en révélant des **patterns** potentiellement fractals lorsque le *même* thème (ou sous-thème) apparaît à différentes échelles.

A. Paliers du Texte : De la Phrase au Document

Niveau Micro : la Phrase.

Le premier palier (micro) regroupe les **mots** (tokens, segments). On définit des pondérations $\omega_{i,j}$ évaluant la similarité ou la synergie entre deux mots (par exemple, affinité sémantique, co-occurrence, relations syntaxiques). Après application de la mise à jour DSL, on peut détecter des *clusters* de mots qui forment un **énoncé** cohérent. Sur le plan mathématique, cette phrase $\mathcal{C}_\alpha^{(0)}$ se caractérise par une somme de pondérations $\sum_{i,j \in \mathcal{C}_\alpha} \omega_{i,j}$ relativement importante, traduisant la focalisation contextuelle.

Niveau Mésoscopique : le Paragraphe.

Le paragraphe regroupe plusieurs **phrases** reliées par un sous-thème commun. Dans un **DSL** multi-niveau, chaque phrase \mathcal{C}_α devient un super-nœud $\mathcal{N}_\alpha^{(1)}$. Les liens $\omega_{\alpha,\beta}^{(1)}$ entre phrases se calculent en agrégeant les poids $\{\omega_{i,j}^{(0)}\}$. Un paragraphe cohésif présente donc un bloc de phrases fortement interconnectées au niveau 1, selon la fonction Ψ (moyenne, somme, etc.). Un paragraphe plus hétérogène peut inciter une **division** (top-down) si la cohésion est jugée insuffisante.

Niveau Macro : le Document.

Le document entier (ou un chapitre d'un livre) s'obtient en **fusionnant** les paragraphes lorsqu'ils partagent un thème majeur. La **dynamique** DSL continue de s'appliquer : si un grand bloc (document) se révèle hétéroclite, on peut le scinder en chapitres ; s'il est déjà homogène, on le considère comme un macro-nœud stable. En outre, on peut aller plus loin en reliant différents documents entre eux, si l'on souhaite construire un **réseau** inter-articles (un corpus).

B. Fractalité et Répétition de Thèmes

Dans un *texte* ou *discours* structuré, un **même** concept (thème principal) se décline souvent en sous-thèmes, puis en sous-sous-thèmes, à différents paliers (chapitre, section, paragraphe, phrase). Cet agencement **auto-similaire** peut être vu comme fractal ; on retrouve le *même* motif d'organisation à des granularités distinctes, par exemple la reprise d'un motif argumentatif ou la récurrence d'un champ lexical sous des variations minimales.

Les textes (et leurs distributions lexicales) montrent parfois des **lois** de puissance. La **distribution** en fréquences des mots (loi de Zipf), la répartition des occurrences de thème, etc. Un **DSL** qui met en place un cycle d'agrégation–division (voir 6.5.3) peut exploiter cette **récurrence** en scindant un bloc dès que l'hétérogénéité interne dépasse un seuil, et en fusionnant localement des entités très similaires. Ainsi, la structure qui émerge est **autosimilaire** : on retrouve la *même* loi de regroupement (ou de scission) d'un paragraphe à l'autre, d'un chapitre à l'autre.

Si l'on trace les super-nœuds (chapitres, sections, paragraphes, phrases) dans un graphe DSL multi-niveau, on voit se dessiner un **arbre** (ou un “graphe fractal”) révélant l'invariance d'échelle. Un concept macroscopique (ex. “analyse fractale du texte”) se reflète en multiples sous-sections, qui elles-mêmes se divisent en paragraphes, etc., chacun reprenant le *même patron* argumentatif.

C. Synergie Multi-Échelle et Valeur Pratique

Grâce à cette **structure** hiérarchique, on navigue dans le texte depuis un **niveau** macro (thème principal) jusqu'à un **niveau** micro (détails dans une phrase). Sur le plan mathématique, on utilise $\omega_{\alpha,\beta}^{(k)}$ pour passer d'un paragraphe α à un autre paragraphe β si leur synergie est forte, ou pour descendre d'un paragraphe α vers ses **phrases** internes. Cette multi-résolution rend l'exploration plus souple.

Dans un contexte évolutif (un document collaboratif, un flux textuel), l'ajout d'un **nouveau paragraphe** ou d'une phrase modifiée se répercute localement (mise à jour des liaisons ω), pouvant mener à la **fusion** avec un sous-thème existant ou la scission d'un paragraphe devenu hétéroclite. Ce fonctionnement limite la nécessité de reconstruire la totalité de la structure, assurant une **adaptation** progressive.

Chaque *phrase* $\mathcal{C}_\alpha^{(0)}$ est un cluster de mots, agrégé en un super-nœud $\mathcal{N}_\alpha^{(1)}$ pour le *paragraphe*. Les paragraphes $\mathcal{N}_\beta^{(1)}$ se regroupent en $\mathcal{N}_\beta^{(2)}$ (chapitre), etc. À chaque niveau, la *même* mise à jour DSL ou la *même* condition d'homogénéité s'exerce, de sorte que l'on obtient, si les thèmes se répètent, une forme de *pattern fractal* (la distribution des liens ω suit une structure similaire d'un niveau à l'autre).

Conclusion

Dans l'**analyse** du **langage**, on retrouve l'idée d'**organisation multi-niveau** : un **texte** se découpe en phrases, paragraphes, sections, documents. Le **DSL** multi-niveau prend en charge ces paliers en :

- **Agrégeant** localement (phrases→paragraphes) lorsque la synergie interne est élevée,
- **Scindant** un bloc (paragraphe, chapitre) si l'hétérogénéité \mathcal{H} devient trop forte,
- **Conservant** la continuité d'une *même* logique (renforcement, division) d'une échelle à l'autre.

Cette approche peut faire émerger une **structure fractale** si le *même thème* (ou la même forme argumentative) se répète à plusieurs échelles. On y trouve alors :

- **Auto-similarité** dans la répartition sémantique (lois de puissance, récurrences lexicales),

- **Réorganisation** adaptative à l'arrivée de nouveaux segments textuels,
- **Navigation** aisée du niveau macro (concept général) vers le niveau micro (phrases, mots).

Ainsi, le **DSL** s'avère un cadre fécond pour modéliser la **fractalité** potentielle des textes (thèmes, sous-thèmes répétitifs), tout en fournissant une base algorithmique permettant au réseau de **réagir** à des modifications ou enrichissements du document, sans bloquer ni devoir réapprendre dans son intégralité.

6.6.2.3. Rétroaction Top-Down si un Sujet Global est Identifié, Influant l'Interprétation Locale

Contexte et Objectif. Dans un **DSL** (Deep Synergy Learning) multi-niveau appliqué à l'**analyse du langage**, l'organisation des entités (mots, fragments de phrases, etc.) s'effectue d'abord au **niveau micro** (groupements locaux ou clusters de tokens), avant que ces ensembles ne soient agrégés pour former des **sous-thèmes** ou des **paragraphes** (niveaux intermédiaires) et, enfin, parvenir à un **sujet global** (niveau macro). L'une des forces du modèle DSL est de permettre une **rétroaction descendante** (top-down) : une fois qu'un **sujet majeur** s'est dégagé, le palier macro peut envoyer un *feedback* qui réoriente ou désambiguïse certains liens locaux. Cette section explique comment, dès que le macro-nœud identifie un thème principal, il peut influencer l'**interprétation** de mots ambigus, de sous-phrases, ou de segments micro, assurant ainsi une **cohérence** multi-niveau.

A. Identification d'un Sujet Global et Flux Descendant

Au fur et à mesure que le **DSL** agrège les liens $\omega_{i,j}$ entre entités (mots, expressions, etc.), on peut parvenir, par un processus d'**agrégation** (bottom-up), à un macro-nœud représentant un **sujet** majeur, tel qu'« économie », « biologie », « intelligence artificielle », ou tout autre concept principal. Cette identification s'effectue souvent via un **cluster** de grande taille, rendu cohérent par la somme ou la moyenne de ses liens internes ($\omega_{\alpha,\beta}$).

Une fois ce thème principal \mathcal{T} établi, un **flux** top-down est possible. Sur le plan **formel**, on introduit un terme $\Delta_{\text{down}}^{(\text{macro})}(i, j)$ dans la mise à jour des pondérations :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i, j) - \tau \omega_{i,j}(t)] + \Delta_{\text{down}}^{(\text{macro})}(i, j).$$

Ce terme $\Delta_{\text{down}}^{(\text{macro})}(i, j)$ peut être **positif** ou **négatif** selon que le macro-nœud \mathcal{T} estime utile de renforcer la liaison (i, j) (car il est jugé pertinent pour le sujet) ou de l'inhiber (car il est hors sujet).

B. Influence sur l'Interprétation Locale (Mots Ambigus, Chunks Polyvalents)

En **linguistique**, de nombreux mots (ex. « bank », « seal », « network ») présentent plusieurs sens possibles. Le choix d'une **interprétation** dépend fortement du **contexte**. Si le macro-nœud a identifié le sujet global \mathcal{T} = « finance », alors un mot comme « bank » est lu dans son acception financière plutôt que géographique (rive d'un fleuve). Mathématiquement, le flux $\Delta_{\text{down}}^{(\text{macro})}$ agit sur les liens $\omega_{\text{bank,loan}}$ (renforcement) vs. $\omega_{\text{bank,river}}$ (diminution).

De la même manière, si le macro-niveau indique un **champ lexical** (ex. « biologie »), des tokens ambigus au niveau micro seront naturellement attirés vers des clusters locaux alignés sur ce thème, et leurs liens avec d'autres sphères seront réduits. Cela **stabilise** la structure micro autour d'une cohérence partagée : le mot « cellule » se connectera plus fortement à « ADN », « protéine » qu'à « prison » ou « téléphone », si le macro-nœud « biologie » est reconnu.

Ce flux descendant n'annule pas la logique micro : si un mot ou une expression n'a réellement **aucun** rapport avec le sujet macro, le score de synergie S restera faible, et la rétroaction top-down ne suffira pas à forcer un lien artificiel. Un **équilibre** se crée par la confrontation du flux ascendant (représentations locales factuelles) et du flux descendant (contexte global), garantissant une **interprétation plus riche** et moins ambiguë.

C. Ampleur du Feedback et Dynamique d'Équilibrage

Mécanisme de contrôle.

Pour éviter des oscillations extrêmes, on peut régler l’amplitude de la rétroaction $\Delta_{\text{down}}^{(\text{macro})}$ par un paramètre $\gamma_{\text{topdown}} > 0$. On définit, par exemple, une fonction $\Phi(\mathcal{T}, i, j)$ qui indique la pertinence du lien (i, j) au vu du sujet \mathcal{T} , puis

$$\Delta_{\text{down}}^{(\text{macro})}(i, j) = \gamma_{\text{topdown}} \Phi(\mathcal{T}, i, j).$$

Si la valeur de Φ est positive, le lien (i, j) est encouragé ; si elle est négative, il est affaibli. Par cette modération, le DSL ne bascule pas trop rapidement.

Analogie cognitive.

Le fait qu’un locuteur ou un lecteur « comprenne » le thème d’un texte et revoie son interprétation des mots locaux renvoie à la **mise en contexte**. Au niveau micro, on s’appuie sur des associations directes (synergie sémantique brute) ; au niveau macro, on oriente ou on “désambiguïse” ces associations pour coller au sujet principal.

Exemple pratique.

Si un article est globalement identifié comme un texte sur l’« IA » (intelligence artificielle), des mots comme « réseau », « neurone » ou « entraînement » seront alignés sur le champ “machine learning” plutôt que sur des sens moins pertinents (réseau social, neurone biologique, entraînement sportif). Les liens $\{\omega_{\text{neurone}, \text{entraînement}}\}$ se verront renforcés sous l’impulsion top-down, consolidant la cohérence IA.

Conclusion

La **rétroaction** top-down (macro \rightarrow micro) joue un **rôle** fondamental dans un **DSL** multi-niveau appliqué au **langage** :

3. **Sujet global identifié.** Le niveau macro détecte un **thème** dominant,
4. **Signal descendant.** On “pousse” un feedback dans la mise à jour $\Delta_{\text{down}}^{(\text{macro})}$, modifiant $\omega_{i, j}$,
5. **Interprétation** locale plus **précise**. Les mots, expressions ou tokens ambigus sont réorientés vers le sens le plus compatible avec le thème identifié,
6. **Équilibre** de la dynamique. On ne force pas la structure locale contre la synergie intrinsèque, mais on l’influence pour une **cohérence** multi-niveau.

Ce mécanisme illustre l’un des principes du **DSL** : l’information circule **ascendante** (agrégation de liens locaux) et **descendante** (validation, scission ou repondération en fonction d’un sujet macro). La **compréhension** textuelle en bénéficie, car la **cohésion** globale rétroagit sur les choix de clustering micro, réduisant l’ambiguïté sémantique et consolidant les **relations** lexicales en un réseau linguistique stable et mieux aligné sur le **contexte**.

6.6.3. Robotique Synergique : Intégration Sensorimotrice

Dans le domaine de la **robotique**, les principes d’**auto-organisation** et de **synergie** (au cœur du **DSL**) s’appliquent tout particulièrement à la gestion **multi-niveau** des informations sensorielles et des actions motrices. Le robot, équipé de multiples **capteurs** (caméras, gyroscopes, LIDAR, capteurs de force, etc.), doit non seulement **fusionner** ces données pour percevoir son environnement, mais également **coordonner** diverses actions (rouler, saisir, se déplacer en essaim avec d’autres robots...) pour mener à bien un **comportement global** cohérent.

6.6.3.1. Micro-Niveau : Capteurs Basiques (Caméras, Gyros...), Macro : Comportement Global (Navigation, Prise d’Objets...)

Principes Généraux et Contexte. Les systèmes robotiques reposent souvent sur une **pluralité** de capteurs : caméras (vision), gyroscopes (orientation), LIDAR, capteurs de force, etc. Pour accomplir des **tâches** plus globales (navigation, interaction, manipulation d’objets), le robot doit intégrer ces multiples flux sensoriels. Dans une **approche** de **Deep**

Synergy Learning (DSL) multi-niveau, l’articulation est la suivante : au niveau **micro**, on s’occupe de la synergie entre capteurs eux-mêmes, tandis qu’au niveau **macro**, on obtient des comportements globaux. Les développements ci-après montrent comment, grâce à la mise à jour adaptative des pondérations $\omega_{i,j}$, le DSL construit des **clusters** sensoriels cohérents et, par agrégation, aboutit à des modules comportementaux plus larges.

A. Niveau Micro : Le Monde des Capteurs

Au niveau le plus bas (ou $\ell = 0$), on considère chaque capteur \mathcal{C}_i comme un **nœud** dans un **SCN**. Il produit un flux de mesures (images, angles, distances) associé à une **entité** \mathcal{E}_i . On relie les paires $\{\mathcal{E}_i, \mathcal{E}_j\}$ par des pondérations $\omega_{i,j}$, qui traduisent la **synergie** ou la **corrélation** entre deux flux sensoriels. Ce mécanisme s’inspire de la mise à jour DSL :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(\mathcal{E}_i, \mathcal{E}_j) - \tau \omega_{i,j}(t)].$$

Si deux capteurs (par exemple, une caméra frontale et un LIDAR) “voient” la même forme d’obstacle, leur **similarité** $S(\mathcal{E}_i, \mathcal{E}_j)$ sera forte, entraînant une hausse de $\omega_{i,j}$. Inversement, des capteurs faiblement corrélés (vision frontale et capteur de force sur la pince) n’auront pas de liaison importante. La **dynamique** DSL, en renforçant ou en diminuant les pondérations, fait émerger naturellement des **clusters** de capteurs coopératifs (ex. cluster “détection d’obstacle” regroupant les capteurs directionnels, cluster “calibration d’équilibre” regroupant gyroscopes + accéléromètres).

On peut écrire la **synergie** $S(\mathcal{E}_i, \mathcal{E}_j)$ de multiples façons : indicateur de corrélation statistique si deux capteurs produisent des mesures parallèles, indice de concordance si la vision confirme les distances du LIDAR, etc. Le **DSL** consolide ces indices pour obtenir, au niveau micro, des sous-ensembles de capteurs spécialisés.

B. Niveau Macro : Le Comportement Global

Au palier supérieur, on **agrège** (via une fonction Ψ) les liaisons $\omega_{i,j}$ internes à chaque cluster sensoriel afin d’obtenir des super-nœuds décrivant des **modules** plus larges. Le robot peut disposer d’un super-nœud “évitement d’obstacle” englobant les capteurs frontaux cohérents, d’un super-nœud “navigation globale” englobant GPS + boussole + gyroscopes, etc. Chacun de ces super-nœuds fournit une **fonctionnalité** ou un **sous-comportement**.

La **tâche** globale (macro) du robot, telle qu’aller d’un point A à un point B en évitant les obstacles, se décompose donc en une **composition** de super-nœuds sensoriels et d’algorithmes de contrôle : le DSL, en reliant ces super-nœuds, détermine un **module** “navigation” intégrant la synergie sensorielle requise (vision + LIDAR + odométrie). Pour la **manipulation** (prise d’objet), un autre macro-module intègre caméras de détection d’objets, capteurs de force sur la pince, etc. Sur le plan **formel**, ces super-nœuds peuvent être traités comme des **nœuds** $\{\mathcal{N}_\alpha^{(k)}\}$ au palier k , tandis qu’un **macro-nœud** unique, fusionnant ces sous-comportements, émerge au niveau ultime.

C. Exemples Concrets

Robot mobile.

Un robot à roue peut comporter :

- un cluster sensoriel “orientation” (gyroscope + accéléromètre) pour stabiliser la trajectoire,
- un cluster “vision frontale + LIDAR” pour évaluer les obstacles,
- un cluster “GPS + boussole” pour la localisation générale.

Ces ensembles, identifiés localement par la logique DSL, se combinent au niveau macro pour orchestrer la **navigation** (choisir la route, freiner si un obstacle est trop proche, etc.).

Bras manipulateur.

Dans une tâche de **saisie d’objets**, on identifie un cluster “capteur force + caméra pince” pour le contrôle de la préhension, éventuellement un cluster “vision externe + localisation d’objet” pour pointer l’objet, et un cluster “contrôle bras + base” assurant la posture globale. La hiérarchie de super-nœuds (micro→macro) donne une vue

modulaire de la robotique, où chaque sous-module sensoriel s'intègre dans un comportement de plus haut niveau (saisir, déplacer, poser).

D. Avantages Mathématiques et Opérationnels

Plutôt que de traiter chaque capteur individuellement dans un *unique* bloc de décision central, le DSL multi-niveau crée des **clusters** sensoriels naturellement cohérents. D'un point de vue mathématique, on aboutit à un **réseau** $\{\omega_{i,j}\}$ plus épars, où seuls les liens justifiés par la **synergie** subsistent. Cela allège la complexité, en substituant un trop-plein de connexions par une structure plus sélective.

Si un capteur se dégrade (ex. caméra obstruée), son lien ω avec les autres capteurs chute (faible S), incitant le système à s'appuyer sur d'autres sources. Au niveau macro, le **comportement global** (ex. "évitement d'obstacles") s'ajuste en s'alimentant davantage d'un LIDAR intact ou d'une caméra latérale encore fiable.

Les clusters sensoriels se mettent à jour **localement** : chaque capteur compare ses mesures à celles d'un petit sous-ensemble de capteurs apparentés. L'agrégation en super-nœuds de plus haut niveau s'effectue de façon asynchrone et incrémentale, favorisant la **réactivité**. On n'a pas besoin de réapprendre *ex nihilo* ou de tout centraliser, ce qui est crucial pour un robot en mouvement.

Conclusion

Dans la **robotique synergique**, le **niveau micro** consiste à gérer la **myriade** de capteurs (vision, inertiels, force, distance...), tandis que le **niveau macro** porte sur le **comportement global** du robot (navigation, prise d'objets, etc.). Le **DSL** relie ces deux paliers en définissant des pondérations $\omega_{i,j}$ qui traduisent la **coopération** sensorielle : à l'échelle micro, des capteurs forment des clusters sensoriels cohérents ; à l'échelle macro, ces clusters se combinent pour accomplir la tâche globale, depuis la simple détection d'obstacles jusqu'à la manipulation.

Cette **organisation** hiérarchique est **adaptative** : si les flux sensoriels évoluent (capteurs défectueux, changement d'environnement), la mise à jour locale des pondérations assure une **auto-organisation** continue, dont les répercussions se font sentir au niveau macro. On obtient ainsi un **réseau** où la **sélection** (agrégation ou division) de sous-systèmes se fait progressivement, sur la base de la **synergie** sensorielle, et où le **comportement** (macro-nœud) émerge de l'intégration structurée de clusters sensoriels (micro). C'est cette **plasticité** qui donne au robot la **robustesse** nécessaire pour évoluer dans un environnement complexe et en perpétuelle évolution.

6.6.3.2. Logiciel Multi-Threads où le DSL Gère la Synergie Localement, puis un "Super-Nœud" Pilote l'Action Globale

Contexte Général et Motivations. Dans la robotique à grande échelle, l'**architecture logicielle** fait souvent appel à un **multi-threading** (ou multi-processus léger) pour traiter en parallèle divers **capteurs** (caméras, gyroscopes, LIDAR, etc.). Chacun de ces fils d'exécution s'occupe d'un sous-ensemble de données ou d'une tâche partielle (comme le traitement d'images ou l'acquisition lidar), tandis qu'un **module** central, parfois appelé "super-nœud" ou "pilot", orchestre le **comportement global** du robot (navigation, saisie d'objet, collaboration, etc.). Au sein du **Deep Synergy Learning (DSL)**, l'idée est d'exploiter cette répartition logicielle : chaque thread met en œuvre localement la **règle** de mise à jour $\omega_{i,j}$, tandis que le super-nœud agrège l'information et oriente l'action finale. On obtient ainsi une **auto-organisation** distribuée sur les capteurs, couplée à une **coordination** hiérarchique pour la prise de décision.

A. Répartition Multi-Threads pour la Gestion Locale de la Synergie

Au **niveau micro**, on considère qu'un ensemble de capteurs $\{\mathcal{E}_i\}$ sont distribués dans différents fils d'exécution (threads). Chaque thread reçoit les flux de quelques capteurs (caméra frontale, caméra latérale, LIDAR, etc.) et traite localement la **synergie** $\omega_{i,j}$. Par exemple, une **mise à jour** DSL de la forme

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(\mathcal{E}_i, \mathcal{E}_j) - \tau \omega_{i,j}(t)]$$

s'exécute au sein d'un thread si \mathcal{E}_i et \mathcal{E}_j relèvent d'un même groupe de capteurs ou d'un domaine d'opération connexe. L'information $S(\mathcal{E}_i, \mathcal{E}_j)$ peut être un indice de **similarité** (corrélation d'images, cohérence de mesures lidar) ou de **complémentarité** (caméra + infrarouge).

Dans un système multi-threads, chaque fil d'exécution tourne à sa propre fréquence, mettant à jour certaines parties de la matrice ω . Pour assurer la **cohérence**, on recourt à des verrous (mutex) ou des algorithmes lock-free afin que $\omega_{i,j}$ ne soit pas altéré de façon incohérente. Chaque thread reçoit périodiquement les états des capteurs, calcule $\Delta\omega$ pour les liens pertinents, puis valide ces changements. Cela **distribue** la tâche de mise à jour DSL et rend l'auto-organisation plus **échelonnée** : des clusters sensoriels locaux émergent par simple renforcement/décroissance en temps réel.

Mathématiquement, la matrice ω est fragmentée en plusieurs *blocs* gérés par autant de threads : chaque bloc correspond aux liens (i, j) entre capteurs dont la synergie doit être évaluée conjointement. Par exemple, on peut coupler la caméra frontale et le LIDAR frontal dans un **bloc** "détection d'obstacles", un autre bloc rassemblant les capteurs inertiels (gyroscopes, accéléromètres) pour la stabilisation. Les **clusters** de capteurs se manifestent localement si $\omega_{i,j}$ se consolide, renforçant la collaboration de ces entités.

B. Super-Nœud pour le Pilotage Global

Une fois les synergies locales (micro) établies, la **tâche** du robot (macro) consiste à agir : se déplacer, saisir un objet, éviter un obstacle, etc. Dans un DSL multi-niveau, on conçoit un **super-nœud** (un thread maître ou un module) qui regroupe les **super-nœuds** issus de l'agrégation sensorielle. Autrement dit, le super-nœud perçoit la configuration globale des clusters (ex. cluster "vision-frontale-lidar", cluster "accéléromètre-gyroscope") et combine leurs informations pour **décider** de l'action. S'il s'avère que la synergie "éviter obstacle" est forte (danger imminent), le super-nœud enclenche la commande motrice de freinage ; si c'est le cluster "saisie d'objet" qui s'active, il dirige le bras vers l'objectif.

Périodiquement, chaque thread local transmet au super-nœud un *résumé* : $\omega_{\alpha,\beta}$ pour différents segments sensoriels, ou un **score** de fiabilité. Le super-nœud peut alors "fusionner" (via Ψ) les données et décider, par exemple, de scinder ou de réunir certains clusters si l'hétérogénéité interne le justifie (voir 6.5.2). Cela se formalise par :

$$\omega_{\alpha,\beta}^{(\text{macro})} = \Psi(\{\omega_{i,j}^{(\text{local})} : i \in \alpha, j \in \beta\}),$$

puis le super-nœud évalue l'opportunité de moduler (inhiber ou renforcer) des liens via un flux descendant (chap. 6.4).

Dans la pratique, un **robot mobile** gère la synergie locale d'"obstacle detection" par un thread "lidar+caméra frontale" ; un autre thread combine inertiels + GPS pour la navigation large. Le super-nœud global reçoit leurs états, voit s'il doit prioriser l'évitement d'obstacles ou continuer la route, et envoie des **commandes** au système moteur. En cas de conflit (capteur en panne), il peut forcer une reconfiguration en poussant un *terme descendant* défavorable aux liaisons du capteur défectueux.

C. Avantages en Robotique Synergique

Une approche **multi-threads** répartit la gestion de la synergie $\omega_{i,j}$; chaque fil d'exécution prend en charge un sous-ensemble de capteurs, allégeant la complexité globale. Le super-nœud ne fait qu'**agréger** et **décider**, évitant de gérer $O(n^2)$ liaisons en un seul point central.

Un événement local (caméra détectant un obstacle) modifie $\omega_{\text{cam,lidar}}$ presque instantanément. Le super-nœud, en lisant ces informations, enclenche l'action appropriée. Cette asynchronie évite d'attendre un cycle complet d'un pipeline monolithique.

La défaillance d'un thread (par ex. une caméra latérale obstruée) n'immobilise pas tout le système. Les autres threads continuent leur mise à jour DSL, et le super-nœud réduit la confiance (ou la synergie) associée au module défaillant. Au besoin, on peut **ajouter** un capteur (thread nouveau) sans reprogrammer la totalité : ses liens ω émergent progressivement dans la logique DSL, et le super-nœud l'intègre si un cluster se forme autour de lui.

Conclusion

Dans une **architecture logicielle** robotique **multi-threads**, le **DSL** opère localement (micro) pour gérer la **synergie** entre capteurs distribués, chaque fil d'exécution maintenant ses pondérations ω selon la formule DSL. Ensuite, un **super-nœud** (thread principal) recueille la **configuration** globale et pilote l'**action** macro (navigation, saisie, interaction). Cette combinaison de :

- **Auto-organisation** distribuée (chaque thread capteur gère ω localement),
- **Agrégation hiérarchique** (super-nœud qui fusionne et oriente la décision),

permet une **répartition** de la charge (scalabilité), une **réactivité** élevée (changement local immédiatement pris en compte), et une **robustesse** (grâce à l'adaptabilité du DSL aux pannes ou ajouts de capteurs). L'ensemble s'inscrit dans la **philosophie** de la robotique synergique : intégrer de multiples flux sensoriels et modules de traitement en un **réseau** cohérent, réagissant en temps réel au monde extérieur.

6.6.3.3. Notion Fractale si on Observe la Même Logique de Commande à Divers Sous-Systèmes Moteurs

L'architecture **DSL** (Deep Synergy Learning) appliquée à la robotique ne se borne pas au traitement des capteurs ; elle peut également s'étendre aux **ensembles d'actionneurs** et de commandes motrices. À l'échelle la plus locale, des groupements de joints ou de moteurs se coordonnent pour des mouvements élémentaires (par exemple, les doigts d'une pince ou les roues antérieures d'un véhicule). À un niveau intermédiaire, plusieurs de ces sous-ensembles coopèrent dans un module plus vaste (un bras complet, un chariot de locomotion), tandis qu'au niveau le plus global (macro-nœud), le robot exécute un **comportement** ou une **tâche** englobante. Lorsque la même logique DSL (mise à jour des pondérations ω , agrégation, division, rétroaction descendante, etc.) est reproduite à chaque échelle d'organisation, il se crée une forme de **structure fractale**, car la même règle d'auto-organisation se réplique du plus petit sous-système moteur à l'unité robotique intégrale.

Il est d'abord essentiel de comprendre le rôle des **sous-systèmes moteurs** à l'échelle locale. Chaque actionneur ou groupe de joints est traité comme une entité \mathcal{E}_i . Les pondérations $\omega_{i,j}$ traduisent la synergie ou la synchronisation entre deux actionneurs i et j . La règle DSL

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(\mathcal{E}_i, \mathcal{E}_j) - \tau \omega_{i,j}(t)]$$

peut conduire à l'émergence de **clusters** moteurs dès lors que plusieurs joints se trouvent souvent co-activés ou dont les positions se coordonnent. Les doigts d'une pince se coordonnent dans la "manipulation fine", les roues droites d'un châssis forment un mini-groupe fonctionnel pour déplacer le côté droit, etc. La mise à jour adaptative des pondérations ω autorise ces regroupements à évoluer si le robot entreprend des tâches différentes (de la locomotion à la saisie d'objets), ce qui modifie les fréquences et les patrons de co-activation.

Une fois ces **clusters** moteurs identifiés au niveau micro, un **palier intermédiaire** agrège leurs synergies, créant des super-nœuds pour des modules plus vastes : un "bras gauche" ou une "base roulante" où se concentrent les synergies internes. Le mécanisme est le même qu'avec les capteurs, simplement transposé au monde des actionneurs. On applique une fonction Ψ agrégeant $\{\omega_{i,j}\}$ sur un sous-système donné, et l'on obtient $\omega_{\alpha,\beta}$ entre super-nœuds α et β . À ce stade, la *même* équation DSL ou la même division top-down peut se produire : si un sous-système devient trop "hétérogène" (par exemple, un grand regroupement d'actionneurs qui n'ont pas tant besoin de coopérer), on scinde, ou si deux sous-systèmes collaborent souvent, leurs liens ω se voient renforcés pour fusionner.

Le **palier macro** couronne le processus, lorsque le robot exécute un **comportement intégral**. Le super-nœud global, englobant l'ensemble des sous-nœuds moteurs, établit quelles combinaisons d'ensembles d'actionneurs déclencher pour chaque tâche. Lorsque le robot alterne entre locomotion et manipulation, il active ou module les liens $\omega_{\alpha,\beta}$ entre la base roulante et le bras, reflétant la co-activation ou la "pertinence conjointe" de ces modules. La même dynamique DSL assure qu'un comportement très souvent sollicité se traduise par des pondérations ω plus élevées entre les sous-systèmes pertinents, tandis qu'un comportement moins usuel demeure moins intégré ou subit la décroissance paramétrée par τ .

La **notion fractale** jaillit du fait que l’on retrouve, à chaque échelle, la *même* logique : le niveau micro (quelques joints) applique la règle DSL pour gérer les liens $\omega_{i,j}$, le niveau intermédiaire (un sous-système comme un bras complet) applique la même équation pour agréger ou diviser les sous-modules, et le niveau macro (tout le robot) applique encore cette formule pour orchestrer les super-nœuds. En pratique, on peut voir des distributions de pondérations ω qui présentent une **auto-similarité** lorsqu’on change d’échelle, ou constater que la fonction de clusterisation exhibe une loi de puissance quant à la taille des modules moteurs. Cela relève d’une **structure fractale**, car la *même forme* d’auto-organisation DSL se reproduit du plus petit sous-système à la commande intégrale de l’agent.

Un bénéfice évident se situe dans la **flexibilité**. À l’échelle micro, on laisse la main à un cluster local pour, par exemple, gérer la coordination fine de quelques doigts. Lorsque le robot doit synchroniser deux bras pour soulever un objet, un palier intermédiaire perçoit la synergie (co-activation récurrente) et forme un super-nœud “opération bimanipulative”, qui, au niveau macro, se connecte éventuellement à la base roulante si le robot doit transporter l’objet. Cette réplique de la *même règle* DSL sur plusieurs plans laisse la structure se reconfigurer s’il apparaît qu’un module d’actionneur n’a plus besoin de coopérer. D’un point de vue mathématique, cela s’apparente à un graphe ω multi-niveau qui, selon les mêmes principes de renforcement ou d’inhibition, fait émerger un ensemble de super-nœuds cohérents.

La conclusion est que lorsqu’on **observe** à chaque palier cette *même* logique de commande auto-organisée, on obtient des **paysages fractals** dans la commande motrice. Il y a un continuum entre de petites sous-entités (couple de joints) et l’entité globale (tout le robot), en passant par des modules (un bras, une base de locomotion), tous gérés par la même mise à jour ω . Cela produit une **cohérence** hiérarchique, une plasticité face au changement de tâche, et des dynamiques macroscopiques qui émergent naturellement d’une multiplication de petits ajustements microscopiques. L’**approche fractale** n’est donc pas qu’un concept abstrait : elle garantit qu’à chaque échelle, la commande obéit à la même *grammaire* DSL, donnant au robot la capacité de gérer un large spectre de configurations motrices sans requérir un contrôle monolithique.

6.6.4. Agents Conversationnels Riches et Contextuels

Le domaine des **agents conversationnels** (chatbots, systèmes de dialogue) bénéficie lui aussi d’une organisation **multi-échelle**. En effet, une conversation ne se limite pas à une suite linéaire de répliques : elle se structure en **segments**, **sous-thèmes**, **intentions** globales, etc. Le **DSL** (Deep Synergy Learning), avec son mécanisme d’**auto-organisation** (pondérations adaptatives ω , agrégation/division multi-niveau), offre un cadre où :

7. Les **segments** de conversation (micro) peuvent se regrouper selon leur cohérence ou leur synergie sémantique,
8. Les **intentions** ou **topics** plus larges (macro) émergent de l’agrégation de ces segments,
9. Le réseau conversationnel peut se réorganiser au fil du dialogue, gérant le contexte de manière dynamique.

Dans ce qui suit (6.6.4.1), nous détaillons comment, au *niveau micro*, on manipule des **segments** de conversation, tandis qu’au *niveau macro*, on repère des **intentions** ou **sujets** d’échange.

6.6.4.1. Micro : Segments de Conversation, Macro : Intentions ou Topics

Dans l’analyse conversationnelle, il est naturel de considérer la discussion sous différents paliers : au niveau **micro**, on manipule des segments (ou “turns”) correspondant à une question, une réponse, ou un bloc de discours. Au niveau **macro**, ces segments s’agrègent pour former des intentions ou “topics” plus larges, tels que l’enchaînement des idées autour d’une question “météo” ou d’une requête “horaires de train”. Le **Deep Synergy Learning (DSL)** offre une manière de faire émerger automatiquement cette organisation multi-niveau : le niveau micro regroupe les segments proches, et le niveau macro identifie les intentions sous-jacentes.

Il est d’abord utile de décrire comment se traite le **niveau micro** des segments de conversation. Chaque segment \mathcal{E}_i représente un bloc de discours (par exemple, une phrase d’un utilisateur, une réponse du chatbot) que l’on encode sous la forme d’un vecteur sémantique \mathbf{v}_i (embedding). On introduit une **synergie** $S(\mathcal{E}_i, \mathcal{E}_j)$ mesurant la similarité sémantique ou contextuelle entre deux segments. Une fonction usuelle est la similarité cosinus :

$$S(\mathcal{E}_i, \mathcal{E}_j) = \frac{\mathbf{v}_i \cdot \mathbf{v}_j}{\|\mathbf{v}_i\| \|\mathbf{v}_j\|}.$$

Dans le DSL, on maintient pour chaque couple (i, j) une pondération $\omega_{i,j}$, mise à jour à l'aide de l'équation

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(\mathcal{E}_i, \mathcal{E}_j) - \tau \omega_{i,j}(t)],$$

où $\eta > 0$ est un taux d'apprentissage et $\tau > 0$ un facteur de décroissance. Lorsque deux segments de conversation \mathcal{E}_i et \mathcal{E}_j abordent un même sujet, leurs embeddings sont proches, ce qui donne une synergie $S(i, j)$ élevée et fait croître $\omega_{i,j}$. Un ensemble de segments fortement interconnectés peut dès lors constituer un **cluster** local, reflétant la poursuite d'un sujet précis (questions et réponses cohérentes, réactions enchaînées, etc.).

Une fois qu'au palier micro on observe des groupes de segments fortement reliés, on peut passer au **niveau macro**. L'agrégation de ces segments permet de définir des super-nœuds, c'est-à-dire des **intentions** ou **topics** plus vastes. On applique généralement une fonction Ψ pour agréger les pondérations micro en $\omega_{\alpha,\beta}^{(\text{macro})}$, selon

$$\omega_{\alpha,\beta}^{(\text{macro})} = \Psi(\{\omega_{i,j} \mid i \in \alpha, j \in \beta\}),$$

où α, β sont des ensembles de segments (clusters) déjà identifiés. On peut choisir Ψ comme une moyenne, une somme, ou un maximum. On obtient alors un graphe macro où chaque super-nœud représente un **topic** (par exemple “discussion sur la météo”, “demandes d'information sur les horaires de train”), et où les arcs $\omega_{\alpha,\beta}^{(\text{macro})}$ traduisent la proximité ou la cohérence entre ces topics (si la conversation a fusionné deux thématiques).

Il est intéressant de rapprocher ce fonctionnement d'un système de chatbot “classique”. Généralement, l'identification d'intentions s'effectue via un classifieur supervisé qui assigne chaque phrase à un label d'intention (ex. salutations, question sur la météo, etc.). Dans le DSL, l'intention n'est pas imposée à l'avance, mais **émerge** de la synergie entre segments. On n'a pas besoin de spécifier une liste fermée d'intentions : si un nouveau sujet apparaît, le DSL l'isole en créant un nouveau cluster de segments corrélés. Cette plasticité s'avère particulièrement utile lorsqu'on veut gérer **plusieurs** sujets en parallèle, sans entremêler leurs segments de manière chaotique.

On peut illustrer ce mécanisme par un petit exemple numérique. Considérons des segments $\{E_1, E_2, E_3, \dots\}$. Les similarités $S(E_1, E_2) = 0.8$, $S(E_2, E_3) = 0.7$, etc., alimentent la mise à jour DSL. Les pondérations $\omega_{1,2}$ et $\omega_{2,3}$ croissent vers $0.8/\tau$ et $0.7/\tau$. En conséquence, on regroupe $\{E_1, E_2, E_3\}$ en un cluster (la même discussion autour d'un thème local). De leur côté, $\{E_4, E_5\}$ peuvent constituer un autre cluster s'ils abordent un sujet distinct (par exemple, un bavardage sur la cuisine). On obtient alors deux **topics**.

Sur le plan pratique, ce schéma confère des **gains** en analyse conversationnelle. Les segments qu'un agent conversationnel reçoit sont organisés en clusters, ce qui permet à l'agent de “savoir” quel sous-ensemble discute d'un sujet donné. Lorsqu'un nouveau segment \mathcal{E}_{new} arrive, il calcule la synergie $S(\mathcal{E}_{\text{new}}, E_i)$ pour les segments existants $\{E_i\}$. Si cette synergie est forte avec ceux du topic “météo”, alors $\omega_{\text{new},i}$ se renforce, et \mathcal{E}_{new} rejoint ce topic, assurant une **contextualisation** immédiate. S'il n'existe pas de topic correspondant (faible synergie avec tout l'existant), le DSL alloue un **nouveau** cluster pour cette thématique émergente.

Le DSL multi-niveau permet également qu'il y ait **coexistence** de plusieurs topics en parallèle : un fil sur la météo, un fil sur la cuisine, éventuellement un fil sur l'économie, etc. Le système ne force pas un “mode monothématique”, comme le ferait un classifieur d'intentions qui assignerait chaque phrase à une intention unique. Ici, les topics constituent des **super-nœuds** agrégés depuis la matrice $\omega_{i,j}$ des segments, et peuvent même avoir des liaisons modestes ou élevées entre eux si la conversation fait des transitions thématiques.

En conclusion, au **niveau micro**, on considère que chaque segment de conversation est une entité \mathcal{E}_i . Le DSL calcule $\{\omega_{i,j}\}$ selon une similarité sémantique, révèle des micro-clusters de segments cohérents, puis agrège ces micro-clusters en **intentions** ou **topics** (niveau macro). Le caractère adaptatif du DSL fait que l'arrivée de nouveaux segments réactualise localement ω , permettant de fusionner ou de scinder des topics sans nécessiter un apprentissage global ou une taxonomie préalable. L'agent conversationnel exploite alors ces topics pour gérer le **contexte** et le **flow** entre multiples sujets, assurant une **robustesse** et une **souplesse** rares dans les architectures de chatbot plus classiques.

6.6.4.2. Multi-Échelle : La Conversation se Hiérarchise en Sous-Thèmes, Thèmes plus Généraux

Lors d'un échange conversationnel, qu'il s'agisse d'un dialogue humain-humain ou d'un système de chatbot interagissant avec plusieurs utilisateurs, on observe fréquemment plusieurs **sous-thèmes** parallèles qui s'insèrent dans un **thème** plus global ou un **contexte** englobant. Le **Deep Synergy Learning (DSL)**, par sa faculté de créer des clusters localement (niveau micro) puis de les **agréger** ou de les **diviser** au fil du temps (niveau macro), permet une **hiérarchisation** organique de la conversation. Les paragraphes qui suivent décrivent comment, au sein d'un DSL, des segments localement liés par la synergie forment des sous-thèmes, et comment ces sous-thèmes à leur tour se rejoignent (ou se distinguent) pour générer des thèmes d'échelle supérieure, parfois avec un caractère **fractal** lorsque la même structure se répète à divers niveaux.

A. Du Sous-Thème Local au Thème Général : Construction Progressive

Tout d'abord, on considère la conversation découpée en **segments** $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$. Chaque segment (phrase, réplique ou bloc de texte) est relié aux autres par des pondérations $\omega_{i,j}$. Dans la **logique** DSL, la mise à jour itérative

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(\mathcal{E}_i, \mathcal{E}_j) - \tau \omega_{i,j}(t)]$$

se fonde sur une **synergie** $S(\mathcal{E}_i, \mathcal{E}_j)$ (similarité sémantique, continuité thématique, etc.). Au fil des itérations, on voit émerger des **clusters** regroupant des segments qui traitent le même micro-sujet, comme “recherche de billets de train” ou “discussion anecdotique sur la météo”. Chacun de ces clusters peut être assimilé à un **sous-thème** local.

Une fois ces sous-thèmes définis, le système agrège les pondérations internes pour former des **super-nœuds** $\{\mathcal{N}_\alpha\}$. Si plusieurs sous-thèmes se trouvent eux-mêmes synergiques (par exemple, tous traitent de voyages, l'un portant sur le train, l'autre sur l'avion, un troisième sur les hôtels), ils se **fusionnent** en un **thème** plus large. Pour ce faire, on utilise une fonction d'agrégation Ψ :

$$\omega_{\alpha,\beta}^{(\text{macro})} = \Psi(\{\omega_{i,j}\}_{i \in \alpha, j \in \beta}),$$

puis on applique la même règle DSL ou un critère \mathcal{H} (hétérogénéité) pour décider de la **fusion** ou de la **division** de thèmes. Ainsi, un grand thème “voyage” peut s'auto-organiser en sous-thèmes “train”, “avion” et “réservation d'hôtel”.

B. Logique Fractale dans la Hiérarchisation de la Conversation

Il est fréquent qu'un même **concept** (ex. “déplacements”) apparaisse à différents niveaux : d'abord, on l'évoque localement dans quelques segments (détails de billets), puis on le retrouve sous forme d'un sous-thème regroupant ces segments, et, enfin, on le voit ressurgir à un niveau plus global où la conversation discute d'un projet de voyage plus vaste. Cette forme de récurrence multi-niveau rappelle la notion de **fractal** (chap. 6.3) : la *même structure* (discussion autour du déplacement) se répète à plusieurs échelles de granularité.

Dans un DSL, la *même* règle de mise à jour $\omega(t+1) = \omega(t) + \dots$ se rejoue entre :

- les entités segments (niveau micro),
- (ii) les super-nœuds sous-thèmes (niveau intermédiaire),
- (iii) les super-nœuds plus englobants (niveau macro).

Le schéma d'agrégation–division (chap. 6.5) se reproduit donc à plusieurs paliers, générant une structure de clusters (ou super-nœuds) “auto-similaire” d'un niveau à l'autre. On peut donc, en certain sens, qualifier de “fractale” cette hiérarchie conversationnelle, puisqu'elle reproduit un *motif* identique d'**auto-organisation**.

C. Avantages Concrets pour l'Agent Conversationnel

Quand un **agent** conversationnel identifie un sous-thème α (par ex. “le train de demain matin”), il possède la liste des segments $\{\mathcal{E}_i\}$ rattachés à α . S'il constate que α se joint à un autre sous-thème β (“réservation d'hôtel”) sous un thème

plus large “voyage”, il unifie son contexte : l’agent peut thus “comprendre” que tous ces segments s’inscrivent dans un plan de voyage global. Cela favorise la **cohérence** dans les réponses et la possibilité de naviguer entre micro-détails (“prix du billet de train”) et macro-sujet (“voyage en Europe la semaine prochaine”).

Dans une conversation chaotique où plusieurs sujets se déploient, le DSL autorise la **coexistence** de clusters (sous-thèmes distincts), lesquels s’agrègent ou se divisent au fil des nouveaux segments. On n’a pas besoin d’une structure préétablie. Chaque **nouveau** segment \mathcal{E}_{new} calcule sa similarité $S(\mathcal{E}_{\text{new}}, \mathcal{E}_i)$ avec les segments existants, renforce ou diminue $\omega_{\text{new},i}$, et finit par rallier un sous-thème ou en créer un nouveau. L’agent peut traiter simultanément plusieurs fils de discussion.

Si un grand sous-thème devient trop large, la procédure DSL (chap. 6.5.2) peut déclencher une scission top-down : on sépare un “macro-sous-thème” en deux plus petits. Inversement, deux sous-thèmes trop proches fusionnent. Le tout s’actualise localement dans la matrice ω , sans exiger un recalcul complet. Cette **adaptation** soutient les dialogues de longue durée ou hautement changeants.

Conclusion

Au sein d’une **conversation** complexe, la **hiérarchie multi-niveau** permet de distinguer :

10. **Sous-thèmes** (niveau micro) : petites grappes de segments, localement synergiques,
11. **Thèmes** globaux (niveau macro) : unification de sous-thèmes fortement apparentés.

Dans un **DSL**, ces *clusters* se forment ou se dissolvent par la mise à jour adaptative de ω . Dès lors que la même *logique* (agrégation, division, feedback descendant) s’applique à plusieurs paliers, on peut parler de **récurrence fractale**. La **répétition** d’un même patron sémantique (micro→macro) reflète la manière dont un concept local (ex. “détails de tickets de train”) s’intègre dans un **contexte** plus vaste (“voyage” ou “organisation d’un séjour”). L’**agent** conversationnel bénéficie ainsi d’une structure interne naturellement évolutive, capable de naviguer entre plusieurs fils de discussion et d’agréger ces fils si une cohérence plus générale se dégage, ou de scinder un sujet si la conversation se subdivise, le tout sans nécessiter un cadre de topics pré-codé ou un entraînement supervisé rigide.

6.6.4.3. Avantage : Le DSL Repère des “Patrons Fractals” de Dialogue ou d’Échanges

Contexte et Enjeu. Dans un **échange** ou un **dialogue**, il n’est pas rare d’observer la récurrence d’un même *modèle d’interaction* à différents niveaux de granularité. Par exemple, on peut avoir un motif local (question–réponse) reproduit à l’échelle plus large (ensemble de sous-thèmes, chacun contenant des séquences de questions–réponses) et enfin à l’échelle globale (plusieurs blocs de discussion qui suivent la même logique). Lorsqu’un **Deep Synergy Learning (DSL)** multi-niveau est appliqué à l’analyse et la structuration du dialogue, cette **auto-similarité** récurrente s’assimile à une **fractalité**. Les développements qui suivent décrivent comment le DSL, par sa démarche d’agrégation et de division hiérarchique, parvient à **repérer** des “patrons fractals” dans l’agencement des segments, et en quoi cela **profite** à l’agent conversationnel.

A. Patrons Fractals : Définitions et Parallèles

Une structure fractale se caractérise par l’**auto-similarité** : la même forme ou le même schéma se reproduit à différentes échelles. Dans le contexte d’un dialogue, on peut voir un petit motif local (ex. “question–réponse–clarification”) réapparaître à une échelle plus large (plusieurs tours de parole structurant la même logique), et éventuellement au niveau d’un macro-sujet (une suite de sous-thèmes organisés en question–réponse). Le DSL, en utilisant la même **règle** (mise à jour des liaisons ω , agrégation, etc.) à chaque palier, capte naturellement cette **auto-similarité**.

Exemple de motif fractal.

Un motif “A pose une question, B répond, A clarifie” peut se répéter dans une conversation courte (quelques segments) ou plus longue (série de sous-thèmes). Chaque *patern* (A, B, C) se traduit par des pondérations $\omega_{i,j}$ élevées lorsque le segment “B” se lie fortement à “A” (réponse cohérente) et “C” se lie à “B” (clarification). Au niveau macro, on retrouve un agrégat de telles triades, mettant en évidence la même structure conversationnelle répétée.

Hiérarchie ascendante (agrégation).

Dans le DSL, on commence par **analyser** les segments individuels $\{\mathcal{E}_i\}$. Si deux segments $\mathcal{E}_i, \mathcal{E}_j$ se montrent récurrents dans la même logique (ex. question–réponse), leur pondération $\omega_{i,j}$ grimpe. Si, en outre, un troisième segment \mathcal{E}_k s’active avec $\{i, j\}$ (par ex. clarification), on peut aboutir à un cluster $\{\mathcal{E}_i, \mathcal{E}_j, \mathcal{E}_k\}$ correspondant à un schéma local. Au palier supérieur, si plusieurs de ces triades suivent une *même* structure, le DSL agrège les clusters en un **super-nœud** “pattern conversationnel”.

Pour formaliser cela, on définit une *énergie* ou un *score* inter-segments. Si un motif $\mathcal{M} = \{\mathcal{E}_a, \mathcal{E}_b, \mathcal{E}_c\}$ reproduit la séquence question–réponse–clarif, alors la somme

$$\Omega(\mathcal{M}) = \sum_{(x,y) \in \mathcal{M} \times \mathcal{M}} \omega_{x,y}$$

peut devenir élevée (les segments $\mathcal{E}_a, \mathcal{E}_b, \mathcal{E}_c$ se relient fortement). Lorsque cette somme $\Omega(\mathcal{M})$ dépasse un certain θ_{motif} , on identifie \mathcal{M} comme un “pattern” stable. Plusieurs motifs analogues $\mathcal{M}', \mathcal{M}''$ peuvent avoir la même structure, révélant la *réurrence* fractale.

Au niveau macro, la même **logique** DSL agit sur ces motifs (clusters) entre eux. Si l’on retrouve \mathcal{M} ou un motif similaire \mathcal{M}' dans un autre sous-thème, on observe une **auto-similarité** dans la distribution des liens. On peut donc parler de fractalité, car l’organisation question–réponse–clarif se répercute à une échelle plus large, comme un “schéma” s’appliquant à plusieurs groupes de segments.

C. Avantages pour l’Agent Conversationnel

Un utilisateur peut aborder plusieurs sous-thèmes de manière identique (à chaque fois : question, réponse, clarification). Le DSL, en reconnaissant ce *pattern*, permet à l’agent de mieux **anticiper** la structure attendue. Il peut par exemple plus rapidement fournir des réponses plus ciblées si la séquence se répète.

Le motif fractal n’est pas rigide. On repère la forme d’échange (ex. question–réponse–clarif) peu importe le *contenant* lexical. Le DSL, via la similarité $\omega_{i,j}$, autorise une grande variété de formulations sans casser le *pattern*. Ainsi, l’agent conversationnel peut exploiter ce schéma structurel pour organiser ses réactions, même si le contenu des segments varie beaucoup.

Dans des dialogues massifs (plusieurs participants, de multiples bifurcations), repérer des **motifs fractals** offre un mode de compression : plutôt que de gérer un graphe monolithique de segments, on sait qu’un certain motif local se décline en de multiples occurrences. On peut regrouper ces occurrences et naviguer plus efficacement dans la structure du dialogue.

Conclusion

En **obtenant** des “patrons fractals” dans la structure du dialogue, le **DSL** révèle l’**auto-similarité** de certains schémas conversationnels, à différents paliers : un *pattern* local (question–réponse–clarif) peut se reproduire dans des sous-thèmes, puis se retrouver encore en macro-sujets. La clé de voûte de cette détection fractale est la *répétition* de la même **règle** (mise à jour ω , agrégation, division, feedback) à chaque niveau. Cette configuration procure à l’**agent** conversationnel :

12. Une **reconnaissance** de schémas conversationnels récurrents,
13. Une **facilité** à gérer simultanément plusieurs occurrences du même motif (ex. multiples questions–réponses structurées),
14. Une **architecture** hiérarchique flexible, où les segments se groupent localement, puis s’unissent au macro-niveau, sans imposer d’a priori strict sur la forme ou le contenu.

Le résultat est un système **robuste** et **évolutif**, capable de cartographier un large dialogue en identifiant les *mêmes formes* d'échange qui se déclinent à divers degrés de granularité, formant ainsi un **patron fractal** de la conversation.

6.6.5. Applications dans la Simulation et la Prédiction d'Événements

Les principes **multi-échelle** du DSL (Deep Synergy Learning) trouvent un écho tout particulier dans la **simulation** et la **prédiction** d'événements. En effet, de nombreux phénomènes (économiques, climatiques, épidémiologiques, boursiers, etc.) s'expriment à la fois sous forme d'**événements ponctuels** (micro) et de **tendances** (macro). Le **DSL** permet alors d'**organiser** ces événements de manière adaptative, dévoilant des **mégapatterns** ou tendances globales tout en gardant la granularité des points individuels.

6.6.5.1. Micro : Événements Ponctuels, Macro : Tendances ou Mégapatterns (ex. Bourse, Climat)

Introduction et Cadre d'Analyse. Dans de nombreux flux temporels (données boursières, variables climatiques, événements sporadiques), chaque "point" observé peut être vu comme un **événement** local. Pour en extraire des **tendances** plus globales, on recourt souvent à une analyse multi-niveau : un **niveau micro** prend en charge l'identité et la collaboration ou similarité des événements ponctuels, tandis qu'un **niveau macro** agrège ces événements pour dégager des **tendances** (ou "mégapatterns") plus vastes, comme un cycle boursier haussier ou un changement climatique global. Le **Deep Synergy Learning (DSL)** fournit une méthodologie pour construire et adapter ces niveaux, tout en traitant l'apparition de nouveaux événements au fil du temps.

A. Niveau Micro : Événements Ponctuels

Il est courant, dans un flux temporel (bourse, climat, logs...), de définir chaque **événement** \mathcal{E}_i comme une entité $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$. Un événement peut consister, par exemple, en une transaction (bourse) ou une perturbation locale (climat).

Pour deux événements \mathcal{E}_i et \mathcal{E}_j , on introduit une **synergie** $S(\mathcal{E}_i, \mathcal{E}_j)$ reflétant leur **corrélation** ou leur **similarité** dans l'espace de variables considérées. On peut écrire :

$$S(\mathcal{E}_i, \mathcal{E}_j) = \rho(\mathbf{x}_i, \mathbf{x}_j),$$

où ρ est un coefficient de corrélation (Pearson, Spearman, etc.) ou tout autre indicateur de concomitance. Cette approche s'adapte aisément aux données boursières (corrélation entre deux transactions) ou aux mesures météorologiques (similitude spatio-temporelle de deux perturbations).

Dans la logique DSL, on entretient pour toute paire (i, j) une pondération $\omega_{i,j}$ modifiée selon :

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(\mathcal{E}_i, \mathcal{E}_j) - \tau \omega_{i,j}(t)].$$

Lorsque deux événements s'avèrent fortement corrélés ou se produisent de manière répétée à des moments similaires, leur synergie S est élevée et $\omega_{i,j}$ augmente. Cela aboutit à la **clusterisation** d'événements ponctuels fortement liés.

B. Niveau Macro : Mégapatterns et Tendances

Une fois que, au niveau micro, les événements $\{\mathcal{E}_i\}$ s'organisent en **clusters** ou sous-ensembles homogènes (transactions identiques, perturbations climatiques similaires), on peut agréger ces ensembles pour former des **super-nœuds** $\{\mathcal{N}_\alpha\}$. Dans le cadre du DSL, on emploie une fonction Ψ :

$$\omega_{\alpha,\beta}^{(\text{macro})} = \Psi(\{\omega_{i,j}^{(\text{micro})}\}; i \in \mathcal{C}_\alpha, j \in \mathcal{C}_\beta).$$

On obtient alors un **graphe** macro où chaque super-nœud \mathcal{N}_α correspond à un **ensemble** d'événements corrélés (e.g. transactions à un moment précis ou perturbations climatiques simultanées). Ce graphe macro, lui aussi soumis à la dynamique DSL, permet de repérer quand plusieurs super-nœuds $\mathcal{N}_\alpha, \mathcal{N}_\beta$ partagent une synergie élevée, suggérant qu'ils forment un **mégapattern** (ex. phase de marché haussière, vague de chaleur régionale).

Dans ce macro-niveau, un mégapattern correspond à un **regroupement** de super-nœuds $\mathcal{N}_\alpha, \mathcal{N}_\beta, \dots$ qui coopèrent régulièrement, signant une tendance persistante. En bourse, on reconnaîtra un **Bull Market** si un large bloc de transactions entretient des liens ω élevés (forte concordance de prix en hausse). En climat, on rassemblera plusieurs perturbations locales (orages, vents forts) en un **bloc** cohérent, trahissant une dépression qui s'étend sur une vaste zone ou un effet de "vague de chaleur".

C. Exemples Concrets

Bourse et événements.

Dans un flux boursier, chaque **transaction** forme un événement ponctuel. On définit la synergie $S(\mathcal{E}_i, \mathcal{E}_j)$ par la ressemblance de leur prix, heure, ou "carnet d'ordre". Les transactions extrêmement proches (mêmes heures, mêmes montants, mêmes actifs financiers) agrègent localement $\omega_{i,j}$ en un **cluster** de micro-événements. Au **niveau macro**, on assemble ces clusters en **phases** (Bull, Bear, neutral), aboutissant à un mégapattern (par ex., un marché systématiquement acheteur pendant deux semaines).

Climat et perturbations.

On conçoit chaque **orage**, chaque **tempête locale**, ou chaque **front froid** comme un événement \mathcal{E}_i ; la synergie $S(\mathcal{E}_i, \mathcal{E}_j)$ tient compte de la distance géographique, de l'intervalle temporel, de la similarité d'intensité. Les orages rapprochés s'agrègent localement. Au niveau macro, des ensembles d'orages répétitifs sur une zone conduisent à un mégapattern "vague de tempêtes" ou "saison cyclonique".

D. Bénéfices Mathématiques et Opérationnels

L'approche DSL se prête particulièrement bien à un flux en **temps réel** ou incrémental. Dès qu'un nouvel événement \mathcal{E}_{new} survient (transaction, perturbation), on l'associe à la matrice ω , on calcule $\omega_{\text{new},j}$ pour les $\{\mathcal{E}_j\}$ déjà existantes, et l'on actualise la **synergie** correspondante. S'il y a suffisamment de liens forts, \mathcal{E}_{new} rejoint un cluster ou, sinon, crée un nouvel ensemble.

Le DSL crée en parallèle un **clustering** de niveau micro (évolution locale) et un de niveau macro (tendances). Cette hiérarchie autorise un compromis entre la **finesse** (événements ponctuels) et la **vision** d'ensemble (cycles, vagues de température). En $O(n)$ ou $O(n^2)$ selon l'algorithme, on peut rafraîchir la structure après chaque événement, voire lot d'événements.

Une fois un mégapattern stabilisé (une synergie $\omega_{\alpha,\beta}^{(\text{macro})}$ élevée entre plusieurs super-nœuds $\{\alpha, \beta\}$), on peut en **déduire** qu'il y a de fortes chances pour que les prochains événements prolongeant cette cohérence se rattachent au même pattern. Sur le plan boursier, on anticipe la poursuite d'une tendance haussière ; sur le plan climatique, on anticipe la prolongation d'une vague de chaleur. Le **DSL** fournit ainsi un mécanisme de repérage de phénomènes étendus sans recourir à une modélisation paramétrique rigide.

Conclusion

À l'échelle **micro**, le DSL considère chaque **événement** (transaction, perturbation) comme une entité \mathcal{E}_i . La **dynamique** de pondération $\omega_{i,j}$ révèle des micro-clusters **cohérents**. Au **niveau macro**, on agrège ces micro-clusters et on détecte des **mégapatterns** ou **tendances** plus globales. Les points saillants sont :

15. **Agrégation** (bottom-up) : de l'événement individuel au méga-ensemble d'événements,
16. **Adaptation** continue : chaque nouvel événement met à jour localement ω , reconfigurant si besoin les patterns,
17. **Structure** multi-niveau explicite : le robot (ou le système d'analyse) identifie à la fois les détails (chacun des événements) et la "vue d'ensemble" (tendances).

On obtient ainsi un **réseau** où la **complexité** (n événements) est amortie par l'auto-organisation : au fil des itérations, les **pondérations** ω s'ordonnent en clusters micro, puis en **macro-nœuds** de tendance ou mégapattern. Ce fonctionnement est particulièrement adapté aux **séries temporelles** évolutives (bourse, climat...), où la **détection** et la **mise à jour** de grandes structures (phases de marché, périodes climatiques) se fait **progressivement** et **auto-organisé**.

6.6.5.2. Éventuels Invariants d'Échelle (Lois de Puissance) dans les Distributions d'Événements

Contexte et Logique Générale. Il existe de nombreux phénomènes, tant en bourse qu'en climatologie, épidémiologie ou sismologie, où les **événements** observés (transactions financières, orages, éruptions volcaniques, etc.) semblent se répartir selon des **lois de puissance** plutôt que des lois gaussiennes. Cette caractéristique se décrit comme *scale-free* ou fractale, car on y discerne une **auto-similarité** : à différentes **échelles** d'observation, on retrouve la même forme de distribution. Le **Deep Synergy Learning (DSL)** s'avère particulièrement pertinent pour analyser et exploiter ces invariants d'échelle, grâce à sa capacité d'**auto-organisation** multi-niveau des événements.

A. Lois de Puissance et Distributions "Scale-Free"

Une **loi de puissance** (ou loi Pareto) se manifeste lorsque la probabilité $P(X > x)$ d'observer un événement d'**intensité** ou de **taille** supérieure à x se comporte comme $x^{-\alpha}$ pour $\alpha > 0$. Concrètement, cela signifie qu'il existe beaucoup d'événements de taille modeste, mais que des événements extrêmement grands (krach boursier, cyclone majeur, séisme de haute magnitude) restent non négligeables, beaucoup plus fréquents que ne le prédirait une loi normale.

Dans les **marchés financiers**, la queue de la distribution des variations de prix s'approche souvent d'une loi de puissance, expliquant les "fat tails" (événements extrêmes plus fréquents qu'en gaussien). En **climat**, l'intensité des tempêtes ou des inondations peut s'inscrire dans une dynamique *heavy-tailed*. En épidémiologie, la survenue d'un foyer extrêmement infectieux correspond à un comportement hors de la zone médiane.

On parle de *scale-free* lorsque la distribution ne change pas fondamentalement si l'on "change d'unité" ou si l'on prend un "zoom" plus ou moins large. Dans un cadre fractal, cette invariance d'échelle suggère une **auto-similarité** : ce que l'on voit au niveau local (quelques événements) se reflète au niveau plus global (cluster d'événements, macro-structures). Le DSL, en permettant une agrégation hiérarchique, peut révéler cet invariant d'échelle dans la distribution de la taille des clusters.

B. DSL et Détection des Invariants d'Échelle

Dans un **DSL**, on définit un **graphe** de pondérations $\omega_{i,j}$ reliant des **événements** $\{\mathcal{E}_i\}$. La mise à jour

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(\mathcal{E}_i, \mathcal{E}_j) - \tau \omega_{i,j}(t)]$$

permette de renforcer ou d'affaiblir les liens en fonction de la synergie S , qui peut refléter une proximité temporelle, géographique, ou d'intensité. Lorsque le processus est **multi-niveau**, on construit des super-nœuds (macro) par agrégation Ψ . La distribution des degrés (ou des tailles de cluster) peut, dans un phénomène *scale-free*, présenter une loi de puissance $P(k) \sim k^{-\alpha}$. Le **DSL** ne postule pas a priori de gaussien ou non, mais organise les événements en clusters, possiblement **dominés** par quelques "hubs" et un grand nombre de petits nœuds, reproduisant la signature d'un réseau *scale-free*.

Dans cette structure, le niveau **micro** prend en charge chacun des événements \mathcal{E}_i . Lorsque plusieurs \mathcal{E}_i s'avèrent fortement liés, ils forment un **cluster** local. Des **clusters** très volumineux (quelques macro-événements) apparaissent, alors qu'une multitude de petits clusters restent marginaux. Ce **déséquilibre** (quelques gros hubs vs. beaucoup de petits nœuds) signale un possible *power-law*. Au niveau macro, les super-nœuds reproduisent le même schéma : on obtient encore quelques super-nœuds massifs (mégapatterns) et beaucoup de plus petits.

En théorie des réseaux complexes, un graphe **scale-free** est défini par une distribution en loi de puissance de ses degrés $\{k_i\}$. Si on associe chaque événement \mathcal{E}_i à un nœud et on calcule le degré en fonction de $\{\omega_{i,j}\}$ (ou de la somme de ces poids), on peut retrouver un $P(k) \sim k^{-\gamma}$. Le DSL, par son mécanisme de croissance (renforcer les liens les plus utiles, laisser s'éteindre les autres), tend à engendrer ou consolider ce genre de structure, avec quelques nœuds "majoritairement connectés", correspondant aux événements les plus extrêmes ou les plus récurrents.

C. Conséquences et Intérêts Pratiques

Une loi de puissance implique que des événements extrêmes, bien que rares, ne sont pas négligeables : on n'a pas la décroissance exponentielle rapide d'une gaussienne. L'**auto-organisation** DSL, en reconnaissant des **macro-nœuds** de grande taille (ex. synonyme de forte corrélation de plusieurs événements), signale la présence d'un "hub" ou d'un

“mégapattern” significatif. On peut alors anticiper que de nouveaux événements \mathcal{E}_{new} se rattachent à ce hub si la même dynamique persiste (ex. marché boursier restant en mode bull, climat restant dans une séquence orageuse).

De nombreux modèles statistiques se heurtent à la difficulté des distributions à queue lourde. Le DSL n’impose pas de forme paramétrique : il adapte ω à ce qui se manifeste, laissant s’exprimer la queue lourde (quelques très gros clusters) ou l’absence de seuil net. Cela évite les **erreurs** qu’entraînerait un a priori gaussien.

Pour mettre en évidence l’**invariance d’échelle**, on peut, par exemple, étudier la distribution des tailles de clusters (au niveau micro, puis macro). S’il apparaît une pente stable en log–log, on conclut à la fractalité. Le DSL, en soulignant les grands clusters dominants ou en révélant une multiplicité de petits clusters, conforte cette analyse : on vérifie qu’il y a un “hub and spoke” structure dans le graphe ω , typique d’une *scale-free network*.

Conclusion

Dans l’étude de flux d’événements, qu’il s’agisse de **bourse**, de **climat** ou d’autres domaines où la **distribtuion** peut présenter des **lois de puissance** :

18. Le **niveau micro** du DSL regroupe des **événements** $\{\mathcal{E}_i\}$ selon leur **synergie** (corrélation, proximité, etc.),
19. Le **niveau macro** agrège ces groupes en **mégapatterns** ou **tendances** (ex. bull market, vague de chaleur),
20. Le **caractère scale-free** (fat tails, invariance d’échelle) se retrouve dans la formation de quelques **macro-clusters** très importants, tout en laissant une myriade de petits clusters.

Ce **phénomène** fractal ou scale-free n’est pas exceptionnel dans les séries temporelles ou spatiales réelles ; au contraire, on le rencontre dès lors que des événements extrêmes sont plus probables qu’un modèle normal ne le prévoit. Le **DSL**, en s’y adaptant sans supposer de forme a priori, apporte un **outil** robuste de représentation multi-niveau, révélant et exploitant les invariants d’échelle présents dans la dynamique des événements.

6.6.5.3. Gains : Meilleure Anticipation, Clusterisation Plus Lisible

Justification et Cadre Global. Les sections précédentes (6.6.5.1–6.6.5.2) ont abordé l’application du **Deep Synergy Learning (DSL)** à des scénarios de simulation ou de prédiction d’événements (transactions boursières, données climatiques, épidémies, etc.). Dans ce contexte, chaque événement ponctuel forme une entité \mathcal{E}_i au niveau micro, tandis que le **DSL** agrège ces entités en super-nœuds macro pour déceler des “mégapatterns” ou tendances globales. Cette structuration multi-échelle engendre deux avantages concrets : une **meilleure anticipation** d’évolutions (ou crises) et une **clusterisation** beaucoup plus lisible, facilitant l’analyse et la prise de décision.

A. Meilleure Anticipation des Évolutions ou Crises

Renforcement local et indicateurs d’alarme.

Dans la dynamique DSL, on maintient pour chaque paire (i, j) un poids $\omega_{i,j}$. Quand un ensemble d’événements $\{\mathcal{E}_k\}$ se révèle fortement corrélé — par exemple, une série de variations boursières liées ou un ensemble de perturbations climatiques proches — leurs pondérations $\omega_{k,\ell}$ s’élèvent, formant un **cluster** local. Lorsque la somme

$$\Omega(\mathcal{C}_\alpha) = \sum_{k,\ell \in \mathcal{C}_\alpha} \omega_{k,\ell}$$

d’un cluster \mathcal{C}_α dépasse un certain seuil θ , on en déduit qu’un **mégapattern** naît (au palier macro). Il se peut qu’il s’agisse d’un début de bulle spéculative en bourse ou d’une instabilité météorologique se généralisant. Le fait de **surveiller** $\Omega(\mathcal{C}_\alpha)$ ou la taille de ce cluster peut fournir un **indicateur** d’émergence potentielle de crise ou de phénomène extrême.

Anticipation de phénomènes extrêmes.

La logique du DSL **prévient** l'analyste ou l'automate d'une dérive importante dès que les pondérations ω se synchronisent autour d'un **sous-groupe** d'événements. Contrairement à un modèle statistique statique (par ex. Gaussien), le DSL s'adapte localement, non seulement aux moyennes, mais aussi aux corrélations actives. Dès la mise en place d'une concentration d'événements inhabituels, le **cluster** associé grandit — signe avant-coureur. Cela facilite des **alertes** précoces, car la synergie locale s'affirme avant même que le mégapattern ne devienne flagrant à la simple observation des moyennes.

B. Clusterisation Plus Lisible et Hiérarchie Compréhensible

Dans des flux de données complexes (bourse, climat, logs de grande dimension), la simple liste d'événements peut être incohérente ou surchargée. Le DSL procure une **hiérarchie** : d'abord, la mise à jour ω repère les micro-regroupements, puis l'**agrégation** (via Ψ) construit un graphe macro où chaque super-nœud représente un **mégapattern** important. Cela se traduit par une **réduction** de la complexité : quelques super-nœuds dominants reflètent la structure globale, tandis que les **petits** clusters assurent une granularité fine pour ceux qui souhaitent analyser les détails.

Au niveau **macro**, les clusters identifiés correspondent à des phases ou des régimes (ex. bull market, “saison cyclonique”), qui sont **significatifs** pour la prise de décision. L'analyste, le trader ou le climatologue n'a pas besoin de gérer individuellement des milliers d'événements : ils peuvent se référer à 2 ou 3 grands mégapatterns. Sur le plan **mathématique**, cette clarification résulte de la **dynamique** DSL, qui renforce certains liens et en éteint d'autres, produisant un graphe plus **lisible** (quelques hubs vs. une multitude de petits nœuds).

Une entité (gestionnaire de portefeuille, centre de prévision météo) peut prendre des décisions plus **ciblées** en considérant seulement la configuration macro des mégapatterns. Si un super-nœud “hausse” grossit dangereusement, un opérateur en bourse peut se méfier d'un krach à venir, ou inversement profiter d'une flambée haussière. Si un super-nœud “vague de chaleur” s'impose, les pouvoirs publics peuvent anticiper des plans d'urgence (restriction d'eau, alertes canicule). Le DSL évite donc la trop grande granularité d'un clustering purement local et dévoile une **vision** multi-niveau.

C. Exemple Numérique Illustratif

Considérons un flux de 1 000 événements $\{\mathcal{E}_1, \dots, \mathcal{E}_{1000}\}$. Chaque nouvel événement \mathcal{E}_{new} met à jour $\omega_{\text{new},j}$ par la formule

$$\omega_{\text{new},j}(t+1) = \omega_{\text{new},j}(t) + \eta[S(\mathcal{E}_{\text{new}}, \mathcal{E}_j) - \tau \omega_{\text{new},j}(t)].$$

Si \mathcal{E}_{new} se révèle très cohérente avec plusieurs $\{\mathcal{E}_j\}$ déjà existants, elle renforce $\omega_{\text{new},j}$ et rejoint un cluster local \mathcal{C}_α . Au **niveau macro**, si $\Omega(\mathcal{C}_\alpha) = \sum_{i \in \mathcal{C}_\alpha} \sum_{j \in \mathcal{C}_\alpha} \omega_{i,j}$ dépasse un certain θ ou si l'on détecte une corrélation transversale avec un autre cluster \mathcal{C}_β , on forme un **super-nœud** $\mathcal{N}_{\alpha,\beta}$ plus vaste. Cela **allège** la représentation : au lieu de manipuler 1 000 événements individuels, l'analyste regarde 5 super-nœuds macro. L'**anticipation** s'améliore, car un macro-nœud en expansion reflète une **dynamique** forte et peut amorcer une crise ou un pic extrême.

Conclusion

En contexte de **simulation** et **prédiction** d'événements, qu'ils soient boursiers, climatiques ou autres, le **DSL** s'impose comme un outil :

21. **Plus apte à anticiper** les évolutions critiques. Le renforcement local ω autour d'un sous-groupe d'événements indique rapidement l'émergence d'un mégapattern (ex. bulle, vague de chaleur).
22. **Plus lisible** dans sa **clusterisation**, grâce au passage multi-niveau (micro→macro). Les analystes ou décideurs n'ont pas à traiter une infinité de micro-événements ; ils lisent un graphe final clair, où quelques super-nœuds incarnent les **tendances** essentielles.

Cette convergence entre **meilleure anticipation** et **clustering plus lisible** illustre la raison d'être du DSL : concilier la finesse de l'information (chaque événement séparé) et la cohésion d'une **vision globale**, tout en assurant une adaptation continue (chap. 9) lorsque de nouveaux événements surviennent.

6.7. Conclusion

6.7.1. Synthèse des Contributions du Chapitre

- Rappeler l'importance de l'**apprentissage multi-échelle** dans le DSL, la possibilité d'observer une **fractalité** ou une auto-similarité à divers paliers, et la manière dont les flux bottom-up / top-down s'organisent.

6.7.2. Rôle de la Fractalité

- Insister sur le fait que la fractalité peut décrire des phénomènes d'**auto-similarité** structurelle quand la répartition des entités et des synergies respectent certaines règles.
- Avantage conceptuel : mieux comprendre la logique d'emboîtement des clusters.

6.7.3. Limites et Perspectives

- Méthodes fractales ne s'appliquent pas à tous les SCN ; c'est un cas où les patterns de synergie reproduisent à chaque échelle les mêmes lois d'organisation.
- Perspectives : explorer plus en détail la dimension fractale, la concevoir comme un indicateur de "cohérence" multi-niveau dans le DSL.

6.7.4. Liens avec les Chapitres Suivants

- Chap. 7 (optimisations) : la multi-échelle et la fractalité peuvent influencer la manière d'optimiser (recuit multi-niveau, etc.).
- Chap. 8 (multimodal) : on peut retrouver des structures fractales dans des flux très hétérogènes.
- Chap. 9 (temps réel) : gérer la fractalité en flux continu, adaptation incrémentale des clusters à différentes granularités.

6.7.5. Vision Globale

- L'apprentissage multi-échelle s'avère un **pilier** pour sculpter la complexité du DSL : il offre une **structure** et des **concepts** (dont la fractalité) qui améliorent la lisibilité et la robustesse de l'auto-organisation.

6.7. Conclusion

Au fil de ce chapitre 6, nous avons mis en avant l'importance de l'**apprentissage multi-échelle** dans le **DSL** (Deep Synergy Learning) et la **possibilité** d'observer une **fractalité** ou une forme d'auto-similarité structurelle à divers paliers. Nous avons également détaillé la façon dont les **flux ascendants** (bottom-up) et **descendants** (top-down) interagissent, soutenant une **dynamique** qui relie intimement les micro-clusters (niveau local) et les macro-structures (niveau global).

6.7.1. Synthèse des Contributions du Chapitre

Apprentissage Multi-Échelle.

L'ensemble des sections étudiées a mis en lumière la **structure** multi-niveau déployée par le **Deep Synergy Learning (DSL)** : plutôt que de se contenter d'un unique palier (comme dans de nombreux modèles neuronaux ou algorithmes de clustering), le DSL organise les **entités** observées selon plusieurs **niveaux** distincts. Les **éléments** au niveau **micro** (patches visuels, tokens textuels, capteurs unitaires, transactions ponctuelles, etc.) sont d'abord reliés par des pondérations $\{\omega_{i,j}\}$ mises à jour via l'équation

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)].$$

Cette étape conduit à la formation de **clusters** ou regroupements locaux. Ensuite, une **fonction d'agrégation** Ψ (voir la section 6.2) permet de "monter" à un niveau **macro** ou **méso** : on crée des **super-nœuds** \mathcal{N}_α correspondant à des ensembles de grande cohérence, puis l'on met à jour les pondérations $\omega_{\alpha,\beta}$ entre ces super-nœuds au moyen de la même règle DSL. Cette **hiérarchisation** s'exprime sous forme d'un **flux ascendant** (bottom-up), où les clusters micro se combinent pour former des macros plus vastes, et d'un **flux descendant** (top-down), par lequel le niveau macro impose un *feedback* pour clarifier, scinder ou réassigner les liens micro si un sous-ensemble se révèle incohérent.

Fractalité et Auto-Similarité.

Il est apparu que dans plusieurs domaines – vision multimodale, conversation, robotique, événements temporels (bourse, climat) –, une **répétition** de motifs se manifeste à diverses échelles : une même trame structurelle ou un même "pattern" se retrouve aussi bien au niveau local (quelques entités) qu'au niveau global (macro-nœuds). Cette **auto-similarité** est l'essence de la **fractalité**, s'illustrant dans les lois de puissance (queues lourdes, distributions scale-free) et dans la répétition de motifs d'interactions (ex. séquences dialogue, organisations sensorimotrices). Le **DSL**, grâce à sa logique d'**auto-organisation** fondée sur la mise à jour $\omega_{i,j}(t+1) = \dots$, met en évidence ces invariants d'échelle : il amplifie les liens dans les zones denses (clusterisation locale), puis agrège ces clusters en super-nœuds macros, pouvant révéler des "hubs" dominants ou des structures globales à la topologie fractale.

Organisation des Flux.

Un point central est la **gestion** conjointe de deux types de flux. D'un côté, un **flux ascendant** (bottom-up) produit les agrégations successives – chaque palier transforme ses entités en super-nœuds pour le palier supérieur. De l'autre côté, un **flux descendant** (top-down) s'exprime en imposant un **feedback** sur les pondérations micro en fonction du contexte macro. Cette rétroaction, dans la formulation DSL, prend la forme d'un **terme** Δ_{down} ou d'une modulation de $\omega_{i,j}$. Elle agit comme un mécanisme de validation, de scission ou d'inhibition quand le niveau macro perçoit une incohérence. Cette **cohérence** entre flux ascendants (consolidation locale) et flux descendants (guidage contextuel) garantit la **stabilité** de la structure globale, évitant les errances ou les convergences trop partielles.

Ainsi, ce chapitre a mis l'accent sur la **puissance** de la démarche DSL pour gérer la **multi-échelle** : qu'il s'agisse de patches d'image s'assemblant en classes sémantiques, de segments de conversation se regroupant en intentions, de capteurs robotique menant à un comportement complet, ou d'événements ponctuels s'agrégeant en mégapatterns, la même **logique** d'auto-organisation fait apparaître à la fois une finesse locale et une vision macro. Les **phénomènes** fractals ou *scale-free* qui émergent (patterns répétitifs, lois de puissance) n'exigent pas une hypothèse statistique rigide : le **DSL** s'adapte localement, identifiant et exploitant toute **répétition** ou **corrélation** à différents paliers, dévoilant ainsi de riches structures hiérarchiques dans des systèmes de grande complexité.

6.7.2. Rôle de la Fractalité

La **fractalité** repose sur l'idée qu'un *même* schéma, observé à une échelle donnée, peut se **répliquer** ou se **réinventer** à d'autres échelles, traduisant ainsi une **auto-similarité** potentielle. Dans le cadre du **Deep Synergy Learning (DSL)**, cette propriété s'exprime par la récurrence des mécanismes d'agrégation et de division à tous les paliers de l'organisation (micro, méso, macro). Les configurations locales, qu'elles correspondent à des clusters de segments de conversation, de capteurs, de patchs visuels ou de transactions, se retrouvent avec une forme analogue au niveau plus global, où l'on regroupe ces mêmes clusters en super-nœuds.

Sur un plan **mathématique**, un système fractal s'identifie fréquemment par l'analyse de la **dimension fractale** d'un graphe ou d'une distribution : si la répartition des degrés des nœuds (ou la répartition des énergies ou intensités) suit une **loi de puissance**, on parle de “*scale-freeness*” ou “invariance d'échelle”. Dans un **DSL**, la construction du graphe $\{\omega_{i,j}\}$ par la mise à jour

$$\omega_{i,j}(t+1) = \omega_{i,j}(t) + \eta[S(i,j) - \tau \omega_{i,j}(t)]$$

peut alors produire un réseau dont la topologie répond à cette caractéristique “hub-and-spoke”, où de gros clusters apparaissent et où la distribution des tailles (ou des degrés) se signale par un comportement de type Pareto. Cette observation reflète l'**auto-similarité** : si, à l'échelle micro, des petits regroupements se forment selon la même règle d'auto-organisation, alors à l'échelle intermédiaire ces regroupements se combinent, puis à l'échelle macro, on retrouve encore le même profil d'agencement.

D'un point de vue **conceptuel**, la fractalité offre un double intérêt. Elle permet d'abord une **comprendre** plus aisée de la hiérarchie formée : au lieu de considérer la structure comme un arbre imposé, on réalise que chaque niveau réutilise la même dynamique $\{\omega_{i,j}\}$ de renforcement et d'inhibition, d'agrégation et de division. Cette itération cyclique de la même loi rend la vision globale plus unifiée, car on sait qu'on applique partout la même “grammaire” d'auto-organisation. On y gagne ensuite en **modélisation** : si les distributions présentent des lois de puissance, on peut raisonnablement s'attendre à trouver des “*fat tails*” (quelques énormes clusters au milieu d'une myriade de petits) à chaque échelle, sans qu'il soit nécessaire de réinventer un nouveau cadre statistique. Cette redondance d'une seule et même règle à plusieurs paliers explique le caractère fractal et simplifie la lecture d'un ensemble potentiellement très complexe. La fractalité n'est donc pas un simple *concept* : c'est un *levier* pour déployer le DSL de façon homogène du local au global, et c'est une *fenêtre* pour percevoir la distribution multi-niveau comme un tout, où la répétition de formes révèle les lois d'organisation profondes.

6.7.3. Limites et Perspectives

Conditions d'Apparition de la Fractalité.

Bien que l'approche **multi-échelle** du Deep Synergy Learning (DSL) s'applique dans de nombreux domaines (vision multimodale, robotique sensorimotrice, analyse conversationnelle, etc.), la **fractalité** n'est pas systématiquement garantie. Il s'agit d'un cas particulier dans lequel la structure ou la dynamique du **Synergistic Connection Network (SCN)** reproduit à plusieurs échelles une forme d'**auto-similarité**, souvent associée à des distributions en lois de puissance ou à un “effet hub” dans le graphe $\{\omega_{i,j}\}$. Un **SCN** qui ne verrait jamais se former de gros clusters dominants, ou dont la répartition des degrés se rapprocherait davantage d'une loi gaussienne, présenterait peu ou pas de **fractalité** mesurable.

D'un point de vue plus formel, la **fractalité** requiert que la *même* loi d'**organisation** (agrégation, renforcement, division) aboutisse, à chaque palier, à une structure similaire à celle observée aux autres paliers. Autrement dit, la répartition des liens $\{\omega_{i,j}\}$ ou la distribution de la taille des clusters suit une loi “autosimilaire” lorsqu'on passe du niveau micro au niveau macro. Dans certaines applications, les **conditions** pour qu'apparaissent des lois de puissance ou des distributions scale-free (longues queues) ne sont pas remplies : on peut être en présence d'un phénomène plus linéaire, plus symétrique, ou dominé par d'autres effets (ex. saturation rapide des ω ou homogénéité rigide). Dans ces situations, la fractalité demeure anecdotique ou absente.

Il importe donc de distinguer l'**architecture** multi-niveau du DSL (toujours présente) de la **fractalité** (cas où la structure s'avère *auto-similaire* à divers paliers). Il est parfaitement concevable qu'un **DSL** multi-niveau ne révèle aucune auto-similarité notable si les données ou la dynamique ne contiennent pas de régularité fractale. La fractalité n'est donc pas une conséquence obligatoire de l'algorithme, mais une propriété émergente dans certaines configurations de $\{\omega_{i,j}\}$ ou dans certains flux d'événements (voir 6.6.5.2) qui induisent, par leur "queue lourde" ou leur récurrence, une structure fractale.

Possibilités de Recherche et Perspectives

Étude de la dimension fractale d'un SCN.

Une piste intéressante consiste à étudier la **dimension fractale** du **Synergistic Connection Network**. On peut imaginer calculer une "dimension de boîte" du graphe $\{\omega_{i,j}\}$ à chaque itération ou pour chaque palier (micro, macro). La **stabilité** de cette dimension fractale, ou sa croissance/diminution, indiquerait dans quelle mesure le réseau tend à s'**auto-similariser**. Un SCN dont la **dimension** fractale s'avère stable (par ex. ≈ 1.6) pourrait être interprété comme "parfaitement" organisé en lois de puissance. À l'inverse, un SCN dont la dimension fractale fluctue beaucoup ou tend vers un régime gaussien montrerait l'absence d'un patron fractal durable.

Indicateur de cohérence ou de maturité.

Sur un plan **conceptuel**, la fractalité peut servir d'indicateur de "maturation" du réseau. On peut envisager un "score fractal" $\mathcal{F} \in [0,1]$: plus ce score est élevé, plus la **répétition** du même schéma à diverses échelles est manifeste. Cela traduirait qu'on a atteint un état d'**auto-organisation** stable où la structure multi-niveau se reproduit à chaque palier. D'un point de vue pratique, un tel indicateur aiderait à diagnostiquer si le SCN est en phase transitoire (score fractal bas) ou en phase aboutie (score fractal élevé).

Heuristiques favorisant la fractalité.

Certains algorithmes DSL pourraient être **modulés** pour encourager la formation de structures fractales, par exemple en sélectionnant des paramètres η, τ, γ (pour l'inhibition) qui renforcent la tendance à créer quelques hubs majeurs et une multitude de petits clusters, typiques des graphes scale-free. Un tel choix pourrait améliorer la **robustesse** : un réseau fractal résiste en général mieux à la perturbation ou à la panne de certains nœuds, les autres niveaux restant intacts (car la structure globale recopie la même organisation). Dans le cas des flux événementiels (bourse, climat, etc.), mettre en évidence la fractalité signifie gérer plus facilement les extrêmes (événements "catastrophiques") et donc gagner en **résilience**.

Conclusion

La fractalité ne constitue pas un **incontournable** de tout SCN : il s'agit d'une **propriété** émergeant dans certains **contextes**, typiquement lorsque la distribution ou l'organisation des entités suit des **lois de puissance** et que la même dynamique s'exprime autosimilairement. Les apports **multi-niveau** du DSL (flux bottom-up, feedback top-down, agrégation Ψ) autorisent, mais ne garantissent pas, ce mode d'organisation fractal. Il reste du **travail** de recherche pour formaliser davantage les conditions exactes sous lesquelles un SCN devient "fractal", comment mesurer sa **dimension** fractale, et comment, éventuellement, tirer profit d'une **structure** fractale pour améliorer la robustesse ou l'efficacité de l'auto-organisation (heuristiques de paramétrage, stratégies pour favoriser ou contrer la formation de hubs dominants, etc.).

6.7.4. Liens avec les Chapitres Suivants

Chapitre 7 (Optimisations).

Le présent chapitre a mis en avant la puissance du **DSL** (Deep Synergy Learning) dans la gestion multi-niveau (micro→macro) et la possibilité de **fractaliser** la structure d'auto-organisation. Pour rendre cette hiérarchie plus stable et plus efficace, on recourt à des mécanismes d'**optimisation**, tels que le **recuit simulé** (injection de bruit pour sortir des minima locaux) ou l'**inhibition** (terme freinant la croissance ubiquitaire des poids ω). Dans une configuration **multi-niveau**, ces techniques peuvent elles-mêmes se décliner à plusieurs paliers : un recuit "local" au niveau micro, un recuit "global" au palier macro, ou encore des stratégies d'inhibition hiérarchique. Le **chapitre 7** détaillera la

manière dont cette logique se met en place, et montrera comment, lorsqu'on sait qu'une structure fractale se réplique d'un palier à l'autre, on peut optimiser localement, puis répliquer le même schéma au palier macro, entraînant une **réduction** notable de la complexité.

D'un point de vue **mathématique**, on adaptera les paramètres η, τ, γ (taux d'apprentissage, facteur de décroissance, amplitude d'inhibition) en jouant sur la récurrence fractale pour accélérer la convergence ou améliorer la robustesse à la sur-segmentation (trop de clusters) ou à la sous-segmentation (regroupement trop vaste).

Chapitre 8 (Multimodal).

La fractalité prend encore plus de sens lorsque l'on gère des **flux très hétérogènes** (vision, audio, texte, signaux divers) dans un cadre véritablement **multimodal**. Le **chapitre 8** décrira comment le **DSL** s'applique pour **fusionner** des sources de données de nature différente, tout en exploitant des patterns récurrents à diverses résolutions (par exemple, motifs d'objets en vision, motifs de forme sonore en audio, motifs lexicaux en texte). Un système multimodal peut observer des invariants d'échelle si la même logique d'auto-organisation apparaît dans chaque modalité, puis se recopie lors de la fusion inter-modale. Le **DSL** fractal détectera et tirera parti de ces symétries à différents niveaux (micro = détail sensoriel, macro = concept global) avec un gain considérable dans l'interprétation d'environnements complexes.

Chapitre 9 (Temps réel).

Dans la plupart des applications réelles, les données (événements, segments, mesures) arrivent **en flux continu**. La fractalité, déjà introduite dans ce chapitre (6.7.3), suppose une auto-similarité potentielle. En **temps réel**, cela signifie que la **dimension fractale** ou la "signature scale-free" du réseau $\{\omega_{i,j}\}$ peut évoluer au fur et à mesure que de nouvelles entités sont incorporées. Le **chapitre 9** décrira précisément comment adapter la **clusterisation** micro et macro dans un **cadre** en perpétuel changement. Si une structure fractale était stabilisée, l'arrivée de nouveaux segments ou événements peut la perturber, forçant le **DSL** à réorganiser ses liens ω . On peut ainsi mesurer la fractalité au fil du temps (log-log plots, dimension fractale dynamique) ou se fixer un **objectif** de maintenir un certain degré d'auto-similarité, marque de l'équilibre ou de la maturité du SCN.

En somme, les chapitres suivants s'appuieront sur les **contributions** du présent chapitre en approfondissant les techniques d'optimisation (chap. 7), en illustrant les scénarios multimodaux (chap. 8) et en finalisant la perspective "flow" continu (chap. 9). L'**idée** demeure de faire interagir la structure multi-niveau (micro→macro) et la **dynamique** d'auto-organisation (ascendant, descendant), tout en tenant compte des **lois** ou **patterns** fractals, lorsque ceux-ci se manifestent naturellement dans les données.

6.7.5. Vision Globale

La **démarche** du **Deep Synergy Learning (DSL)** ne se limite pas à un **traitement** local de paires d'entités : elle met en avant un **apprentissage multi-échelle** qui, du niveau **micro** (regroupement local) au niveau **macro** (agrégation de clusters plus vastes), structure la **complexité** de manière hiérarchique. Il en résulte une organisation claire de la **synergie** $\{\omega_{i,j}\}$, où chaque palier se construit sur le précédent au lieu de traiter toutes les entités dans un **graphe monolithique**. Cette **stratification** apporte de multiples avantages, qu'il s'agisse de la lisibilité, de l'adaptation ou de la possibilité d'exploiter des propriétés fractales.

La notion de **fractalité** occupe une place centrale dans la **vision globale** du DSL. Il s'agit d'**observer** et d'**exploiter** l'**auto-similarité** potentielle : lorsque les mêmes patterns ou lois d'organisation émergent d'un niveau à l'autre, on parle de processus fractal. Autrement dit, si un phénomène s'instancie à l'échelle micro (quelques entités se renforçant mutuellement) et que la même forme de distribution ou de lien réapparaît à une échelle supérieure (super-nœuds se reliant selon des lois semblables), on reconnaît une **autosimilarité** d'échelle. Dans ce contexte, la fractalité prend la forme d'une **répétition** du même schéma d'auto-organisation, conduisant par exemple à des distributions en lois de puissance ou à des "hubs" dominants dans le graphe.

En pratique, l'**apprentissage multi-échelle** proposé par le DSL s'avère particulièrement puissant pour plusieurs raisons :

23. Lecture améliorée de la dynamique interne (micro) et des schémas (macro) :

Le modèle permet de **circonscrire** des petits groupements de données (patches visuels, tokens textuels, capteurs locaux, transactions ponctuelles) afin d'en extraire des **clusters** cohérents. Simultanément, les **super-nœuds** obtenus aux niveaux supérieurs (macro) font ressortir des “grands schémas” (catégories visuelles, intentions conversationnelles, comportements robotiques, tendances de marché) qui, autrement, seraient noyés dans la masse. Cette complémentarité rend possible une *navigation* entre le micro (analyses très localisées) et le macro (vision plus globale ou sémantique), sans se perdre dans la complexité.

24. Ordonnancement de la synergie $\{\omega\}$:

La **hiérarchie** rend plus robuste et plus interprétable la mise à jour des pondérations $\omega_{i,j}$. Au lieu de maintenir un énorme graphe plat où les connexions foisonnent de manière incontrôlée, on regroupe, on agrège, on divise si besoin, et on définit des ponts clairs entre les niveaux. Cela **stabilise** souvent le processus, réduit les illusions de sur-connexion et permet d'**isoler** des incohérences au bon palier (micro ou macro).

25. Résilience et plasticité :

Le fait de disposer d'une **organisation** à plusieurs échelles confère au réseau la possibilité de s'**adapter** localement à des bouleversements (nouveaux segments, panne d'un capteur, brusque hausse d'une action, etc.) tout en conservant au niveau **macro** une **cohésion** d'ensemble. Les flux ascendants (bottom-up) et descendants (top-down) s'équilibrent : si un petit groupe change de structure, cela reste contenu ; si un macro-nœud se scinde, cela reconfigure le palier global sans démanteler toute l'organisation micro.

La **fractalité** s'avère être un **levier** précieux dans cette vision globale. Lorsqu'on constate un patron fractal, cela signifie que les *mêmes* lois d'agrégation ou de distribution se retrouvent d'un niveau (micro) à l'autre (macro). On en tire deux conséquences principales :

- **Exploitation** des invariants d'échelle : on peut analyser un phénomène (visuel, conversationnel, boursier, etc.) à petite échelle et en extrapoler des **lois** semblables à grande échelle. Le DSL se charge, par la règle $\omega(t+1) = \omega(t) + \eta[S - \tau\omega(t)]$, de *conserver* cette structure lorsqu'on assemble les clusters.
- **Compréhension** plus profonde du système : une fractalité marquée indique une **auto-similarité** persistante, susceptible d'être utilisée pour la **prédiction** (p. ex. distribution heavy-tailed) ou pour l'**optimisation** (cibler seulement quelques “hubs” dominants). Si la structure fractale est souhaitable, on peut d'ailleurs concevoir des paramètres ou heuristiques (chap. 7) favorisant sa stabilisation.

En définitive, la **coexistence** d'un apprentissage multi-échelle (ancré dans la philosophie DSL) et d'une possible fractalité (auto-similarité à plusieurs paliers) consolide l'**architecture** : on **voit** mieux la dynamique interne, on **dégage** de grands patterns, on maintient plus aisément la **résilience** face à l'arrivée de nouvelles entités ou aux fluctuations extrêmes. Les sections suivantes (p. ex. chap. 7, 8, 9) approfondiront divers **cas** (optimisations, multimodalité, temps réel) où cette démarche se concrétise, mais la synthèse de ce chapitre demeure : l'**apprentissage multi-niveau** et la **fractalité** ne sont pas juste des éléments décoratifs, mais bien des **pilliers** fondateurs de la manière dont le **DSL** s'adapte et se structure dans des contextes complexes ou “scale-free.”